

서브패턴 기반 무작위 학습 알고리즘을 위한 샘플링 수 하한

*허민오, 장병탁
서울대학교 컴퓨터공학부
e-mail: moheo@bi.snu.ac.kr, btzhang@bi.snu.ac.kr

Sampling Lower Bounds for Subpattern-based Randomized Learning Algorithms

*Min-Oh Heo, Byoung-Tak Zhang
School of Computer Science and Engineering
Seoul National University

Abstract

In machine learning, subpatterns of training data instances are sampled to estimate the model considering the information of dependency without any assumption on the interrelation of features. Practically, the number of subpattern samples is critical to the time and space cost as well as to the minimization of estimation error. Here, we derive the sampling lower bounds for subpattern-based randomized learning algorithms. We consider the process of sampling of features as a binomial counting process. We show that the subpattern length and the number of subpattern samples have the negative logarithmic relationship within a fixed probability error. The theoretical results and simulation results are provided to validate.

I. 서론

기계학습은 학습 데이터로부터 모델을 생성하는 방법론을 다루기 때문에, 인자 간의 조건부 독립성과 같은 데이터에 대한 가정에 따라 모델의 표현력과 복잡도가 크게 달라진다. 데이터에 대한 어떠한 가정도 존

재하지 않을 경우, 다수의 인자들이 동시에 연관된 고차원 연관 정보(higher-order associative information)를 표현하려면 차원의 저주(curse of dimensionality)에 따라 조합의 수가 폭발적으로 증가하게 되며, 이에 따라 많은 데이터 샘플을 필요로 한다. 이러한 어려움을 극복하기 위한 방법들은 주로 차원 축소(dimensionality reduction)를 통해 인자 수를 줄이고, 유효 인자로의 변환에 기반하는 방법과 통계에 기반하여 모분포를 반영하는 모델을 근사적으로 추정하는 방법으로 크게 나눌 수 있다[1,5]. 근사적인 방법 중 하나로써, 학습 데이터 인스턴스의 서브패턴들을 샘플링하여 모델을 표현하는 방법이 있다[2]. 이 알고리즘들은 인자 집합에서 무작위로 k 개의 인자를 택하여 k -subpattern을 생성하는 과정을 학습 데이터 인스턴스마다 샘플링 수만큼 반복한다.

본 논문에서는 샘플링의 무작위성에 의해 모든 인자들을 포함하지 못하는 경우를 막기 위해서는 총 인자 수 F 와 k 에 따라 어느 정도의 샘플링 수를 필요로 하는가에 관한 하한을 유도하였다. 이를 위하여, 서브패턴의 샘플링 과정을 인자별로 binomial counting processes로 표현하고, 샘플링을 수행할 때마다 선택된 인자의 수를 총 인자 수와 서브패턴을 위해 선택한 인자 수에 대한 관계식으로 나타내었다.

II. 본론

2.1 서브패턴 기반 무작위 알고리즘

서브패턴 기반 무작위 알고리즘(subpattern-based randomized algorithm)은 학습 데이터 집합 내 각각의 인스턴스에서 서브패턴을 샘플링 하는 과정을 통해 모델을 추정하는 알고리즘의 한 분류를 의미한다. 이 분류의 알고리즘들은 다수의 인자들 간의 고차원 연관성을 근사적으로 표현할 수 있는 장점이 있다. 실제의 예로, 하이퍼네트워크 모델에 기반한 알고리즘이 서브패턴 기반 무작위 알고리즘이다 [2].

서브패턴 기반 무작위 알고리즘을 다음과 같이 정의한다. N 개의 인스턴스를 가진 학습 데이터 집합을 $D = \{X^{(n)}\}_{n=1}^N$ 라 하자. 이 데이터는 F 개의 인자로 이루어져 있다. 한 번의 서브패턴을 샘플링하는 과정은 다음과 같다.

- 1) 인자 집합에서 무작위로 k 개의 인자를 택한다.
- 2) 선택된 인자의 값을 가져와 순서를 고려하지 않은 k -subpattern¹⁾을 생성한다.
- 3) 생성된 서브패턴을 별도 library에 보관한다.

위의 과정을 학습 데이터 인스턴스 각각에 대하여 샘플링 횟수 R 회씩 시행하여 총 R_T 회를 한다.

2.2 모든 인자가 1회 이상 선택되기 위한 샘플링 하한

서브패턴 기반 무작위 알고리즘에서 총 R_T 개의 서브패턴을 샘플링 할 경우, $R_T = N \times R$ 이 된다. 또한, 그림 1과 같이 총 F 개의 인자 중 i 번째 인자를 f_i , 샘플링된 j 번째 서브패턴을 s_j , 한 번 샘플링할 때의 선택된 인자 수를 K 라고 정의한다. 여기서 논의의 편의를 위해 서브패턴을 샘플링 할 때, 중복을 허락하여 K 개의 인자를 선택한다고 가정하자. 이 경우, 임의의 인자 f_i 가 선택될 확률은 i 에 관계없이 다음과 같다.

$$p = \frac{K}{F} \quad (1)$$

이에 따른 r 번째 샘플링, i 번째 인자에 대한 선택여부에 대하여, 선택되지 않는 사건을 0, 선택되는 사건을 1로 표현하는 확률변수를 X_{r,f_i} 라고 정의하고, 총 R_T 번의 샘플링을 시행했다고 할 때, R_T 번의 샘플링 이




그림 1. 서브패턴 샘플링 과정

후에 인자 f_i 가 선택된 횟수는 다음과 같이 각 시행에 따른 확률변수의 합으로 표현될 수 있다.

$$S_{f_i} = \sum_r X_{r,f_i} \quad (2)$$

이 합의 과정은 binomial counting processes이므로, R_T 번의 샘플링 이후 인자 f_i 가 m 번 선택될 확률은 다음과 같다 [6].

$$P[S_{f_i} = m] = \binom{R_T}{m} p^m (1-p)^{R_T-m} \quad (3)$$

이 때, 인자 f_i 가 q 개 이하로 선택될 확률 p_q 는

$$p_q = P[S_{f_i} \leq q] = \sum_{m=0}^q \binom{R_T}{m} p^m (1-p)^{R_T-m} \quad (4)$$

이며, 각 인자에 대한 process는 중복을 허락하는 가정에 따라 서로 무관하므로, $n(f_i)$ 를 인자 f_i 가 선택된 횟수라고 할 때, 모든 F 개의 인자가 q 보다 많이 선택될 확률은 다음과 같다.

$$p_{\forall i, n(f_i) > q} = (1 - p_q)^F \quad (5)$$

여기서, $p_{q=0}$ 이 아래와 같으므로,

$$p_{q=0} = \binom{R_T}{0} p^0 (1-p)^{R_T} = (1-p)^{R_T} \quad (6)$$

모든 F 개의 인자가 한번 이상 선택되는 확률($q=0$ 인 경우)은 아래 식과 같다.

$$p_{\forall i, n(f_i) > 0} = (1 - (1-p)^{R_T})^F \quad (7)$$

이 확률값이 특정 확률값 $1-\epsilon$ (단, $0 \leq \epsilon \leq 1$)보다 커지기 위한 한계 샘플링 수의 경계값 R_{th} 을 얻기 위해 식 (7)을 R_T 에 대하여 정리하면 아래와 같다.

$$R_{th} \geq R_T = \log_{1-p} (1 - \sqrt[F]{1-\epsilon}) \quad (8)$$

모든 F 개의 인자가 한번 이상 선택되는 확률을 $1-\epsilon$ 로 고정시킬 때, 한계 샘플링 수의 경계값 R_{th} 과 임의의 인자 f_i 가 선택될 확률 p 는 $(1-p)^{R_{th}} = C$ (C 는

1) 본래 k -subpattern은 조합론(combinatorics)에서 쓰이는 용어로 순서가 고려된 크기가 k 인 원본패턴의 부분집합을 의미한다[3].

상수)의 관계를 갖게 된다.

여기서, ‘중복을 허락하여 인자를 선택한다는 가정’을 배제할 경우, 한 번의 샘플링 과정마다 이미 선택된 인자가 겹쳐서 선택되는 경우가 사라짐에 따라 한계 샘플링 수가 낮아질 수 있다. 즉, 실제로는 R_{th} 를 택하면 샘플링 하한보다 큰 값이 되며, 모든 인자가 1 회 이상 선택되기에 충분하다.

2.3 일반적인 샘플링 하한

2.2 절에서 유도한 샘플링 하한은 각 인자가 최소한 1회 이상 모델에 포함되기 위한 하한으로, 학습을 위한 최소한의 기준이다. [4]에서는 순열을 이용한 확률식을 활용하여 서브패턴의 샘플링 수가 늘어남에 따라 선택되지 못한 인자 수가 급격히 줄어드는 것을 실험적으로 보였다. 하지만, 인자의 특성을 제대로 표현하기 위해서는 샘플링 된 더 많은 서브패턴이 필요하다.

다루는 문제와 응용에 따라 인자가 나타내는 정보와 가설공간을 규정짓는 모델이 달라지므로, 필요한 검정력(statistical power) 및 sample complexity를 고려하여 식 (5)에서 유도한 확률 $p_{v_{i,n}(f_i) > q}$ 에 q 값을 정하는 과정을 통해 필요한 샘플링 하한을 유도하는 것이 가능하다.

III. 실험 결과

먼저, 2.2절에서 유도한 확률식의 특성을 설명하기 위해 서브패턴의 길이 k 와 샘플링 횟수에 따른 모든 F 개의 인자가 한 번 이상 선택될 확률의 추이를 그림 2에 도시하였다. 확률에 대한 에러 ϵ 를 고정시킬 경우, 식 (8)에서 유도한 바와 같이 서브패턴의 길이가 길어짐에 따라 한계 샘플링 횟수의 경계값이 로그함수적으로 줄어든다. 만약, 서브패턴의 길이가 고정될 경




그림 2. 서브패턴의 길이 k 와 샘플링 횟수에 따른 모든 F 개의 인자가 한 번 이상 선택될 확률의 추이


$\epsilon = 0.01$
시행횟수 1000 회

서브패턴 길이	유도한 확률		시뮬레이션 결과 (선택된 인자 수)
	모든 인자가 선택될 확률	한계 샘플링 횟수 R_{th}	
5	0.9901	1077	499.9920 (0.0891)
10	0.9901	536	499.9880 (0.1089)
20	0.9900	265	499.9880 (0.1089)
30	0.9901	175	499.9850 (0.1216)


그림 3. 유도한 확률 결과와 시뮬레이션 결과의 비교
(총 인자 수 500, 시행 횟수 1000회, $\epsilon=0.01$)

우, 특정 확률에 도달하기 위해서는 샘플링 횟수는 지수함수적으로 증가되어야 한다.

2.2 절에서 유도한 확률과 한계 샘플링 횟수를 검증하기 위하여 시뮬레이션을 시행하고 그 결과와 유도한 값과 비교하였다. 여기에 쓰인 값은 총 인자 수는 500, $\epsilon=0.01$ 이다. 설정한 ϵ 값에 따라 모든 인자가 선택될 확률이 0.99이며, 이에 따른 한계 샘플링 횟수는 정수여야 하므로 그림 3과 같이 식 (8)에 따라 얻은 값의 ceiling를 취하고 이 설정값을 이용하여 1,000 회의 시



(a) 선택되지 않은 인자 수의 평균



(b) 선택되지 않은 인자 수의 표준편차

그림 4. 시뮬레이션 결과. 각 샘플링 횟수와 서브패턴 길이 별로 100회씩 시행. 선택되지 않은 인자 수 평균(a)과 표준편차(b)

물레이션을 수행하였다. 이 결과는 표본 평균과 표본 표준편차는 그림 3과 같이 주어지므로, 실제 기댓값인 499.990과 비교할 때 동일하다. (t -검정, 유의수준 0.05)

전체적인 양상을 파악하기 위하여 샘플링 과정을 시물레이션 하여 인자별로 선택되지 않은 인자 수를 그림 4에 그래프로 나타내었다. 이 시물레이션은 각 샘플링 횟수와 서브패턴 길이 별로 100회씩 시행되었으며, 총 인자 수 F 는 500으로 가정하였다. 그림 4 (a)에 선택되지 않은 인자 수의 평균, 그림 4 (b)에 표준편차를 도시하였다. 샘플링 횟수가 증가함에 따라 선택되지 않은 인자 수가 지수함수적으로 감소하며, 서브패턴의 길이가 길수록 그 속도는 빨라진다. 또한, 샘플링 횟수에 대한 확률값의 변동이 큰 구간에서 표준편차가 비교적 크게 나타나는데, 이는 확률값이 0 또는 1에 가깝지 않아서 선택되지 않은 인자 수의 변동이 크기 쉽기 때문에 나타나는 현상이다.

IV. 결론 및 향후 연구 방향

본 논문에서는 하이퍼네트워크 모델을 비롯한 서브패턴 기반 무작위 알고리즘에서 가장 기본적인 샘플링 하한을 유도하였다. 이 경계값은 각 인자들이 최소한 1회 이상 샘플링이 되는 하한이므로, 인자의 특성을 제대로 표현하기 위해서는 더 많은 샘플링 된 서브패턴이 필요하다. 이는, 다루는 문제와 응용에 따라 특성이 달라지므로, 식 (5)에서 유도한 일반적인 확률을 기반으로 하여 적당한 샘플링 하한을 유도하는 것이 가능하다. 또한, 전체 인자를 포함하게 하기 위해서는 샘플링 횟수보다는 서브패턴의 길이를 늘리는 것이 지수함수적으로 빠르다.

[2]와 같은 실제 서브패턴 기반 무작위 학습 알고리즘에서는 데이터 분포를 추정하기 위해 각 서브패턴마다 웨이트를 부여하여 중첩한다. 이러한 경우에도 본고에서 제시한 하한은 학습 알고리즘의 파라미터 세팅을 위한 가이드라인을 준다.

향후 연구 방향으로, 서브패턴들에 웨이트가 부여된 모델의 경우, 길이가 비교적 짧은 서브패턴들만으로도 분포 추정이 가능해지는 현상이 목격되는데, 이러한 모델에 대한 샘플링 수와 본고에서 다룬 하한을 비교하는 연구를 진행할 것이다.

감사의 글

이 논문은 교육과학기술부의 재원으로 국가연구재단의 지원을 받아 수행된 연구(314-2008-1-D00377, Xtran)

이며, 지식경제부 및 한국산업기술평가관리원의 IT산업원천기술개발사업(KI002138, 차세대 맞춤형 서비스를 위한 기계학습 기반 멀티모달 복합 정보 추출 및 추천 기술 개발, MARS) 및 교육과학기술부의 BK21-IT사업에 의해 일부 지원되었음. 또한, 활발한 논의로 많은 아이디어를 제공해주신 양진산 박사님께 감사드립니다.

참고문헌

- [1] C. M. Bishop, "Pattern Recognition and Machine Learning", Springer, 2006.
- [2] B.-T. Zhang, "Hypernetworks: A molecular evolutionary architecture for cognitive learning and memory", IEEE Computational Intelligence Magazine, 3(3), pp. 49-63, 2008.
- [3] M. Bóna, "A walk through combinatorics: an introduction to enumeration and graph theory", World Scientific, 2002.
- [4] S.-J. Kim, J.-W. Ha and B.-T. Zhang, "Evolutionary Layered Hypernetworks for Identifying microRNA-mRNA Regulatory Modules", IEEE World Congress on Computational Intelligence (WCCI-CEC 2010), 2010 (to appear).
- [5] T. M. Mitchell, "Machine Learning", McGraw-Hill, 1997.
- [6] A. Leon-Garcia, "Probability and Random Processes for Electrical Engineering", Addison-Wesley Publishing Company, 1994.