

랜덤 하이퍼그래프 메모리 모델을 이용한 문장생성에 멀티 모달리티가 미치는 영향

*윤웅창, 장병탁
서울대학교 전기컴퓨터공학부
e-mail : {wcyoon, btzhang}@bi.snu.ac.kr

Effects of multi-modality on sentence generation by random hypergraph memory model

*Woongchang Yoon, Byoung-Tak Zhang
School of Computer Science & Engineering
Seoul National University

Abstract

In this paper, we introduce a generation method based on the random hypergraph memory model using multimodal cue. In order to demonstrate the effects of multi-modal cue on sentence generation, we compare experimental results of the sentence generation given only text or image cues and image-text multi-modal pair cues. For experiments, we use TV drama screen shots and script data. The image-text corpus are converted into a set of weighted hyperedge. Our aim is to generate sentences using cues based on these set of hyperedges. It is our experiment's result show that language generation is helped by multi-modality data more than only text or image data. We accomplish to simulate effects of supporting memory improvement by multi-modal data set without templates or rote learning.

I. 서론

기계를 이용한 언어 생성 문제는 오래전부터 시도되어 왔지만[1], 인간 수준의 언어를 생성 하는 데는 한계를 보이고 있다. 그럼에도 불구하고, 기계 학습에

서의 언어 생성은 최근까지도 여러 방법으로 시도되고 있는 연구 중의 하나이다[2]. 언어는 학습의 일환이며, 더 나은 방법의 언어 학습 방법이 결과적으로 더 좋은 결과의 언어 생성이 가능하여 질 것이라고 생각할 수 있다[3]. 학습의 효율을 높이는 방안은 여러 가지가 있을 수 있으나 멀티모달 데이터를 이용한 학습의 효과를 높이는 방법은 이전부터 알려져 왔다[4]. 이러한 방법을 사용하여 멀티 모달리티를 언어생성에 이용하려는 시도[5]도 있었지만, 기계 학습을 이용한 언어 생성에 있어서 멀티 모달리티가 미치는 영향을 명확하게 보이지는 않았다.

본 논문에서는 멀티 모달리티가 주는 기억 향상 도움 효과를 시뮬레이션하기 위해서, 주어진 멀티모달 정보를 이용하여 랜덤 하이퍼그래프 메모리 모델을 통해서 문장을 생성 한다. 우리는 멀티모달 정보가 문장 생성에서 주는 효과를 확인하기 위하여 단일 텍스트 또는 단일 이미지와 멀티 모달 정보에 따른 실험을 각각 수행하여 이를 비교 분석하였다. 이 실험을 위해서 비디오 데이터를 활용하여 이전 시점의 조각 정보를 제공하고 이를 단서로 해당 문장을 생성하는 실험을 수행하였으며, 단순 암기학습이나 템플릿을 사용하지 않고 문장을 생성한다.

결과적으로 단순 텍스트, 단순 이미지, 텍스트-이미지 쌍의 단서를 통한 실험으로 멀티 모달리티와 단순 모달리티의 영향과 텍스트와 이미지가 문장생성에 미치는 영향을 보였다.

II. 본론

2.1 랜덤 하이퍼그래프 메모리 모델

이 실험에서 사용한 랜덤 샘플링 및 학습 알고리즘은 랜덤 하이퍼그래프 메모리 모델인 하이퍼네트워크 모델을 사용하였다. 랜덤 하이퍼그래프 메모리 모델은 $H = (V, E, W)$ 로 표현될 수 있다. 각 V, E, W 는 정점, 연결선, 가중치를 나타내며 데이터 $D = \{d^{(i)}\}_{i=1}^m$ 가 주어졌을 때, H 의 원소를 h 라고 가정하면

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

$$h_{MAP} = \arg \max_{h \in H} P(D|h)P(h) \approx \arg \max_{h \in H} P(D|h) \quad \text{로}$$

나타낼 수 있다. 이 경우에는 아래와 같은 가정이 필요하며, $Z(W)$ 는 정규화 식이다.

$$P(D|h) = \prod_{i=1}^m p(d^{(i)}|h)$$

$$p(d^{(i)}) = \frac{\sum_{j=1}^J w^{(j)}}{Z(W)}$$

j 번째 하이퍼에지가 가지는 가중치가 시간 t 에서 $w_t^{(j)}$ 로 나타내어지고, 하이퍼에지의 일치와 불일치에 따른 가중치를 표현하면,

$$w_t^{(j)} = \begin{cases} w_t^{(j)} = w_{t-1}^{(j)} + \gamma \cdot \Delta w \\ w_t^{(j)} = w_{t-1}^{(j)} - \gamma \cdot \Delta w \end{cases} \text{이고,}$$

여기서 γ 는 학습의 비율을 나타낸다.




그림 1. 랜덤 하이퍼그래프 메모리 모델(하이퍼네트워크)의 예. 이 모델은 정점들(vertices)과 하이퍼에지들(hyperedges)로 구성되며, 하나의 하이퍼에지는 임의의 정점들로 연결된다.

2.2 데이터 처리

일반적으로 비디오 데이터는 화상, 소리, 문자 등 여러 모달리티가 결합되어 있으며 수집 및 가공의 용이

성을 가지고 있어서 멀티모달리티 실험을 위한 좋은 데이터라고 볼 수 있다. 이 실험에서는 미국의 유명 TV 시트콤인 프렌즈(Friends)를 사용하여 실험을 하였다. 실험에 사용한 데이터의 수는 특정 시점에 해당되는 이미지와 텍스트 343쌍을 사용하였다. 스크립트와 대화문의 대조를 통해서 노이즈를 제거하고 단어사전을 만들어서 각 문장이 어떠한 단어로 이루어져 있는지를 암호화 하였다. 이미지는 특정 자막에 해당되는 이미지를 200×150픽셀로 캡처한 후 균등한 92개의 그물망 형태로 자르고 k -군집화 기법으로 2000개의 군집으로 나누었다. 각 군집을 바탕으로 이미지 사전을 작성하고 각 조각이 어떤 군집에 속하는지를 암호화 하였다.

표1. 텍스트-이미지 쌍의 예

이미지 단 서	
텍스트 단 서	which one of the guys will you listen to?
예 상 문 장	I do not know, I have to listen to both of them, they do not exactly let each other finish.

2.3 문장 생성 실험

우리는 이 실험에서 멀티 모달리티와 단순 모달리티가 문장 생성에 있어서 미치는 영향을 보고자 하였으며 단순 모달리티의 경우에는 이미지와 텍스트의 차이 또한 알아보려고 하였다.

실험은 텍스트 단서만을 주고 나서 문장 생성을 하는 실험 1, 이미지 단서만을 주고 나서 문장생성을 하는 실험 2, 이미지-텍스트 쌍으로 단서를 주고서 문장 생성 결과를 보는 실험 3으로 이루어진다.

하이퍼네트워크의 구성은 모든 이미지와 텍스트 데이터에 대해서 랜덤 샘플링을 이용하여 일정한 수의 하이퍼에지를 생성하며, 이미지와 텍스트 데이터를 비교하여 일치여부에 따라 가중치를 증가, 감소하는 방식을 취한다. 이러한 과정을 일정시간 반복하면서 일정 역치 값 이하를 가지는 하이퍼에지를 제거하고 새로운 하이퍼에지를 생성하여 해집단의 품질을 높게 된다. 이 실험에서는 데이터의 10배에 정도에 해당하는 하이퍼에지를 생성하였다.

랜덤 샘플링 방식은 비교적 많이 쓰이고 있는 n -그램 방식을 사용하였으며 하나의 이미지 또는 텍스트 데이터의 1/3정도의 길이로 설정하였다.

하이퍼네트워크가 구성되면 생성될 문장의 이전 시점의 단서(이미지, 텍스트, 이미지-텍스트 쌍)를 이와 일치하는 하이퍼예지를 모두 후보군에 저장한다. 저장된 후보군과 단서의 위치 데이터를 비교하여 문장을 생성하며 중복이 발생할 경우 가장 큰 가중치를 가지는 후보를 선택한다. 결론적으로 텍스트 단서를 이용하여 최종 생성되는 문장은 모든 하이퍼예지 중에서 특정 하이퍼예지가 주어진 단서와 일치할 확률과 후보군 안의 하이퍼예지가 가진 위치정보와 주어진 단서와 일치할 확률, 후보군 안의 모든 하이퍼예지 중에서 가중치가 가장 높은 하이퍼예지가 뽑힐 확률의 곱으로 나타내어 진다. 후보군의 크기를 n , 원본 데이터의 길이가 m , 단서의 위치정보가 l_o , 후보군에서의 특정 하이퍼예지가 가지는 위치정보가 l_r 일 때 유사도 s 는 다음과 같이 표현할 수 있다.

$$s = \sum_{i=1}^n \sum_{j=1}^{m-2} \frac{(l_o - l_r)^2}{m}$$

III. 실험 결과

각 모달리티 별로 단서를 주고 그에 따른 세 가지의 실험에 따른 결과는 그림 2와 같았다. 즉, 단일 텍스트 < 단일 이미지 < 멀티모달(텍스트-이미지 쌍)의 순으로 문장 생성이 잘 되는 것을 볼 수 있다.

모달리티	텍스트	이미지	멀티모달
정확도(%)	83.579	85.317	90.323




그림 2. 각 모달리티별 문장생성 결과

결과를 통하여 볼 때 단일 텍스트를 이용한 문장 생성보다는 단일 이미지가 좀 더 나은 결과를 얻을 수 있고 멀티 모달리티를 활용할 때 문장생성이 가장 잘 되는 것을 볼 수 있다. 이는 우리 실험의 최종 목표인 언어생성에서의 멀티 모달리티의 효과를 잘 보일 수 있는 결과라고 생각된다.

IV. 결론 및 향후 연구 방향

본 논문에서는 멀티 모달리티가 문장생성에 미치는 영향을 단일 모달리티와 멀티 모달리티 단서를 주고 문장생성 실험을 수행하고 그에 따른 결과를 통해서 그 효과를 확인 할 수 있었다. 그 결과 단일 모달리티 보다는 멀티 모달리티가 텍스트 보다는 이미지가 문장생성에 있어서 더 나은 결과를 보인다는 것을 확인 하였다.

본 논문은 멀티 모달리티가 문장생성에 긍정적인 영향을 미친다는 사실을 보였지만, 어떻게 해서 그러한 결과가 나타나는지에 대해서는 추후 실험을 통해서 밝혀내야 하는 것이 과제로 남아있다. 또한 데이터의 양을 늘려서 문법이나 자연어 처리 관점에서 연구를 수행하는 것이 향후 연구의 목표라고 할 수 있다.

감사의 글

이 논문은 교육과학기술부의 제원으로 국가연구재단의 지원을 받아 수행된 연구(314-2008-1-D00377, Xtran)이며, 지식경제부 및 한국산업기술평가관리원의 IT산업원천기술개발사업(K1002138, 차세대 맞춤형 서비스를 위한 기계학습 기반 멀티모달 복합 정보 추출 및 추천 기술 개발, MARS) 및 교육과학기술부의 BK21-IT 사업에 의해 일부 지원되었음.

참고문헌

- [1] Cecile L. Paris, William R. Swartout, William C. Mann, Natural Language Generation in Artificial Intelligence and Computational Linguistics, Springer US, 2010.
- [2] Verena Rieser, Oliver Lemon, Natural language generation as planning under uncertainty for spoken dialogue systems, Proceedings of the 12th Conference of the European Chapter of the Association for Computational Linguistics table of contents, p.683-691, 2009.

- [3] Ehud Reiter and Robert Dale, Building Natural Language Generation Systems, Cambridge University Press, 2006.
- [4] Cisco Systems, Inc, Multimodal Learning Through Media: What the Research Says. 2008.
- [5] Oliviero Stoc, Massimo Zancanaro, Multimodal Intelligent Information Presentation (Text, Speech and Language Technology), Springer. 2005.
- [6] B.-T. Zhang, Hypernetworks: A molecular evolutionary architecture for cognitive learning and memory, IEEE Computational Intelligence Magazine, 3(3):49-63, 2008