

하이퍼망 메모리 기반 유아 언어학습 및 생성 모델

이지훈⁰¹ 이은석² 장병탁^{1,2,3}

서울대학교 생물정보학 협동과정¹

서울대학교 인지과학 협동과정²

서울대학교 컴퓨터공학부³

jllee@bi.snu.ac.kr, eslee@bi.snu.ac.kr, btzhang@bi.snu.ac.kr

A Hypernetwork Memory-Based Model of Sentence Learning and Generation in Children: How a Child Learns to Produce Language from a Video Corpus

Ji-Hoon Lee⁰¹ Eun Seok Lee² Byoung-Tak Zhang^{1,2,3}

Graduate Program in Bioinformatics, Seoul National University¹

Cognitive Science Program, Seoul National University²

Department of Computer Science & Engineering, Seoul Nation University³

1. 서론

유아들의 언어습득에 있어서 중요한 점 하나는 학습자에 대한 언어환경의 노출이다. 유아가 접하는 언어환경은 부모와 같은 인간뿐만 아니라 각종 미디어와 같은 인공적 환경도 포함되며, 유아는 이러한 방대한 언어환경을 탐색하면서 언어를 학습한다. 본 연구는 대용량의 언어 데이터 노출이 영향을 미치는 유아언어학습을 유연하고 적절하게 모사하는 인지적 기제에 따른 기계학습 방식을 제안한다.

현대언어학을 지배하고 있는 생성문법은 언어습득의 핵심이 구문의 학습에 있다고 주장하고 있다. 구문론은 잘 형성된 문장형태와 잘못 형성된 형태를 구분하는 기준이 되며 문장을 구문적으로 옳거나/그른 코드로 맵핑하는 것을 배우는 과정이 언어습득과정이라고 본다. 또 이러한 과정을 가능하게 하는 기제는 태어날 때부터 가능하다고 본다[1].

하지만 소리/단어/문장 스트림으로부터 언어적 패턴을 사실상 추출해내는 확률기반 기계학습적인 접근을 통한 연구로 인해 생성문법이론에 대해 많은 비판이 가해졌다. 구문론적 규칙을 가지고 해 공간을 탐색하는 것보다는, 언어의 확률적이고 통계적인 측면에 대한 정보의 증가를 통해 언어학습이 가능하다는 입장이 확률기반 언어습득론이다[2].

언어습득에 있어서 최근 나타나는 또다른 계산론적 방법론으로 발달 모델을 들 수 있다. 앞서의 두 입장은 언어의 특정 현상을 시간의 흐름을 무시한 채 그 자체만으로 고립시켜놓은 상태에서 다룬다. 이러한 접근은 언어습득의 과정을 중요하게 뒷받침하는 발달적 측면을 도외시할 가능성이 높다. 발달 모델은 이러한 점을 보충한다. 즉 incremental, open-ended 방식으로 학습이 가능하도록 한다[3,4,5].

2. 언어 하이퍼망 모델

하이퍼망 H는 두 개 이상의 여러 개의 정점의 집합 X, 두 개 이상의 정점의 집합인 하이퍼에지 E, 하이퍼에지의 가중치 (weight) 집합 W 로 구성된다[6]. 본 논문의 하이퍼망 언어 모델에서는 문장의 단어가 정점이 되고, 순서정보가 있는 연결된 단어 묶음이 하이퍼에지가 되며, 각 하이퍼에지의 출현 빈도가 가중치가 된다. 이때 연결되는 단어의 개수를 Order라 한다.

기존의 하이퍼망은 하이퍼에지 내 정점들 간의 방향성을 고려하지 않지만 본 논문의 언어 하이퍼망에서는 정점의 순서를 고려한다. 이것은 문장 생성 문제에 있어서 연결된 단어간의 선후 관계에 의미를 부여함으로써 언어 특성에 맞는 하이퍼망을 만들기 위해서이다. 언어 하이퍼망은 유아의 언어 자극 정도에 따라 다르게 생성되며, 생성된 하이퍼망을 통해 문장을 생성함으로써 유아의 언어 학습 양상을 모사할 수 있다.

3. 문장 생성 실험

언어환경은 총 11단계로 구성하여 단계별로 총합적으로 incrementally 학습시키고, 각 단계별로 주어진 키워드에 따라 생성되는 문장 100개를 추출한 후, 이들 중 구문론적으로 옳은 문장과 의미론적으로 옳은 문장들의 분포와 비율을 분석하였다.

각 단계별로 학습시키는 문장은 유아용 비디오의 자막으로 구성되어 있다. 실험에 쓰인 문장데이터의 비디오는 <늑대와 7마리 아기양> <미피와 친구들> <루니툰스> <가이유> <도라도라> <심어롱 맥도널드 농장> <꼬마기관차 토마스> <티모시네 유치원> <곰돌이 푸> <굿모닝 헬로키티> <찰리브라운과 스누피>이다. (학습순서에 따라 나열)

유아의 언어 학습 양상을 모사하기 위한 방법으로 문장생성 알고리즘은 다음과 같다:

단계 1. 주어진 키워드 $L_q = (x_q)$ 를 하이퍼망 H 에서 검색하여 동일한 키워드를 포함하는 하이퍼에지를 찾아 $M = \{L_1, L_2, \dots, L_m\}$ 에 저장.

단계 2. M 에서 Roulette wheel selection을 통해 하이퍼에지 $L_h = (x_{q-1}, x_q, x_{q+1})$ 선택

단계 3. 키워드 $L_q = (x_{q-1})$ 을 업데이트 한 후 단계 1, 2 를 다시 수행 하여 $L_{left} = (x_{q-2}, x_{q-1}, x_q)$ 를 정한다.

단계 4. 키워드 $L_q = (x_{q+1})$ 을 업데이트 한 후 단계 1, 2 를 다시 수행하여 $L_{right} = (x_q, x_{q+1}, x_{q+2})$ 를 정한다.

단계 5. L_{left} 를 L_{right} 연결하여 부분 문장 $L_h = (x_{q-2}, x_{q-1}, x_q, x_{q+1}, x_{q+2})$ 을 생성한다.

단계 6. 단계 3-5 를 $L_q = (x_{q-2})$ 과 $L_q = (x_{q+2})$ 에 수행한다. 이 과정을 문장이 종료조건을 맞이할 때까지 반복 수행한다.

문장 생성의 종료는 생성되고 있는 문장의 양쪽 말단에 위치한 단어들이 하이퍼망 상에서 종료 단어 이거나 시작 단어일 확률이 높을 경우 종료하도록 하였다.

4. 결과 및 결론

학습 데이터를 구성하는 형태별 어휘들의 개수 (type number)는 총 6124개이고 사용된 모든 어휘 개수 (token number)는 총 252936개로서 small world를 형성한다. 하이퍼망이 형성하는 전체 가설공간, 즉 총 문장 개수의 크기는 32744개이다. 학습단계는 총 11회에 걸쳐 진행했다. 주어진 키워드에 대해 생성된 문장의 정합성에 대한 분석 기준은 다음과 같다:

- * 문장의 구문론적 정합성: 생성된 문장이 문법적으로 옳은지의 여부를 살펴보았다.
- * 문장의 의미론적 정합성: 의미적으로 옳은 문장인지 여부.
- * 정합적으로 생성된 문장의 길이가 학습 단계 수의 증가에 의해 영향을 받는지의 여부.




그림 1 각 학습 단계별 정합적 문장 생성 비율(%)

그림 1에서 보는 것과 같이, 실험 결과 학습 단계가 진행될수록 생성된 문장이 정합적일 확률이 높아졌다. 구문론적 정합 문장 생성의 비율과 학습단계 수 간의 상관분석 결과 (two-tailed test), $r_{obs} = 0.9056$, $df = 9$, $t_{obs}(9) = 6.405$ ($p < .001$) 로 유의했다. 또 의미론적 정합 문장 생성 비율에 대한 상관분석 결과도 $r_{obs} = 0.9715$, $df = 9$, $t_{obs}(9) = 12.2908$ ($p < .001$) 로, 학습단계의 수 증가가 강한 영향을 끼침을 보여준다.

본 실험을 통해, 데이터가 증가하면서 정합적인 문장의 생성 능력이 늘어감을 알 수 있었다. 또 정합적인 문장의 평균길이 또한 증가하였기 때문에, 유아언어학습의 보편적인 양상을 반영하는 부분이라 할 수 있다.

종합적으로, 본 실험이 언어학습의 발달적 측면을 일부나마 잘 묘사한 것으로 볼 수 있다. 차후 좀더 많은 양의 데이터와 학습단계, 언어학습에 영향을 끼치는 다양한 심리학적 변인들로 연계 실험을 진행할 필요가 있다.

감사의 글

이 연구는 한국학술진흥재단(KRF-2008-314-D00377), 과학재단 미래유망 파이오니어 사업, 정보통신연구진흥원 IT산업원천기술개발사업(IITA-2009-A1100-0901-1639), BK21-IT에 의하여 지원되었음.

참 고 문 헌

- [1] Marcus, G., *Poverty of the stimulus arguments*, Cambridge MA, MIT Press, pp. 660-661, 1999.
- [2] Seidenberg, M. and MacDonald, M., A probabilistic constraints approach to language acquisition and processing, *Cognitive Science*, Vol 23, pp. 569-588, 1999.
- [3] Weng, J., A theory for mentally developing robots, In *Second International Conference on Development and Learning*, IEEE Computer Society Press, 2002.
- [4] Lungarella, M., Metta, G., Pfeifer, R., and Sandini, G., Developmental robotics: A Survey, *Connection Science*, Vol.15(4) pp. 151-190, 2003.
- [5] Oudeyer, P.-Y., Kaplan, F., and Hafner, V., Intrinsic motivation systems for autonomous mental development, *IEEE Transactions on Evolutionary Computation*, Vol. 11(2) pp. 265-286, 2007.
- [6] Kim, S., Heo, M.-O., and Zhang, B.-T., Text classifiers evolved on a simulated DNA computer, *IEEE Congress on Evolutionary Computation*, pp. 9196-9202, 2006