

하이퍼네트워크를 이용한 이진화 주식 데이터의 예측에서 모델 차수의 검증

이성배[○] 장병탁

서울대학교 컴퓨터공학부

sblee@bi.snu.ac.kr, btzhang@snu.ac.kr

Hypernetwork Model for Prediction on the Directions of Stock Prices and Analysis on effects of Order Parameter

Seong-Bae Yi[○] Byoung-Tak Zhang

School of Computer Science, Seoul National University

요 약

Hypernetwork에 기반한 방식을 이용하여 binary 형태의 주가 데이터를 학습 후 주가의 방향에(오를지 내릴지) 대한 예측을 하는 경우에 있어서 모델 차수 (이하 order)가 예측률에 어떠한 영향을 미치는지 조사하였다. Hypernetwork 모델에서 각 order에 얼마만큼의 비중을 줄 것인가를 결정하는 것은 학습결과에 큰 영향을 미치는 요소로서, order는 해결하고자 하는 문제의 특성과 목적에 따라 다르게 설정되어야 한다. 실험 결과, 주식 데이터의 방향 예측 문제에 있어서는, 높은 order를 사용하면 training 데이터에 대한 예측률이 큰 폭으로 향상하게 되지만, 학습하지 않은 testing 데이터에 대해서는 오히려 낮은 order를 쓰는 것이 더 유리하다는 사실을 확인하였다. Hypernetwork 모델의 구조상 학습하는 과정에서 높은 order들이 주어진 데이터를 더 잘 recall 하므로 자연히 더 많은 weight를 갖게 되고 따라서 낮은 order들은 상대적으로 비중이 축소되는 것이 일반적인데, 실제 예측성능의 향상을 위해서는 높은 order에 대한 의존도를 적정 수준에서 제한할 필요가 있다.

1. 서 론

주식시장을 포함한 금융 시장에서 시계열 데이터를 예측하는 것은 경제 영역에서 가장 중요한 활동 중의 하나이다. 오늘날처럼 경제 교류가 국제화되고 규모가 거대해지고 다양한 파생상품과 위험투자가 일반화 된 경우에는 정확한 예측이 더욱 절실하다. 그런 데에 반해, 주가에는 경제뿐만 아니라 정치, 사회적인 요소까지 아울러 너무나 다양한 요소들이 크고 작은 영향을 미치므로 그것을 예측하기란 상당히 어려운 작업이다. 그러함에도 일정한 조건 아래에서 주가의 방향을 예측하는 것이 가능하다는 사실이 증명되었다 [1]. 또한 주가의 예측은 실질적으로 불가능하다는 random walk에 반하는 실험결과도 제시되었다 [2, 3]. 이러한 주장의 밑바탕에는 주가 데이터를 포함한 복잡한 시계열 데이터에는 너무나 복잡하여 실제로 랜덤하다고 밖에 볼 수 없는 요인들이 작용하기 때문에 예측이 무의미하게 느껴질 수도 있지만 긴 시간을 놓고 볼 때, 서로 유사한 크고 작은 패턴이 반복적으로 발생하기 때문에 그러한 패턴을 잡아낼 수 있다면 예측도 가능하다는 믿음이 깔려있다.

본 논문에서도 그러한 전제하에 복잡한 데이터 속에 내재되어 있는 특정 패턴을 찾아 학습시키고 그것을 바탕으로 주가의 방향을 예측하고자 한다. 사용된 주가 데이터는 Binary type으로 코드화 된 것으로서

증가기준으로 오르면 1, 오르지 못하면 0의 값을 갖는다. 이진 타입의 시계열 데이터는 주식 시장만이 아니라 비가 올 확률과 같이 실제적인 상황에서 특정 사건의 발생 여부를 구하는 문제에 사용되기도 한다 [4]. 학습 모델은 data-driven 학습과 population 의 운용이 특징인 hypernetwork 모델의 기본적인 형태를 사용하였다 [5]. 이진형 주가 데이터의 예측과 관련하여 정교한 hypernetwork 모델의 적용에 대해서는 Elena B˘autu의 연구에 소개되어 있다 [6].

본 논문은 hypernetwork의 주요 파라미터인 order의 크기에 따라 결정되는 global learning과 local learning의 특징이 시계열 데이터에서도 유효하게 적용되는지의 여부와 각 order에 따른 구체적인 예측률의 변동이 어떻게 차이가 나는지에 대해 초점을 두었다. 이 결과를 이용하면 hypernetwork 방식으로 주가 또는 시계열 데이터를 분석할 때 기초자료로서 활용될 수 있을 것이다.

논문의 구성은 hypernetwork에 기반한 학습 모델에 대한 간략한 설명과 시계열 데이터에의 응용방법을 소개하고 다음으로 실험의 목적 및 결과에 대해 설명하는 순서로 이루어졌다.

2. Hypernetwork 학습 모델

Hypernetwork 학습 모델은 확률에 기반하여 랜덤하게

형성되는 무수한 하이퍼엣지 (hyperedge)들을 population으로 가지는 집단적인 성격의 확률 그래프 학습 모델이다 [7, 8]. 하이퍼엣지는 데이터의 feature로 주어진 객체들이 상호간 다양한 연결고리를 맺음으로써 형성되어, order의 크기에 따라 그 복잡도가 결정되고 각 연결고리의 강도는 weight라는 파라미터를 통해 표현한다. 이 하이퍼엣지에 어떤 객체를 할당하느냐에 따라 전체 hypernetwork의 학습 성격이 크게 달라지고(classification 문제인가 memorial 문제인가 또는 evolutionary optimization이나 등), weight와 order를 어떻게 주느냐에 따라 성능 평가의 결과에 영향을 미치며 학습 과정에서 주어진 데이터에서 어떤 부분을 강하게 학습할 것인지를 결정하게 된다.

Hypernetwork의 구성요소를 수학적으로 간단히 도식화한다면 다음과 같다. $H = (X, E, W)$. 여기서 X 는 feature들을 표현하는 꼭지점의 집합 $X = \{X_1, X_2, \dots, X_n\}$ 이며, E 는 그 꼭지점들을 연결한 선(edge)의 집합 $E = \{E_1, E_2, \dots, E_m\}$ 이며, W 는 각각의 E 에 대응되는 weight의 집합 $W = \{W_1, W_2, \dots, W_m\}$ 이다. Order가 k 인 하이퍼엣지는 주어진 데이터에서 랜덤하게 뽑은 k 개 이하의 feature를 원소로 구성된 And-Set(각 원소가 and로 결합)이다. 특히 모든 하이퍼엣지들의 k 가 동일하다면 k -uniform hypernetwork라 부르며, 본 논문에서는 order의 변화에 따른 학습의 특징을 살펴보기 위해 이 모델을 이용하였다. 최신의 Hypernetwork 학습 모델에 대한 자세한 내용은 다음 논문을 참고하면 좋다 [9].




그림 1. Order3의 하이퍼엣지가 2개 형성된 hypernetwork 구조 예

3. 시계열 데이터의 적용

Hypernetwork 모델에 기반한 학습은 DNA 구조나 임상 데이터 같은 바이오통학 및 의학 분야와 텍스트 마이닝 및 인지과학 분야에서 많은 연구가 이루어졌다 [10,11,12,13]. 그에 비해 아직 시계열 데이터를

중심으로 시도한 연구는 미흡한 편이다. Hypernetwork가 시계열 데이터에서의 예측에도 유용한가에 대해서는 아직까지 명확히 밝혀진바 없다. 그러나 최근 binary 형태의 시계열 데이터의 예측 문제에 대해서 hypernetwork 모델의 유용성을 밝힌 예가 있다. [6]. 본 논문은 그러한 결과를 다시 한번 실험적으로 확인하고, 좋은 예측 결과를 얻기 위해 구체적으로 order를 어떻게 설정하는 것이 좋은가를 밝히는 데에 초점을 맞추었다.

표 1. 이진화 주식데이터에 대한 타 알고리즘의 예측률

Algorithm	DJI-93-97	DJI-01-08	KS11-97-02
Training hit ratio			
SVM	49.42%	54.09%	51.97%
NB	55.81%	56.63%	54.04%
LOGREG	55.49%	56.12%	54.21%
DT	82.82%	80.91%	81.06%
MLP	83.03%	71.11%	79.25%
KNN	64.81%	66.49%	64.88%
RF	98.84%	99.17%	99.22%
Test hit ratio			
SVM	47.50%	60.00%	47.50%
NB	57.50%	65.00%	35.00%
LOGREG	57.50%	60.00%	35.00%
DT	60.00%	55.00%	50.00%
MLP	62.50%	75.00%	45.00%
KNN	62.50%	65.00%	47.50%
RF	62.50%	65.00%	62.50%

(hypernetwork의 예측률은 training set에 대해 좌측부터 각각 97%, 84%, 91%이며, test set에 대해 68%, 68%, 56%로서 타 알고리즘보다 뛰어나다 [6]. 'DJI-년도-년도'는 해당 기간의 다우지수, 'KS11-년도-년도'는 해당기간의 KOSPI지수. 다우보다 KOSPI의 예측률이 어렵다는 것을 알 수 있다. 자세한 설명은 [6] 참조)

Hypernetwork 모델을 시계열 데이터에 적용하기 위해서는 하이퍼엣지를 구성하는 요소를 분석하고자 하는 시계열 데이터의 기본 단위로 바꾸는 방법이 가장 쉽게 접근할 수 있는 방법이다. 예를 들어 만약 시계열 데이터가 0 또는 1의 값을 갖는다면 $H = (X, E, W)$ 에서 $X = \{0, 1\}$, $E = \{00, 01, 000, 0001, \dots\}$ 로 구성할 수 있을 것이다. k -uniform의 order만을 갖는다면 $E = \{b_1 b_2 \dots b_k \mid b_i = 0 \text{ 또는 } 1\}$ 와 같이 간단히 구성될 것이다. 여기서 b_i 가 가질 수 있는 값의 종류는 시계열 데이터를 몇 비트의 데이터로 표현하느냐에 따라 결정된다. 만약 n 가지로 표현될 수 있는 시계열 데이터를 k -order를 갖는 hypernetwork 모델로 구성한다면 가능한 최대의 하이퍼엣지의 수는

$$\sum_{i=1}^k n^i$$

이 될 것이다. 따라서 하이퍼엣지들간의 연산을 기본 연산으로 하는 hypernetwork에서는 n 과 k 가 커질수록 계산량이 크게 늘어나는 문제점이 있다. 게다가 보유하고 있는 하이퍼엣지들의 수가 많다고 해서 학습

성능이 무한정 좋아지는 것은 아니므로 데이터의 특성에 따라 n 과 k 의 값을 적절히 제한할 필요가 있다. 그것이 어렵다면 총 보유할 수 있는 하이퍼엣지의 수를 제한하고 중요도가 떨어지는 하이퍼엣지를 교체하는 방식으로 구성해야 한다.

본 논문에서는 k -uniform의 방식을 사용하였고 데이터의 정보가 0과 1만으로 간단히 표현되므로, hypernetwork 모델에서 흔히 쓰이는 하이퍼엣지의 중요도를 평가 및 교체 관리하는 작업이 생략되어 있다. Binary 형태의 시계열 데이터는 0과 1의 연속으로 이루어진 sequential 데이터를 order 크기로 잘라내고 맨 뒤의 부분을 tag로 나머지 앞의 부분을 패턴 또는 feature set으로 하여 하나의 sample을 구성하여 학습용 데이터로 변환시킨다. (hypernetwork에서는 이러한 과정을 sampling으로 표현한다) 총 n 일(개)로 이루어진 sequential 데이터가 k -order로 학습된다면 있다면 $n-k+1$ 개의 sample이들 형성되는 것이다. 그리고 이 sample 중에서 빈도가 높거나 필요하다고 판단되는 sample을 하이퍼엣지로 구성하게 된다.




그림 2. 시계열 데이터에서 sampling 과정

이렇게 하이퍼엣지를 구성하면 각각의 엣지에 대해 학습을 통해 weight값을 조절하는 과정이 이루어지는데 weight 조절 방법에 대한 식은 다음과 같다.

$$w_E^{j+1} = w_E^j + \delta(E, E')$$

여기서 w_E^{j+1} 은 하이퍼엣지 E 의 갱신될 weight값을 나타내며 이전 weight에서 reward 함수 $\delta(E, E')$ 를 더한 만큼 변동한다는 뜻이다. Reward 함수는 weight를 E 와 다른 하이퍼엣지 E' 들을 비교하여 일치할수록 높은 값을 주는 역할을 하는데 여기서는 다음과 같은 정의를 이용했으나 문제에 따라 적절히 바꾸어 주는 것이 좋다.

$$\delta(E, E') = \begin{cases} k, & \text{if } \forall i \in [1, k'], \exists j \in [1, k] : \\ & e'_i = e_j \wedge t_E = t_{E'} \\ -k, & \text{if } \forall i \in [1, k'], \exists j \in [1, k] : \\ & e'_i = e_j \wedge t_E \neq t_{E'} \\ 0, & \text{otherwise} \end{cases}$$

여기서 $E = \{b_{e_1}, b_{e_2}, \dots, b_{e_k}\}$ 는 tag 값 t_e 를 가지는 k -order의 하이퍼엣지이고, b_n 은 E 를 구성하는 n 번째 꼭지점이다. 비교되는 E' 들도 같은 구성이다. Weight 업데이트에 관해 자세한 사항을 알고 싶으면 다음 부분을 참조 바란다 [6, 15]. 본 논문에 쓰인 방식은 예측 값을 결정하는 부분을 제외하고는 [6]에 제시된 $HM(n, n)\delta$ 모델과 동일하다. 2가지의 종류가 있는 결과 예측에 대해 서로 상반된 답을 하는 하이퍼엣지들이 존재할 경우 각 weight의 비중에 따라 랜덤하게 결정하는 방법이 많이 쓰이는데 다음과 같다.

표 2. 결과예측 결정 방법

1. $threshold = \frac{w_1}{w_1 + w_2}$
2. if $random() < threshold$
then
 $answer = lastElementsof(E_1)$
else
 $answer = lastElementsof(E_2)$
3. if $answer == test\ data$
then $O++$
else $X++$
 (단, O는 맞은 개수, X는 틀린 개수)
4. 처음으로 돌아가 다음날 예측을 한다

만약 어떤 패턴에 대해 그것과 prefix가 일치하는 하이퍼엣지가 없을 경우 해당 패턴은 학습하지 못 한 새로운 패턴인 것이며 이 경우는 답을 하지 않고 성능 평가 계산에 포함되지 않는다. 이에 대해 랜덤하게 대답하게 할 수도 있다.

4. 실험 목적

[6]의 논문은 order의 크기를 5에서 16까지 설정하였는데 직관적으로 볼 때, 16일 동안의 오르고 내리는 패턴이 실제 주식 데이터의 학습에서 의미 있는 정보가 될 수 있느냐가 문제시 될 수 있다. 그 논문에서 활용한 데이터가 약 1200개(일) 정도인데, order가 16일인 경우 총 2^{16} 가지 중 하나의 패턴이 하나의 하이퍼엣지로 구성되는데, 과연 그것이 패턴이라 불릴 만큼 자주 등장할 수 있느냐를 산술적으로 계산한다면,
 $1200 / 2^{16} = 0.03$

order를 10일로 줄이더라도

$$1200 / 2^{10} = 1.17$$

10일의 order를 사용한 하이퍼엠티일 경우 1200번 시행해서 평균적으로 1번 등장하는 패턴이라는 뜻이다. 물론 데이터에 바이어스가 있어 실제로 자주 등장하는 패턴이 간혹 존재하겠고 그것을 학습해내는 것이 또한 학습 모델로서의 강점이 되는 것이지만, order의 사용 범위에 대해 명확히 해 둘 필요성이 있다.

일반적으로 hypernetwork에서 order의 역할은 단순히 하나의 측면에서 평가할 수 있는 parameter가 아니기에 그것이 결과에 미치는 영향을 직접 실험을 통해 확인하기 전까지는 불분명한 경우가 많다. 그러나 단순히 볼 때, 학습하는 과정에서 order가 높을수록 각각의 하이퍼엠티들이 더 많은 객체의 결합으로 형성되기 때문에 보다 구체적인 상황에 민감하게 반응하게 (local learning)되고, 반대로 order가 낮다면 최소한의 중요 정보만으로 하이퍼엠티를 구성하기 때문에 주어진 데이터의 전 영역에서 공통적으로 발견되는 패턴에 민감하게 반응할 (global learning) 확률이 크다고 가정할 수 있을 것이다 [14].

Hypernetwork에 기반한 모델이 많이 응용되었던 Classification 영역만이 아니라 다음에 나타날 데이터의 정확한 예측이 중요한 문제인 시계열 영역에서도 이러한 성질이 유효하게 적용되는지 확인하는 작업은, 다양한 order의 상대적 비중과 weight함수를 조절하고 사용할 order의 범위를 결정해야 하는 evolutionary hypernetwork 모델에 있어, 가장 중요한 문제일 것이다.

5. 실험 데이터 설명 및 결과 분석

Order가 낮을 경우는 별 문제가 없지만 10이상이 되면 하이퍼엠티가 형성되지 못해 예측이 불가능한 비율이 급격히 증가하게 되며, 15정도만 되더라도 테스트 데이터에 대해 70% 이상이 대답하지 못하는 경우가 발생하였다. 따라서 의미 있는 결과를 얻기 위해 order의 범위는 10으로 제한하였다. 이때 예측에 대한 평가는 예측 후 답을 알려주고, 틀리게 예측하더라도 정답을 기반으로 다시 예측하는 SSP (step-by-step prediction)을 기준으로 잡았다.

학습에 사용한 주식 데이터는 잘 알려진 6가지 종목에 대해 2001/02/07 ~ 2008/05/22까지 1800 거래일이며 테스트 데이터의 경우 2008/05/23 ~ 2009/03/11까지 200거래일이다. 위 기간 동안 한국증시는 오랜 장기 횡보와 여러 번의 대세 상승과 조정을 겪었으며 미국발 서브프라임과 세계금융시장 붕괴로 인한 대폭락을 겪었다. 특히 마지막 시기에 등장한 폭락기를 테스트 기간으로 정하여 학습 기간과는 데이터의 특징이나 분포가 의도적으로 비슷하게 나올 가능성을 차단하였다. 참고로 동기간 한국증시의 주가 움직임은 대체로 다음과 같은 형태가 전형적이다.





그림 3. 현대중공업(좌)과 삼성전자(우)의 주가 차트

실험은 업종 대표 종목 6개에 대해서 각각 20번의 학습과 테스트를 반복하였고 order를 2에서 10으로 증가시키면서 예측률(%)을 측정하였다.






그림 4. 각 종목의 order별 예측률(%) 그래프
(실선이 training set, 점선이 testing set)

표 3. 각 종목에 대한 Order별 예측률

종목명	oder	2	3	4	5	6	7	8	9	10
SK	train	53.9	53.9	54.6	55.3	56.7	59.4	67.6	72.6	86.1
텔레콤	test	53.8	53.7	52.2	55.4	55.5	51.6	50.4	53.3	49.8
삼성	train	53.8	54	55.9	57.6	59.4	62.1	65.6	72.0	81.9
전자	test	50.1	49.7	55.4	54.1	56.2	51.1	51.6	44.6	38.6
금호	train	52.8	53.3	54.6	56.3	57.3	63.9	68.6	77.8	86.5
전기	test	51.6	43.8	49.6	56.1	53.9	53.8	50.5	46.7	47.8
현대중공업	train	50.6	53.8	54.5	56.7	60.4	63.6	67.3	75.2	84.2
	test	55.4	46.2	48.4	47.8	53.3	54.4	54.9	45.7	51.1
현대차	train	54.4	55.7	56.1	56.9	59.2	61.3	67.3	75.9	84.5
	test	50	50.2	53.3	49.1	50.1	48.4	53.1	45.2	48.3
KTF	train	53.6	53.6	55.2	55.6	57.9	62.1	66.2	74.7	84.5
	test	52.2	52.1	52.6	51.4	50.7	48.9	46.7	47.3	45.1

단위 %, 굵은 선은 가장 예측률이 높은 상위 2개 데이터 표시

Order가 높을수록 세밀하게 학습하게 되고 따라서 학습한 것과 동일한 데이터에 대해서 높은 예측률을 지니게 된다. Order가 높아짐에 따라 training 데이터에 대해 전 종목 공통적으로 우상향 곡선을 보이고 있다. order 10에서 80% 이상의 예측률을 보였으며, 표에 제시되지 않았지만 order를 15까지 올리면 95% 이상의 예측률이 나오기도 하였다. 높은 order일수록 recall (주어진 데이터의 복원)에 유용하다는 것을 알 수 있다.

Testing 데이터에 대한 예측률은 55% 전후의 값으로 Random Forest를 제외하면 50%를 넘지 못하는 타 학습 알고리즘과 비교하여 볼 때(표 1참조) hypernetwork가 상대적으로 패턴을 잘 인식하며 예측 성능이 우수하다고 볼 수 있다.

한편 testing 데이터에서 가장 예측률이 높게 나오는 경우는 종목에 따라 다르지만 대체로 4~8 order 사이에서 최대 예측률을 보이고 있다. 그 이상으로 order가 커지면 오히려 예측률이 50% 아래로 떨어지는데 training 데이터에 대해 80%이상의 예측률을 나타냈던 것과는 대조적이다. 또한 4~8 order의 특징을 살펴보면 training 데이터와 testing 데이터간의 예측률 차이가 근소하다는 것을 알 수 있다. 이는 학습 후 실제 응용 과정에서 그만큼 신뢰성을 가질 수 있다는 의미이다. Order가 2~3으로 극히 낮은 경우는 패턴으로서 인정하기에 정보 길이가 부족하다. 반대로 10정도로 order가 높아지면 주어진 데이터에 대해 패턴의 완벽한 학습은 가능할지는 모르지만 그 외의 데이터에 대해서는 오히려 신뢰성이 떨어짐을 위에서 확인 하였다. 4~8의 order는 global learning의 관점에서 그 이상의 order는 local learning의 관점에서 바라볼 수 있다. 이상을 종합하면 다음과 같이 표현될 수 있다.




그림 5. order에 따른 예측률 모형

예측하고자 하는 데이터가 학습으로 이용된 데이터와 비슷한 패턴을 가지고 있다는 사실을 알 수 있다면 order가 높은 하이퍼넷지에 weight를 더 주고, 잘 모르겠거나 비슷하지 않다면 낮은 order에 weight를 더 주는 것이 일반적으로 유리하다고 볼 수 있겠다. 10

이상의 order에서는 결과를 예측해야 하는 패턴에 대하여 하이퍼넷지가 존재하지 않아 답하지 못하는 경우가 많아지므로(15-order에서 70%) 그것들을 하이퍼넷지로 구성하는 것은 적절치 않다. 10-order만으로도 주어진 데이터에 대해 80% 이상의 학습률을 보이고 있기 때문에 order의 범위를 확장하여 계산시간을 늘릴 필요는 없다고 본다. 따라서 다양한 order를 섞어 구성할 때 4~10으로 범위를 한정하는 것이 바람직하다. 주식 데이터가 binary 타입이 아니고 좀 더 많은 경우의 수를 갖는 데이터라면 비슷한 실험을 통하여 적정 order 범위를 파악할 수 있을 것이다.

6. 결론

본 논문에서는 시계열 데이터의 예측 문제에 대해 hypernetwork에 기반한 학습 모델의 유용성을 검증하고 적용 방법을 간단히 제시하였다. 특히, 하이퍼넷지를 구성할 때 order에 따라 예측률에서 어떤 차이가 나는지 분석하였는데, order가 높을수록 주어진 데이터의 패턴을 세밀하게 학습하여 recall 성능은 좋아지지만 미지의 데이터에 대해서는 오히려 더 낮은 예측률을 보인다는 사실을 확인하였다. Binary 형태의 주식 데이터에 대해서는 4~8 정도의 order에서 전반적으로 좋은 testing 결과를 보였고 10-order를 초과하면 오히려 overfitting이 발생한다는 사실을 확인하였다. 다양한 order를 섞어 쓸 경우 목적에 맞게 각 order의 비중을 조절한다면 더 높은 예측률을 얻을 수 있을 것이다. 앞으로의 연구에서는 다양한 order를 혼합하여 하이퍼넷지를 구성할 때, 각기 order별로 얼마만큼의 가중치를 주는 것이 좋은지에 대해 알아볼 것이다. 또한 1bit 정보 단위에서 2~3bits 정보 단위의 시계열 데이터로 확장하는 방안을 고려할 것이다.

참고문헌

- [1] P. F. Christoffersen and F. X. Diebold, "Financial asset returns, direction-of-change forecasting, and volatility dynamics," *Management Science*, vol. 52, no. 8, pp. 1273–1288, 2006.
- [2] Andrew W. Lo and A. Craig MacKinlay "Stock Market Prices do not Follow Random Walks: Evidence from a Simple Specification Test," *The Review of Financial Studies*, vol. 1, no. 1, pp. 41–66, 1988.
- [3] Kausik Chaudhuri and Yangru Wu, "Random walk versus breaking trend in stock prices: Evidence from emerging markets", *Journal of Banking and Finance*, vol. 27, pp. 575–592, 2003.
- [4] R. Hyndman, "Nonparametric additive regression models for binary time series," In *Proceedings of 1999 Australasian*

Meeting of the Econometric Society, pp. 7–9, 1999.

- [5] B.-T. Zhang and J.-K. Kim, "DNA hypernetworks for information storage and retrieval," In *Preliminary Proceedings of the Twelfth International Meeting on DNA Computing* (DNA 12), pp. 283–292, 2006.
- [6] Elena Băutu, Sun Kim, Andrei Băutu, Henri Luchian and Byoung-Tak Zhang, "Evolving Hypernetwork Models of Binary Time Series for Forecasting Price Movements on Stock Markets," In *Proceedings of IEEE Congress on Evolutionary Computation* (CEC 2009) (accepted).
- [7] S. Kim, S.-J. Kim, and B.-T. Zhang, "Evolving hypernetwork classifiers for microRNA expression profile analysis," In *Proceedings of IEEE Congress on Evolutionary Computation* (CEC 2007), pp.313–319, 2007.
- [8] C.-H. Park, S.-J. Kim, S. Kim, D.-Y. Cho, and B.-T. Zhang, "Use of evolutionary hypernetworks for mining prostate cancer data," *International Symposium on Advanced Intelligent Systems*, pp.702–706, 2007.
- [9] B.-T. Zhang, "Hypernetworks: A molecular evolutionary architecture for cognitive learning and memory," *IEEE Computational Intelligence Magazine*, vol. 3, no. 3, pp. 49–63, 2008.
- [10] S. Kim, S.-J. Kim, and B.-T. Zhang, "Evolving hypernetwork classifiers for microRNA expression profile analysis," In *Proceedings of IEEE Congress on Evolutionary Computation* (CEC 2007), pp. 313–319, 2007.
- [11] J.-W. Ha, J.-H. Eom, S.-C. Kim, and B.-T. Zhang, "Evolutionary hypernetwork models for aptamer-based cardiovascular disease diagnosis," In *Proceedings of The Genetic and Evolutionary Computation Conference* (GECCO 2007), pp. 2709–2716, 2007.
- [12] J.-K. Kim and B.-T. Zhang, "Evolving hypernetworks for pattern classification," In *Proceedings of IEEE Congress on Evolutionary Computation* (CEC 2007), pp.1856–1862, 2007.
- [13] B.-T. Zhang and C.-H. Park, "Self-assembling hypernetworks for cognitive learning of linguistic memory," In *Proceedings of International Conference on Computer, Electrical, and Systems Science, and Engineering* (CESSE2008)(WASET), vol. 27, pp.134–138, 2008.
- [14] B.-T. Zhang, "Random hypergraph models of learning and memory in biomolecular networks: shorter-term adaptability vs. longer-term persistency," *The First IEEE Symp. on Foundations of Computational Intelligence* (FOCI '07), pp. 344–349, 2007.
- [15] C.-H. Park, "Sentence Generation and Completion by Learning Random Hypergraph Models," *서울대학교 공학석사 학위 논문*, pp. 4-13, 2008.