

클러스터 기반 가중치 부여를 통해 희소성을 제거한 협력적 여과

신원진[○], 김선, 장병탁

서울대학교 컴퓨터 공학부

wjshin@bi.snu.ac.kr, skim@bi.snu.ac.kr, btzhang@bi.snu.ac.kr

Sparsity Eliminated Collaborative Filtering Using Cluster-based Weighting

요 약

협력적 여과는 상품을 추천하기 위해서 널리 사용되는 추천 기술 중 하나이다. 하지만 전자 상거래 데이터는 거래량에 비해 상품과 고객의 수가 현저히 많기 때문에 훈련 데이터가 상대적으로 매우 희박하다. 따라서 전자상거래에서 협력적 여과를 이용한 추천은 그 정확도가 상당히 떨어진다. 이 논문에서는 상품을 클러스터링한 후에 클러스터에 선택적으로 가중치를 부여하는 방식으로 협력적 여과의 희소성 단점을 극복하는 새로운 방법을 제안한다. 여기서는 카테고리, 판매자와 같은 상품 정보를 이용하여 유사 상품을 클러스터링하며 고객이 어떤 클러스터에 속한 상품을 많이 구매할수록 그 클러스터에 속한 다른 상품을 살 가능성이 높다는 가정 하에 선택적으로 가중치를 부여한다. (주)디디에이치의 인터넷 쇼핑몰인 스토리샵의 데이터를 이용하여 실험한 결과 클러스터링을 이용하여 선택적 가중치를 부여한 방식이 기존의 순수 협력적 여과보다 추천 정확도가 향상됨을 알 수 있었다.

1. 서 론

협력적 여과는 전자상거래에서 널리 사용되는 성공적인 추천 방식 중 하나이다[1, 2, 3]. 협력적 여과는 고객의 상품 구매 이력을 바탕으로 아직 구매하지 않은 상품에 대한 선호도를 예측하며, 모델 기반 방식과 메모리 기반 방식으로 구분된다[4].

전통적인 추천 방식인 내용 기반 추천은 상품간의 유사도를 바탕으로 고객이 이전에 구매한 상품과 유사도가 높은 상품을 추천해 주는 방식이다. 이 방식은 고객이 이전에 구매한 상품과 유사한 상품만을 추천하기 때문에 고객이 구매한 상품과 다른 종류의 상품군은 추천하지 못한다는 한계가 있다[5].

협력적 여과 추천은 목표 고객과 비슷한 구매 성향을 갖는 다른 고객들의 구매 이력을 분석하여 목표 고객이 아직 구매하지 않았지만 관심이 있을만한 상품을 추천해 주는 방식이다. 이 방식은 다른 고객의 구매 이력을 사용하기 때문에 목표 고객이 기존에 구매한 상품과 유사하지 않은 상품군도 추천할 수 있다는 장점이 있다[5]. 하지만 협력적 여과 추천도 몇 가지 한계를 가지고 있다.

첫째는 새로운 상품 문제(new item problem)이다[5]. 전자상거래에는 매일 새로운 상품이 등록된다. 협력적 여과 추천은 고객의 구매 이력 분석을 기반으로 하기 때문에, 새로 등록된 상품은 충분한 수의 고객에 의한 구매가 발생할 때까지 추천되지 못한다. 둘째는 희소성(sparsity) 문제이다. 전자상거래에는 많은 고객과 상품이 등록되어 있지만 그에 비하여 구매 이력은 매우

희박하다. 그렇기 때문에 구매 이력을 이용해서 고객간의 유사성을 구하거나 그 밖의 다른 패턴을 찾아내기가 매우 어렵다[6].

순수한 협력적 여과는 고객이 과거에 구매하지 않은 종류의 제품군도 추천하는 우연히 발견하는 능력(serendipity)을 갖고 있음에도 불구하고 구매 이력의 희소성으로 인해 추천 정확도가 그다지 높지 않다[6]. 따라서 협력적 여과의 이러한 단점을 극복하기 위해서 협력적 여과에 다른 방식을 결합한 연구[7, 8, 9, 10]와 희소성을 제거하기 위한 연구[12]가 진행되어 왔다. 이 논문은 협력적 여과의 희소성 문제를 해결하여 추천 정확도를 높이기 위한 새로운 방법을 제안한다.

전자 상거래에서 구매 이력이 희박한 이유는 고객이 1) 모든 상품에 관심이 있는 것은 아니기 때문이거나 2) 관심 있는 모든 상품을 구매할 수 있는 것은 아니기 때문이다. 관심 없는 상품에 대한 구매 이력이 없는 것은 ‘구매 의사(관심) 없음’을 나타내는 정보이다. 그러나 관심은 있지만 기회 비용이나 경제적인 이유로 구매하지 못한 상품은 구매의사 없음(0)과 구매(1)의 중간에 해당하는 정보의 부재이다. 전자상거래의 데이터 희소성은 관심은 있지만 구매하지 못한 상품에 대한 선호도를 표현할 수 없기 때문에 발생한다. 따라서 2)로 인해 발생한 결측값(missing value)을 구매의사 없음(0)과 구매(1) 사이의 상품 선호도를 나타내는 적절한 값으로 채운 후 협력적 여과 추천을 적용한다면 희소성 문제가 해결되어 기존의 순수 협력적 여과보다 더 나은 추천 정확도를 보일 것이다.

이 논문에서는 고객이 관심은 있지만 구매하지 못한 상품을 찾아서 적절한 선호도 값을 부여하는 방식으로 데이터 희소성 문제를 해결한 후에 협력적 여과 추천 알고리즘을 적용하였다.

썬디디에이치가 운영하는 인터넷 쇼핑몰 스토리샵 [11]의 데이터를 이용하여 실험한 결과 데이터 희소성 문제를 해결한 후 협력적 여과를 적용한 새로운 접근 방법이 기존의 순수 협력적 여과 방식보다 월등히 좋은 성능을 보인다는 것을 알 수 있었다.

2. 관련 연구

2.1 내용 기반 추천

내용 기반 추천은 상품간의 유사도를 바탕으로 다른 상품을 추천하는 방식으로 사용자 프로파일과 상품의 내용을 비교함으로써 상품을 추천한다[13]. 이 방식은 주로 정보 검색에서 많이 이용하는 방식으로 고객이 구매한 상품과 다른 종류의 상품을 추천할 수 없다는 한계가 있다.

2.2 협력적 여과 추천

협력적 여과는 고객간의 유사도를 바탕으로 상품을 추천하는 방식이다. 즉, 다른 고객의 상품 구매 내역을 이용하여 어떤 고객이 관심 있을 만한 상품을 추천하는 방식으로 크게 메모리 기반 알고리즘과 모델 기반 알고리즘으로 구분된다[4].

메모리 기반 방식은 추천을 위해서 전체 고객의 구매 내역을 이용하지만 모델 기반 방식은 학습과 추천을 위해서 목표 고객의 구매 내역만을 이용한다.

3. 클러스터 기반 가중치 부여를 통해서 희소성을 제거한 협력적 여과 알고리즘의 골격

우선 이 논문에서 사용되는 용어를 정의한다. $C = \{c_1, c_2, \dots, c_M\}$ 은 전자상거래를 이용하는 고객 집합, $P = \{p_1, p_2, \dots, p_N\}$ 은 전자상거래에서 판매하는 상품 집합이다. 클러스터 $clst_k$ 는 P 의 부분집합으로 $\sum clst_i = P$ 이다. $Clst$ 는 클러스터 집합으로 $Clst = \{clst_1, clst_2, \dots, clst_L\}$ 이다. 여기서 상품과 고객의 수는 M, N 그리고 클러스터의 수는 L 개라고 가정한다.

$M \times N$ 고객-상품 거래내역 행렬($c2p_tran$)은 고객의 상품 거래 내역을 나타내는 행렬이다. $M \times L$ 고객-클러스터 선호도 행렬($c2clst_Inter$)은 고객의 클러스터에 대한 선호도를 나타내는 행렬이다. $M \times N$ 고객-상품 선호도 행렬($c2p_Inter$)은 고객의 상품에 대한 선호도를 나타내는 행렬이다. $M \times N$ 고객-상품 잠재 거래내역 행렬($c2p_poten$)은 고객에게 경제적 능력과 같은 제약이 없다고 가정했을 때, 고객의 거래 내역을 예측한 행렬이다.

클러스터 기반 가중치 부여를 통해서 희소성을 제거한 협력적 여과 알고리즘의 골격은 다음과 같다.

알고리즘: 클러스터 기반 가중치 부여를 통해 희소성을 제거한 협력적 여과

- 전처리1: 고객 c_i 가 상품 p_j 를 구매하면 1, 그렇지 않으면 0인 고객-상품 거래내역 행렬 $c2p_tran(i, j)$ 을 생성한다.

$$c2p_tran(i, j) = \begin{cases} 1 & \text{if } c_i \text{ purchased } p_j \\ 0 & \text{otherwise} \end{cases}$$

- 전처리2: 상품을 클러스터링하여 상품 클러스터 $Clst$ 를 생성한다.

1. 고객-상품 선호도 행렬 $c2p_Inter(i, j)$ 를 구한다.

1.1 고객 c_i 의 클러스터 $clst_k$ 에 대한 선호도는 고객 c_i 가 클러스터 $clst_k$ 에서 구매한 상품 수에 비례한다.

$$c2clst_Inter(i, k) = \frac{\sum_{p_j \in clst_k} c2p_tran(i, j)}{\sum_{p_j \in P} c2p_tran(i, j)}$$

1.2 고객 c_i 의 상품 p_j 에 대한 선호도는 p_j 가 속한 클러스터 $p_j \in clst_k$ 의 선호도와 같다.

$$c2p_Inter(i, j) = c2clst_Inter(i, k),$$

where $p_j \in clst_k$

2. 고객-상품 거래내역($c2p_tran$)과 고객-상품 선호도($c2p_Inter$)를 결합하여 고객-상품 거래내역의 희소성을 제거한 고객-상품 잠재 거래내역($c2p_poten$)을 구한다.

$$c2p_poten(i, j) = c2p_tran(i, j) + c2p_Inter(i, j)$$

3. 고객-상품 잠재 거래내역에 협력적 여과 알고리즘을 적용하여 고객에게 상품을 추천한다.

3.1 유사 상품 클러스터링

우선 유사한 종류의 상품을 찾아야 한다. 즉, 유사 상품을 클러스터링해야 한다. 여기서는 유사 상품을 클러스터링하는 방법으로 1)카테고리나 판매자 정보와 같이 주어진 상품 정보를 직접 클러스터로 이용하는 방법(3.1.1, 3.1.2)과 2)상품 정보를 특징으로 기계 학습 알고리즘을 적용하여 클러스터를 찾는(3.1.3) 두 가지 방법으로 접근하였다.

3.1.1 주어진 상품의 카테고리 정보 이용




그림 1. '모던 블록 선반 세트'의 3단계 카테고리

첫 번째 방법은 주어진 상품의 카테고리 정보를 이용하는 것이다. 일반적으로 전자상거래에서 상품은

대분류, 중분류, 소분류의 3단계 카테고리가 부여된다. 예를 들어, 그림 1의 ‘모던 블록 선반 세트’는 가구-인테리어 (대분류)▶거실가구 (중분류)▶장식장/수납장 (소분류) 카테고리의 상품이다.

카테고리는 판매자가 상품을 등록할 때 선택하게 되는데 카테고리를 정확하게 등록할수록 고객이 해당 상품을 쉽게 찾을 수 있으므로 판매자는 가능한 한 정확하게 카테고리를 등록할 것이다. 따라서 카테고리 정보는 비슷한 상품을 묶은 신뢰할만한 정보라고 할 수 있다.

하지만 쇼핑몰에 따라 카테고리의 기준이 달라서 그 기준이 반드시 비슷한 상품군이 아닐 수도 있으며 어떤 카테고리는 너무 광범위한 상품을 포함할 수도 있다. 그리고 시대와 유행에 따라서 카테고리 구조가 바뀌기 때문에 카테고리 정보에 노이즈가 있을 수 있다는 단점이 있다.

3.1.2 주어진 상품의 판매자 정보 이용

일반적으로 한 판매자는 비슷한 종류의 상품을 판매한다. 의류를 판매하는 판매자가 식품을 취급하는 경우는 거의 없으며 식품을 판매하는 판매자 역시 의류나 기타 다른 종류의 상품을 파는 일은 거의 없다. 그러므로 한 판매자가 판매하는 상품들을 유사한 상품이라고 볼 수 있으며 상품의 판매자는 유사한 상품을 묶는 신뢰할만한 정보라고 할 수 있다.

하지만 이 경우에는 유사한 상품을 판매하는 판매자들에 속한 상품들을 묶을 수 없으므로 이 경우에는 유사한 상품임에도 불구하고 그 정보를 표현할 방법이 없다. 따라서 판매자가 판매하는 물품이 거의 없는 경우에 비슷한 상품들을 많이 찾을 수 없다는 단점이 있다.

3.1.3 기계 학습을 이용한 상품 클러스터링

마지막 방법은 상품 정보를 특징으로 클러스터링 알고리즘을 이용해서 유사 상품 클러스터를 찾아내는 것이다. 클러스터링 알고리즘을 적용하기 위해서는 특징과 데이터 특성에 맞는 클러스터링 알고리즘의 선택해야 한다.

상품을 클러스터링하기 위해 특징으로 사용할 수 있는 속성으로는 상품명, 가격, 카테고리, 판매자가 있다. 상품명은 동의어 분석 등 텍스트 분석을 요하는데 이것은 그 자체로 하나의 연구주제로 상당한 시간과 노력을 요하는 반면 이 연구의 핵심 주제에서 벗어나므로 특징 후보에서 제외했다. 데이터 분석 결과 한 카테고리 내의 상품 가격은 저가부터 고가까지 매우 다양하며 그 편차는 평균 30만원으로 매우 크다는 것을 알 수 있었다. 따라서 가격도 특징 후보에서 가격을 제외시켰다. 일반적으로 비슷한 상품은 같은 카테고리를 갖으며 한 판매자는 서로 관련 있는 상품들을 판매한다. 따라서 카테고리 와 판매자를 유사 상품을 클러스터링하는 유용한 속성이라고 판단하여 특징으로 선택하였다.

클러스터링을 하기 위한 수 많은 알고리즘이 존재한다. 이 논문에서는 대표적인 분할 알고리즘인 k -Means와

k -Medoids을 이용하여 유사 상품을 클러스터링하였다. 유사도 측정 함수는 코사인 유사도 함수를 변형하여 새로 정의하였다.

3.2 고객의 상품 선호도 계산

고객이 구매한 상품이 그의 관심 상품이라는 사실은 명백하다. 그러므로 고객이 구매한 상품과 같거나 비슷한 종류의 상품을 그의 관심 상품이라고 정의할 수 있다. 예를 들어, 어떤 고객이 스웨터를 구매했다면 같은 종류인 가디건이나 비슷한 종류인 가방에 관심이 있을 확률은 높지만 다른 종류인 컴퓨터에 관심이 있을 확률은 낮다. (즉, 다른 옷도 구매를 하고 싶었지만 경제적으로 구매하지 못했을 가능성은 높지만 경제적 사정으로 컴퓨터를 구매하지 못했을 가능성은 매우 낮다.) 따라서, 구매한 상품과 같은 클러스터에 속한 상품이 관심 상품일 것이라고 가정한다. 또한 문제를 단순화하기 위하여 같은 클러스터에 속한 상품들의 선호도는 모두 같다고한다.

상품 선호도를 구하는 방법은 다음과 같다. 우선 고객-클러스터 선호도 $c2clst_Inter$ 를 계산한다. 클러스터 $clst_k$ 에 속한 상품의 선호도는 그 상품이 속한 클러스터의 선호도와 같다고 정의한다.

3.2.1 클러스터 선호도 계산

고객 c_i 의 클러스터 $clst_k$ 에 대한 선호도는 그 클러스터에서 구매한 상품 수에 비례한다. 따라서 고객 c_i 의 클러스터 $clst_k$ 에 대한 선호도 $c2clst_Inter(i, k)$ 는 다음과 같다.

$$c2clst_Inter(i, k) = \frac{numOfProducts(i, clst_k)}{numOfProducts(i, P)} \quad (1)$$

$numOfProducts(i, S)$ 는 고객 c_i 가 집합 S 에서 구매한 상품의 수이다.

3.2.2 상품 선호도 계산

상품 선호도는 그 상품이 속한 클러스터의 선호도와 같다. 그러므로 상품 p_j 이 클러스터 $clst_k$ 에 속한 상품일 때, 고객 c_i 의 상품 p_j 에 대한 선호도 $c2p_Inter(i, j)$ 는 다음과 같다.

$$c2p_Inter(i, j) = c2clst_Inter(i, k) \quad \text{where } p_j \in clst_k \quad (2)$$

3.3 고객-상품 거래 내역과 고객-상품 선호도 결합하여 희소성 제거(데이터 스무딩)

위에서 언급했듯이 데이터 희소성은 협력적 여과의 추천 정확도를 떨어뜨리는 주요 원인이다[6]. 그러므로 3.2.2에서 계산한 고객-상품 선호도를 이용해서 고객-상품 거래내역의 결측값을 채워 데이터 희소성을 제거한다.

기존의 고객-상품 거래 내역은 이진수로 정의되었다. 즉, 고객이 어떤 상품을 구매하면 1, 구매하지 않으면 0의 값을 가진다.

$$c2p_tran(i, j) = \begin{cases} 1 & \text{if customer } i \text{ purchased product } j \\ 0 & \text{otherwise} \end{cases} \quad (3)$$

전자상거래에는 거래 내역에 비해 고객과 상품의 수가

현저히 많기 때문에 고객-상품 거래내역은 매우 희박하다는 특성을 갖는다. 희소성을 제거하기 위해 고객-상품 거래 내역에 고객-상품 선호도를 결합하여 희소성을 제거한 고객-상품 잠재 거래내역 $c2p_poten$ 을 새로 정의한다.

$$c2p_poten(i, j) = c2p_tran(i, j) + c2p_Inter(i, j) \quad (4)$$

고객-상품 잠재 거래내역은 고객이 상품 구매에 있어서 경제적 능력과 같은 제약이 없다고 가정했을 때의 거래내역으로 고객-상품 거래 내역과 고객-상품 선호도의 합으로 정의한다. 구매하지 않은 상품에 대한 잠재 거래내역 값은 구매한 상품의 점수인 1보다는 작지만 그 상품이 속한 클러스터의 상품을 많이 구매할수록 커진다.

고객-상품 잠재 거래내역은 고객-상품 거래내역에서 거래가 없는 상품에 고객-상품 선호도 값을 부여함으로써 희소성 문제를 해결하였다.

3.4 협력적 여과 알고리즘을 이용한 상품 추천

마지막으로 식 (4)에서 구한 고객-상품 잠재 거래내역에 협력적 여과 알고리즘을 적용하여 상품을 추천한다.

우선, M명의 고객과 N개의 상품의 고객-상품 잠재 거래 내역을 나타내는 $M \times N$ 행렬 $c2p_poten$ 을 구한다. $c2p_poten$ 은 식 (4)를 이용해 구할 수 있다.

그 후에 상품 벡터를 특징으로 하여 고객간 유사도를 측정한다. $M \times M$ 고객 유사도 행렬 $simm$ 은 코사인 유사도 함수를 약간 변형한 형태이다[4].

$$simm = c2p_poten^T \times c2p_poten \quad (5)$$

$simm(i, j)$ 값이 높다는 것은 고객 i 와 고객 j 가 비슷한 제품을 많이 구매했음, 즉 구매 성향이 유사함을 의미한다.

마지막으로 위에서 구한 고객 유사도 행렬 $simm$ 과 고객-상품 잠재 거래내역 행렬 $c2p_poten$ 에 협력적 여과 알고리즘을 적용한다. 협력적 여과 알고리즘을 적용하는 식은 다음과 같다.

$$c2p_CF = simm \times c2p_poten \quad (6)$$

$c2p_CF(i, j)$ 는 고객 i 의 상품 j 에 대한 잠재 구매의사($\neq$ 잠재 구매내역)를 나타내는 점수이다. 그러므로 목표 고객에 대한 잠재 구매의사 점수가 가장 높은 상위 n 개의 상품을 추천한다.

4. 결과 및 논의

4.1 데이터 집합

이 실험에서는 ㈜디디에이치가 운영하는 온라인 쇼핑몰인 스토리샵[11]의 데이터를 사용하였다. 데이터는 크게 상품정보, 고객정보, 주문정보가 있으며 상품정보의 세부 데이터로는 상품의 판매자, 카테고리

정보 등이 있다.

스토리샵[11]은 2006월 4월에 개설되었으며 본 실험은 2006년 4월부터 2008년 11월까지의 전화주문 고객, 비회원 고객, 회원의 주문 데이터를 이용하여 수행되었다.

이 기간동안 온라인 회원, 전화주문 고객, 비회원 고객의 수는 각각 약 1만5천명, 4천명, 8천명이다. 전화주문 고객과 비회원 구매 고객의 경우 전화번호와 주소를 키로 하여 임의의 아이디를 생성하였다. 같은 기간동안 전화주문 고객, 비회원 고객, 회원의 주문 건수는 각각 약 1천건, 5만6천건, 1만4천건이며 등록된 상품 수는 약 6만개이며

고객별 특성은 다음과 같다. 전화주문 고객은 ㈜디디에이치에서 발행하는 잡지를 보고 전화로 상품을 주문하는 고객으로 1인당 주문 건수는 2.5건으로 재구매율이 높은 편이며 상품 구매 성향이 가장 뚜렷하다. 회원 고객은 재구매율이 가장 높지만 1회 거래 후 거래하지 않는 유형 회원이 많기 때문에 1인당 주문 건수는 3.5건으로 비교적 적다. 비회원 고객의 1인당 주문 건수는 1.7건으로 가장 낮다.

카테고리는 2008년 말 기준으로 약 900개, 판매자는 약 700명이다.

실험에서는 추천에 소요되는 시간과 노이즈를 줄이기 위해 1개 이하의 상품을 구매한 고객과 3개 이하의 구매 이력을 갖는 상품을 임의로 제거하는 데이터 전처리를 수행했다. 전처리 후 전화주문 고객, 비회원 고객, 회원 고객의 고객-상품 행렬의 크기는 각각 1274×380 , 519×268 , 4817×2539 로 축소되었다. 이는 반복실험을 위하여 데이터를 전처리한 것으로 전처리 후에도 데이터는 희소성의 특징을 갖으며 모든 경우 성능을 향상시키기 때문에 성능 향상의 비율에는 큰 영향을 미치지 않는다. 하지만 실제 추천 서비스를 제공할 때는 전체 상품 목록을 이용해야 함을 밝혀둔다.

4.2 정확도 측정 기준

추천 정확도를 측정하는 방법은 다음과 같다. 어떤 고객의 주문이 m 건이라면 그 고객의 거래 내역 중 $m-1$ 건은 훈련 데이터로 사용하고 나머지 1건은 테스트 데이터로 사용한다.

고객에게 추천된 상위 10개의 추천 상품 목록에 테스트 데이터가 있으면 고객이 구매 의사가 있는 상품을 올바르게 추천한 것이므로 성공, 그렇지 않으면 실패이다. 이렇게 전체 n 명의 고객이 있을 때, 추천이 성공한 고객의 수를 s 명이라고 할 때, 성공률을 다음과 같이 정의한다.

$$successRate = \frac{s}{n} \quad (7)$$

4.3 성능

4.3.1 추천 정확도

고객의 클러스터 선호도를 기반으로 선택적으로 가중치를 부여한 협력적 여과(Category-weighted CF,

Vender-weighted CF, Cluster-weighted CF)가 기존 방법보다 성능이 항상 되었음을 보이기 위해 기존의 순수 협력적 여과(Naïve CF)와 거래 내역이 없는 경우 임의로 가중치를 부여한 랜덤 협력적 여과(Random CF)와 성능 비교를 하였다.

유사 상품의 클러스터링 방법에 따라서 성능 차이를 보이는데 Category-weighted CF는 주어진 카테고리를 클러스터로 이용한 것, Vender-weighted CF는 상품의 판매자를 클러스터로 사용한 것, Cluster-weighted CF는 기계학습 방법을 이용하여 클러스터를 생성한 것이다.

기계학습 알고리즘을 이용하여 클러스터링을 한 경우 클러스터의 수는 $k=50$ 으로 설정하였으며 클러스터링 방법은 k -Means와 k -Medoids를 사용하였다. 그리고 각 실험은 10회 반복하였다.

	Naïve CF	Random CF	Category-weighted CF	Vender-weighted CF	Cluster-weighted CF
전화주문	36.8%	36.7%	42.7%	47%	46%
비회원	38.2%	37.1%	43.8%	62.5%	60%
회원	21.3%	21.4%	23.0%	29.7%	25%

표 1 가중치 부여 방식에 따른 협력적 여과 추천의 성능

표1은 가중치 부여 방법에 따른 협력적 여과의 추천 성능을 나타낸다. 고객의 제품 선호도를 고려하지 않고 임의의 선호도를 부여한 Random CF의 경우는 순수한 협력적 여과 Naïve CF와 비슷한 성능을 보였다. 그러나 카테고리를 기반으로 선호도를 부여한 Category-weighted CF의 경우는 Naïve CF보다 월등히 좋은 성능을 보였으며 판매자를 기반으로 선호도를 부여한 Vender-weighted CF는 Category-weighted CF보다 더 좋은 성능을 보였다. 이를 통해서 고객이 상품에 부여한 카테고리에는 노이즈가 있거나 쇼핑물이 정한 카테고리가 실제로 상품을 잘 클러스터링하지 못한다는 것을 알 수 있다.

마지막으로 주어진 클러스터 정보를 이용하지 않고 상품 정보를 특징으로 기계학습 알고리즘을 통하여 클러스터를 생성한 경우에는 Category-weighted CF와 Vender-weighted CF의 중간 정도의 성능을 보였다.

이 논문에서는 클러스터링 알고리즘으로 k -Means와 k -Medoids를 사용했는데, 이 경우 상품 판매자 정보를 클러스터로 이용했을 때보다 정확도가 떨어짐을 알 수 있다. 쇼핑물 데이터에 적합한 클러스터링 방법을 찾아서 적용하거나 현재 클러스터링 알고리즘의 개선을 하면 더 나은 성능을 기대할 수 있을 것이다.

5. 결론

이 논문에서 우리는 협력적 여과의 문제점 중 하나인 데이터 희소성을 제거하기 위한 새로운 방법을 제안한다. 데이터 희소성 문제를 해결하는 가장 원시적인 방법은 고객-상품 거래 내역이 없는 경우 1보다 작은 임의의 값을 부여하는 것이다. 하지만 이

논문에서는 고객의 상품 선호도를 예측하여 선호도에 따른 점수를 부여하는 방식을 제안한다.

고객의 상품 선호도를 예측하는 방법은 다음과 같다. 우선 상품 정보를 이용하여 유사 상품끼리 클러스터링한다. 그 후에, 고객이 각 클러스터에서 구매한 상품의 수와 비례하는 점수를 각 클러스터에 부여한다. 각 클러스터에 부여된 점수가 곧 그 클러스터에 속한 상품들의 선호도가 된다.

(주)디디에이치의 인터넷 쇼핑몰인 스토리샵[11]의 거래 내역을 이용하여 실험한 결과 위 방법이 순수 협력적 여과나 랜덤 협력적 여과보다 월등히 좋은 성능을 나타냄을 알 수 있었다.

그러나 클러스터링 방법에 따라 추천 성능이 차이를 보였으며 육안으로 확인한 결과 상품이 너무 많거나 거의 없는 노이즈 클러스터가 존재함을 알 수 있었다. 따라서 전자상거래 데이터에 적합한 클러스터링 알고리즘을 적용을 통해 더 나은 추천 성능을 기대할 수 있을 것이다.

고객의 상품 선호도를 예측하는 또 다른 방법으로는 로그 분석이 있다. 로그 분석을 통해 고객이 클릭한 상품, 클릭 횟수, 상품 열람 시간, 장바구니에 담은 상품 등을 알 수 있는데, 이는 고객의 상품 선호도를 예측하는 중요한 단서이다.

이후에 전자 상거래 데이터에 적합한 클러스터링 알고리즘 연구와 로그 분석을 통한 고객의 상품 선호도 예측 및 가중치 부여에 대한 연구를 통해 협력적 여과의 성능을 높이기 위한 노력을 계속해 나갈 것이다.

감사의 글

본 논문은 BK21 사업과 중소기업청에 의해 지원되었음을 밝힙니다.

6. 참고 문헌

- [1] Hill, W. and Stead, L. and Rosenstein, M. and Furnas, G., Recommending and evaluating choices in a virtual community of use, Proceedings of the SIGCHI conference on Human factors in computing systems, pp. 194-201, 1995.
- [2] Resnick, P. and Iacovou, N. and Suchak, M. and Bergstrom, P. and Riedl, J., GroupLens: An open architecture for collaborative filtering of netnews., Proceedings of the 1994 ACM conference on Computer supported cooperative work, pp. 175-186, 1994.
- [3] Shardanand, U. and Maes, P., Social information filtering: algorithms for automating "word of mouth", Proceedings of the SIGCHI conference on Human factors in computing systems, pp. 210-217, 1995.
- [4] Breese, J.S. and Heckerman, D. and Kadie, C., Empirical analysis of predictive algorithms for collaborative filtering, Proceedings of the Fourteenth Conference on Uncertainty in

Artificial Intelligence , pp. 43-52, 1998.

- [5] Adomavicius, G. and Tuzhilin, A., Towards the next generation of recommender systems: a survey of the state-of-the-art and possible extensions, IEEE transactions on knowledge and data engineering, vol. 17, no. 6, pp. 734-749, 2005.
- [6] Huang, Z. and Zeng, D. and Chen, H., A comparison of Collaborative-filtering Recommendation Algorithms for E-commerce, IEEE Intelligent Systems, vol. 22, no. 5, pp. 68-78, 2007.
- [7] Xue, G.R. and Lin, C. and Yang, Q. and Xi, W.S. and Zeng, H.J. and Yu, Y. and Chen, Z., Scalable Collaborative Filtering Using Cluster-based Smoothing, Proceedings of the 28th annual international ACM SIGIR conference on Research and development in information retrieval, pp. 114-121, 2005.
- [8] Melville, P. and Mooney, R.J. and Nagarajan, R., Content-Boosted Collaborative Filtering for Improved Recommendations, Proceedings of the National Conference on Artificial Intelligence, pp. 187-192, 2002.
- [9] 고수정, 김진수, 김태용, 최준혁, 이정현, 이정현, 협력적 여과와 내용 기반 여과의 병합을 통한 추천 시스템에서의 사용자 선호도 발견, 한국정보과학회, 정보과학회논문지 : 컴퓨팅의 실제 제7권 제6호, pp. 684-695, 2001.
- [10] 류영석, 양성봉, 전자상거래를 위한 대표 속성을 이용한 협력적 여과 방법, 정보통신연구진흥원, 2000.
- [11] www.storyshop.kr
- [12] van Meteren, R. and van Someren, M., Using content-based filtering for recommendation, Proceedings of the Machine Learning in the New Information Age: MLnet/ECML2000 Workshop, 2000.
- [13] Sarwar, B. and Karypis, G. and Konstan, J. and Riedl, J. and MINNESOTA UNIV MINNEAPOLIS DEPT OF COMPUTER SCIENCE, Application of dimensionality reduction in recommender system-a case study, In ACM WebKDD Workshop, 2000.