

심층 개념구조 학습을 통한 드라마 등장인물 소셜 네트워크 분석

남장균^o, 김경민, 장병탁

서울대학교 컴퓨터공학부

{cjnan, kmkim, btzhang}@bi.snu.ac.kr

Social Network Analysis of TV Drama Characters via Deep Concept Hierarchies

Chang-Jun Nan^o, Kyung-Min Kim and Byoung-Tak Zhang

School of Computer Science and Engineering, Seoul National University

요 약

TV 드라마는 현대 인류사회의 거대한 지식을 담고 있는 빅데이터이다. 정치, 문화, 경제 등의 다양한 지식들이 드라마 속 등장인물 중심 이야기 전개 방식에 따라 나타난다. 하지만 드라마 데이터를 다루려면 효과적인 동적 멀티모달 데이터 및 이미지 처리기법이 필요하기 때문에 드라마 데이터 분석은 쉽지 않다. 본 논문에서는 이러한 문제점들을 해결하기 위해 최근 연구된 심층 개념구조(DCH)와 컨볼루션-순환 딥러닝(C-RNN)을 사용하여 드라마 등장인물의 소셜 네트워크를 분석해보았다. DCH는 등장인물의 시각적 언어 개념을 계층적 구조를 사용해 다양한 추상 단계로 표현할 수 있고 MCMC 기법을 통해 전체 개념 공간을 효율적으로 탐색할 수 있다. 실험을 위해 총 4400분 분량의 TV드라마 "Friends" 데이터를 사용했고 C-RNN모델을 사용하여 장면 속 등장인물을 인식하였다. 그리고 DCH를 사용해 등장인물의 소셜 네트워크를 구축한 뒤 등장인물 사이 친밀도와 스토리 전개에 따른 관계 변화를 분석하였다.

1. 서 론

인간은 가정 및 사회에서의 역할을 통하여 관계를 이해하고 이를 통하여 감정 및 사건을 분석한다. "Role Theory"에서 인간은 자신의 사회적 역할에 따라 예측 가능한 방식으로 행위를 결정한다고 주장하였다[1]. 즉 소셜 네트워크 분석을 통하여 인간과 환경의 상호작용을 이해하는데 도움이 될수 있음을 보여준다. 컴퓨터 공학 측면에서는 이러한 사회적 역할에 대한 지식을 이용하여 비디오를 분석하는데 있어서 드라마는 아주 적절한 데이터이다. 하지만 드라마속의 인물 관계는 구체적인 사건뿐만아니라 때로는 추상적인 지식으로 표현되고 있다. 이러한 멀티모달 프라퍼티하고 다이나믹한 특성상 비디오를 분석하는데 어려움이 있다.

최근에 비디오 분석 관련 연구들이 많이 진행되고 있다. [2]는 영화 등장인물에 대한 그룹 클러스터링을 통해 등장인물 대립관계를 예측하였고 [3]에서는 장면 컨텍스트, 의상 등 특징을 학습하여 소셜 네트워크를

구축하였다. 기존 연구에서는 특정된 비디오를 이용하여 등장인물 역할과 사회적 배경에 대한 지식을 미리 정의한 다음 분석을 시도하였다. 이런 방법은 많은 시간과 인력이 필요할뿐만 아니라 선입견으로 인해 정확한 분석을 할수 없는 우려가 있다.

본 연구에서는 비디오 데이터로부터 자동으로 지식을 학습할수 있는 심층 개념구조(Deep Concept Hierarchies, DCH)를 사용하여 등장인물의 소셜 네트워크를 분석하였다. DCH 모델은 스토리의 전개에 따라 순차적 베이지안 추론과 MCMC 기법을 통해 점진적으로 학습한다. 실험을 위한 데이터로 4400분 분량의 드라마 "Friends"를 사용하였다. 등장인물을 인식하기 위해 컨볼루션-순환 딥러닝 모델을 적용하였고 DCH를 이용하여 소셜 네트워크의 변화를 분석하였다. 제시된 캐릭터 분석 프레임워크는 기존 연구보다 다양한 인물관계를 표현할 수 있었고 자동화와 시간에 따른 변화를 분석할수 있는 면에서 비디오 분석 기술에 기여가 될것으로 보인다.




그림 1 심층 개념 네트워크의 구조

2. 심층 개념구조

2.1 심층 개념구조 생성

그림1은 심층 개념구조를[4] 나타낸다. 모델 자체는 멀티레이어로 구성 되었고 SPC 모델[5]을 이용하여 이미지-자막 페어를 구성하여 Monte Carlo Sampling 방법을 통해 H층의 Low-Layer 하이퍼에지를 구성한다. C¹층 노드는 H층 하이퍼에지의 부분집합을 클러스터링 한 조합이고 노드의 수량은 학습에 따라 변하게 된다.

$$Sim(\mathbf{h}^m) = Dist(\mathbf{h}^m)/|\mathbf{h}^m| \quad (1)$$

$\mathbf{h}^m$ 는 C¹층의 m번째 노드에 연결된 하이퍼에지들이고 함수 $Dist$ 는 에지 사이들의 유클리드 디스턴스이다. $Sim(\mathbf{h}^m)$ 가 임계값을 넘을 때 노드는 두개로 갈라지게 된다. 그중 임계값은 Sim 들의 평균과 표준편차에 의해 정한다. C²층의 노드는 등장인물에 대응되며 C¹층과의 연결은 등장인물들이 나타나는 Scene에 의해 결정된다.

2.2 심층 개념구조 학습

본 연구에서 비디오의 매개 이미지-자막 페어를 하나의 mini corpus로 정의하였고 심층 개념구조의 학습과정에서 순차적으로 시각적 언어 개념망을 만드는 동시에 에피소드를 관찰하면서 순차적 베이시안 추론에 의해 개념망의 이미지-자막 페어를 업데이트 한다.

$$P_t(\mathbf{e}, \alpha, \mathbf{c}^1 | \mathbf{r}, \mathbf{w}, \mathbf{c}^2) = \frac{P(\mathbf{r}, \mathbf{w} | \mathbf{e}, \alpha, \mathbf{c}^1, \mathbf{c}^2) P(\mathbf{c}^2 | \mathbf{e}, \alpha, \mathbf{c}^1) P_{t-1}(\mathbf{e}, \alpha, \mathbf{c}^1)}{P(\mathbf{r}, \mathbf{w}, \mathbf{c}^2)} \quad (2)$$

이진 벡터 $\mathbf{r}, \mathbf{w}$ 는 이미지패치와 단어의 특징벡터이고 $\mathbf{c}^1, \mathbf{c}^2$ 는 노드의 존재여부를 판단한다. $\mathbf{e}$ 는 하이퍼에지들의 집합이고 α 는 에지들의 가중치이다. 파라미터 $\theta(\mathbf{e}, \alpha)$ 와 $\mathbf{c}^1, \mathbf{c}^2$ 가 주어졌을 때 (2)의 수식으로 학습이 진행된다. P_t 는 t번째 에피소드에 대한 매개변수의 확률 분포이다. t번째 에피소드를 관찰하였을 때 사전 확률 분포 $P_{t-1}(\theta)$ 는 likelihood와 normalization을 계산함으로써 사후 확률 분포를 업데이트한다. 업데이트 된 사후 확률

분포는 그다음 에피소드의 학습의 사전 확률 분포로 사용된다. 데이터 생성 관련항은 텍스트와 이미지패치의 피쳐로 나누어 져 있다.

$$P(\mathbf{r}^{(d)}, \mathbf{w}^{(d)} | \mathbf{e}, \alpha, \mathbf{c}^1, \mathbf{c}^2) = \sum_{n=1}^N \log P(\mathbf{r}_n^{(d)} | \mathbf{e}, \alpha, \mathbf{c}^1, \mathbf{c}^2) + \sum_{n=1}^N \log P(\mathbf{w}_n^{(d)} | \mathbf{e}, \alpha, \mathbf{c}^1, \mathbf{c}^2) \quad (3)$$

$\mathbf{d}$ 는 에피소드의 d번째 이미지-자막 순서이고 이 때 m번째 엘리먼트가 1인 확률은 (4)와 같다.

$$P(\mathbf{w}_m^{(d)} = 1 | \mathbf{e}, \alpha, \mathbf{c}^1, \mathbf{c}^2) = \exp \left(S_m^w - \sum_{i=1}^{|\mathbf{e}^c|} \alpha_i \right), \quad (4)$$

s. t. $S^w = \sum_{i=1}^{|\mathbf{e}^c|} \alpha_i \mathbf{e}_i^w$

$\mathbf{e}^c$ 는 값이 1인 $\mathbf{c}^2$ 에 연결된 노드의 하이퍼에지 집합이고 S_m 은 $\mathbf{s}$ 의 m번째 엘리먼트이다. $\mathbf{e}_i^w$ 은 i번째 하이퍼에지의 단위벡터이다. 학습초기에 에지들의 가중치는 에피소드에서 나타나는 빈도수에 의해 부여되고 새로운 에피소드를 학습할 때 식(6)으로 가중치를 업데이트한다.

$$\alpha_i^t = \lambda \alpha_i + (1 - \lambda) \alpha_i^{t-1} \quad (5)$$

λ 는 이전 에피소드에 비해 새로운 에피소드를 학습하는 비중이다. 본 연구에서는 λ 를 0.9로 정한다.

3. 컨볼루션-순환 딜러닝 모델

드라마 등장인물을 인식하기 위하여 컨볼루션-순환 딜러닝(C-RNN)[6]을 적용하였다. 모델은 데이터로부터 특징점을 자동으로 추출할수 있는 단일 계층 CNN과 얼굴인식에 얼굴을 추론하는 Deep RNN의 조합으로 이루어졌다. 학습 알고리즘은 4단계로 기술된다.

- 단계1.Face Detection을 통한 얼굴 이미지를 정규화 및 화이트닝을 거친후 K-means를 적용하여 군집화.
- 단계2.단일 계층의 CNN을 통해 컨볼루션 벡터를 추출.
- 단계3.벡터들을 Tree구조 RNN에 입력하여 재귀적 학습.
- 단계4.최상위 벡터를 Softmax에 입력하여 결과를 출력.

4. 실험 결과

4.1 데이터 및 전처리

학습을 위한 데이터로 드라마 "Friends"의 183편, 총 4400분 분량의 비디오를 사용하였다. 제안된 C-RNN모델의 학습을 위해 6명 등장인물의 얼굴 이미지 6000장을 학습시켜 테스트 한 결과 89%이상의 인식율을 보였다. 추출된 이미지패치는 CNN모델을 사용하여 4096차원의 벡터로 나타내었고 자막은 단어들의 집합으로 변환한 뒤 word2vec[7]을 적용하여




그림 2 PCA를 적용한 2차원 공간의 매핑 결과
200차원의 벡터로 나타내었다.

4.2 심층개념구조를 이용한 소셜 네트워크 분석

그림 2는 6명 등장인물의 C^1 층 노드 하이퍼에지를 PCA를 이용하여 2차원 공간에 매핑한 결과이다. PCA 매핑 결과에서 시나리오의 전개에 따라 하이퍼에지가 각 등장인물을 중심으로 군집되어 가는 것을 볼 수 있다.

그림 3은 심층 개념구조를 통해 시간의 전개에 따라 등장인물 소셜 네트워크를 분석한 결과이다. 등장인물의 하이퍼에지 가중치는 에피소드에서 인물과의 관련성을 의미함으로 두 등장인물들이 동시에 포함되어 있는 에지들의 가중치는 친밀도로 정의할 수 있다.

그래프에서 두 인물 사이에 연결된 선의 개수는 그들이 공유하는 하이퍼에지의 개수를 표시하고 각 등장인물에 표시된 히스토그램은 기타 인물과 공유하는 하이퍼에지들의 가중치의 합이다. 즉 통계값이 높을수록 높은 친밀도를 의미한다. 그래프를 보면 드라마 10편의 인물관계는 연관성이 많이 없었지만 49편까지 학습한 등장인물간 소셜 네트워크는 상대적으로 연관성이 높았다. 또한 Ross, Joey, Phoebe는 기타 인물에 비해 높은 가중치를 가지고 있다. 이런 정보는 드라마속의 인물 등장 비율, 대본 수량, 인물 중요성 등 기타 관련 정보를 추측하는데 수학적 근거가 될 수 있다.

5. 결론 및 논의

본 논문에서는 TV드라마 "Friends"에 등장하는 인물들사이 소셜 네트워크를 분석하는 프레임워크를 제안하였다. 컨볼루션-순환 딥러닝을 이용하여 비디오의 얼굴을 인식한 뒤 심층 개념구조를 통해 6명 등장인물 소셜 네트워크를 구축하였다. 제안한 인물관계 분석방법을 사용한 결과 캐릭터 사이의 친밀도와




그림 3 구축된 등장인물 소셜 네트워크

스토리 전개에 따른 인물관계 변화를 관찰할 수 있었다.

감사의 글

이 논문은 2015년도 정부(미래창조과학부)의 재원으로 한국연구재단의 지원(NRF-2010-0017734-Videome)과 정보통신기술진흥센터의 지원(R0126-15-1072-SW스타랩, 10035348-mLife, 10044009-HRI.MESSI)을 받아 수행된 연구임.

참고문헌

- [1] B. J. Biddle. "Recent development in role theory". In *Annual Review of Sociology*, 12:67-92, 1986.
- [2] L. Ding and A. Yilmaz. "Inferring social relations from visual concepts". In *IEEE International Conference on Computer Vision (ICCV2011)*, pp. 699-706, 2011.
- [3] Z. Song, M. Wang, X. Hua and S. Yan. "Predicting occupation via human clothing and contexts". In *IEEE International Conference on Computer Vision (ICCV2011)*, pp. 1084-1091, 2011.
- [4] J.-W. Ha, K.-M. Kim and B.-T. Zhang. "Automated construction of visual-linguistic knowledge via concept learning from cartoon videos". In *Proceedings of the Twenty-Ninth AAAI Conference on Artificial Intelligence (AAAI 2015)*, pp. 522-528, 2015.
- [5] B.-T. Zhang, J.-W. Ha and M. Kang. "Sparse population code models of word learning in concept drift". In *Proceedings of Annual Meeting of the Cognitive Science Society (CogSci 2012)*, pp. 1221-1226, 2012.
- [6] 이범진, 이충연, 장병탁. "컨볼루션-순환 딥러닝을 이용한 컬러-깊이-열화상 얼굴 이미지 인식 방법". *2014 한국정보과학회 동계학술발표회 논문집 (KCC2014)*. pp. 616-618, 2014.
- [7] T. Mikolov, I. Sutskever, K. Chen, G. Corrado, J. Dean, "Distributed Representation of Words and Phrases and Their Compositionality", In *Proceedings of Advances in Neural Information Processing Systems (NIPS 2013)*, 2013.