

교차 도메인에서의 행동 예측을 위한 미래 상태 생성 방법

김현서^o, 허유정, 김기범, 장병탁
서울대학교

{hskim, yjheo, kskim, btzhang}@bi.snu.ac.kr

Future State Generation for Action Prediction in Cross Domain

Hyunseo Kim, Yu-Jung Heo, Kibeom Kim, Byoung-Tak Zhang
Seoul National University

요 약

최근 활발하게 연구되는 이미지 기반 모델 강화학습은 시각 데이터로부터 에이전트 행동, 움직임을 추론하는 과정이 필수적이다. 따라서 테스트 환경과 학습 환경이 달라지는 경우가 많은 실제 환경에서 이미지 기반 강화학습을 활용하기 위해서는 모델이 일반성을 갖고 있어야 한다. 하지만 테스트 환경을 한번도 보지 않은 상태에서 미래 이미지 예측을 할 때는 그 예측 정도가 낮아지게 된다. 본 논문에서는 행동벡터를 추론하여 미래 이미지 예측하는 과정에서 여러가지 조건들을 추가 제거하였을 때 생성된 이미지의 질이 얼마나 달라지는지 관찰하고 그 해결방법에 대해 논의한다.

1 서론

기존 강화학습은 많은 시행착오가 필요한 강화학습의 특성상 실제 환경이 아닌 시뮬레이션 환경에서 주로 적용되었다. 그에 따라 에이전트의 현재 상태는 시뮬레이터에서 제공하는 값을 활용하여 측정하였고, 실제 환경과 같이 이미지를 이용해 상태를 추측할 필요가 없었다. 하지만 강화학습이 딥러닝과 결합하여 발전하면서 실제 환경에서도 강화학습을 쓰려는 시도가 이어졌고, 그에 따라 이미지 기반 강화학습의 필요성이 대두되었다.

이미지 기반 강화학습 중에서도 모델 기반 강화학습은 주로 예측을 통해 자기-지도적으로 환경 모델을 학습해나간다. 이 논문과 유사한 Visual MPC [1]는 한번 학습한 환경모델이 충분히 일반화를 잘하여 새로운 환경도 예측해낼 수 있지만, 예측가능한 행동을 가우시안 분포 내로 제한하였다.

이 논문 모델의 기반이 된 논문 [2]은 후보 행동 벡터를 임의로 생성하여 다음 상태 이미지를 예측하고, 그 이미지 품질에 따라 행동 벡터의 품질을 결정하였다. 후보 행동 벡터를 어떻게 설정하느냐에 따라 모델의 예측 성능이 크게 갈린다는 점에서 사전 지식없는 활용하기 어렵다고 볼 수 있다.

U-Net 기반의 목표 생성기를 사용한 논문[3]도 있는데, 이 논문에서는 이미지 생성을 용이하게 하기 위해 모든 픽셀을 생성하기보다는 전이, 즉 이전 이미지의 픽셀을 이용하여 다음 이미지를 만드는 방식을 채택하였다. 다만 이 논문에서는 다음 이미지를 생성할 때 행동벡터를 입력값으로 받지 않고, 행동과 이미지를 결부시키는 작업은 따로 학습한다.

이처럼 이미지 기반 강화학습은 이미지와 행동벡터를 연관짓기 위해 많은 노력을 했지만, 이미지에서 직접 행동을 추론하는 것을 학습한 논문은 Forward-consistency [4] 외에 많은 연구가 이루어지지 않고 있다. 그 이유는 고차원 이미지로부터 원하는 차원수의 행동벡터를 추론해내는 것이 쉽지 않기 때문인데, Forward-consistency에 의하면 추론된 행동벡터를 이용하여 다시 이미지를

생성해내는 작업을 활용하여, 행동 벡터 추론의 정확도를 높일 수 있다고 한다.

이 논문에서는 Forward-consistency에 기반하여 다음 상태 이미지를 예측함으로써 행동예측의 품질을 높인다. 그 과정에서 학습 환경과 테스트 환경이 달라졌을 때 다음 상태 이미지의 품질이 얼마나 달라지는지 관찰한다.

2 행동 예측을 위한 미래 상태 생성

행동 예측을 위한 미래 상태 생성 모델은 Inverse Dynamics 모듈 I 와 미래 상태 생성 모듈 G 로 나뉜다. Inverse Dynamics 모듈은 시간 t 에서의 행동을 예측하고 미래 상태 생성 모듈은 에이전트의 미래 상태를 이미지로 생성하는 모듈이다.

두 모듈은 같이 학습되면서 예측값을 서로 보정해준다. 먼저, Inverse dynamics 모듈에서는 에이전트가 탐험할 때 얻게 되는 시간 t 일때의 상태와 $t+k$ 일때의 상태를 보고 어떤 행동을 취해야하는지 추론한다. 생성 모듈에서는 그 행동을 실제로 취했을 때 상태 $t+k$ (k 는 1 이상의 자연수이다.) 이미지를 생성해냄으로써 Inverse Dynamics에서의 예측 행동의 품질을 평가한다.

2.1 Inverse Dynamics 학습 모듈

Inverse dynamics 학습 모듈에서는 시간 t 의 이미지 O_t 와 $t+k$ 의 이미지 O_{t+k} 를 받아서 컨볼루션 레이어 특징 벡터 값 c_t 와 c_t 를 선형 레이어에 통과한 행동 벡터값 a_t 을 도출한다. 선형 레이어를 통과한 행동 벡터값 a_t 은 실제 행동벡터와 비교하여 예측값의 품질을 평가하기 위해 사용되고, 컨볼루션 레이어 특징 벡터 c_t 는 이 다음 모듈인 이미지 생성 모듈의 입력값으로 활용된다.

$$a_t = I(O_t, O_{t+k}) \in \mathbb{R}^n, \quad k = 1, 2, \dots, T \quad (1)$$




그림 1: 모델 흐름도. (a) 학습할 때의 모델. (b) 테스트 때의 모델.

2.2 미래 상태 생성 모듈

미래 상태 생성 모듈 G 은 Inverse Dynamics 학습 모듈에서 예측한 컨볼루션 레이어 특징 벡터 c_t 를 이용하여 다음에 등장할 이미지를 생성하는 모듈이다. 이미지를 생성해내야 하므로 행동 벡터 a_t 보다는 이미지 상 위치와 관련된 값을 가지는 컨볼루션 레이어의 결과값 c_t 를 활용하였다. G 는 현재 상태 이미지 O_t 와 컨볼루션 레이어 특징 벡터 c_t , LSTM의 분포에서 샘플링한 벡터 z_t 를 이용하여 다음 상태 이미지 O_{t+k} 를 생성한다.

$$\hat{O}_{t+k} = G(O_t, c, z_t), \quad z_t = \text{LSTM}(O_t), \quad z_t \sim \mathcal{N}(\mu, \sigma) \quad (2)$$

이 모듈은 [2]의 이미지 생성 모델을 기반으로 구성하였으며 수식은 2와 같다.

수식 2에 등장하는 LSTM 모듈은 그림 1에서 볼 수 있듯 O_t 과 O_{t+k} 을 따로 학습하여 순차적 변화 양상에 대한 정보를 제공함으로써 이미지 생성의 질을 높일 수 있다. 두개의 LSTM 값이 발산하게 되면 원하는 정보를 얻기 힘들므로 그 사이의 쿨백-라이블러 (Kullback-Leibler) 손실함수($\mathcal{L}_{KLD}$) 계산함으로써 LSTM 값이 큰 변동없이 안정적으로 학습될 수 있도록 하였다. 쿨백-라이블러 다이버전스를 활용하여 LSTM 분포를 최대한 가깝게 하였으므로 이미지를 예측할 때는 t 시점 혹은 $t+k$ 시점 중 하나의 LSTM 값만을 활용하였다. 최종 손실함수는 식 3과 같다.

$$\mathcal{L} = \mathcal{L}_{image} + \mathcal{L}_{action} + \mathcal{L}_{KLD} \quad (3)$$

이때, $\mathcal{L}_{image}$ 은 생성 이미지와 정답 이미지 사이 L_1 손실 값을 의미하며, $\mathcal{L}_{action}$ 은 예측된 행동 벡터와 정답 행동 벡터 사이의 L_1 값을 의미한다. 또한, $\mathcal{L}_{KLD}$ 은 두 LSTM 네트워크 사이의 쿨백-라이블러 다이버전스를 의미한다.

3 실험

실험은 Mujoco에서 구현된 InvertedPendulum과 Pendulum의 색깔을 다르게 설정한 새로운 도메인 환경을 이용하였다. 학습 데이터 및 환경은 DisentanGAIL [5]의 환경 및 데이터와 동일하게 하였다.

그림 2에서 행동 예측을 위한 미래 상태 생성 모델이 얼마나 환경에 강건하게 에이전트 행동을 예측할 수 있는지 실험해 보았다. 먼저 그림 2의 (a), (b), (c), (d)는 입력 이미지 사이의 시간 간격이 달라졌을 때, LSTM의 유무에 따른 이미지 생성의 결과를 보인다. 그림 2 (a)는 생성 이미지가 입력 이미지와 시간 간격이 크지 않고 LSTM의 출력값을 이용하여 이미지를 생성하였기에 예측한 이미지의 품질이 좋다. 하지만 (b)는 LSTM 정보를 사용하지 않고 오로지 행동벡터의 값에 의존하여 이미지를 생성하면서 행동벡터에 의해 치우친 이미지를 생성하였다. (c)는 (a)와 같은 모델을 사용하였지만 예측하는 이미지와 입력 이미지 간 시간 간격이 커지면서 (b)와 유사한 정도로 예측 품질이 낮아졌다. (d)는 예측 시간 간격도 크면서 LSTM 정보를 사용하지 않았기에 예측 이미지가 흔들리는 정도를 벗어나 형태가 일그러질 정도로 예측 품질이 떨어졌다.

학습단계와 테스트 단계 모두 동일한 환경의 에이전트 이미지 정보를 활용한 (a), (b), (c), (d)와 달리, (e)는 학습 단계와 테스트 단계의 에이전트 색깔이 다르다. (e)가 학습단계에서 접한 에이전트는 (a-d)와 같이 파란 선위의 노란 동그라미를 가진 에이전트인데, 테스트 단계에서 접한 에이전트는 빨간 선위의 파란 동그라미 에이전트이다. (e)의 예측 결과 이미지를 살펴보면 행동 예측을 위한 미래 상태 생성 모델이 LSTM 정보를 활용하고 시간 간격을 작게 주어도 색깔 변화에 취약한 것을 볼 수 있다.

4 결론

본 논문에서는 행동 예측을 위한 미래 상태 생성 모델을 구성하여 이미지 기반 모델 강화학습에서 이미지만을 활용해 환경모델을 추론해낼 수 있는지 평가해보았다. 그림 2에서 관찰할 수 있듯이 특정 환경에 대해 학습을 한 후 그에 대해 환경모델을 추론하는 것은 가능하였지만, 유사한 환경에서 학습한 후 보지 않은 환경에 대해 추론하는 것은 불가능한 것으로 보인다. 그림 2에서는 환경에서 색만 바뀌었을 뿐인데, 예측 이미지 품질이 떨어졌다.

본 논문에서 제시한 행동 예측을 위한 미래 상태 생성 모델은 예




그림 2: 정답 이미지 및 각 설정에 따른 학습결과. $\hat{O}$ 는 생성이미지이고, O 는 정답 이미지이다. (a) skip frame 1이고, LSTM이 적용됨. (b) skip frame 1이고, LSTM 없음. (c) skip frame 3이고, LSTM 있음. (d) skip frame 3이고, LSTM 없음. (e) 학습 때와 테스트 때의 에이전트 색깔이 달라짐.

측하는 이미지와 행동 벡터값이 이미 데이터에 존재하기 때문에 손쉽게 $L1$ 손실함수를 활용하여 평가하고 있지만, 추후에 데이터에 없는 이미지를 예측하기 위해서는 다른 손실함수를 활용해야 할 것이다. 예를 들면 에이전트와 다른 환경에 있는 멘토를 모방할 때 멘토의 다음 타임스텝 $t + k$ 이미지와 에이전트의 예측한 다음 타임스텝 $t + k$ 이미지는 배경 환경과 멘토와 에이전트의 상태가 다를 것이므로 그대로 비교할 수 없다. 따라서, Structural Similarity Index Measure (SSIM)과 같은 구조 비교함수를 활용할 수 있을 것으로 예상된다.

5 사사

이 논문은 2021년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원(2015-0-00310-SW.StarLab/25%, 2017-0-01772-VTT/25%, 2018-0-00622-RMI/25%, 2019-0-01371-BabyMind/25%)의 지원을 일부 받았음.

참고 문헌

[1] F. Ebert, C. Finn, S. Dasari, A. Xie, A. Lee, and S. Levine, “Visual foresight: Model-based deep reinforce-

ment learning for vision-based robotic control,” *arXiv preprint arXiv:1812.00568*, 2018.

- [2] A. Wu, A. Piergiovanni, and M. S. Ryoo, “Model-based behavioral cloning with future image similarity learning,” in *Conference on Robot Learning*, pp. 1062–1077, PMLR, 2020.
- [3] P. Sharma, D. Pathak, and A. Gupta, “Third-person visual imitation learning via decoupled hierarchical controller,” 2019.
- [4] D. Pathak, P. Mahmoudieh, G. Luo, P. Agrawal, D. Chen, Y. Shentu, E. Shelhamer, J. Malik, A. A. Efros, and T. Darrell, “Zero-shot visual imitation,” 2018.
- [5] E. Cetin and O. Celiktutan, “Domain-robust visual imitation learning with mutual information constraints,” 2021.