

다수준 등장인물 주의집중을 통한 비디오 스토리 이해 기법

최성호^{*}, 온경운, 허유정, 서아정, 장유원, 이민수, 장병탁
서울대학교

{shchoi, kwon, yjheo, ajseo, ywjang, mslee, btzhang}@bi.snu.ac.kr

Video Story Understanding with Multi-level Character Attention Model

Seongho Choi, Kyoung-Woon On, Yu-Jung Heo, Ahjeong Seo, Youwon Jang, Minsu Lee, Byoung-Tak Zhang
Seoul National University

요약

비디오 이해 능력을 평가하는 방법 중 하나인 비디오 스토리 질의응답 (Video Story QA)은 비디오 스토리에 대한 인공 지능의 이해 정도를 질의응답을 통해서 평가한다. 기존의 비디오 질의응답과는 다르게 비디오 스토리 질의응답은 등장인물 중심으로 질의응답이 이루어지며 스토리의 계층적 이해를 고려하여야만 해결할 수 있다. 본 논문에서는 다수준 등장인물 주의집중 기법을 소개하면서 비디오 스토리 질의응답 문제를 해결하는 기법을 제안한다. 또한, 제안하는 기법의 비디오 스토리 이해 능력은 대규모 비디오 스토리 질의응답 데이터셋인 DramaQA를 사용하여 평가한다. 이를 이용하여 논문에서 제안하는 기법과 기존 연구들과의 비교실험을 통해 비디오상의 등장인물 주석을 활용하여 스토리를 다수준으로 이해하는 방법이 기존의 방법보다 비디오 스토리 질의응답에서 효과적임을 보인다.

1 서론

최근, 비디오 스토리 질의응답(Video Story QA) 데이터셋은 비디오 스토리 이해 지능을 측정하기 위한 보편적인 평가 기준으로 자리잡고 있다 [?, ?, ?]. 제안된 비디오 스토리 질의응답에서는 주어진 비디오와 부가 정보를 이용해서 오지선다의 질의응답을 해결한다. 특히, 시각 입력과 언어적 입력의 복잡한 상관관계를 학습하는 것은 물론 상당히 긴 비디오에서 질의응답을 풀기 위한 핵심 정보를 찾아야 하기 때문에 문제를 해결하기 위해 다양한 도전과제들을 수행해야하는 연구 주제라고 할 수 있다. 이러한 문제를 풀기 위해서 기존에는 기억 망을 활용한 기법[?, ?, ?], 주의 집중을 활용한 기법[?], 맥락 일치를 활용한 기법[?] 등이 제시되었다. 하지만 기존의 기법들은 등장인물에 대한 일관성을 계산모델에서 학습하지 않으며, 다수준으로 계층화되는 스토리의 구조를 효과적으로 학습할 수 없다.

본 논문에서는 다수준 등장인물 주의집중 기법을 소개하며, 기존의 비디오 스토리 이해 기법이 다루지 않았던 핵심적인 문제를 효과적으로 해결하고자 한다. 또한, 이를 검증하고자 비디오 스토리 이해 평가에 사용되는 데이터셋인 DramaQA[?]를 사용한다. DramaQA 데이터셋에서 본 논문에서 제안하는 기법과 기존 연구들과의 비교실험을 통해 비디오상의 등장인물 주석을 활용하여 스토리를 다수준으로 이해하는 방법이 기존의 방법보다 비디오 스토리 질의응답에서 효과적임을 보인다.

2 관련 연구

비디오 스토리 질의응답을 해결하기 위해 최근 다양한 방법론들이 소개되어왔는데, 대표적으로 세 가지 부류로 나누자면 기억 망을 활용한 기법[?, ?, ?], 주의 집중을 활용한 기법[?], 맥락 일치를

활용한 기법[?]이 있다.

기억 망을 활용한 기법들은 주어진 질의응답에 대한 핵심 정보를 긴 비디오의 수많은 정보들 사이에서 찾기 위해 이를 기억 망에 저장하여 활용하는 방식으로 문제를 해결한다. 주의 집중을 활용한 기법은 주의 집중을 여러 층에 걸쳐 진행함으로써 시각/언어적 핵심 정보의 표상만을 효과적으로 나타낸다. 맥락 일치를 활용한 기법들은 질의응답의 맥락과 주어진 비디오의 맥락을 세부적으로 비교함으로써 질의응답에서 높은 성능을 달성하였다. 최근 흐름은 이러한 맥락 일치와 비슷한 주의 집중 기법을 고도화한 것으로 비디오의 인물과 물체의 세부적인 정보들까지 질의응답과 비교하여 정답을 추론하는 형태의 기법들이 제안되고 있다.

3 제안 모델

3.1 맥락 임베딩 모듈

모델 입력은 질문, 5개의 정답 후보, 두 가지 입력 스트림(대본, 시각적 메타 데이터가 포함된 비디오)으로 구성된다. 각각의 정답 후보에 질문을 이어붙여 만든 QA 쌍은 $QA_i \in \mathbb{R}^{(T_Q+T_{A_i}) \times D_W}$ 로 표현한다. 대본은 $S \in \mathbb{R}^{T_{sent} \times T_{word} \times D_W}$ 로 표현한다. 행동과 감정은 단어 임베딩으로 바운딩박스 특징벡터에 이어붙인다. 시각적 메타데이터가 포함된 비디오는 $V \in \mathbb{R}^{T_{shot} \times T_{frame} \times (D_V+2 \times D_W)}$ 로 표현한다.

인물의 이름에 대한 일관성을 유지하기 위해 대본의 화자와 바운딩박스의 등장인물 이름을 사용한다. 이름 정보는 모두 원핫 벡터로 변환되고 각각 입력 스트림에 연결한다. 그런 다음 양방향 LSTM을 사용하여 입력 스트림에서 문맥적 의미를 포함시킨다. 각각의 문맥적 스트림은 $H^{QA_i} \in \mathbb{R}^{(T_Q+T_{A_i}) \times D}$, $H^S \in \mathbb{R}^{T_{sent} \times T_{word} \times D}$ 와 $H^V \in \mathbb{R}^{T_{shot} \times T_{frame} \times D}$ 으로 표현한다.




그림 1: 다수준 등장인물 주의집중 기법을 통한 비디오 스토리 이해 기법. 제안하는 기법은 저수준 및 고수준 표현을 사용하여 비디오, QA, 등장인물 간의 상관 관계를 학습한다. 답변 선택에 대한 최종 점수는 각 입력에 대한 출력 점수의 합계로 계산한다.

3.2 등장인물 중심의 다수준 표현 기법

각 중심 인물의 특성과 같은 배경지식이 있다는 가정하에 각 인물에 대한 벡터를 $\mathbf{m} \in \mathbb{R}^d$ 으로 표현한다. 각 질의와 정답 i 번째 후보 응답 쌍을 사용하여 질의응답의 인물 정보 $\mathbf{q}_i = \sum_j \mathbf{m}_j$ 를 얻는다.

이 $\mathbf{q}_i$ 를 쿼리로 사용하여, 저수준 맥락 임베딩 E_H^V 와 E_H^S 으로부터 주의집중 기법을 이용하여 등장인물 중심의 고수준 스토리 표현들을 얻는다. 각 고수준 스토리 표현은 다음과 같다.

$$E_H^V[j] = \text{softmax}(\mathbf{q}_i H^V[j]^\top) H^V[j] \quad (1)$$

$$E_H^S[j] = \text{softmax}(\mathbf{q}_i H^S[j]^\top) H^S[j] \quad (2)$$

$E_H^V[j]$ 와 $E_H^S[j]$ 는 각각 대본에서 문장수준의 임베딩과 시각적 입력에서 Shot수준의 임베딩을 표현한다. 저수준 스토리 표현을 위해서는 H^S 와 H^V 를 2-D 행렬로 바꾸면 $E_L^S \in \mathbb{R}^{(T_{\text{sent}} * T_{\text{word}}) \times D}$ 와 $E_L^V \in \mathbb{R}^{(T_{\text{shot}} * T_{\text{frame}}) \times D}$ 를 얻을 수 있다.

3.3 맥락 매칭 기법

맥락 일치 모듈은 질문과 답변을 쿼리로 사용하여 각 입력 스트림을 쿼리가 반영된 문맥으로 변환한다. 이 접근 방식은 [?]의 주의 흐름층을 참고하였다. 맥락 벡터는 각 쿼리 단어에 대한 해당 맥락 벡터의 유사점수에 기반하여 가중치 합으로 수정된다. E^S 으로부터 C^{S,QA_i} 를, E^V 으로부터 C^{V,QA_i} 를 얻는다.

3.4 정답 선택 기법

대본과 시각입력으로부터 저수준, 고수준 임베딩에 대해 E^S , C^{S,QA_i} , $E^S \odot C^{S,QA_i}$ 를 이어붙인다. 여기서 $\odot$ 은 행렬의 원소별 곱을 뜻한다. 또한, 질의응답 쌍에 대본의 화자 또는 시각적 메타데이터의 인물 이름이 나타날때 TRUE가 되는 이진 플래그 f 를 이

어붙인다. 정리하면 다음과 같다.

$$X_L^{S_i} = [E_L^S; C_L^{S,QA_i}; E_L^S \odot C_L^{S,QA_i}; f] \quad (3)$$

$$X_H^{S_i} = [E_H^S; C_H^{S,QA_i}; E_H^S \odot C_H^{S,QA_i}; f] \quad (4)$$

이와 같은 방식으로 $X_L^{V_i}$ 와 $X_H^{V_i}$ 또한 얻을 수 있다.

각 스트림 $X_L^{S_i}$, $X_H^{S_i}$, $X_L^{V_i}$, $X_H^{V_i}$ 에 대해 다양한 커널 크기로 1차원 합성곱 필터를 적용하고 각 필터로부터 나온 결과를 연결한다. 모든 시간에 대해 max-pool과 선형 레이어를 적용하여 i 번째 정답 후보에 대한 스칼라 점수를 계산한다. 최종 점수는 네 가지 다른 스트림 점수의 단순 합계이며, 모델은 최종 점수가 가장 큰 정답 후보를 정답으로 선택한다.

4 실험 결과

표 1은 제안하는 모델에 대한 정량적 결과를 보여준다. 제안하는 모델의 다수준 표현이 효과적인지 확인하기 위해 전체 모델 Our (Full)의 성능을 저수준 스토리 표현을 제외한 모델 Our-Low, 고수준 스토리 표현 모듈을 제외한 모델 Our-High와 비교하였다. 이러한 실험 결과는 고수준 표현 모듈이 어려운 질문을 처리하는 데 도움이 되는 반면 저수준 표현 모듈은 쉬운 질문을 처리하는 데 유용하다는 것을 보여준다. 그림 2에서는 제안하는 모델의 올바른 예측 사례와 비교하는 모델의 추론 결과를 보여준다. 모델에서 고수준의 스토리 표현이 없으면 모델은 스토리를 완전히 이해할 수 없으며 낮은 수준의 세부 사항에 집중하는 것을 보여준다.

또한, 제안하는 모델과 기존에 제안되었던 모델의 비교성능을 표 1에 나타내었다. MemN2N[?]과 TVQA[?]는 해당 논문에서 제안되었던 비디오 스토리 질의응답 모델이며 $+\alpha$ 는 제안되었던 모델을 DramaQA 데이터셋에서 제공하는 주석을 활용하도록 변경한 것이다. DramaQA 데이터셋에서는 비디오에 대한 다양한 등장인물 중

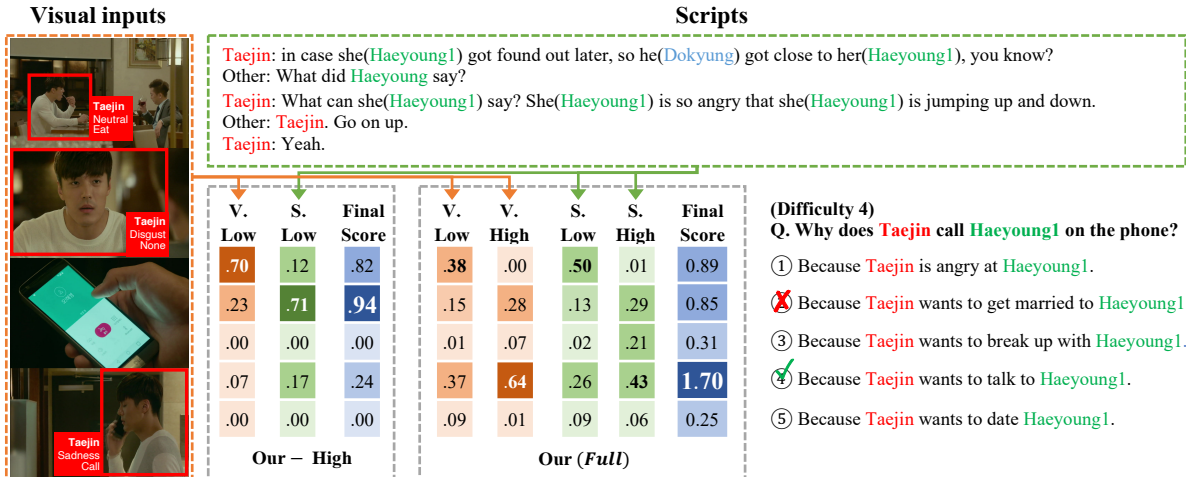


그림 2: 제안하는 모델의 올바른 예측 사례. 다중 수준 표현의 효과를 보기 위해 Our (Full) 및 Our-High의 결과를 함께 나타내었다. 시각 입력에 대한 점수는 주황색으로, 대본 입력에 대한 점수는 녹색으로, 최종 점수는 파란색으로 표기하였다. Our (Full)에 대한 예측 결과는 정답인 녹색 체크마크(✓)로, Our-High에 대한 예측 결과는 빨간색 십자마크(X)로 표시하였다.

Model	Diff. 1	Diff. 2	Diff. 3	Diff. 4	Overall
MemN2N [?]	59.82	52.64	41.56	38.63	53.37
MemN2N+ α	64.39	58.15	44.74	42.79	57.96
TVQA [?]	66.05	61.78	53.79	53.55	62.06
TVQA+ α	74.80	72.57	53.30	55.75	69.45
Our-High	75.68	72.53	54.52	55.66	70.03
Our-Low	74.49	72.37	55.26	56.89	69.60
Our (Full)	75.96	74.65	57.36	56.63	71.14

표 1: DramaQA 테스트셋에 대한 정량적 실험 결과. Our(Full)은 제안하는 모델의 모든 요소가 포함되어 있으며, Our-High와 Our-Low는 각각 Our(Full)로부터 고수준과 저수준 표현 스트림을 제거하였다.

심의를 주석을 제공하므로 공평한 비교를 위해 변경하였다. 표 1와 같이 제안하는 모델의 성능이 주어진 테스트셋에 대해 더욱 효과적으로 질의응답을 해결한다.

5 결론

본 논문에서는 비디오 스토리 질의응답 문제를 효과적으로 해결하는 다수준 등장인물 주의집중 기법을 제안하였다. 제안하는 기법은 비디오상의 등장인물 주석을 활용하여 스토리를 다수준으로 이해하는 방법이다. DramaQA 테스트셋에 대한 성능 비교를 통하여 제안하는 기법이 기존의 방법보다 비디오 스토리를 효과적으로 이해했음을 검증하였다.

사사

이 논문은 2021년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원(2015-0-00310-SW,StarLab/25%, 2017-

0-01772-VTT/25%, 2018-0-00622-RMI/25%, 2019-0-01371-BabyMind/25%)의 지원을 받았다.

참고 문헌

- [1] M. Tapaswi, Y. Zhu, R. Stiefelhausen, A. Torralba, R. Urtasun, and S. Fidler, "MovieQA: Understanding Stories in Movies through Question-Answering," 2015.
- [2] J. Lei, L. Yu, M. Bansal, and T. L. Berg, "Tvqa: Localized, compositional video question answering," in *EMNLP*, 2018.
- [3] S. Choi, K.-W. On, Y.-J. Heo, A. Seo, Y. Jang, M. Lee, and B.-T. Zhang, "Dramaqa: Character-centered video story understanding with hierarchical qa," 2020.
- [4] S. Na, S. Lee, J. Kim, and G. Kim, "A read-write memory network for movie story understanding," in *The IEEE International Conference on Computer Vision (ICCV)*, Oct 2017.
- [5] K. M. Kim, M. O. Heo, S. H. Choi, and B. T. Zhang, "Deepstory: Video story QA by deep embedded memory networks," *IJCAI International Joint Conference on Artificial Intelligence*, pp. 2016–2022, 2017.
- [6] K. Kim, S. Choi, J. Kim, and B. Zhang, "Multimodal dual attention memory for video story question answering," in *Computer Vision - ECCV 2018 - 15th European Conference, Munich, Germany, September 8-14, 2018, Proceedings, Part XV* (V. Ferrari, M. Hebert, C. Sminchisescu, and Y. Weiss, eds.), vol. 11219 of *Lecture Notes in Computer Science*, pp. 698–713, Springer, 2018.