

Oligonucleotide Microarray의 Probe 선택을 위한 진화적인 접근 방법

An Evolutionary Approach for Probe Selection of Oligonucleotide Microarrays

김 선

서울대학교 컴퓨터공학부 바이오지능연구실
skim@bi.snu.ac.kr

장 병 탁

서울대학교 컴퓨터공학부 바이오지능연구실
btzhang@bi.snu.ac.kr

Abstract

Oligonucleotide DNA microarray는 유전자 분석등을 위한 대표적인 방법으로 생물정보학 분야에서 널리 사용되고 있는 도구이다. DNA Microarray를 사용하는 대표적인 예는 알려진 유전자 도메인을 바탕으로 내용을 알지 못하는 DNA 서열을 분석하는 것이다. 이를 위해 간단하게는 알려진 유전자의 모든 서열을 DNA Microarray 위에 올려놓은 후, 서열을 알고자 하는 DNA를 대상으로 실험하는 방법을 생각할 수 있다. 그러나 이러한 방법은 실험 결과의 정확도 및 Microarray의 제작비용 등을 고려해 볼 때 상당히 비효율적인 방법이다. 따라서 일반적으로는 알려진 유전자 도메인을 기준으로 인식하고자 하는 목표 유전자를 정한 후, 서열의 일부분을 선택해 DNA Microarray를 제작하는 probe 선택 과정을 거친다. 그러나 Microarray 분석과정에 영향을 미치는 복합적인 요소들로 인해 현재까지 probe를 선택하는 결정적인 방법이 존재하고 있지 않다. 이에 본 논문에서는 DNA 서열 분석을 위한 probe 선택 문제에 있어서 진화연산을 이용한 접근 방법을 연구한다. 제시된 방법은 가능한 probe 집합들로 이루어진 해집합을 구성한 후, 진화 과정을 통해 목표 유전자와 결합되는 probe 집합을 선택하게 된다. 본 논문에서는 GenBank로부터 얻은 일련의 유전자를 대상으로 제시된 방법을 실험하였으며 그 결과를 분석하였다.

1. 서 론

DNA microarray는 분자생물학 및 DNA 컴퓨팅 분야에서 널리 사용되고 있는 실험 분석 도구이다. 근래의 생물정보학 연구에서 적지 않은 부분이 유전자 분석을 통해 도움을 받고 있고 이를 통해 이전에 설명되지 못했던 많은 유전 조직들을 인식할 수 있게 되었다. 그리고 이런 유전자를 이용하는 문제 중 하나가 DNA microarray를 사용해 알려지지 않은 DNA 서열을 인식하는 것이다[1, 2]. DNA microarray는 DNA 칩이라고도 하며, 일련의 DNA 조각들로 이루어져 있는 점(spot)들이 유리 표면 위에 놓여진 형태를 가진다. 여기에서 일련의 DNA 조각들을 probe라고 하며, 이 probe와 유전자의 결합, 즉 hybridization 과정을 통해 유전자 발현 정보 또는 DNA의 유전적인 다형성 등을 알아낼 수 있다. DNA microarray는 크게 다음과 같은 두 가지 형식의 칩으로 나뉘어진다. 하나는 cDNA 칩이며, 다른 하나는 oligonucleotide 칩인데 둘 사이의 가장 큰 차이점은 cDNA 칩은 제작자가 probe의 DNA 서열을 임의대로 디자인 할 수 없는데 반해, oligonucleotide 칩은 제작자가 목적에 따라 probe의 서열을 디자인 할 수 있다는 점이다. 따라서 oligonucleotide 칩의 경우 각 유전자 서열에서 다른 유전자들과 중복되거나 유사한 서열이 있을 경우 이를 피해 일련의 DNA 서열을 선택할 수 있다는 장점을 가진다.

본 논문에서는 DNA microarray 중 oligonucleotide 방법에 의해 만들어지는 칩을 다루고자 하며, 특정 유전자를 인식하기 위한 oligonucleotide microarray를 제작하는 데 있어서 이에 적합한 probe 서열을 선택하는 문제를 적용하고자 한다. DNA microarray를 구성하는 일련의 점들은 각기 다른 서열을 갖는 probe들로 구성되며, 각 probe는 특정 유전자와의 결합을 목적으로 디자인된다. 여기에서 목표가 되는 유전자는 clone library로 구성된 후 제작된 DNA microarray와의 hybridization 과정을 통해 분류되게 된다. 그러나 DNA microarray의 제작 과정에 있어서 영향을 미치는 물리, 화학적인 복합 요소들로 인해 현재까지 probe를 선택하는 결정적인 방법은 존재하고 있지 않다는 데 문제가 있다. 한편, DNA microarray상에 존재하는 probe의 개수는 곧 hybridization 횟수와 관계가 있고 이는 실험 결과의 정확도 및 microarray의 제작 비용 문제와 연결된다는 것을 알 수 있다. 따라서 유전자 서열 분석에 있어서 최적의 probe 집합은 목표로 하는 유전자들을 모두 분석하면서 가능한 최소의 probe 개수로 구성되도록 해야 한다고 추정할 수 있다.

이에 본 논문은 probe 선택을 위한 결정적인 방법이 존재하지 않는 상태에서 진화 연산을 이용한 접근 방법을 연구하고자 한다. probe 선택을 위한 문제는 다음과 같이 크게 두 가지로 나누어 볼 수 있는데, 한가지는 인식하고자 하는 목표 유전자 각각에 대한 probe를 별도로 두는 것으로써 이 경우 목표 유전자의 개수와 DNA microarray 상의 점(spot)의 개수는 일치하게 된다. 다른 문제는 같은 목표 유전자에 대해 가능한 최소의 probe 개수로 이를 구별하여 인식할 수 있는 DNA microarray를 구성하는 것이다.

본 논문에서는 일정한 probe 개수로 구성되는 DNA microarray에서 목표 유전자를 모두 인식하는 probe 집합을 찾기 위한 알고리즘을 제시하며, 이 알고리즘은 목표 유전자의 개수보다 적은 probe 수를 입력하게 함으로써 가능할 경우 보다 적은 개수로 구성된 probe 집합을 찾도록 해준다. 제시된 방법은 목표 유전자의 일부 서열을 임의로 선택한 일련의 probe들로 해집합을 구성하며 유전적인 진화 연산과정을 통해 목표 유전자를 인식하는 probe 집합을 찾으려고 시도한다.

2장에서는 관련 연구를 설명하며, 3장은 본 논문에서의 probe 선택을 하기 위한 문제를 정의한다. 4장은 진화연산 기법 중 유전 알고리즘을 이용한 probe 선택 방법에 대해 서술하고, 5장에서는 GenBank로부터 얻어진 HPV 유전자 데이터를 바탕으로 한 실험 및 결과를 분석한다.

2. 관련 연구

DNA microarray에서의 probe 디자인 문제는 DNA microarray 제작 및 실험 결과와 관련해된 가장 중요한 문제 중 하나이다. 따라서 그 중요성에 따라 microarray 제작과 관련된 여러 소프트웨어들이 probe를 디자인하는 기능을 제공한다. 그렇지만 상용 소프트웨어의 경우 probe 선택을 위한 구체적인 방법을 알기 힘들며, 학문적인 연구의 경우 그 중요성에 비해 상대적으로 많은 결과가 나와 있지 않은 상태이다.

일반적으로 probe 선택을 위해 사용되는 방법은 인식하고자 하는 목표 유전자를 선택하고, DNA microarray에 심고자 하는 probe의 길이를 선택하는 것으로부터 시작된다. 먼저 초기 후보 probe 집합은 목표 유전자 서열을 probe의 길이에 따라 sliding window방식으로 뽑아내어 구성된다. 그리고 이렇게 선택된 probe 집합 중에서 목표가 아닌 유전자와의 결합(cross hybridization)이 일어날 가능성 있는 후보들은 제외된다. 마지막으로 실험에 영향을 주는 melting temperature, 2차원 DNA 구조 등을 고려해 목표 유전자와의 hybridization이 가장 잘 일어날 가능성이 있는 probe를 최종적으로 선택하게 된다[3, 4].

Drmanac et al.은 rDNA clone들의 서열 정보를 기반으로 한 빈도 수를 바탕으로 probe를 선택하는 방법을 제시하였다[5]. 그러나, rDNA는 서로 중복된 영역이 많이 존재하기 때문에 빈도 수를 이용한 probe 선택 방법에는 한계가 존재하게 된다. Herwig et al.은 probe 선택을 최적화

문제로 보고 정보 이론에서의 엔트로피 최대화 문제를 이용한 probe 선택 기법을 제시하였다[6]. 여기에서 probe는 DNA 서열에 대해 클러스터링이 잘되는 방향으로 진행되도록 선택되며, 이를 위해 엔트로피가 최대가 되도록 하는 probe를 선택하도록 하였다. Li. et al.은 free energy 및 melting temperature를 기준으로 한 probe 선택 기법을 제시하였다[7, 8]. 이 방법은 한 유전자에 대한 최적의 probe 서열은 그 유전자에 대해서는 hybridization free energy가 최소가 되면서 다른 유전자들에 대해서는 최대가 되도록 구성 될 것이라는 것에 착안하고 있다.

Bourneman et al.은 probe 선택 문제를 두 가지 유형으로 나누어 각 문제를 해결하고자 하였다[9]. 첫째는 probe의 개수를 고정한 상태에서 가능한 많은 clone들을 구분할 수 있도록 하는 probe 집합을 선택하는 문제이며, 이를 위해 simulated annealing을 이용한 방법을 제시하였다. 둘째 문제는 고정된 clone에 대해서 이를 구분할 수 있는 최소한의 개수로 구성되는 probe 집합을 찾는 것으로써, Lagrangian relaxation을 이용한 동적 프로그램 방법을 제안하였다. Probe 선택과 관련된 가장 최근의 결과로는 Tobler et al.이 기계학습 기법을 적용한 연구가 있다[10]. 여기에서는 후보 probe 중, 목표 유전자와 가장 잘 결합하는 최적의 probe를 학습 및 예측과정을 통해 풀고자 하였다. 해당 연구에서는 몇 가지 probe 서열에 대한 기존 실험 결과를 바탕으로 naive Bayes, 인공신경망, 결정 트리 등의 기계학습 기법을 이용, 학습을 하였으며, 후보 probe가 입력으로 들어왔을 때의 hybridization 결과를 예측함으로써 적절한 probe를 찾는 방법을 제시하고 있다.

3. 문제 정의

이 장에서는 본 논문에서 연구하고자 하는 probe 선택 문제를 풀기 위해 oligonucleotide fingerprinting 문제를 정의하고자 한다. 먼저 간단하게 DNA microarray에서 probe와 목표 유전자와의 hybridization을 설명하면 다음과 같다. DNA는 A, G, C, T의 염기로 구성이 되며, A와 T, G와 C는 서로 상보적인 관계로써 결합이 이루어지고 다른 조합의 결합은 존재하지 않는다. 따라서 만약 <그림 1>과 같은 서열의 유전자 ①, ②, ③이 있고, 이 중 유전자 ①만을 인식하는 길이 5의 probe를 선택한다고 할 경우, <그림 2>의 DNA 서열을 갖는 microarray를 제작하면 될 것이다.

① AGCTGCC
② TAGCTAA
③ AATTTTA

<그림 1> 유전자 서열 예

유전자① ⇒ AGCTGCC
probe ⇒ TCGAC

<그림 2> 유전자 및 probe 예

여기에서 유전자 ①과 probe는 서로 상보적인 관계를 가지기 때문에 결합이 일어나지만, 유전자 ②와 ③은 서로 상보적인 관계가 아니기 때문에 결합이 일어나지 않는다. 따라서 위의 probe 서열로 제작된 DNA microarray에서 유전자 ①과의 hybridization이 일어난다면, 형광 발현 결과 (fluorescence response)의 정도가 클 것이며 따라서 인식하고자 하는 DNA 서열이 유전자 ①이라는 것을 알 수 있게 된다.

이를 일반화 시켜서 생각해 보면 다음 내용으로 정리할 수 있다. DNA microarray에서의

hybridization 과정을 통한 형광 발현 결과는 clone 안에서 probe가 발생되는 빈도 수에 비례한다고 가정할 수 있다. 즉, clone 안에서 한 probe에 해당하는 시퀀스가 많이 존재할 때와, 적게 존재할 때의 형광 발현 정도는 달라지게 된다. 예를 들어, <그림 3>과 같은 두 개의 clone c_1 , c_2 가 있다고 하자[9].

$$c_1 = \text{AAACCTGA}$$

$$c_2 = \text{AAACATAAA}$$

<그림 3> clone c_1 , c_2

이 경우 clone 서열에서의 probe 서열 발생 빈도 수를 가지고 형광 발현 정도를 생각해 볼 수 있으며, 이는 r 단계로 나눌 수 있다. 만약 $r = 1$, probe $p = \text{CCT}$ 라면, probe 서열은 c_1 서열 안에 한번 나타나는데 반해 c_2 에는 나타나지 않으므로 이 때 probe p 에 의해 clone c_1 과 c_2 는 구별 가능하다고 말할 수 있다. 이번에는 위 clone에서 probe $p = \text{AAA}$ 인 경우를 생각해 보자. $r = 1$ 일 때는 c_1 과 c_2 를 구별할 수 없지만, 형광 발현 단계(r)를 2로 했을 경우에는 c_1 과 c_2 는 구별 가능하게 된다는 것을 알 수 있다. 왜냐하면 서열 AAA가 c_1 에서는 한번 나타나지만, c_2 에는 두 번 나타남으로 인해 hybridization 결과, 형광 발현 정도가 달라지기 때문이다.

위에 설명한 hybridization 과정을 Borneman et al.에 나와 있는 fingerprint 문제로 정의하면 다음과 같다[9].

clone 집합 $C = \{c_1, c_2, \dots, c_m\}$

probe 집합 $P = \{p_1, p_2, \dots, p_n\}$

이 때, clone c_i 에 대한 hybridization 결과는 probe p_j ($j=1, \dots, n$)에 대한 형광 발현 결과 값으로 구성되는 벡터로 표현할 수 있고, 이를 clone c_i 의 fingerprint, 즉, $\text{fingerprint}(c_i)$ 라고 한다. 그리고 clone c_1 , c_2 에 대한 fingerprint 값이 만약 $\text{fingerprint}(c_1) \neq \text{fingerprint}(c_2)$ 라면, c_1 과 c_2 는 주어진 probe 집합에 의해 구별 가능하다고 말한다. 정리하면 probe 선택 문제는 유전자 서열로 구성되어 있는 clone 들을 대상으로 형광 발현 단계 r 에 대해 fingerprint 값을 서로 다르게 하는 DNA 서열 조각 집합, 즉, probe 집합을 찾는 문제로 정의할 수 있다. 한편 본 논문에서는 형광 발현 단계에 대해서는 $r=1$ 인 경우에 대해서만 실험에 적용하였다.

지금까지 설명한 clone 및 probe의 서열의 일치만을 고려한 hybridization 결과 예측은 실험실 환경에서 얻는 결과와는 일치하지 않는다. Hybridization 과정에서 두 DNA 서열이 서로 일치하는 부분을 가지고 있다는 것만으로 단순히 서로 결합하지는 않기 때문이다. 뿐만 아니라 hybridization 자체가 화학적인 반응이기 때문에 실험 조건도 결과에 많은 영향을 끼치게 된다. 그리고 이것은 현재 probe 선택에 대한 결정적인 방법이 존재하지 않는 원인이기도 하다. 따라서 본 논문에서는 실험의 단순화를 위해 DNA 서열 사이의 화학적인 연관성 및 실제 실험 환경을 배제한, 즉 DNA 서열에 따른 결합만을 생각하는 이상적인 hybridization만을 가정하도록 한다. 그러나 여기에서 제안하는 probe 선택방법은 진화연산을 통해 최적해를 얻는 방법으로써 목적함수의 변경에 의해 진화의 방향을 설정할 수 있기 때문에 경우에 따라서 다른 실험 조건을 고려하는 경우로 확장할 수 있다.

4. Probe 선택 알고리즘


본 논문에서는 3장에서 설명한 서열기반의 hybridization 문제를 바탕으로 진화연산 기법을 이용한 probe 선택문제를 다루며, 이를 위해 진화연산의 대표적인 방법에 해당하는 유전 알고리즘을

이용한다. 유전 알고리즘은 자연계의 진화 원리를 응용한 것으로써 결정적인 풀이방법이 존재하지 않는 문제들에 대해 좋은 성능을 보여주는 확률적인 탐색 기법이다[11, 12].

유전 알고리즘에서 한 문제에 대한 가능한 해(solution)는 염색체로써 표현되며, 해집합은 이러한 염색체들의 집합으로 이루어진다. 초기 해집합은 임의로 선택된 염색체들로 구성되며, 매 세대마다 이전 세대를 이루고 있는 해 중에서 우수한 품질을 가진 염색체들을 이용, 새로운 염색체를 생성한다. 여기에서 다음 세대를 구성하기 위해서 선택되는 염색체를 부모해(parents)라고 하며, 이를 바탕으로 생성되는 새로운 염색체를 자식해(offspring)라고 한다. 한 세대를 이루는 염색체들의 품질을 평가하는 기준은 적합도 함수(fitness function)에 의해 결정되고, 부모해는 각 개체들의 품질에 비례해 임의로 선택되게 된다. 세대간의 진화를 위해 사용되는 연산으로는 선택(selection), 교차(crossover), 및 변이(mutation) 등이 있으며, 이렇게 생성된 자식 해들은 이전 세대의 해 집단 중에서 적합도가 낮은 반질의 염색체 일부와 대체된다. 유전 알고리즘은 언뜻 보기에는 임의의 해를 생성하기 때문에 어떤 방향이 없이 해를 찾아가는 것처럼 보이지만, 성능을 개선하는 방향으로 탐색 위치를 옮기기 위해 현재까지의 진화 정보를 효율적으로 이용하는 기법이다. 다음에 설명하는 것은 probe 선택에 있어서 본 논문에서 사용한 각 개체의 표현 방법 및 유전적인 연산자에 관한 설명이다.

4.1 개체 표현

유전 알고리즘에 있어서 하나의 염색체는 가능한 해를 나타내며, probe 선택 문제에 있어서는 하나의 가능한 probe 집합을 의미한다. 본 논문에서 probe는 DNA의 상보적인 결합 특징에 의해 목표 유전자들이 구별되므로, 각 probe 서열은 목표 유전자의 서열 일부 중에서 선택되도록 한다. 따라서 해집합의 각 개체는 하나의 DNA microarray를 구성하는 probe 서열들의 집합이며, 각 probe의 DNA 서열이 어떤 목표 유전자의 어느 위치에서 추출한 서열인지를 알려주는 정보를 포함하기만 하면 된다. 본 논문에서 사용한 각 개체의 표현 방법을 그림으로 나타내면 다음과 같다(<그림 4>).



<그림 4> 개체 표현 방법

<그림 4>는 목표 유전자(gene id)와 서열 시작위치(start position)로 구성되는 probe들의 정보로 구성되는 개체를 이차원 구조로 나타낸 것이다. 여기에서 한 개의 개체, 즉 probe는 고정된 길이 c 를 가지고 있으며, n 개의 probe로 구성된다. 따라서 그림에서 첫째 probe의 DNA 서열은 13번 목표 유전자의 3번째부터 시작되어 길이 c 만큼의 범위에 해당하는 서열을 의미하게 된다.

4.2 적합도


적합도(fitness)는 각 개체의 품질, 즉 우열 정도를 나타내며 본 논문에서는 적합도를 판단하는 기준으로 fingerprint 결과를 이용한다. 어떤 probe 집합(개체)과 목표 유전자들에 대한 clone 사이의 hybridization 결과는 각 조합에 따라 $clone(C) \times probe(P)$ 형태를 가지는 행렬로 나타낼 수 있다. $C \times P$ 행렬에 있어서 열을 기준으로 뽑은 벡터 값을 이용하면, probe집합이 각 clone을 얼마나 잘 구별할 수 있는지 알 수 있으며, 자세한 내용은 3장에서 이미 설명하였다. 따라서 probe 선택

문제가 궁극적으로 목적하는 바는 목표 유전자를 구별하는 것이기 때문에, 적합도는 probe 집합에 대한 목표 유전자의 구별 가능 정보를 비율로 나타낸 값으로 정의할 수 있다. 예를 들어, 하나의 probe 집합 P 에 대해 각 probe의 fingerprint값이 모두 상이하면, 주어진 목표 유전자를 모두 구별할 수 있다는 것을 의미하고, 이때 개체의 적합도는 1이 된다. 반면, 목표 유전자 서열을 전혀 구별할 수 없다면 적합도는 0이 된다.

4.3 유전 연산자

각 세대에 있어서 진화를 위해 사용되는 연산자는 선택, 교차, 변이 등이 있으며, 각 유전 연산자를 위해 사용한 방법은 다음과 같다.

부모해를 선택하기 위해 사용한 연산은 roulette wheel 방법으로써 각 개체는 그 적합도 값에 비례해 부모해로 선택될 확률이 결정된다. 즉, 적합도 값이 높은 개체는 부모해로 선택될 확률이 높고, 그렇지 않은 개체는 그만큼 부모해로 선택될 확률이 작아지게 된다. 교차 및 변이 연산자는 부모해로부터 자식해를 생성하기 위해 수행하는 방법이다. 교차 연산자는 일반적으로 임의의 교차 지점을 생성한 후, 이를 기준으로 부모해의 교차를 통해 새로운 자식해를 생성하는 과정이며, 변이 연산자는 이렇게 생성한 자식해의 일부 정보를 교체함으로써 해 공간에서 새로운 탐색 위치를 찾는데 도움을 준다.



<그림 5> 교차 연산

본 논문에서 모든 해는 항상 일정 길이 n 의 probe로 구성되며, 따라서 부모해의 cut point는 항상 동일해야 한다. 교차 연산은 cut point를 한 개로 잡는 one-point 교차로 수행되며, <그림 5>에 나타난 것과 같이 자식해는 cut point를 기준으로 부모해를 교차하는 방법에 의해 생성된다.

변이연산은 교차연산에 의한 자식 해 생성 후 이루어지며, 그 목적은 해집합이 해 공간의 한 방향을 향해서만 진화를 함으로써 지역해에 수렴하는 것을 방지하고 해의 다양성을 유지시키는 데 있다. 변이는 임의의 개체를 선택한 후, 개체 중 임의의 probe를 선택해 그 정보를 바꾸는 방법에 의해 수행되며, 한 probe 정보에 해당하는 목표 유전자 id, probe 서열 시작 위치가 모두 임의의 값으로 변경된다.

5. 실험 및 결과


실험을 위해 사용한 데이터는 자궁경부암을 일으키는 바이러스로 알려져 있는 HPV 서열을 GenBank로부터 검색하였으며, DNA microarray를 통해 인식하고자 하는 목표 서열은 HPV 중 감염 위험 정도가 크다고 판단되는 16개 HPV를 대상으로 선정하였다. DNA microarray의 hybridization에서의 형광 발현단계는 본문에서 밝힌 것과 같이 $r=1$ 인 경우로 한정했다. 실험에 사용된 기본 파라미터 값은 다음과 같다.

- 해집합을 구성하는 개체 수 : 100

- 한 probe의 서열 길이 : 20
- 교차 연산 비율 : 0.3
- 변이 연산 비율 : 0.2

한 개체의 probe 개수는 구별하고자 하는 서열 개수인 16부터 시작해 probe 개수를 줄여가면서 적합도 값이 1인 probe 집합을 찾을 수 있는지 실험하였다.

다음 <그림 6>은 한 개체의 probe 수가 16인 경우에 대한 실험 결과를 나타낸 것이다. 각 세대에 따른 해집합의 평균 적합도 값 변화를 나타낸 것으로써 자식해를 생성하여 새로운 세대를 만들어 감에 따라서 평균 적합도가 증가하는 것을 볼 수 있다. 이는 유전 알고리즘에 의한 probe 선택에 있어서 세대가 진행됨에 따라 목표 유전자를 모두 구별할 수 있는 방향으로 진화가 이루어지고 있음을 나타내는 것이다. 세대는 목표 유전자를 모두 구별할 수 있는 서열을 처음으로 찾을 수 있을 때까지 진행하도록 하였으며, 여기에서 처음으로 발견된 probe 집합을 최적해로 간주하였다. 16개의 probe 집합을 찾는 실험에 있어서는 평균 28세대를 진행한 후에 최적해를 찾을 수 있었다.



<그림 6> 평균 적합도 변화

한편, probe 집합을 이루는 probe의 개수는 실험 비용 문제와 관련이 있으며, 같은 크기의 목표 유전자를 구별하는 경우 보다 작은 probe들로 구성되는 DNA microarray의 비용이 그렇지 않은 경우보다 적게 들게 된다. 따라서 한 개체의 probe 개수를 줄여가면서 최적해를 찾을 수 있는지 여부를 실험에 보았으며, 12~16개로 구성되는 probe 집합에 대해 모두 최적해를 찾을 수 있었다. 그러나 11개 이하로 구성되는 probe 집합에 대해서는 최적해를 발견할 수 없었다.

<표 1>은 한 개체를 구성하는 probe 개수에 대한 최적해를 평균 몇 세대에 찾을 수 있었는지 테이블로 나타낸 것이다. 사용해야 하는 probe의 개수가 줄어들면 그만큼 제한된 개수로 같은 크기의 목표 유전자를 구별해야 하기 때문에 더 많은 세대가 진행된 후에야 최적해를 발견하게 된다.

	12	13	14	15	16
평균 최적해 발견 세대	175	140	110	37	28

<표 1> Probe 개수에 따른 평균 최적해 생성 시기

6. 결론 및 향후과제

본 논문은 oligonucleotide microarray에서 주어진 목표 유전자 서열을 구별하는 probe 집합을 찾기 위해 진화연산을 통한 접근 방법을 연구해 보았다. 그리고 DNA probe 선택을 위한 결정적인 방법이 존재하지 않는 상황에서 해공간 상의 최적해를 찾아가는 데 진화연산 기법은 효율적으

로 적용될 수 있음을 보여주었다. 실험은 감염시 위험정도가 높은 HPV 서열을 GenBank로부터 검색해 수행하였으며, 20개의 DNA 서열로 구성되는 probe에 대해 12개로 구성된 probe 집합까지 최적해를 찾을 수 있었다.

한편 형광 발현 단계(r)를 다양화했을 경우에 대한 실험 결과를 분석해 볼 필요가 있으며, 본 문제에서 가정한 형광 발현 단계에 대해 실제 실험 결과와의 비교를 통한 현실화 가능성도 검토해 봐야 할 사항이다. 향후 과제로는 서열만을 기준으로 한 본 논문의 probe 선택 방법에 덧붙여, 실제 실험에서 많이 사용되고 있는 probe 선택 방법 중 하나인 melting temperature(T_m), cross hybridization 등을 세대 진화에 고려하는 것 등이 연구되어야 할 것이다.

감사의 글

본 연구는 교육부 BK21-IT 사업, 국가지정연구실(NRL) 사업 및 산업자원부 차세대신기술사업에 의하여 일부 지원되었음.

7. 참고 문헌

- [1] Pace, N. R., (1997). A Molecular View of Microbial Diversity and the Biosphere, *Science*, 276, pp. 734-740.
- [2] Simon, N., et al., (2000). Oligonucleotide Probes for the Identification of Three Algal Groups by Dot Blot and Fluorescent Whole-Cell Hybridization, *The Journal of Eukaryotic Microbiology*, 47(1), pp. 76-84.
- [3] <http://www.olympus.co.jp/Special/specialE.html>
- [4] Tolstrup, N., et al., (2002). Optimal Design of Oligos for Micro Array Gene Expression Profiling, *The 10th International Conference on Intelligent Systems for Molecular Biology*, Poster.
- [5] Drmanac, S., et al., (1996). Gene Representing cDNA clusters defined by hybridization of 57,419 Clones from Infant Brain Libraries with Short Oligonucleotide Probes, *Genomics*, 37, pp. 29-40.
- [6] Herwig, R., et al., (2000). Information Theoretical Probe Selection for Hybridisation Experiments, *Bioinformatics*, 10, pp. 890-898.
- [7] Li, F. and Stormo, G. D., (2000). Selecting Optimum DNA Oligos for Microarrays, *Proceedings of the IEEE International Symposium on Bio-Informatics and Biomedical Engineering*, pp. 200-207.
- [8] Li, F. and Stormo, G. D., (2001). Selection of Optimal DNA Oligos for Gene Expression Arrays, *Bioinformatics*, 17, pp. 1067-1076.
- [9] Borneman, J., et al., (2001). Probe Selection Algorithms with Applications in the Analysis of Microbial Communities, *Proceedings of the 9th International Conference on Intelligent Systems for Molecular Biology*, pp. 39-48.
- [10] Tobler, J. B., et al., (2002). Evaluating Machine Learning Approaches for Aiding Probe Selection for Gene-Expression Arrays, *Proceedings of the 10th International Conference on Intelligent Systems for Molecular Biology*, pp. 164-171.
- [11] Back, T., (1996). *Evolutionary Algorithms in Theory and Practice*, Oxford University Press, 1996.
- [12] Holland, J., (1975). *Adaptation in Natural and Artificial Systems*, University of Michigan Press.