

은닉마코프 모델을 이용한 정보추출

엄재홍, 장병탁
서울대학교 컴퓨터공학부
서울시 관악구 신림동 산56-1
Tel: (02)880-{1835, 1833}
Email: {jheom, btzhang}@scail.snu.ac.kr

Information Extraction Using Hidden Markov Models

Jae-Hong Eom, Byoung-Tak Zhang
School of Computer Science and Engineering, Seoul National University

요 약

최근 들어 컴퓨터와 인터넷의 보급으로 인해 제공되는 정보의 양이 지수적으로 증가하고 있다. 이에 따라서, 단순한 정보검색의 범위를 넘어선 문헌정보 추출이나 문서자동 요약, 또는 대상 문서에서 특정한 정보만을 추출하는 기술에 대한 필요성이 늘어나고 있다. 이에 본 논문에서는 모델의 상태 수 조정이 가능한 은닉마코프모델(Hidden Markov Model)을 이용하여 특정 도메인에 대한 정보추출을 수행하는 방법을 제안한다. 필드 정보를 이용하여 구성된 모델의 상태를 이후 상태간의 거리측정을 이용하여 병합하는 방법으로 전체 모델의 상태 수를 줄일 수 있도록 하였다. 논문에서는 생물학 관련 학회와 컴퓨터과학 관련 학회에서 제공되는 논문제출 요청 안내문서인 CFP(Call For Papers or Participation)문서로 구성된 데이터에서 은닉마코프모델을 사용하여 학회의 이름, 개최일자, 개최장소, 학회관련 참고 웹사이트 URL, 논문제출 마감일자, 학회 연락처(phone, fax, e-mail)와 같은 필드들을 학습한 후 추출을 수행하도록 하였다. 실험결과 모델의 상태를 고정하는 방법보다 추출 정확도를 향상시켰으며 때 약 10%의 속도 향상을 얻을 수 있었다.

ABSTRACT

Recently, due to the popularity of computers and the Internet, the amount of information provided to users has been increased exponentially. This implies that information technology needs to go beyond dealing with simple information retrieval. In other words, information technology must be able to support more advanced information processing techniques, such as information extraction and automatic document summarization. In this paper, we propose a flexible-state HMM based information extraction method for the specific domain. We reduced the number of model states by merging two states according to the inter state distance. Here, we used CFP (Call For Papers or Participation) documents of computer science and biology conferences as a dataset. The proposed HMMs learn to distinguish the fields, and then extract conference names, dates and locations, conference URLs, deadlines for paper submission and contact information (phone, fax, e-mail) from the CFP text. The result shows improved average extraction accuracy with 10% increase in average extraction speed compared with fixed-state HMMs.

키워드: 정보추출, 은닉마코프모델(HMMs), 비터비알고리즘, EM 알고리즘

1. 서론

최근 인터넷이 발달함에 따라 많은 양의 정보들에 대한 온라인 접근이 그 어느 때보다도 쉬워지고 있으며, 신문이나 잡지 학술논문 등의 각종 정보들이 디지털화되어 온라인상 문서의 형태로 존재하게 되었다. 이러한 정보의 증가로 인한 정보 과부하(information overload)는 사용자들로 하여금 모든 정보를 소화하기 힘들게 만들고 있다[7]. 이에 정보검색이라는 분야가 온라인 문서의 증가와 함께 활발히 발전되어 사용자들이 인터넷 상에서 필요한 문서를 찾는 데 많은 도움을 주고 있다. 또한 많은 수의 문서를 접근하는데에서 오는 어려움을 덜기 위하여 사용자들의 관심도를 학습해 사용자의 개입 없이 정보를 여과하여주는 여러 가지 에이전트 시스템들도 등장하고 있다.

하지만 늘어나는 문서를 효율적으로 검색한 후, 또는 원하는 분야의 문서를 에이전트 시스템이 여과(filtering)하여 준 후에는, 결국 사용자가 문서 내에서 찾으려고 하는 특정 필드의 정보가 있게 마련인데, 이것은 검색 결과나 여과의 결과물이 다른 문서와 마찬가지로 방대한 경우 사용자들을 곤란하게 만든다. 이에 정보검색이나 여과의 결과물에서 원하는 필드를 자동으로 추출하는 시스템이나 이를 위한 방법에 관한 연구의 필요성이 대두되게 되었다.

정보추출은 정보검색보다 세부적인 작업으로, 일반적인 분야에 대한 정보추출을 처리하기 위해서는 자연언어처리와 같은 고수준의 기술이 요구된다. 따라서 제한된 특정 분야에 대한 정보추출을 처리하는 대부분의 정보추출 시스템들은 일반적으로 완전한 자연언어처리를 사용하기보다는 자연언어처리에서 사용되는 일부 방법론들에 더하여, 정보추출을 수행하려고 하는 구체적인 목적 분야로부터 사용 가능한 지식을 결합한 방법을 사용한다. 예를 들어 Christian 등은 과학 논문들에서 생물학적 정보, 특히 단백질과 단백질 사이의 상호작용에 관한 정보를 문장에서 이들 관계를 표현할 때 주로 사용되는 동사들을 기초로 구성하는 시스템을 구현하였다[2].

정보추출에 대한 필요성이 널리 인식된 후, 은닉마르코프모델이나 문법규칙(Grammar Rule), 기계학습(Machine learning), 여러 가지 자연언어처리 기법 등의 방법을 이용한 정보추출에 관한 여러 연구가 진행되었다. 은닉마르코프모델이 정보추출에 응용된 초기의 예로는 Leek의 연구를 들 수 있다. Leek은 HMMs를 이용하여 생물의학 텍스트에서 유전자의 위치를 찾는 데 응용하였다[6]. Leek의 HMMs의 모델은 생물의학 텍스트라는 분야에 적합하도록 각 분야에 대한 언어 모델링(language modeling)을 각 상태에 반영시켜 수동으로 정교하게 구성된 정적모델 구조를 가졌다. 또한 Leek은 언어의 문법(syntax)을 표현하기 위해서 망 구조(network topology)를 사용하였으며, 각 상태는 유니그램(uni-gram) 언어모델을 기반으로 구성하였다. 알려지지 않은 토큰(token)들은 공백 상태(gap state)를 두어 처리하였다. Leek의 연구는 전통적으로 음성인식에 사용되어온 HMMs를 비교적 성공적으로 정보 추출에 응용한 초기의 예라고 할 수 있다.

기존에 음성인식에 널리 사용되어 오던 은닉마르코프모델이 정보검색에 응용되기도 하였다. David 등은 문서가 내부구조로 가지고있는 주제별 구조를 은닉마르코프모델로 모델링하여 사용자가 찾으려고 하는 정보와 어느 정도 유사한 문서인지를 판단하여 정보검색을 수행하는 HMMs를 이용한 정보검색 시스템을 제안하였다[4]. 또한 정보추출 방법의 예로 HMMs를 사용하지는 않았지만 형식화된 간단한 온라인 세미나 안내 자료의 시간, 장소, 연사 등과 같은 각각의 주요 필드에 대하여 여러 가지 기계학습 기법들을 사용하여 구성한 학습자(learner)들을 학습시켜 이들의 예측 결과를 regression을 이용하여 병합하여 필드의 추출을 수행하는 다중기법(multistrategy)을 사용한 정보추출 방법을 들 수 있다[4].

이러한 여러 가지 방법들 중에서 은닉마르코프모델은 음성데이터와 같은 순차적 데이터를 인식하는데 널리 사용되어온 모델로서 일련의 순차적인 성질을 내포하고있는 데이터를 다루는 문제에 잘 적용될 수 있다[9]. 여러 가지 정보를 담고있는 문서들 중에서 본 논문에서 사용한 학회참가요청(Call for Papers) 문서나 세미나 안내문서, 또는 논문과 같은 문서들은 어느 정도 지정된 형식을 따르고있기 때문에 내부적으로 순차적 성질을 가진 문서로 고려할 수 있다. 이 때문에 음성 데이터와 같이 명확한 순차적 성질을 가지는데 응용된 은닉마르코프모델을 위와 같은 문서에 사용하여 정보추출의 문제를 해결할 수 있는 것이다. 그러나 텍스트 문서에 응용된 기존의 은닉마르코프모델은 초기 모델의 세부 구조까지 모델 설계시점에서 설계자가 직접 지정해야만 했으며, 시스템의 모델 구조는 이때 정적으로 정해지게 되었다[6]. 이렇게 됨으로써 처리하는 데이터와, 필드의 특징에 따른 적합한 모델 구조를 학습할 수 없었으며 단지 초기에 정해진 제한적 모델 구조의 확률값 조정을 통하여 데이터의 특징에 대한 학습을 수행할 수 있었다. 이에 본 논문에서는 보다 유연한 HMMs의 모델 구조로 시작하여, 데이터의 특징을 학습한 후 이를 이용하여 모델 구조를 구체화하는 방법으로 정보추출을 수행하는 시스템을 구현하고, 그 성능을 CFP데이터를 이용한 실험을 통하여 평가한다.

2. 은닉마르코프모델(Hidden Markov Models)

HMMs은 관찰이 불가능한 미지(hidden)의 확률론적 과정(stochastic process)을 관찰이 가능한 기호(symbol)를 발생시키는 다른 확률론적 과정을 통하여 모형화(modeling)하는 이중의 확률론적 과정이다[9]. 예를 들어 우리가 쉽게 관찰할 수 있는 음파나 공기의 압력, 또는 조음기관의 위치 등을 이용하여 두뇌의 활동을 모형화 하는 것을 생각해 볼 수 있다. 이러한 HMMs은 다음과 같이 2개의 상태집합과 3개의 확률 집합으로 구성되는 5개의 요소를 갖는다.

- 은닉상태집합(hidden state set)

마르코프 프로세스에 의해서 설명되는 상태들의 집합으로 관찰가능하지 않으며 HMMs의 은닉(Hidden)은 이러한 은닉상태를 지칭한다.

- 관찰가능 상태집합(observable state set)

외형적으로 눈에 보이는 전이 상태들의 집합

- π 벡터

특정 은닉 상태가 시간 $t=1$ 일 때 모델의 확률

- 상태전이 행렬(A)

이전의 은닉상태에서 현재의 은닉상태로의 전이 확률을 나타내는 것으로 모델 내부의 은닉 상태들 간의 전이 확률을 나타내는 행렬

- 관찰확률 행렬(B)

특정 은닉상태에서의 관찰 가능한 각각의 상태들에 대한 확률을 나타내는 행렬

이와 같이 HMMs은 관찰 가능한 상태들과 은닉상태들간의 확률적 관계를 이용하여 확장된 표준 마르코프 프로세스라 볼 수 있다. HMMs은 상태들 간의 전이 관계를 다음과 같은 가정을 통해 규정한다.

$$P(q_t=j | q_{t-1}=i, q_{t-2}=k, \dots) = P(q_t=j | q_{t-1}=i) \quad (1)$$

$$P(q_t=j | q_{t-1}=i) = P(q_{t+l}=j | q_{t+l-1}=i) \quad (2)$$

식 (1)은 마르코프 모델의 상태 전이는 이전의 상태들과는 무관하며, 단지 바로 전 단계의 상태에 의해서만 다음상태의 결정이 영향을 받는다는 것을 의미하는 것으로, 시간 t 에서의 상태 q_t 가 상태 j 로 결정되는 것은 시간 $t-1$ 의 상태 q_{t-1} 에 따라 결정된다는 것을 나타낸다. 이는 **1차 마르코프 가정**(first order Markov assumption)라 불리며 HMMs의 기본 이론을 구성하는 요소로 식 (2)와 같이 시간 t 이후의 모든 상태에 대하여 일반화 될 수 있다.

모델의 상태들이 출력하는 기호에 대한 모델 관찰열(observation symbol sequence)은 다음의 식 (3)과 같이 표현될 수 있다.

$$O = O_1, O_2, \dots, O_{T-1}, O_T \quad (3)$$

여기서 T 는 관찰열의 지속시간을 나타내는 시간이다. 이후 N 을 은닉 상태들의 개수라 하고, M 을 관찰 기호의 개수를 표현한다.

$$Q = \{q_1, q_2, \dots, q_N\} \quad (4)$$

$$V = \{v_1, v_2, \dots, v_M\} \quad (5)$$

위의 식 (4)는 모델 내부에 있는 각각의 상태를 나타내며, 식 (5)는 상태에서 관찰이 가능한 기호들의 집합을 의미한다.

은닉마르코프모델(λ)은 다음과 같은 (Π, A, B) 의 3가지 요소로 정의된다.

- $\Pi = (\pi_i), \pi_i = P(q_1 = i), \quad 1 \leq i \leq N$
상태들의 초기 확률값을 표현하는 벡터
- $A = (a_{ij}), a_{ij} = P(q_{t+1} = j | q_t = i), \quad 1 \leq i, j \leq N$
상태들간의 전이 확률 행렬로 $P(x_i | x_{j-1})$ 와 같이 된다.
- $B = (b_j(k)), b_j(k) = P(o_t = v_k | q_t = j), \quad 1 \leq k \leq M, 1 \leq j \leq N$
관찰확률 행렬을 나타내며 $P(y_i | x_j)$ 와 같이 표현된다.

위에서 상태전이 행렬 A 는 모든 내부상태들간의 전이확률을 표현하며 다음과 같이 구성된다.

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1j} & \cdots & a_{1N} \\ a_{21} & a_{22} & \cdots & a_{2j} & \cdots & a_{2N} \\ \vdots & \vdots & \cdots & \vdots & \cdots & \vdots \\ a_{i1} & a_{i2} & \cdots & a_{ij} & \cdots & a_{iN} \\ \vdots & \vdots & \cdots & \vdots & \cdots & \vdots \\ a_{M1} & a_{M2} & \cdots & a_{Mj} & \cdots & a_{MN} \end{pmatrix} \quad (6)$$

식 (6)이 가지는 각 원소는 식 (7)과 같이 정의되며, a_{ij} 는 식 (8), (9)와 같은 제약 조건을 갖는다.

$$a_{ij} = P(q_t = j | q_{t-1} = i) \quad 1 \leq i, j \leq N \quad (7)$$

$$a_{ij} \geq 0, \quad \forall i, j \quad (8)$$

$$\sum_{j=1}^N a_{ij} = 1, \quad \forall i \quad (9)$$

여기에서 A, B 두 행렬은 시간에 독립적으로 가정하는데, 실제적인 문제에 있어서 이것은 마르코프 모델이 가지는 비현실적 가정이 된다. 하지만, HMM은 하나의 벡터와 두 개의 행렬을 이용하여 실제의 시스템을 충분히 모델링할 수 있기 때문에 앞서와 같은 가정을 통한 근사 모델링으로 널리 사용된다.

이렇게 HMM을 정의하고 나면 실제로 모델을 정보추출에 사용하기 위해서는 다음과 같은 3가지 문제를 해결해야만 한다.

1. 확률평가(probability estimation)의 문제

관찰되어진 관측열 $O=(o_1, o_2, \dots, o_T)$ 와 모델 $\lambda=(\Pi, A, B)$ 에 대하여 주어진 HMM에서 관찰되어진 순서의 확률 $P(O|\lambda)$ 를 계산하는 문제.

2. 최적 상태 순서의 결정(optimal sequence) 문제

관찰된 관측열 $O=(o_1, o_2, \dots, o_T)$ 와 모델 λ 에 대하여 최적의 상태순서

$q=(q_1, q_2, \dots, q_T)$ 순서를 생성할 확률이 가장 높은 은닉상태들 간의 순서를 찾는 문제.

3. 매개변수 추정(parameter estimation) 문제

관찰된 관측열 $O=(o_1, o_2, \dots, o_T)$ 에 대하여 $P(O|\lambda)$ 를 최대로 하는 모델 $\lambda=(\Pi, A, B)$ 의 매개변수(parameter)를 결정하는 문제로 다음과 같이 표현될 수 있다.

$$\max_{\lambda} \{P(O|\lambda)\} \quad (10)$$

문제 1의 경우 은닉상태(hidden state)를 고려해야 하기 때문에 확률을 평가하는 문제가 복잡해진다. 문제 2의 경우는 데이터를 가장 잘 설명하는 상태 순서를 결정하기 위해서 ‘최적’의 기준을 정하는 것이 필요하다. 이처럼 HMMs를 사용하기 위하여 해결해야 하는 위와 같은 3가지 문제를 해결하기 위해서 몇몇 방법들이 널리 쓰여왔다. 확률평가 문제(문제 1)의 경우 전향 알고리즘(forward algorithm)과 후향 알고리즘(backward algorithm)을 이용하여 해결이 가능하며, 최적의 상태 순서의 경로를 결정하는 문제(문제 2)는 일반적으로 동적 프로그래밍 기법의 하나인 비터비알고리즘(viterbi algorithm)을 이용하여 결정한다[9]. 모델의 확률을 최대로 하는 매개변수의 추정(문제 3)은 EM알고리즘으로 알려진 Baum-Welch알고리즘을 사용하여 처리한다[1,3,9].

3. 은닉마르코프모델을 이용한 정보추출

3.1 정보추출을 위한 은닉마르코프모델

정보추출에 은닉마르코프모델을 적용하기 위해서는, 먼저 HMMs의 각 모델 파라미터를 사용하여 텍스트 데이터에 사상(mapping)시켜야 한다. 또한, 사용하는 텍스트 데이터에서 추출하려고 하는 필드에 대한 모델을 구성하는 작업도 필요하다. 본 장에서는 텍스트 데이터의 각 요소들을 HMMs의 파라미터들에 어떻게 대응시켰는지, 그리고 이를 이용하여 모델을 구성하는 것에 대하여 설명하도록 한다.

3.1.1 정보추출에 대한 HMMs의 적용

본 논문에서는 HMMs을 이용하여 정보 추출을 수행하기 위해서 HMMs의 각 요소들을 다음과 같이 실험 텍스트 데이터의 각 요소들로 고려하였다.

우선 HMMs 모델의 관찰열 O 는, 출현한 키워드가 속한 단어집합의 번호벡터로 고려하였다. 여기에서 단어집합의 번호벡터는, 모델에 특정 단어가 입력으로 들어오는 경우 이 단어가 미리 정의된 어떤 집합에 속하는지를 판단하여 단어나 단어들이 출현할 때 이를 집합의 번호로 표현한 것을 의미한다. 단어가 속한 단어집합은 실험 전에 전처리 과정을 통하여 각 실험 데이터에 대하여 아래의 표 1~2와 같은 규칙으로 출현하는 단어들로 정의하였다. 단어집합을 정의하는 데에는 해당 필드가 출현한 부분을 기준으로 전후 3단어씩을 고려하였다.

다음으로 모델의 은닉 상태는 추출하려는 필드의 개수만큼 정의하고, 상태간의 전이를 위한 중간 상태를 고려하기 위해서 추출하려는 필드의 수 + 1개의 중간단계 상태를 고려하였다. 즉, 각 필드의 모델에 대해서 제공되는 초기 추상 모델 상태의 수는 다음과 같이 된다.

$$\text{Number of initial model State} = 2 \times \text{Number of Target Field} + 1 \quad (11)$$

위의 식 (11)에서 표현된 상태의 수는 초기 추상모델의 상태의 수를 나타내는 것으로, 훈련을 통해서 구성된 최종 모델은 식 (11)의 것보다 적은 상태를 갖는다.

아래의 표 1~2는 본 논문에서 사용한 CFP 실험데이터에 대한 각각의 추출필드와 이를 위한 단어집합을 구성하는 규칙을 사전 정의한 것이다. 정의된 단어집합은 실험의 훈련단계에서 단어 규칙을 추가하거나 삭제하는 과정을 통하여 수정되어질 수 있도록 하였다.

표 1. CFP(Call-For-Papers) 데이터의 각 필드별 단어규칙 집합

필드 이름	단어규칙	실제 예
학회 이름 (1)	$\{n\text{-NAME_SYM} + \text{year}\},$ $\{n\text{-NAME_SYM} + "" + \text{year}\},$ $\{n\text{-NAME_SYM} + "-" + \text{year}\},$ $\{n\text{-NAME_SYM} + " " + \text{year}\}, \text{ etc.}$ NAME_SYM := Capital character Begin with Capital Character year := 4-digit 2-digit $2 \leq n \leq 15$	ICONIP 2000 SIGIR'2001 PRICAT'01 KDD01 EC-Web 2000 CL2000 CECCO 2000 CEC 2001
학회 날짜 (2)	$\{\text{day} + \text{month} + "," + \text{year}\},$ $\{\text{day} + "," + \text{month} + "," + \text{year}\},$ $\{\text{day} + \text{th} + \text{D_SYM} + \text{day} + \text{th} + \text{month} + \text{year}\},$ $\{\text{day} + \text{D_SYM} + \text{day} + "," + \text{year}\},$ $\{\text{month} + \text{day} + \text{D_SYM} + \text{day} + "," + \text{year}\}, \text{ etc.}$ D SYM := "-" "to"	23 September, 2000 24th to 28th July, 2000 8-12 July, 1999 August 20-23, 2000

표 2. CFP(Call-For-papers) 데이터의 각 필드별 단어규칙 집합 (계속)

필드 이름	단어규칙	실제 예
학회 장소 (3)	{PLACE + <NL> + CITY + "," + COUNTRY}, {PLACE + "," + CITY + "," + COUNTRY}, etc. NL := new line character	Riviera Hotel Las Vegas, Nevada USA
참고 URL (4)	{URL_MARK + URL}, etc. URL_MARK := "http://" "www."	http://www.genetic-algorithm.org/GECCO2000/gecco2000mainpage.htm
논문 제출 마감일 (5)	{DUE_SYM + <NL> + date}, {DUE_SYM + ":" + date}, {DUE_SYM + date}, etc. DUE_SYM := "Important Dates" "Deadline" "Due Dates" "Submission Deadline" "Paper Submission" "Dates" "Schedule" "Conference Schedule" "CALENDAR"	Important Dates December 20, 1999: Deadline for the submissions of the proposals. SUBMISSION DEADLINE: January 26, 2000
학회 연락처 (6)	{CON_SYM1 + ":" + number}, {CON_SYM2 + ":" + e-mail}, etc. CON_SYM1 := "Phone" "Tel" "Fax" CON_SYM2 := "E-MAIL"	Phone: 650-328-3123. FAX: 650-321-4457. E-MAIL: gecco@aaai.org .

시스템에서는 위의 표 1~2와 같이 정의된 규칙을 기반으로 각각의 데이터를 처리하면서 입력으로 들어오는 단어집합을 고려하여 HMMs의 관찰열 O 를 단어 집합별 번호를 출력함으로써 구성한다. 예를 들어 입력으로 들어온 데이터가 다음의 그림 1과 같다고 하면, 시스템은 이와 같은 CFP데이터를 읽어나가면서 표 1~2와 같이 정의된 CFP데이터의 필드별 번호를 고려하여 다음과 같이 관찰열 O 를 생성한다(표 1~2의 각 필드 하단에 괄호로 붙여진 번호 1~6까지를 각 필드를 표현하는 상태들에 순서대로 할당하고, 상태간의 전이 중간단계를 영어 소문자 알파벳순으로 할당하였다고 가정하자. S :시작상태, E :끝 상태).

$$O=(o_1, o_2, \dots, o_T) = S \ 1 \ a \ 2 \ b \ 3 \ c \ 4 \ d \ 5 \ e \ 6 \ E \quad (12)$$

SECOND CALL FOR PAPERS FIFTH ANNUAL INTERNATIONAL CONFERENCE ON COMPUTATIONAL MOLECULAR BIOLOGY (RECOMB 2001) April 21-24, 2001 Montreal, Canada
US National Science Foundation http://recomb2001.gmd.de The Fifth Annual Conference on Research in Computational Molecular
... CALENDAR: Deadline for submission of papers: Sep 30, 2000 Notification of acceptance/rejection: Dec 5, 2000 Deadline for reception of final papers: Jan 5, 2001 STEERING COMMITTEE: ...
INFORMATION: CANADA H3C 3J7 Tel: (514) 343-7501 Fax: (514) 343-2254 email: recomb01@CRM,UMontreal,CA

그림 1. CFP 데이터의 위치별 각 필드 출현 예

3.1.2 필드 인식을 위한 HMM의 구조와 초기 HMM구조의 변경

본 논문에서는 CFP 데이터를 표현하기 위하여 데이터 전체를 표현하는 하나의 HMMs를 구성하였다. 모델은 기본적으로 식 (11)에서와 같이 초기 은닉 상태를 갖는다. 식 (11)의 상태 수는 모델의 시작상태(S)와 종료상태(E), 그리고 각 필드를 표현하는 상태와 이들 사이의 중간 전이단계를 표현하는 상태들을 포함한 것이다. 즉, 기본적으로 데이터의 각 필드들은 하나의 상태와 중간 전이상태로 표현되고있는 것이다. 이렇게 모델을 구성하고 나면 일반적으로 사용되는 고정 상태를 가지는 HMMs보다 많은 초기상태를 가지는 모델이 구성된다. 일반적으로 논문 데이터의 경우, 고정 상태의 HMMs으로 구성하게 되면 그림 2와 같이 각 필드를 하나의 상태로 표현하는 모델을 구성하게된다[10]. 하지만 데이터 필드의 특성을 보다 자세히 고려하면 몇 개의 필드를 HMMs모델의 하나의 상태로 표현할 수 있다. 만일 이렇게 하여, 1개 이상의 필드를 하나의 상태로 표현할 수 있다면, 모델의 인식 정확도를 유지하면서도 최종 모델의 상태 수를 줄일 수 있게 된다. 모델의 상태수가 줄게되면 전향-후향 알고리즘(forward-backward algorithm)이나 비터비알고리즘, 그리고 EM알고리즘을 이용하여 모델파라미터를 최적화하는 과정에서 고려해야 하는 경우의 수가 급격하

게 줄게 되어 정보추출의 전반적 속도향상을 기대할 수 있게 된다.




그림 2. 각 추출 필드별로 하나의 모델 상태를 가지는 HMMs의 예[10]

이에 본 논문에서는 초기에는 다소 많은 상태로 구성된 모델을 이용하지만 데이터의 추출 필드가 가지는 단어 규칙들을 학습하여, 초기 상태를 감소시켜 최종 모델을 구성하는 HMMs을 사용한다.

참고로 본 논문에서는 앞에서 설명한 것과 같이 각각의 필드를 표현하는 두 상태가 최종적으로 하나의 상태로 병합되는 경우 병합되어 생성된 상태는 HMMs의 관찰열을 생성할 때 병합되기 이전의 상태처럼 관찰열 O 를 생성하도록 하였다.

아래의 표 3은 본 논문에서 사용하는 자기구성 은닉마르코프모델의 알고리즘에 대한 의사코드(Pseudo code)를 나타낸다.

Step 0. Do data preprocessing and generate field generation rule R for each field. τ = initial model state by equation (11). Step 1. Construct initial model λ_0 with internal state τ and R. Step 2. If ($nState_{min} \leq nState_{\lambda} < nState_{max}$) goto step 5. Step 3. Compute field distance. Step 4. Merge nearest two state. $nState_{\lambda} \leftarrow nState_{\lambda} - 1$ goto step 2. Step 5. Compute $P(O \lambda)$ with observation $O=(o_1, o_2, o_2, \dots, o_T)$ and model $\lambda=(\pi, A, B)$ Step 6. Estimate optimal model parameter with EM algorithm in table 5. Step 7. Find optimal state sequence $q=(q_1, q_2, q_2, \dots, q_T)$ with given observation $O=(o_1, o_2, o_2, \dots, o_T)$ and model λ.

표 3. 자기구성 HMM의 동작 의사코드(pseudo code)

표 3의 Step 3에서 상태 i 와 j 사이의 거리는, 두 상태를 연결하는 가장 짧은 경로의 상태전이 확률의 합의 역수로 계산된다. 확률의 합이 0.5를 넘지 않는 경우 두 상태간의 거리는 매우 큰 값으로 고려되어 상태간의 병합 가능성을 차단한다.

3.2 HMMs을 이용한 정보추출 시스템의 설계 및 구현

추출 시스템은 아래의 그림 3과 같은 구조를 가진다. 그림 3의 "Field rule Generator"는 앞에서 설명한 표 1~2와 같은 규칙을 전처리로부터 받아 유지한다. 생성된 규칙은 이후 초기모델(λ_0)의 상태를 감소시켜 모델의 복잡도를 감소시키는데 사용된다.

아래의 그림 3은 정보추출 시스템의 전체 구성도를 나타낸다.




그림 3. 정보추출 시스템의 전체 구성도

4. 실험 및 결과

4.1 학회 안내 데이터(Call-For-Papers Data)

CFP데이터는 각 학회의 웹사이트나 메일링리스트로 안내되는 학회 논문제출 안내 문서를 직접 수집하여 구성한 텍스트 데이터이다. 데이터는 크게 학회의 이름, 개최지, 날짜, 장소, 학회에서 다루는 주제(topic), 위원회 명단, 논문제출 스케줄, 연락처 등을 포함하고 있다. 본 논문에서는 실험에 사용하기 위해서 CFP데이터를 표 4와 같은 필드에 대하여 SGML형식으로 태깅(tagging)을 하였다. 데이터에 포함된 이와 같은 SGML형식의 태그는 모델 훈련에 사용되었다. 실험에서 사용한 CFP데이터는 컴퓨터과학(Computer Science)분야 학회(Conference)의 CFP문서 200개와 생물학(Biology) 분야의 학회 CFP문서 100로 총 300개의 서로 다른 학회에 대한 CFP문서로 구성되어 있으며, 전체 데이터의 크기는 2051K바이트이다.

아래의 그림 4는 RECOMB 2001의 CFP데이터의 일부를 표현한 것이다. 그림 4와 같은 CFP데이터는 표 4의 SGML 형식의 태그를 이용하여 전처리하여 그림 4와 같이 구성하였다. 그림 4의 "<NL>"은 개행 문자(newline character)를 표현한다.

실험에서는 전체 300개의 CFP문서 중에서 임의로 선택한 200개의 CFP문서를 훈련데이터로 사용하였고, 나머지 100개를 이용하여 훈련된 모델의 성능을 검증하는데 사용하였다.

```
<NL>
<paragraph><sentence> SECOND CALL FOR PAPERS </sentence></paragraph>
<NL>
<paragraph><sentence> FIFTH ANNUAL INTERNATIONAL CONFERENCE ON
COMPUTATIONAL MOLECULAR BIOLOGY </sentence></paragraph>
<NL>
<sentence><paragraph>(<c_name>RECOMB 2001</c_name>)</sentence></paragraph>
<NL>
<paragraph><date>April 21-24, 2001</date></paragraph>
<paragraph><location>Montreal, Canada</location></paragraph>
<NL>
<paragraph><sentence>Organized by <NL> Centre de recherches math?atiques
<NL> Universite de Montreal <NL></sentence></paragraph>
<NL>
<paragraph><sentence>Sponsored by <NL>
Association for Computing Machinery (ACM-SIGACT)</sentence></paragraph>
<NL>
<paragraph><sentence>with support from <NL> Celera Genomics <NL>
Compugen <NL> IBM Corporation <NL>
International Society for Computational Biology (ISCB) <NL>
SLOAN Foundation <NL>
SmithKline Beecham <NL>
US Department of Energy <NL>
US National Science Foundation </sentence></paragraph><NL>
<NL>
<c_url>http://recomb2001.gmd.de</c_url>
<NL><NL>
<paragraph><sentence>The Fifth Annual Conference on Research in
Computational Molecular <NL> Biology (<c_name>RECOMB 2001</c_name>),
sponsored by the Association for Computing <NL>
Machinery Special Interest Group on Algorithms and Computation Theory <NL>
(ACM-SIGACT) with support from Celera Genomics, Compugen, IBM <NL>
```

그림 4. CFP 데이터의 예 (SGML형식의 태그 포함)

그림 5~6은 고정모델 HMMs과 자기구성 HMMs을 사용한 CFP 데이터에 대한 정보추출의 결과를 모델이 가지는 상태의 수의 변화에 따른 성능변화로 표현한 것이다. 그림 7은 각각 두 방법이 주어진 모든 데이터에 대하여 정보추출 작업을 완료할 때까지의 소요시간을 상대적으로 표현한

것이다.

표 4. CFP 학회 안내 데이터에 포함된 필드들

필드 이름	설 명	필드 구분 태그(Tag)
학회 이름	학회 이름을 표시 필드	<c_name> ... </c_name>
학회 날짜	학회의 개최일 표시 필드	<date> ... </date>
학회 개최장소	학회 개최장소 표시 필드	<location> ... </location>
학회 참고 URL	학회의 웹 페이지 주소	<c_url> ... </c_url>
논문제출 마감일	논문이나 초록 제출 마감일	<due_date> ... </due_date>
학회 연락처	전화, 팩스, 전자우편과 같은 연락처	<c_contact> ... </c_contact>
단락의 표시	CFP 데이터 내에서 단락의 시 작과 끝을 표시한다.	<paragraph> ... </pagragraph>
문장의 표시	CFP 데이터 내에서 문장의 시 작과 끝을 표시한다.	<sentence> ... </sentence>

그림 5와 6을 비교해보면 동일한 CFP 데이터에 대해서 완전히 모델의 상태를 고정한 경우(그림 5)보다 초기에 어느 정도 모델의 상태 조정을 허용한 경우(그림 6)에 월등히 추출 성능이 높아지는 몇몇 필드들을 볼 수 있다. 이것은 추출할 필드에 대한 모델의 학습이 자기구성 HMMs를 사용한 경우에 고정상태를 사용한 경우보다 더 잘 이루어졌다는 것을 나타낸다고 볼 수 있다.




그림 5. 고정모델 HMM을 사용한 CFP데이터 정보추출




그림 6. 자기구성 HMM을 사용한 CFP데이터 정보추출




그림 7. HMM과 S-HMM의 시간지연 - CFP 데이터

그림 6~7은 모델의 상태를 변화시킬 수 있도록 구성한 HMMs의 경우에 초기에 상태를 고정 한 HMMs보다 약 4%정도의 추출 정확도의 향상을 나타내고 있다. 또한, 그림 7은 자기구성 HMMs의 처리 속도가 모델의 상태를 초기에 완전히 고정한 HMMs보다 약 10%정도 향상되었다는 것을 보여주고 있다.

5. 결론

본 논문에서는 모델의 상태가 초기에 고정되는 기존의 HMMs의 응용과는 달리, 전처리 단계에서 데이터를 통하여 얻은 규칙을 기반으로 초기 모델의 구조를 구성하고 구성된 모델간의 거리를 계산하여 병합 가능한 모델의 상태를 하나로 묶어줌으로써, 정확도를 어느 정도 유지하면서도 모델을 이용하여 구성된 시스템 전체의 속도를 향상시킬 수 있는, HMMs을 이용하여 정보추출 방법을 제안하였다.

논문에서 사용한 자기구성 은닉마르코프모델의 경우 모델의 상태가 초기에 고정되는 경우와 달리 데이터의 규칙에 기반하여 초기 모델을 잡을 수 있어, 데이터에서 추출 필드가 연속하여 나오는 경우 이를 표현하는 모델의 각 상태들을 병합할 수 있도록 해준다. 이는 결국 시스템 전체의 시간지연을 감소시켜주는 효과를 다져오며, 두 개의 필드를 하나의 상태로 인식한다 하더라도 연속되는 필드를 하나로 표현한 것이기 때문에 추출 정확도는 그대로 유지할 수 있다.

본 논문에서는 상태를 고정시켜둔 HMMs보다 어느 정도 데이터에 대한 지식을 사용하여 모델의 재구성을 허용하는 자기구성 HMMs이 정보추출의 도메인에 대하여 보다 효율적임을 학회참가 안내 정보로 구축한 CFP데이터에 대한 실험을 통하여 보여주었다.

이렇게 HMMs을 사용하여 구성된 정보추출 방법은 특정 분야에 대한 대량의 온라인논문들이나 기타 다른 문헌을 대상으로 필요한 정보만을 추출하는데 응용될 수 있다. 또한, 문서집합에서 미리 지정한 주요 필드들을 자동으로 추출할 수 있게 되면 문서에 대한 데이터베이스를 구성하거나 하는데 있어서 많은 노력과 비용을 줄일 수 있다.

하지만 HMMs을 이용하여 보다 효율적으로 정보추출을 처리할 수 있도록 하기 위해서는 문서를 학습시키는 단계에 있어서 필요한 작업을 최소한으로 줄이는 연구가 더 필요하며, 문서에서 필드 부분을 분석하여 구성된 필드생성규칙 이외에 분야의 사전지식을 추가적으로 활용하여 추출의 정확도를 높이는 연구가 필요하다.

참고문헌

- [1] Cherkassky, V., Mulier, F. "Learning From Data - Concepts, Theory, and Methods", Wiley-Interscience Publication ,1998.
- [2] Christian Blaschke, Miguel A. Andrade, Christos Ouzounis, Alfonso Valencia, "Automatic extraction of biological information from scientific text: protein-protein interactions", *Proceedings on the Seventh International Conference on Intelligent Systems for Molecular Biology(ISMB)*, pp. 60-67, 1999.
- [3] Dempster, A. P., Laird, N. M., and Rubin, D. B., "Maximum likelihood from incomplete data via the EM algorithm (with discussion)", *Journal of Royal Statistic Society B*, Vol. 39, pp. 1-38, 1977.
- [4] David, R. H., Miller, Leek, T., Richard, M., Schwartz, "A Hidden Markov Model Information Retrieval System", *Proceedings on the 22nd annual international ACM SIGIR conference on Research and development in information retrieval*, pp. 214-221, 1999.
- [5] Freitag, D., "Multistrategy Learning for Information Extraction", *15th International Conference on Machine Learning(ICML-98)*, 1998.
- [6] Leek, T. R., "Information Extraction using hidden Markov models", *Master's thesis*, UC San Diego, 1996.
- [7] Maes, "Agent that reduce work and information overload", *Communications of the ACM*, Vol. 37, No. 7, pp. 31-40, 1994.
- [8] Mitchell, T. M., "Machine Learning", McGraw-Hill Publication, 1997.
- [9] Rabiner, L. R., "A Tutorial on Hidden Markov Models and selected applications in speech recognition", *Proceedings of IEEE*, Vol. 77, No. 2, February 1989.
- [10] Seymore, K., McCallum, A., Rosenfeld, R., "Learning Hidden Markov Model Structure for Information Extraction", *AAAI'99 Workshop on Machine Learning for Information Extraction*, pp. 37, 1999.