

은닉변수 신경망 모델에 기반한 정보 탐색

장병탁¹⁾ · 김청택¹⁾ · 오경환²⁾

서울대학교 컴퓨터공학부¹⁾ / 서울대학교 심리학과¹⁾ / 서강대학교 컴퓨터학과²⁾

Information Mining based on Latent Variable Models

Byoung Tak Zhang¹⁾ · Cheong Tag Kim¹⁾ · Kyung Whan Oh²⁾

Seoul National University¹⁾ / Sogang University²⁾

초록 : 은닉변수모델에 기반한 문서집합으로부터의 주제어 추출과 이에 기반한 의미 커널을 활용한 문서 간 유사도 측정 기법을 개발하였다. 또한 신경망 모델에 기반한 웹 콘텐츠 분류와 사용자 마이닝 기법은 실제 웹 데이터에 대해 우수한 성능을 보였다.

Abstract : We developed effective techniques for topic words extraction and the estimation of document similarity using semantic kernels based on latent variable models. Also, the devised method for the classification of web contents and usage mining showed good performance in real-world web data sets.

연구 배경

대규모 텍스트 문서 집합이나 웹 콘텐츠로부터 관련 콘텐츠들을 분류하고 그들로부터 유용한 정보를 추출하는 것은 매우 중요한 일이다. 이러한 정보탐색 및 획득을 위한 핵심 중의 하나는 사용자의 정보 요구에 대한 정보의 관련성에 관한 문제라고 할 수 있다. 은닉변수 신경망 모델은 데이터 내에 내재된 특성의 효율적 분석이 가능한 도구로서 이의 적절한 활용은 대규모 문서 내 개념 파악, 단어 및 문서 간 유사도 측정 및 이에 기반한 정보 분류에 큰 도움을 줄 수 있을 것이며, 수많은 사용자들의 사용 패턴들에 내재된 특징 패턴들을 추출하고 이에 기반한 웹 콘텐츠 추천에 효과적으로 적용될 수 있을 것이다.

연구 내용

1. 은닉의미커널을 이용한 문서 유사도 측정 : 문서 집합 내의 개념 또는 의미 관계의 자동 분석은 효율적인 정보 획득과 단어 수준 이상의 개념 수준에서의 문서 비교를 가능케 한다. 단어들 간의 의미관계를 문서 간 유사

도 측정에 활용하기 위한 방안으로서 은닉변수모델의 일종인 다중요인모델을 이용하여, 텍스트 문서로부터 의미적으로 유사하거나 적어도 동일 주제에 관련된 단어들의 집합을 추출하고 이에 기반한 의미커널 구축 기법을 고안하였다.




그림 1. 은닉변수모델 기반 의미 커널을 이용한 문서 유사도 측정




그림 2. 문서 집합들에 대한 precision-recall 그래프

4개의 표준 문서집합(MEDLINE, CACM, CISI, CRANFIELD)에 대한 실험에서 제안된 방법은 기존 VSM, GVSM, k-means, LSA 등의 방법론에 비해 검색의 평균 정확도 면에서 더 우수한 결과를 보였다(그림 2).

2. 잠재의미분석과 축 회전에 의한 문서 분류 : 단어의 다중 벡터표상을 가능하도록 하기 위해서, 행렬을 단순히 기본 구조를 분해하고 차원을 축소하여 재결합하는 LSA 모델에서 한 걸음 더 나아가 새롭게 찾아진 축을 적절히 회전하여 인간이 해석 가능한 결과물을 내놓을 수 있는 ELSA 기법을 고안하였다. 제안된 ELSA 기법은 $X = U\Sigma V^T = UTT^{-1}\Sigma V^T$ 연산에 의해 축 회전을 수행한다. 파스칼 대백과 사전으로부터 추출된 한국어 문서 집합에 대해 실험을 하였으며, 그림 3은 단어 과실에 대해 중의어 의미 해소가 성공적으로 수행된 예를 보인다.




그림 3. ELSA 방식에 의한 중의어 의미 해소

3. SVR을 이용한 협동 추천 시스템 : SVR(Support Vector Regression)을 이용하여 웹 콘텐츠 요청 사용자들의

이용 패턴을 모형화하였다. SVR을 이용한 시스템은 다음과 같은 절차를 거쳐 수행된다. 초기의 로그 데이터는 전처리(preprocessing) 과정을 통하여 모델을 구축하는데 있어 필요한 정보만을 적절한 형태로 나타내게 된다. 이렇게 정제된 로그 정보는 사용자가 방문한 페이지와 페이지에 머문 시간을 담아서 하나의 인스턴스로 이용하고 모든 웹 페이지들에 대해 개별적으로 독립적인 SV Regression 모델을 구축한다. 이때, SVR은 해당 콘텐츠를 제외한 나머지 콘텐츠들에 대한 선호도를 축으로 하는 회귀 모형이 된다. 실험을 통해, SVR 기반의 연속성 데이터를 이용하는 모델이 기존의 일반적인 메모리 기반 방식인 Pearson correlation 기법과 정확도 면에서 큰 차이가 없음을 알 수 있었으며, 또한 수행시간 면에서 SVR 모델이 Pearson correlation 기법보다 획기적으로 단축된 것을 볼 수 있다.




그림 4. 데이터 수에 따른 시간비용

참고문헌

- [1] S. Kim and B. T. Zhang, Genetic Mining of HTML Structures for Effective Web-Document Retrieval, *Applied Intelligence*, 18(3), pp. 243-256, 2003.
- [2] J. S. Jang, S. H. Jun, K. W. Oh, Fuzzy Web Usage Mining for User Modeling, *International Journal of Fuzzy Logic and Intelligent Systems*, Vol. 2 No. 3, pp. 204-209, 2002.
- [3] J. H. Chang, J. W. Lee, Y. S. Kim, and B. T. Zhang, *Topic Extraction from Text Documents using*.