

은닉변수모델 기반의 의미 커널을 이용한 문서 검색

장정호 · 장병탁

서울대학교 컴퓨터공학부

Text Retrieval using Semantic Kernel based on Latent Variable Models

Jeong Ho Chang · Byoung Tak Zhang

School of Computer Science and Engineering, Seoul National University

초록 : 문서 집합 내의 개념 또는 의미 관계의 자동 분석은 보다 효율적인 정보 획득과 단어수준 이상의 개념 수준에서의 문서 비교를 가능하게 한다. 이를 위해 은닉변수모델을 이용하여 문서 집합으로부터 단어들 간의 의미 관계를 자동적으로 추출하고 이를 통해 문서 간 유사도 측정을 효과적으로 하기 위한 방안을 제시한다. 은닉변수모델로는 다중요인모델의 학습이 용이한 헬름홀츠 머신을 활용하며 이의 학습 결과에 기반하여, 문서 간 비교를 위한 의미 커널(semantic kernel)을 구축한다. 4개의 표준 문서 집합에 대한 검색 실험에서 제안된 기법을 적용함으로써 기본 VSM(Vector Space Model)에 비해 20% 이상의 평균 정확도 향상을 이룰 수 있었다.

Abstract : The automatic analysis of concepts or semantic relations in document sets enables the comparison of documents in the concept level other than the simple word level. In this research, we present a method, based on latent variable models, to automatically extract the semantic relationships between various words and to estimate the similarity among documents effectively. We use Helmholtz machines, a latent variable model that makes ease of the learning of multiple cause models for the automatic text analysis, and construct semantic kernels for the estimation of document similarity. In the retrieval experiment for four standard document sets, our methods shows a significantly improved performance, over 20% compared with the basic VSM, in terms of average accuracy.

연구 배경

인터넷의 발달과 이에 따른 정보량의 폭발적 증가로 온라인 텍스트나 전자화된 문서의 양이 크게 증대되고 있다. 하지만 이러한 데이터의 방대함이 곧바로 사용자들의 요구 정보 획득의 용이함을 의미하는 것은 아니다. 오히려 정보 과부하(information overload)를 유발하여 다양한 주제에 관련된 문서에 대한 검색과 조직화를 어렵게 하는 측면이 있다. 이를 위한 자동화된 정보탐색 및 획득 기술의 핵심 내용 중의 하나는 사용자의 정보 요구에 대한 정보의 관련성(relevance)에 관한 것인데, 이는 문서의 표현 방식과 직결된 문제라고 할 수 있다. 기본 벡터공간모델(VSM)에서의 'bag-of-words' 방식은 간단하면서도 어느 정도 좋은 성능을 내지만, 단어들 간의 의미 관계를 고려하지 못한다는

점에서 문제가 있으며, 이는 유의어와 동의어에 관련된 문제로 볼 수 있다. 따라서, 사용자 요구에 보다 부합되는 효과적 정보 제공을 위해서는 단어 수준이 아닌 개념 수준에서의 문서 간 유사도 측정 및 이에 기반한 정보의 검색이 필요하다.

접근 방법

은닉변수 모델의 하나인 헬름홀츠 머신(Helmholtz machine)을 이용하여 텍스트 문서로부터 의미적으로 서로 유사하거나 적어도 동일 주제에 관련된 단어들의 집합을 추출하고 이에 기반한 의미 커널(semantic kernel) [2]을 구축하여 문서 간 유사도를 측정하고 이를 정보 검색에 적용한다. 헬름홀츠 머신(Helmholtz machine) [1]은 다중요인모델 계층적 생성 모델에서의 학습과 추

른 과정을 용이하게 하기 위한 근사화 방법 중의 하나로서, 뉴런 형태의 확률적 처리 단위로 구성된 다층 연결망으로 표현된다. 헬름홀츠 머신 기반 문서 분석에서 최종적으로 활용되는 것은 은닉노드에서 입력노드에 이르는, 즉 각 토픽이 단어들에 대해 가지는 가중치들의 집합이며, 이는 $M \times K$ 행렬 R 로 표현할 수 있다. M 은 문서 집합을 구성하는 어휘 개수, K 는 은닉공간의 차원, 즉 설정된 토픽의 개수를 의미하며 R 의 각 열은 M 개의 어휘에 대한 가중치 집합으로 정의되는 하나의 잠재의미 자질이다. 이로부터 두 문서 d_1 과 d_2 의 유사도 측정은 그림 1과 같은 과정을 통해 이루어진다.




그림 1. 의미 커널에 의한 문서 유사도 측정

결과

그림 2는 4개의 표준 문서 집합(MED, CACM, CISI, CRAN)에 대한 검색실험 결과를 precision-recall 그래프 형태로 제시한다. 기본 벡터공간 모델에서의 코사

인 유사도 측정치에 의한 결과(word-space)를 기본성능으로 하고 generalized VSM(doc-index), k-means 알고리즘, LSA, 헬름홀츠 머신(HM)에 의한 방법을 비교하였다. 전체적으로 볼 때, 헬름홀츠 머신과 이에 기반한 의미 커널에 의한 유사도 측정 기법이 VSM 기법에 의한 기법보다 1% 유의 수준에서 성능 향상이 있음을 확인하였으며, 나머지 방법론에 비해서도 적어도 5% 유의수준에서 향상된 성능을 얻을 수 있었다.




그림 2. 4개의 문서 집합에 대한 검색 성능

참고문헌

- [1] Dayan, P., Hinton, G. E., Neal, R. M. and Zemel, R. S., The Helmholtz machine, *Neural Computation*, 7, 889-904, 1995.
- [2] Cristianini, N., Shawe-Taylor, J., and Lodhi, H., Latent semantic kernels, *Journal of Intelligent Information Systems*, vol. 18, no. 2/3, pp. 127-152, 2002.