

동적 하이퍼네트워크 알고리즘을 이용한 사람 행동의 점진적 학습 및 스키마 분석

장수용

서울대학교 컴퓨터공학부

Incremental Learning and Schema Analysis of Human Motion with Dynamic Hypernetwork Algorithm

Sooyong Jang

초록

사람의 행동 데이터를 학습하고 재생성하는 방법은 다양하게 연구되어 왔다. 하지만 인간 수준의 행동 학습을 위해서는 스키마 학습, 점진적 학습과 같은 추가적인 요소가 도입되어야 한다. Piaget의 스키마 이론에 기반한 학습 방식의 경우에는 새로운 학습 데이터가 입력될 경우 기존의 스키마를 활용하여 학습을 할 수 있으므로 효율적인 학습이 가능하다. 또한 점진적 학습이 가능한 경우에는 새로운 데이터가 계속 유입되는 실제 환경에서 사용하기 적합하다. 이에 본 논문에서는 스키마 이론에 기반한 학습과 점진적 학습이 가능한 동적 하이퍼네트워크 알고리즘을 소개한다. 동적 하이퍼네트워크 알고리즘은 데이터 속에 존재하는 자질들간의 관계를 하이퍼에지라는 형태로 부분적으로 저장하는 방식으로 학습을 하고, 자기조직화를 통한 추론을 하는 알고리즘이다. 실험에서는 Microsoft Kinect 센서를 통해서 수집한 사람 행동 데이터를 점진적으로 학습 가능한지를 확인하였다. 또한, 학습 후 스키마 분석을 통해 유사한 행동을 찾아내고, 이러한 행동을 동적 하이퍼네트워크 알고리즘이 학습하고 재생성 할 때, 어떠한 차이를 보이는지 분석하였다.

목차

1	서론	5
2	핵심 연구 내용	6
2.1	동적 하이퍼네트워크 알고리즘	6
2.2	동적 하이퍼네트워크 알고리즘의 점진적 학습 및 추론	7
2.3	동적 하이퍼네트워크 알고리즘의 스키마 분석 용이성	7
3	실험	8
3.1	데이터	8
3.2	점진적 학습 실험	8
3.2.1	실험 방법	8
3.2.2	실험 결과	10
3.3	스키마 분석 실험	11
3.3.1	실험 방법	11
3.3.2	실험 결과	12
4	결론	15
4.1	실험 결과 논의	15
4.2	추후 연구	15
	참고문헌	17

그림 목차

그림 1 하이퍼에지 추출	6
그림 2 사람 동작 학습 및 재생성 실험	9
그림 3 한가지 행동 데이터만 학습하고 동일한 행동 다른 데이터를 시드로 하여 재생성한 결과	10
그림 4 점진적 학습 검증을 위한 실험 결과	11
그림 5 오른쪽 팔꿈치 관절의 X축 회전각에 해당하는 하이퍼에지 분포	13
그림 6 악수하기와 오라는 수신호의 하이퍼에지 분포 부분을 확대한 그림	13
그림 7 행동 별 데이터 수에 따른 에러값 비교	14

표 목차

표 1 동적 하이퍼네트워크 알고리즘의 추론 과정	7
표 2 스키마 분석 실험 대상	12

1 서론

자연스러운 사람 행동을 재생성하는 방법은 다양하게 연구되어 왔다. Arisan 등은 모션 캡처 학습 데이터를 자르고 붙이는 방식으로 새로운 사람 행동을 합성하는 방식을 연구했고[1], Liu 등은 물리학 기반의 모션 캡처 데이터에서 파라미터를 최적화 하여 행동을 합성하는 방법을 제시하였다[2]. 또한 Talyor 등은 Conditional Restricted Boltzmann Machine (CRBM) 이라는 계층적 모델을 제안하여 사람 동작을 재생성 하는 실험을 하였다[3]. 하지만 인간 수준의 행동학습을 위해서는 학습 알고리즘에 추가적으로 고려해야 할 요소가 있다. Zhang은 인간 수준 기계학습의 도전과제 요소로 구성적 (스키마) 학습, 점진적 학습 등을 꼽았다[4].

스키마(Schema) 학습의 개념은 Piaget에 의해 제시되었다. Piaget는 스키마는 사람의 지능적인 행동의 기본적인 구성요소중의 하나이며, 동화(assimilation)와 조절(accommodation)이라는 방법을 통해 적응(adaptation)하여 스키마를 만들거나 확장시킨다고 주장하였다[5]. 스키마를 통해 기존에 학습한 동작의 패턴을 새로운 동작을 학습할 때 이용할 수도 있기 때문에, 효율적인 학습이 가능하게 된다. 이러한 스키마 이론과 관련된 연구로 Dominici 등은 갓난아기의 발달 과정에서 걸음걸이의 패턴이 어떻게 변화되어가는지를 분석한 바 있고[6], Platt 등은 액션 스키마(action schema)라는 로봇 행동의 추상화된 형식에 기반한 학습을 통해 로봇의 잡는 행동의 질을 향상시키는 연구를 하였다[7].

점진적 학습은 데이터가 새로이 계속 들어오는 환경에서 평생 학습이 가능하고[8], 일괄 학습 방식에 비해서 많은 양의 데이터를 학습하는데 유리하다는 장점이 있다[9]. 점진적 학습 방식은 일괄 학습 방식에 비해서 모델을 설계하기가 어려운 측면이 있지만, 지속적인 학습이 필요할 경우에는 위에서 언급한 장점으로 인해서 유용하게 사용된다.

본 논문에서는 이러한 스키마 학습 및 점진적 학습 요소를 고려하여 설계한 동적 하이퍼 네트워크 알고리즘을 소개한다. 이는 Zhang이 제시한 하이퍼네트워크 알고리즘[10]을 시계열 데이터에 적용 가능하도록 확장시킨 것으로, 학습데이터 내의 각 자질 사이의 관계를 부분적으로 저장하고 자기조직화를 통해 추론하는 구조를 지니며 간단한 샘플링 과정만으로 학습이 가능한 모델이다. 2장에서는 동적 하이퍼네트워크 알고리즘의 학습 및 추론 방법에 대해 자세히 설명하고, 스키마 학습 및 점진적 학습 측면에 대해 논의한다. 3장에서는 실험 설계와 데이터, 실험 방법에 대해 소개하며, 마지막으로 4장에서는 연구 결과 및 추후 연구에 대해 논의한다.

2 핵심 연구 내용

이번 장에서는 먼저 동적 하이퍼네트워크 알고리즘에 대하여 학습 방법과 자기조직화를 통한 추론방법의 두 부분으로 나누어서 설명한다. 그 다음에는 알고리즘의 점진적 학습 특성과 스키마 분석의 용이성에 관하여 논의한다.

2.1 동적 하이퍼네트워크 알고리즘

동적 하이퍼네트워크 알고리즘은 다음과 같은 방식으로 학습이 이루어진다. 먼저 그림 1에서 보는 것과 같이 노드 형태로 표시된 시공간 데이터가 있을 때, 이 데이터 중에서 임의의 시간 t 를 선택한 후의 타임 스텝만큼 임의의 공간적 위치에서 노드들을 선택하여 이를 연결하여 하이퍼에지(hyperedge)로 만든다. 하이퍼에지의 시간적 차원을 o_t , 공간적 차원을 o_s 라고 하면, 그림 1에서는 $o_t = 3$ 이고, $o_s = 2$ 인 경우로, 연두색과 빨간색으로 표시된 노드들을 연결하여 만든 하이퍼에지 2개를 표현하고 있다. 이런 식으로 다양한 시간 t 와 공간적 위치를 선택하여 여러 하이퍼에지를 만들게 된다. 이런 방식으로 미리 정해진 하이퍼에지 개수만큼 위의 작업을 반복하여 필요한 수의 하이퍼에지를 추출하게 된다. 그리고 이렇게 생성된 하이퍼에지들을 모아서 하이퍼네트워크로 만들게 된다. 이런 방식을 통해서 데이터의 일부분을 추출하여 저장하는 방식으로 동적 하이퍼네트워크 알고리즘은 학습을 하게 된다.




그림 1 하이퍼에지 추출

동적 하이퍼네트워크의 추론은 이렇게 생성된 하이퍼네트워크를 기반으로 한다. $(o_t - 1)$ 차원의 시드(seed) 데이터가 주어졌을 때, 다음 스텝의 데이터를 생성하기 위해서는 다음과 같은 방식으로 진행된다.

- 1 $(o_t - 1)$ 크기의 데이터와 하이퍼네트워크 상의 모든 하이퍼에지와 매칭을 한다.
 - 1.1 하이퍼에지와 데이터 간에 상응하는 위치에 해당하는 값들의 차이를 계산하고 이

	차이 값의 역수를 각 하이퍼에지의 가중치로 사용 (가중치가 높을수록 차이가 적음)
2	가중치가 높은 순으로 하이퍼에지를 정렬
3	가중치가 높은 순으로 정해진 개수만큼 하이퍼에지를 선택
4	선택된 하이퍼에지들의 마지막 스텝의 값들의 가중평균으로 추론하고자 하는 데이터로 사용
5	크기 o_t 의 윈도우를 이동하면서 1 ~ 4 의 작업을 원하는 생성 데이터 프레임 수만큼 반복 하여 원하는 크기의 데이터를 생성

표 1 동적 하이퍼네트워크 알고리즘의 추론 과정

위의 방식으로 처음에는 시드로 주어진 $(o_t - 1)$ 크기의 데이터만을 사용하여 추론을 하고, 그 다음부터는 윈도우를 하나 이동하여서 새로 생성된 데이터를 포함한 $(o_t - 1)$ 크기의 데이터를 이용하여 추론을 하게 된다.

2.2 동적 하이퍼네트워크 알고리즘의 점진적 학습 및 추론

동적 하이퍼네트워크 알고리즘은 학습 데이터에 존재하는 자질들간의 관계를 하이퍼에지라는 형태로 추출하여서 부분적으로 저장하는 알고리즘이다. 이러한 특성으로 인해서 동적 하이퍼네트워크 알고리즘은 점진적 학습에 적합한 알고리즘이다. 동적 하이퍼네트워크 알고리즘을 이용한 점진적 학습 과정을 설명하면 다음과 같다. 기존의 데이터로 학습이 완료된 상태의 하이퍼네트워크가 존재 했을 때, 추가적으로 새로운 데이터가 유입 되게 되면 유입된 새로운 데이터 내에서 하이퍼에지를 추가적으로 추출하여서 하이퍼네트워크에 저장하는 방식으로 점진적 학습을 할 수 있다.

2.3 동적 하이퍼네트워크 알고리즘의 스키마 분석 용이성

이전에 언급한 것처럼 동적 하이퍼네트워크 알고리즘은 하이퍼네트워크에 저장되어 있는 하이퍼에지라는 형태로 학습을 하는 알고리즘이다. 그리고 하이퍼에지가 갖고 있는 값은 학습 데이터에서 추출한 값들이다. 따라서 하이퍼네트워크에 존재하고 있는 하이퍼에지들을 살펴봄으로써 학습된 모델의 상태를 확인할 수 있다. 따라서 학습이 된 하이퍼네트워크의 하이퍼에지를 분석하는 방법으로 스키마 분석을 손쉽게 할 수 있다.

3 실험

이번 장에서는 동적 하이퍼네트워크 알고리즘을 통하여, Microsoft의 Kinect 센서로 수집한 사람 행동 데이터를 학습하고 추론하는 과정에서의 점진적 학습 분석과 스키마 분석을 하는 실험에 관하여 설명한다. 먼저 사용한 데이터에 대해 설명하고, 실험 방법을 설명한 후에 마지막으로 실험 결과를 정리하였다.

3.1 데이터

이 실험에서 사용한 사람 행동은 총 5가지로 정의하였다. 이 5가지 행동은 박수치기, 손 흔들기, 악수하기, 가라는 수신호, 오라는 수신호이다. 위의 5가지 행동을 반복하면서 Microsoft의 Kinect 센서와 Brekel Kinect 프로그램을 이용하여, BVH이라는 파일 형식으로 각 행동을 할 때의 모든 관절의 ZXY축에 대한 각도 값을 기록하였다. 이렇게 기록된 파일에는 관절이 양 팔에 4개씩, 다리에 3개씩, 머리, 목, 척추, 엉덩이에 1 개씩 총 18개가 존재하고, 각 관절마다 ZXY축에 대한 회전각 값이 하나씩 존재하여, 총 54 차원의 데이터가 존재한다. 각 행동 데이터는 30 FPS로 기록 되었으며, 총 프레임 수는 200~300 프레임 정도 된다.

이렇게 BVH 형식으로 기록한 파일에 존재하는 54 차원의 데이터를 추출한 후, 다운샘플링하여 학습데이터를 만들었다. 각 행동 별로 5번씩 데이터를 수집하여 점진적 학습 실험을 하였고, 추가로 각 행동 별로 5번씩 데이터를 더 수집하여, 행동마다 총 10개의 데이터로 스키마 분석을 하였다.

3.2 점진적 학습 실험

3.2.1 실험 방법

여기서부터는 박수치기, 손 흔들기, 악수하기, 가라는 수신호, 오라는 수신호 행동을 각각 a_{dap} , a_{wave} , $a_{handshake}$, a_{go} , a_{come} 이라고 정의하고, 각 데이터의 i 번 째 데이터를 a_{dap}^i , a_{wave}^i , $a_{handshake}^i$, a_{go}^i , a_{come}^i 이라고 한다.

점진적 학습을 검증하기 전에, 동적 하이퍼네트워크 알고리즘의 기본적 학습 성능을 검증하기 위한 실험을 진행하였다. 행동 데이터 중 a_{dap}^1 만 학습한 후에 a_{dap}^1 , a_{dap}^2 , a_{dap}^3 의 세 데이터의 각각 처음 2 프레임을 시드로 주어서 재생성 실험을 하였다.

점진적 학습을 검증하기 위해서 2가지 실험을 진행하였다. 전체적인 실험 과정은 그림 2와 같다. 먼저 Microsoft의 Kinect 센서를 통하여 관절데이터를 기록하여 데이터를 만들어 놓은 상태에서, 2장에서 설명한 것과 같이 하이퍼에지들을 추출(sampling)하는 과정을 통해서 학습을 하고, 다음으로 하이퍼네트워크를 기반으로 추론하여 관절 데이터를 재생성하는 방식으로 진행되었다.




그림 2 사람 동작 학습 및 재생성 실험

점진적 학습 능력 검증을 위한 두 번의 실험 중에서 첫 번째 실험은 동일한 행동 종류로 진행하였다. 즉, 처음에는 각 행동 별로 a_i^1 에서 a_i^5 ($i = dp, wave, hands\ shake, go, ame$) 까지 점진적으로 학습하면서 재생성 실험을 하였다. 예를 들어, a_{dp} 의 경우를 보면 처음에는 a_{dp}^1 만을 학습한 후에, a_{dp}^1 의 처음 2 프레임을 시드로 주고 재생성을 하고, 다음에는 a_{dp}^2 를 추가적으로 점진적으로 학습한 후에, a_{dp}^1 와 a_{dp}^2 의 데이터의 각 처음 2프레임을 시드로 주고 각각 재생성을 하는 식으로, a_{dp}^5 의 데이터까지 진행한다. 이런 식으로 각 행동 별로 따로 실험을 한다. 재생성 성능 평가를 위해서는 재생성 된 데이터와 원본 데이터 사이의 Dynamic Time Warping (DTW)값을 사용한다. 모든 실험은 3번씩 반복하고, 각각의 실험을 통해 얻은 DTW의 로그 값에 평균을 취하였다.

두 번째로는 다른 종류의 행동 데이터를 이용하여 점진적 학습을 실험했다. 이 실험의 경우에는 각 행동 데이터의 첫 번째 데이터만을 사용하여 실험을 하였다. 이 실험은 $a_{dp}^1, a_{wave}^1, a_{handshake}^1, a_{go}^1, a_{ame}^1$ 을 하나씩 차례대로 점진적으로 학습을 하고 재생성을 하였다. 즉, 처음에는 a_{dp}^1 만을 학습하여 a_{dp}^1 의 처음 2 프레임

을 시드로 하여 재생성 실험을 하고, 다음에는 a_{wave}^1 를 추가적으로 학습하고, a_{dnp}^1 와 a_{wave}^1 의 데이터의 각 처음 2프레임을 시드로 주고 각각 재생성을 하는 식으로 a_{come}^1 까지 진행하였다. 이 실험의 경우에도 3번 반복하여서 DTW의 로그값을 각각 계산하여 평균을 취하였다.

3.2.2 실험 결과

기본적 학습 성능을 검증하기 위한 실험의 결과는 그림 3과 같다.




그림 3 한가지 행동 데이터만 학습하고 동일한 행동 다른 데이터를 시드로 하여 재생성한 결과

그림 3에서 위의 그래프는 a_{dnp}^1 의 데이터로 재생성을 한 결과이고, 아래 왼쪽 그래프는 a_{dnp}^2 으로, 아래 오른쪽 그래프는 a_{dnp}^3 으로 재생성을 한 결과이다.

다음으로 점진적 학습 검증 실험 결과는 그림 4와 같다. 그림 4에서 위의 그래프는 동일한 행동 종류만을 사용하여 실험한 결과이고 아래 그래프는 다른 행동 종류를 사용하여 실험한 결과이다.




그림 4 점진적 학습 검증을 위한 실험 결과

3.3 스키마 분석 실험

3.3.1 실험 방법

스키마 분석을 위한 실험은 다음과 같이 진행되었다. 먼저 학습의 측면에서 유사한 행동과 유사하지 않은 행동을 찾기 위하여 학습이 완료된 모델의 상태를 시각화하였다. 이를 위해 5가지 행동에 대하여, 각 행동 별로 10개의 행동 데이터를 학습하였다. 학습은 a_{clap} , a_{wave} , $a_{handshake}$, a_{go} , a_{come} 순서대로 각 행동의 10개의 데이터를 차례대로 학습하였다. 즉, 먼저 a_{clap}^1 에서 a_{clap}^{10} 까지 차례대로 점진적으로 학습하고, 다음에 a_{wave}^1 에서 a_{wave}^{10} 까지 차례대로 학습하는 방식이었다.

이렇게 동적 하이퍼네트워크 알고리즘을 통해 학습된 데이터는 하이퍼에지의 형태로 저장되어 있다. 따라서 하이퍼에지의 분포를 보는 것을 통해서 학습된 상태를 확인할 수 있으므로, 하이퍼에지의 분포를 시각화하였다. 이 실험에서는 하이퍼에지의 차원(order)을 3차원($o_t = 3, o_s = 1$)으로 하였다. 여기서 하이퍼에지의 시간 t 에서의 값을 x 좌표, $t+1$ 에서의 값을 y 좌표, $t+2$ 에서의 값을 z 좌표로 하여 하이퍼에지들을 3차원 그래프로 그릴 수 있다. 학습 데이터의 54 차원 중에서 모든 행동에 대해서 움직임이 많은 오른쪽 팔꿈치의 관절 데이터를 사용하였다. 이렇게 그린 그래프를 기반으로 가장 비슷한 분포를 보이는 행동 쌍과 가장 다른 분포를 보

이는 행동을 한 쌍을 해서 총 두 쌍을 선택하였다.

이렇게 선택된 행동 두 쌍과 악수하기 동작에 대해서 재생성 실험을 진행하였다. 재생성 실험의 전체적인 과정은 점진적 학습 실험과 비슷하게 진행되었다. 실험은 다음과 같은 행동 쌍을 대상으로 진행하였다.

- $(a_{sin_tur_1}, a_{sin_tur_2})$
- $(a_{sin_tur_2}, a_{sin_tur_1})$
- (a_{diff_1}, a_{diff_2})
- (a_{diff_2}, a_{diff_1})
- $(a_{handshake}, a_{handshake})$

참고: $(a_{action_1}, a_{action_2})$: a_{action_1} 데이터로 학습, a_{action_2} 데이터로 시드로 재생성
 $a_{sin_tur_i}$: 가장 비슷한 행동 쌍, a_{diff_i} : 가장 다른 행동 쌍

표 2 스키마 분석 실험 대상

점진적 학습 재생성 실험과 같이 성능 평가를 위하여 원본 데이터와 재생성된 데이터 사이의 DTW 값을 사용하였다. 위의 쌍마다 각각 3번씩 실험을 반복하여서 평균을 내서 사용하였다. 그리고 $a_{sin_tur_i}$ 와 a_{diff_i} 의 경우에는 각각 학습 데이터와 시드 데이터를 바꿔서 실험해서 얻은 두 개의 평균값을 다시 평균값을 취해서 해당 쌍의 평가기준으로 사용하였다.

3.3.2 실험 결과

동적 하이퍼네트워크 알고리즘으로 학습한 하이퍼네트워크에서 오른쪽 팔꿈치 관절의 X축에 대한 각도 값에 대한 하이퍼에지의 분포를 3차원 공간에 그리면 그림 5와 같다. 그림 5에서 보이는 것과 같이 가장 근접한 분포를 보이는 것은 $a_{handshake}$ 와 a_{come} 이다. 그리고 이와는 반대로 가장 다른 분포를 보이는 것은 a_{dip} 과 a_{go} 이다. 이는 하이퍼에지의 각 행동 별 분포의 중점들을 비교해도 같은 결과를 얻을 수 있다. 그림 5에서 X자로 표시된 점이 각 분포의 중점인데, $a_{handshake}$ 와 a_{come} 의 분포가 집중되어 있는 부분을 확대한 것이 그림 6이다. 그림 6에서 빨간색 원으로 표시된 부분이 $a_{handshake}$ 와 a_{come} 의 하이퍼에지 분포의 중점을 표시한 부분이다. 그림 5와 그림 6으로 봤을 때, $a_{handshake}$ 와 a_{come} 의 중점이 거리가 가장 가깝고, a_{dip} 과 a_{go} 의 중점의 거리가 가장 멀다. 즉, 분포와 분포의 중점 사이의 거리로 판단하였을 때, $a_{handshake}$ 와 a_{come} 이 가장 유사한 행동이며, a_{dip} 과 a_{go} 가 가장 상이한 행동임을 알 수 있다.




그림 5 오른쪽 팔꿈치 관절의 X축 회전각에 해당하는 하이퍼에지 분포




그림 6 약수하기와 오라는 수신호의 하이퍼에지 분포 부분을 확대한 그림

이렇게 찾아낸 가장 유사한 ($a_{handshake}, a_{come}$), 가장 상이한 (a_{clap}, a_{go})과, 대조군인 ($a_{handshake}, a_{handshake}$), 이렇게 총 세 쌍을 대상으로 학습, 재생성 실험을 하여서 구한 에러 값인 DTW의 로그 값을 계산한 결과는 그림 7과 같다. 그림 7을 보면, 모든 데이터 수의 경우에 대해서 동일한 행동 종류로 학습을 하고, 재생성을 하였던 ($a_{handshake}, a_{handshake}$)의 경우가 DTW의 로그 값이 가장 작았고, 그 다음으로 가장

유사했던 ($a_{handshake}, a_{come}$)의 경우가 그 다음으로 DTW의 로그 값이 작았고, 마지막으로 가장 상이했던 (a_{clap}, a_{go})의 경우가 DTW의 로그 값이 가장 큰 것으로 나타났다.




그림 7 행동 별 데이터 수에 따른 어려움 비교

4 결론

이번 장에서는 실험한 결과를 요약하고 논의 하며, 그리고 이번 연구에서 부족했던 점 및 추후 연구에 대해서 논한다.

4.1 실험 결과 논의

실험을 통하여 동적 하이퍼네트워크 알고리즘은 기본적인 학습을 할 수 있다는 것을 검증하였고, 더 나아가 점진적 학습이 가능함을 확인하였다. 하지만 점진적 학습의 어려움으로 사용하였던 DTW의 로그값이 데이터 수가 증가함에 따라 오히려 증가하기도 하였다. 이는 동적 하이퍼네트워크 알고리즘이 여러 가지 파라미터에 영향을 받기 때문이라고 생각된다. 예를 들어, 하이퍼에지의 개수를 높게 잡았을 경우 특정 데이터에 의존적이 될 수 있으므로 성능이 감소할 수 있다. 하지만 이런 점을 고려하더라도 점진적 학습이 가능함을 확인할 수 있었다.

스키마 분석을 위한 실험한 결과에서 학습한 후의 하이퍼에지들의 분포로 판단할 때, $a_{handshake}$ 와 a_{ome} 의 행동이 학습했을 때 가장 유사한 분포를 보이는 것을 확인할 수 있었다. 이는 두 행동의 유사성을 생각했을 때 어느 정도 예상 가능한 결과임을 알 수 있다. 이와는 반대로 a_{dp} 와 a_{go} 가 제일 다른 분포를 보임을 확인하였고, 이 또한 행동의 차이를 봤을 때도 추측 가능한 결과이었다.

그리고 선택된 행동 쌍을 통해 재생성 실험을 해 본 결과 동적 하이퍼네트워크 알고리즘이 스키마 학습이 가능함을 확인하였다. 학습한 모델의 하이퍼에지의 분포가 비슷한 $(a_{handshake}, a_{ome})$ 으로 실험한 결과와 다른 행동 쌍으로 실험한 결과와 비교를 해 보면, 학습한 행동과 시드로 이용한 행동의 종류가 같은 경우($(a_{handshake}, a_{handshake})$)의 DTW의 로그 값보다는 크지만 가장 분포가 달랐던 (a_{dp}, a_{go}) 의 쌍으로 대상으로 한 DTW의 로그 값보다는 작았다. 이는 $(a_{handshake}, a_{ome})$ 의 경우 두 행동 중의 하나만을 학습할 때 스키마가 형성되면서 학습이 이뤄지므로, 학습할 때 사용하지 않았던 행동의 데이터를 시드로 주어져도, 학습하면서 형성된 스키마를 활용하여 생성을 하게 되므로 에러로 볼 수 있는 DTW의 로그 값이 비교적 다른 행동이라고 볼 수 있는 (a_{dp}, a_{go}) 의 쌍의 경우보다 작게 나오게 된 것이다.

4.2 추후 연구

재생성 실험에서 생성된 데이터의 원본 데이터와 비교할 때 기준으로 Dynamic Time

Warping (DTW) 값을 계산하여 로그 값을 취하여 사용하였다. 하지만 정확한 비교 기준이 없어서 DTW 값을 사용하였는데 보다 정확한 기준이 필요할 것이다. 또한 분포가 비슷한 행동 쌍을 찾을 경우에는 분포를 그래프로 그린 후에 보는 방법과 분포의 중점의 거리로 찾는 방식으로 하였는데, 분포를 비교하는 수학적 방법이 필요로 하다.

이 논문에서는 동적 하이퍼네트워크 알고리즘이 점진적 학습이 가능함을 실험을 통해 확인하였다. 하지만 또한 점진적 학습 및 추론의 성능을 향상시킬 필요가 있음을 확인하기도 하였다. 그렇기에 이 동적 하이퍼네트워크 알고리즘의 점진적 학습 및 추론 성능을 향상시킬 추가적인 연구가 필요로 하다.

그리고 이 논문에서는 동적 하이퍼네트워크 알고리즘의 스키마가 형성이 되는 지만을 분석했지만, 이 알고리즘의 스키마 학습 성능을 향상시키기 위한 추후 연구가 더 필요로 하다. 그리고 Piaget에 의하면 새로운 경험을 하게 되면 새로운 스키마가 만들어지거나 기존의 스키마가 수정되기도 한다고 하였다. 이러한 스키마의 변화 과정이 동적 하이퍼네트워크 알고리즘으로 새로운 데이터를 학습하면서도 일어나는지를 확인할 필요가 있다.

참고문헌

- [1] O. Arikian, D. A. Forsyth, Interactive Motion Generation from Examples, *ACM Transactions on Graphics*, Vol. 21, No. 3, pp. 483-490, 2002.
- [2] C. K. Liu, A. Hertzmann, and Z. Popvic, Learning Physics-Based Motion Style with Nonlinear Inverse Optimization, *ACM Transactions on Graphics*, Vol.24, pp. 1071-1081, 2005.
- [3] G. W. Taylor, G. E. Hinton and S. Roweis, Modeling Human Motion Using Binary Latent Variables, *Advances in Neural Information Processing Systems*, pp. 1345-1352, 2007.
- [4] B.-T. Zhang, SNU Videome Project: Human-level machine learning from videos, *Communications of the Korean Institute of Information Scientists and Engineers*, 29(2):17-31, 2011
- [5] M. A. Arbib, Schema Theory, *In the Encyclopedia of Artificial Intelligence*, 2nd Ed., Wiley-Interscience, pp. 1427-1443, 1992.
- [6] N. Dominici et al., Locomotor Primitives in Newborn Babies and Their Development, *Science*, Vol. 334, No. 6058, pp. 997-999, 2011.
- [7] R. Platt, R. A. Grupen, and A. H. Fagg, Improving Grasp Skills Using Schema Structured Learning, *In proceedings of the Fifth International Conference on Development and Learning*, 2006.
- [8] 장병탁, 차세대 기계학습 기술, *정보과학회지*, 2007, 25(3).
- [9] C. M. Bishop, “Pattern Recognition and Machine Learning”, Springer, 2006, pp. 143-144.
- [10] B.-T. Zhang, Hypernetworks: A molecular evolutionary architecture for cognitive learning and memory, *IEEE Computational Intelligence Magazine*, 3(3):49-63, 2008.