

불균형 데이터 집합에서의 학습을 통한 microRNA 목표 유전자 예측 방법

이제근^{01,2} 김수진^{1,2} 장병탁^{1,2,3}

서울대학교 생물정보학 협동과정
서울대학교 바이오정보기술 연구센터(CBIT)
서울대학교 컴퓨터공학부

jkrhee@bi.snu.ac.kr, sjkim@bi.snu.ac.kr, btzhang@bi.snu.ac.kr

microRNA target prediction by learning from imbalanced datasets

Je-Keun Rhee^{01,2} Soo-Jin Kim^{1,2} Byoung-Tak Zhang^{1,2,3}

Graduate Program in Bioinformatics, Seoul National University
Center for Bioinformation Technology (CBIT), Seoul National University
Department of Computer Science & Engineering, Seoul National University

요 약

기계학습을 이용한 분류 문제에서 적절한 학습 데이터의 사용은 분류 정확도에 많은 영향을 미치게 된다. positive 데이터와 negative 데이터로 구성된 일반적인 이진 분류 문제의 경우, 충분한 학습 데이터 뿐 아니라 각 데이터 집합에 존재하는 데이터 수의 균형 역시 분류 정확도를 높이는 데에 중요하다. 하지만 실제 문제에서는 이와 같은 조건을 항상 만족하기는 쉽지 않다. 특히 생물학 데이터 분류 문제에서 positive 데이터만 존재할 뿐, negative 데이터는 존재하지 않거나 학습을 위해 사용하기에는 그 수가 부족한 경우가 많다. 이와 같은 상황에서는 많은 경우에 임의로 negative 데이터를 구성하여 학습에 사용하거나 기존 데이터로부터 여러 가지 샘플링 방법을 이용하여 각 집합의 비율을 맞춰서 학습을 수행하게 된다. 하지만, 이와 같은 방법으로 negative 데이터를 구성하는 것은 사용된 데이터의 특성에 따라 분류 성능 및 모델의 특성에 많은 차이를 보이는 기계학습 방법들의 일반적인 특성들을 생각해볼 때 적절한 방법이 아니다. 따라서 본 논문에서는 여러 가지 단일 클래스 분류기의 분류 방법을 실제 microRNA 목표 유전자 예측 문제에 적용하여, 단일 클래스 분류기의 이용이 불균형 데이터 집합에서의 분류 문제에 적합하게 적용될 수 있음을 확인한다.

1. 서 론

기계학습(machine learning) 기법은 데이터를 군집화(clustering)하거나 분류(classification)하기 위한 목적으로 유용하게 사용되는 방법이다. 특히 기존의 알려진 데이터를 기반으로 하여 새로운 데이터의 클래스를 분류하는 방법은 생물학적 연구에서 유용하게 사용될 수 있다. 기존의 전통적인 생물학 연구에서의 실험 방법과는 달리, 생물정보학(bioinformatics)적인 연구를 통해 컴퓨터를 이용하여 그 결과를 미리 예측해보는 것은 생물학 연구와 각종 의약학적 응용에서 많은 도움이 될 수 있다. 실제로 기계학습 기법들은 DNA 서열 및 각종 구조 정보를 이용한 유전자 및 그 기능 예측, 임상 정보와 유전자 발현 정보에 기반한 질병 진단 및 질병 요인 탐색, 단백질 상호작용 정보 예측 등 다양한 목적으로 널리 사용되고 있다[1, 2, 3].

분류를 목적으로 하는 기계학습 기법들은 많은 종류가 존재한다. 이 중 가장 많이 사용되는 대표적인 방법들은 의사결정 나무(decision tree), 인공 신경망(artificial neural networks), 베이즈안망(Bayesian networks), 서포트 벡

터 머신(support vector machine, SVM) 등이다. 이들 방법들은 각각 나름대로의 특징들을 가지고 있기에, 그 목적에 따라 적절한 분류 기법을 사용하게 된다. 하지만 이들 방법들은 기본적으로 학습 데이터에 기반하여 모델을 만들어 분류를 수행하므로, 학습 데이터의 구성 및 그 특성에 따라 그 성능에 차이를 보이게 된다. 이진(binary) 분류 문제의 경우 학습 데이터는 positive 데이터와 negative 데이터로 구성된다. 일반적으로 각 데이터는 충분한 수의 학습 데이터를 이용하여 전체 모집단의 데이터 분포를 대표할 수 있어야하며, 각 학습 클래스 집단의 데이터 수에서도 어느 정도 균형이 맞는 경우에 좋은 분류 모델을 만들 수 있다. 하지만 실제 문제에서는 이와 같은 조건을 완벽하게 만족하기 어렵다. 모집단의 분포를 정확하게 알고 반영하는 것이 실질적으로 불가능할 뿐 아니라, 알고 있는 사실이 한정된 상황에서 각 집단에 속하는 데이터 수의 균형을 맞추는 것 역시 간단하지 않은 일이다. 특히 생물학 문제에서는 이와 같은 문제가 더욱 빈번하게 나타난다. 첫 번째 문제는 생물학적인 현상에 대해 기본적으로 알려진 사실이 충분히 많지 않은 경우가 많다는 점이다. 이로 인해 대부분의 경우

학습 데이터 수가 분류 모델을 이용하기에 충분치 않은 경우가 많다. 또한 기존에 연구된 사실이 전체 생물학적인 현상을 반영하는 것이 아니라는 점도 문제가 될 수 있다. 실제로 positive 데이터는 기존에 알려진 사실들에 기반하여 학습 데이터를 구성하는 것이 가능하지만 negative 데이터의 경우 특정 현상에 대해 이것이 실제로는 전혀 일어날 수 없는 사실인지, 혹은 실제로는 가능하지만 아직 실험적인 어려움으로 밝혀내지 못한 것인지를 구분하는 것이 어렵다. 따라서 생물학 문제에서는 많은 경우에 negative 데이터를 명확하게 정의하기에는 어려움이 있다. 따라서 많은 경우에서 positive 데이터에 비해 negative 데이터가 부족한 현상이 나타나며, 이러한 데이터 집합 간에 그 수의 불균형으로 인해 적절한 분류 모델을 만드는 데에 많은 어려움이 발생하게 된다.

Negative 데이터가 존재하지 않거나 부족한 문제를 해결하기 위한 한 가지 방법은 임의(random)로 negative 데이터를 발생시켜서 이를 학습 데이터로 사용하는 것이다. 이와 같은 방법을 이용하면 데이터 수의 균형은 맞출 수 있지만 임의로 만들어진 데이터가 실제로 negative인지는 증명할 수 없다. 다른 방법으로는 샘플링(sampling)을 이용하는 방법이 있을 수 있다. 샘플의 수가 많은 positive 데이터 집합에서 일부 데이터만을 추출하여 negative 데이터 집합과 데이터 수의 균형을 맞추는 것이다. 하지만 이와 같은 방법은 대부분의 생물학 문제에서 학습을 위한 데이터가 전체적으로 부족하다는 점을 생각해볼 때, 보다 적은 학습 데이터만을 이용하여 분류 모델을 만들게 되는 것이므로, 적절한 분류 모델을 만들 수 있는 방법이라 보기 어렵다. 반대로 학습 데이터가 부족한 negative 데이터 집합에서 반복적으로 중복 추출을 통해 데이터 균형을 맞추는 방법도 있다. 이 방법은 기존의 positive 데이터를 모두 사용할 수는 있지만, 일부 편중(bias)되어있을지도 모르는 negative 데이터 집합 데이터를 반복 사용함으로써 과적합(overfitting)의 문제가 쉽게 나타날 수 있다.

따라서 본 논문에서는 이와 같은 데이터 불균형 문제점을 해결하기 위한 방법으로서 단일 클래스 분류기(one-class classifier)를 사용한다. 일반적인 분류 모델이 이진 분류, 혹은 다중 분류 문제를 다룰 수 있는 데에 비해, 단일 클래스 분류기는 positive 데이터에 기반하여 특이점(outlier)을 구분한다. 따라서 positive 데이터에 비해 negative 데이터가 소량만 존재하는 경우에도 효과적으로 분류하고 예측하는 것이 가능하다. 따라서 최근 이슈가 되고 있는 microRNA 목표 유전자 예측 문제에 다양한 단일 클래스 분류기 모델을 이용하여, 생물학 문제에서의 클래스 불균형 문제의 해결 가능성을 확인한다(그림 1).

2. 단일 클래스 분류 방법

단일 클래스 분류기에는 여러 가지 방법이 존재한다[4]. 이 중 본 논문에서 사용한 다섯 가지 방법에 대해 간단하게 소개한다.




그림 1 전체적인 실험 개요

2-1. Support vector data description (SVDD)

SVDD는 분류 대상이 되는 하나의 학습 클래스에 속한 데이터만을 이용하여 학습을 수행할 수 있는 단일 클래스 문제(one-class classification problems)를 해결하는데 유용한 기법 중 하나이다. 이진 분류에서 우수한 성능을 보이는 SVM을 변형하여 만들어진 이 방법은 그림 2와 같이 특이점(outlier)을 검출하여 주어진 목적(target) 데이터 대부분을 포함하는 구(hypersphere) 형태의 경계선을 찾는다[5]. SVM이 자질 공간(feature space)에서 두 클래스의 데이터를 선형으로 분류하기 위한 경계면(hyperplane)을 찾는 것을 목적으로 하는 것과는 달리 SVDD에서는 목적 데이터를 최대한 포함하는 최소한의 구 형태의 분류 경계선을 찾는 것이다.




그림 2 SVM과 SVDD의 기본 개념 비교

2-2. One-class K-nearest neighbor

K-nearest neighbor (K-NN) 방법은 가장 간단하게 사용될 수 있는 분류 방법 중 하나이다. K-NN은 테스트 데이터에서 가장 가까운 거리에 위치하는 K개의 데이터에 대한 클래스에 따라 데이터를 분류하는 방법이다. 단일 클래스 방법에서의 분류는 수식 (1)과 같이 수행한다.

$$target(x) = \begin{cases} 1 & \text{if } \frac{d(x, NN(x))}{d(NN(x), NN(NN(x)))} < \delta \\ -1 & \text{else} \end{cases} \quad (1)$$

수식 (1)에서 $d(\cdot, \cdot)$ 는 두 데이터 간의 거리를 의미한다. 데이터 x 에 대해 x 에서 가장 가까이 존재하는 다른 데이터를 $NN(x)$ 라고 했을 때, x 과 $NN(x)$ 에 대한 거리의 정규화(normalize)된 값이 특정한 상수 δ 보다 작은 경우에 샘플 x 가 목적 클래스의 값을 가지는 것으로 분류하는 것이다.

2-3. One-class K-means

일반적인 K-means 방법은 K 개의 집합으로 데이터를 군집화하고자 하는 목적으로 사용된다. 하지만, 조금 변형하면 K-means 방법을 군집화 대신 단일 클래스 분류기로서 사용하는 것이 가능하다. 데이터를 K 개의 집합으로 군집화한 후에, 새로운 데이터 x 에 대해 각 군집의 중심점(centroid)까지의 최소 거리에 따라 분류하는 것이다.

$$target(x) = \begin{cases} 1 & \text{if } \min_i (x - c_i)^2 < \delta \\ -1 & \text{else} \end{cases} \quad (2)$$

수식 (2)에서 c_i 는 i 번째 군집의 중심점을 의미한다.

2-4. One-class Gaussian

Gaussian 모델은 밀도 추정(density estimation)을 위해 사용되는 방법이다. 이 방법에서는 기본적으로 목적 클래스에 해당하는 데이터들이 가우시안 분포(gaussian distribution)를 따른다고 가정하여 학습 데이터로부터 가우시안 분포의 파라미터들의 적절한 값을 추정하여, 데이터의 전체 분포를 추정한다. 새로운 데이터 x 가 입력으로 들어오면, 식 (3)과 같은 방식으로, 이 값이 학습 데이터로부터 추정된 분포에 의해 잘 설명될 수 있는지에 따라 x 에 대한 목적 클래스를 결정한다.

$$target(x) = \begin{cases} 1 & \text{if } (x - \mu)^T \Sigma^{-1} (x - \mu) < \delta \\ -1 & \text{else} \end{cases} \quad (3)$$

식 (3)에서 μ 는 학습 데이터로부터 추정된 가우시안 분포의 평균값, Σ 는 공분산을 의미한다.

2-5. One-class PCA

주성분분석(Principal component analysis, PCA)은 일반적으로 차원 축소(dimension reduction) 등의 목적으로 주성분(principal components)이라 불리는 직교하는(orthogonal) 축으로 데이터를 사영(projection)시키는 방법이다. 단일 클래스 분류 문제에서는 식 (4)와 식 (5)에서와 같이 학습 데이터로부터 얻어진 PCA 분석 모델의 고유벡터(eigenvector) 및 고유값(eigenvalue)에 의해 만들어진 행렬 W 를 이용하여 새로운 데이터 x 를 사영시켰을 때의 에러값에 의해 목적 클래스를 결정하게 된다.

$$x_{proj} = W(W^T W)^{-1} W^T x \quad (4)$$

$$target(x) = \begin{cases} 1 & \text{if } \|x - x_{proj}\| < \delta \\ -1 & \text{else} \end{cases} \quad (5)$$

3. 문제 설명

3-1. microRNA 목표 유전자 예측

생체 내의 기능은 각 유전자의 발현에 의해 그 역할을 수행하게 되며, 이 유전자 발현 과정은 전사(transcription)와 번역(translation)의 과정을 통해 일어나며 생물학에서는 이를 중심이론(central dogma)라고 부른다. DNA로 되어있는 유전자는 전사 과정을 통해 mRNA로 발현되고, 여기서 다시 번역 과정을 통해 단백질(protein)로 발현되는 것이다. 생체 내에서 실제로 특정한 기능을 수행하는 것은 바로 이 단백질들의 작용에 의해서이다. 과거에는 전사 과정에서 작용하는 전사 조절 인자(transcription factors)에 의해 주로 유전자 발현이 조절되는 것으로 생각하였다. 하지만 번역 과정에서 유전자 발현을 조절할 수 있는 microRNA (miRNA)가 발견된 이후, miRNA에 의한 유전자 조절 과정에 대한 많은 새로운 연구들이 최근 들어 활발하게 수행되고 있다. miRNA는 약 22nt 크기의 작은 RNA 분자로서, 세포 내에서 miRNA는 유전자가 mRNA로 전사된 후, 그림 3에서와 같이 mRNA의 3' UTR 영역에 결합하여, mRNA가 단백질로 번역되는 것을 억제하는 역할을 수행한다[6]. 특히 miRNA들이 암을 비롯한 질병 발생 과정 등에도 중요한 영향을 미치는 것으로 알려지면서, miRNA 관련 연구는 생물학 연구에서 핵심적인 위치를 차지하고 있다.




그림 3 miRNA의 세포내 조절 기작

사람의 경우 수백 개의 miRNA가 존재하는 것으로 알려져 있으며, 이들 각각의 miRNA들이 어떤 유전자의 발현을 억제할 수 있는지 확인하는 것은 생명 현상 이해와 질병 연구와 치료제 개발 등의 목적을 위해 매우 중요한 문제이다. miRNA의 목표(target) 유전자 예측은 전 세계의 많은 연구자들에 의해 활발하게 수행되고 있다. 대표적인 목표 유전자 예측 방법들은 표 1에 보인다. miRNA 목표 유전자 예측은 일반적으로 상보적인 결합 서열 정보와 그 때의 구조 및 에너지 정보들에 기반하여 목표 유전자 가능성을 예측한다.

표 1 대표적인 microRNA 목적 유전자 예측 연구

Target연구	웹사이트
miRanda[7]	http://www.microrna.org/miranda.html
PicTar[8]	http://pictar.bio.nyu.edu
TargetScan[9]	http://genes.mit.edu/targetscan
miTarget[10]	http://cbiit.snu.ac.kr/~miTarget
RNAhybrid[11]	http://bibiserv.techfak.uni-bielefeld.de/rna-hybrid/welcome.html

3-2. 실험 데이터

microRNA 목표 유전자 예측을 위한 데이터는 기존의 miTarget 연구에서 사용된 데이터를 사용하였다[10]. miTarget 연구에서는 SVM 모델을 이용하여 miRNA 목표 유전자를 예측하였다. 이 데이터는 총 41개의 자질 집합(feature set)으로 구성되며, 각각에 대한 정보는 표 2에 보인다.

표 2 실험에서 사용된 feature 구성

Feature 구분	Feature의 특성
Structural Features	miRNA와 유전자가 결합하였을 때의 구조적 특성 정보
Thermodynamic Features	결합 에너지에 기반하여 얻어진 특성 정보
Position-based Features	각 위치별 서열 조성 정보

4. 실험 결과

본 논문에서의 miRNA 목적 유전자 예측은 miTarget 연구에서 사용한 데이터 중 152개의 문헌에서 증명된 positive 데이터와 30개의 negative 데이터를 이용하여

학습을 수행하였다. 표 3은 단일 클래스 분류기를 이용한 경우 5-fold cross-validation을 통해 얻어진 분류 정확도 결과를 보여준다. 표 3에서 SVDD는 support vector data description, KNNDD는 단일 클래스 K-NN 방법, Kmeans_DD는 단일 클래스 K-means 방법, Gaussian_DD는 단일 클래스 Gaussian 방법, PCA_DD는 단일 클래스 PCA 분류 방법을 사용했을 때의 분류 결과이다. 분류 결과는 positive 데이터와 negative 데이터에 대해서 각각의 에러율을 기준으로 보여준다.

표 3 분류 방법에 따른 SVDD 성능 변화

분류 방법	False positive	False Negative
SVDD	0.3361	0.5667
KNNDD	0.3290	0.7000
Kmeans_DD	0.3022	0.7000
Gaussian_DD	0.5510	0.3667
PCADD	0.4004	0.6000

본 연구는 positive 데이터와 negative 데이터 집합의 학습 데이터 수의 불균형 상황에서 단일 클래스 분류기를 사용함으로써보다 정확한 분류 모델을 만들 수 있는지 여부를 확인하는 것을 목적으로 한다. 이를 위해 동일한 학습 데이터를 이용하여 일반적으로 가장 높은 분류 성능을 내는 것으로 알려져 있는 이진 분류기(binary classifier)인 SVM을 이용하여 분류 결과를 비교해보았다. 표 4는 SVM을 이용한 경우의 분류 정확도를 보여준다.

표 4 이진분류기를 이용한 분류 정확도

	Accuracy	Sensitivity	Specificity
SVM	0.8516	0.9800	0.2000

이진 분류 SVM을 이용하여 분류하였을 때의 전체 분류 정확도(accuracy)는 85.16%이다. 이 값만을 보았을 때는 이진 분류 SVM을 이용하는 경우에도 정확한 분류가 가능한 것처럼 보인다. 하지만 민감도(sensitivity)와 특이도(specificity)의 측면을 함께 살펴보면 이 분류 결과가 정확한 결과라고 말하기 어렵다. 대부분의 다른 클래스 불균형 데이터 문제에서와 마찬가지로, 본 실험 결과도 데이터 개수가 적은 쪽의 클래스에 대한 예측 정확도가 매우 낮음을 알 수 있다. 즉, 클래스를 모르는 데이터가 들어왔을 경우, 학습에 사용된 negative 클래스에 해당하는 샘플 수가 매우 부족했기 때문에, negative 데이터들은 적절한 분류가 어려운 것이다. 따라서 이진 분류기를 이용하는 경우 표 5에서와 같이 positive 데이터에 대해서는 거의 정확한 분류가 가능하여 전체 분류 정확도는 높은 것처럼 보이지만, 실제로는 대부분의 데이터를 positive 클래스로만 예측하고 있는 것이다.




그림 4 각 분류방법에 따른 Specificity 비교

그림 4는 이진 클래스 SVM을 이용하였을 때와 단일 클래스 분류기들을 이용하여 분류한 경우의 특이도 값을 비교한 것이다. 이진 분류기인 SVM를 이용한 경우의 특이도를 다른 단일 분류기를 이용했을 때와 비교하면, 다른 어떤 단일 분류 방법과 비교해도 특이도가 낮음을 알 수 있다. 이는 클래스 불균형 데이터 집합에 대해서는 단일 클래스 분류기를 사용하는 것이 더 효율적일 수 있음을 보여주는 것이다.

본 실험 결과에서 한 가지 특이한 점은 단일 클래스 Gaussian 방법을 이용한 경우의 특이도가 다른 방법들에 비해 월등히 높다는 점이다. 물론 민감도 측면에서는 다른 방법들보다 성능이 낮기 때문에 절대적으로 이 방법이 좋은 방법이라고는 말할 수 없다. 하지만, 본 연구에서 사용한 데이터에 대해서는 단일 클래스 Gaussian 방법이 이상점에 해당하는 데이터를 잘 구분해낼 수 있다는 것을 보여주며, 이는 데이터를 구획화하는 형태로 분류하는 다른 일반적인 방법과는 달리 학습 데이터의 분포를 고려하는 Gaussian 분류 방법의 특성에 의해 이와 같은 결과가 나타난 것으로 보인다.

그림 5는 같은 데이터에 대해서 각각의 단일 클래스 분류기에 대한 분류 성능을 cost curve를 이용하여 표현한 것이다. Cost curve는 분류 성능 평가에 많이 사용되는 ROC curve와 비슷한 목적으로 다양한 분류 방법에 대한 분류 성능 평가 결과를 시각화하여 보기에 유용한 방법이다[12].

5. 결론

본 논문에서는 클래스 불균형 문제가 존재하는 생물학 데이터에 단일 클래스 분류 방법을 적용하여 그 결과를 확인해보았다. 데이터의 특성에 따라 그 결과는 물론 변화될 수 있지만, 본 연구의 결과를 볼 때 목적 클래스 불균형 데이터에서는 이진 클래스나 다중 클래스 분류기를 사용하는 것보다 그 목적에 따라서는 단일 클래스 분류기를 이용하는 것이 보다 효율적일 수 있음을 알 수 있다.




그림 5 각 단일 클래스 분류기에 대한 cost curve

기계학습을 이용한 분류 문제에서 분류 성능을 높이기 위해서는 사용하기 위한 적절한 분류기를 선정하고 최적의 성능을 내기 위한 파라미터를 조율하는 것이 중요하다. 하지만 기계학습 방법들이 학습 데이터를 기반으로 모델을 만든다는 점을 고려하면 이에 앞서 학습 데이터의 선정이 무엇보다도 중요한 문제임을 알 수 있다. 실제로 많은 경우에 학습 데이터의 특성은 진지하게 고려하지 않고, 분류 모델의 전체 정확도만 높이려고 하고 있다. 하지만, 실제 문제들, 특히 최근에 새롭게 밝혀져, 많은 연구가 진행되지 않은 중요한 문제들의 경우에는 학습에 이용하기 위한 데이터의 수가 부족한 점과, 클래스 불균형을 가질 수 있다는 점을 간과해서는 안된다. 또한 전체 분류 정확도 측면만 아니라, 다양한 분류 성능 측정 방법을 이용하여, 분류 결과가 과적합에 의한 결과거나 특정 클래스에 대해서만 분류를 잘하고 있는 것이 아닌지 확인해보는 것 역시 필요한 부분이다.

이와 같은 관점에서 볼 때, 본 연구에서 수행된 단일 분류기를 이용한 분류 방법은 생물학 연구에서 많이 존재하는 이런 문제점들을 해결하기 위한 하나의 좋은 해결책이 될 수 있다. 단일 클래스 분류기들은 기존의 전산학적, 공학적 연구에서는 전체 데이터에서 무의미한 정보(noise)나 이상점 등을 찾아내고자 하는 목적으로 주로 사용되어 왔으나 [13], 본 연구에서 보여주는 것과 같이 생물학 데이터에서의 클래스 불균형 데이터 문제를 해결하기 위한 방법으로도 유용하게 사용될 수 있을 것이다.

본 연구에서는 5가지의 분류기만을 사용하였으나, 이 외에도 많은 단일 클래스 분류 방법에 대한 연구가 많이 진행

되고 있다. 따라서 사용 목적 데이터의 특성에 따라 적절한 방법을 선택하여 이용하면, 일반적으로 많이 사용되는 이진 분류기를 사용한 것보다 효과적으로 불균형 데이터 문제를 해결할 수 있을 것이다. 또한 본 연구에서 단일 클래스 gaussian 방법의 특이도가 다른 방법에 비해 월등히 좋다는 점을 고려하면, 가우시안 혼합 모델(gaussian mixture model)에 기반한 단일 클래스 분류 방법을 이용하면, 보다 민감도와 특이도 양 측면 모두에서 우수한 성능을 보일 수 있을 것으로 기대한다.

참고문헌

- [1] A. Bernal, K. Crammer, A. Hatzigeorgiou, F. Pereira, Global Discriminative Learning for Higher-Accuracy Computational Gene Prediction, *PLoS Comput. Biol.*, 3(3): e54, 2007.
- [2] T.S. Furey, N. Cristianini, N. Duffy, D.W. Bednarski, M. Schummer, D. Haussler, Support vector machine classification and validation of cancer tissue samples using microarray expression data, *Bioinformatics*, 16(10): 906-914, 2000.
- [3] L. Nanni and A. Lumini, An ensemble of K-local hyperplanes for predicting protein-protein interactions *Bioinformatics*, 22(10): 1207-1210, 2006.
- [4] D.M.J. Tax, One-class classification: Concept learning in the absence of counter examples. Ph D Thesis, 2001.
- [5] D.M.J. Tax and R.P.W. Duin, Support Vector Data Description, *Machine Learning*, 54(1): 45-66, 2004.
- [6] D.P. Bartel, MicroRNAs: genomics, biogenesis, mechanism, and function, *Cell*, 116(2): 281-297, 2004.
- [7] B. John, A.J. Enright, A. Aravin, T. Tuschl, C. Sander, D.S. Marks, Human MicroRNA targets, *PLoS Biol.*, 3(7): e264, 2005.
- [8] D. Grün, Y.L. Wang, D. Langenberger, K.C. Gunsalus, N. Rajewsky, microRNA target predictions across seven Drosophila species and comparison to mammalian targets, *PLoS Comput. Biol.*, 1: e13, 2005.
- [9] B.P. Lewis, C.B. Burge, D.P. Bartel, Conserved seed pairing, often flanked by adenosines, indicates that thousands of human genes are microRNA targets, *Cell*, 120: 15-20, 2005.
- [10] S.-K. Kim, J.-W. Nam, J.-K. Rhee, W.-J. Lee, B.-T. Zhang. miTarget: microRNA target-gene prediction using a Support Vector Machine, *BMC Bioinformatics*, 7(1): 411, 2006.
- [11] M. Rehmsmeier, P. Steffen, M. Höchsmann, R. Giegerich, Fast and effective prediction of microRNA/target duplexes, *RNA*, 10: 1507-1517,

2004.

- [12] C. Drummond and R.C. Holte, Explicitly representing expected cost: An alternative to ROC representaiton, *Proc. of the Sixth ACM SIGKDD Intl. Conf. on Knowledge Discovery and Data Mining.*, 198-207, 2000.
- [13] V. Hodge and J. Austin, A Survey of Outlier Detection Methodologies, *Artif. Intell. Rev.*, 22(2): 85-126, 2004.