

ks 진화연산 기반 하이퍼네트워크 모델을 이용한 microRNA-mRNA 조절 모듈 분석

김수진^{01,2} 하정우³ 장병탁^{1,2,3}

서울대학교 생물정보학 협동과정

바이오지능기술연구센터(CBIT)

서울대학교 컴퓨터공학부

sjkim@bi.snu.ac.kr, jwha@bi.snu.ac.kr, btzhang@bi.snu.ac.kr

Analysis of microRNA-mRNA Regulatory Modules by Evolutionary Hypernetwork Models

Soo-Jin Kim^{01,2} Jung-Woo Ha³ Byoung-Tak Zhang^{1,2,3}

Interdisciplinary Program in Bioinformatics, Seoul National University

Center for Biointelligence Technology

School of Computer Science & Engineering, Seoul National University

요 약

microRNA (miRNA)와 mRNA는 질병 관련 메커니즘을 포함한 복잡 다양한 생물학적 과정에 영향을 주는 유전자 조절 네트워크의 중요한 부분을 구성한다. 생물학적 체계에서 중요한 조절 작용을 하는 miRNA는 각각의 목표 mRNA의 발현을 억제하거나 분해를 촉진시키는 메커니즘을 유도함으로써 암을 포함한 다양한 질병 발생 기전에 영향을 줄 수 있다. 따라서, 밀접하게 연관되어 상호작용이 추정되는 miRNA와 mRNA 조절 모듈 분석은 병리학적으로 흥미로운 연구라 할 수 있다. 본 논문에서는 다수 인자들 간의 상호 연관 관계 분석이 가능한 진화연산 기반의 하이퍼네트워크 모델을 이용하여 협력적으로 생물학적 조절 메커니즘에 참여하는 miRNA-mRNA 모듈을 발견하고자 한다. 제안된 하이퍼네트워크 모델은 세포적 분자 네트워크 작용 현상을 모방한 구조로서 기존의 그래프 모델과 달리 인자들간의 고차원 연관 관계를 학습함으로써 다수의 miRNA와 mRNA 요소간 상호작용 분석을 가능하게 하여 생물학적으로 유의한 miRNA-mRNA 조절 모듈을 효율적으로 탐색 할 수 있다. 본 논문에서는 miRNA와 mRNA 발현 데이터를 이용하여 특정 조건하에서 기능적으로 상관관계가 존재하는 miRNA-mRNA 조절 모듈을 탐색하여 생물학적으로 유의한 분석 결과를 실험결과로서 제시하고 있다.

1. 서 론

최근 생물학계에서 가장 중요한 발전 중 하나는 유전자 발현을 조절하는 다양한 RNA의 발견이다. 특히, 내생적 ~22 뉴클레오타이드(nt)로 구성된 작은 non-coding RNA 중 하나인 microRNA (miRNA)는 동물과 식물뿐만 아니라 바이러스에서도 유전자 발현을

제어하고 세포를 기능적으로 조절하는 중요한 역할을 하는 것으로 밝혀져 현 생물학계에서 주목 받고 있는 연구 대상 중 하나로 인식되고 있다. miRNA는 조직, 발생 특이적으로 발현되며 그것의 목표 유전자를 조절하여 단백질로 합성되는 과정에서 안정성을 떨어뜨려 mRNA의 분해를 촉진시키거나 mRNA의 3' UTR (Untranslated Region) 영역에 상보적으로

결합하여 단백질로 번역되는 것을 억제함으로써 유전자 조절 네트워크의 주요 메커니즘을 조절한다. 따라서 연구자들은 실험과 전산학적 접근 방법으로 생물학적 프로세스에서 miRNA의 기능을 알아내기 위해 많은 연구를 진행하였다[1,2]. 이를 위해 초기에는 miRNA와 그것의 목표 유전자를 찾는 것을 주요 초점으로 하는 연구가 수행되었다[3,4]. 또한, 다양하게 유전자 발현 프로파일링 측정 기술이 발달함에 따라 세포적 상태와 환경적 조건에 따라 다르게 발현되는 특이적 miRNA 탐색하고 그에 따른 기능적 분석이 가능하게 되었다[5,6]. 이 외에도 다양한 접근방법을 통해 miRNA 관련 연구가 지속적으로 활발히 진행되고 있다. 그런데 생체 내에서 중요한 역할을 하는 miRNA는 기능적으로 그의 목표 유전자를 조절함으로써 다양한 기전이 발생하기 때문에 복잡한 생체 시스템에서 miRNA의 조절 메커니즘을 이해하기 위해서는 miRNA와 mRNA 사이의 복합 상호작용에 수반되는 기능적 모듈을 찾는 것이 중요하다. 이에 Yoon and De Micheli은 전사 후 유전자 조절에서 수반되는 miRNA와 그것의 목표 유전자의 그룹을 찾는 miRNA 조절 모듈 분석을 위한 전산학적 방법을 제안하였다[7]. 제안한 모델은 miRNA와 mRNA의 발현 정보는 고려하지 않고 서열 수준에서 miRNA와 mRNA duplex에 관계하여 탐색한 결과를 보여준다. 그러나, miRNA와 mRNA 발현 정보는 특정 생물학적 프로세스에서 miRNA-mRNA 모듈을 탐색하는데 유용할 수 있다. 따라서, 최근에는 목표 유전자 정보와 발현 프로파일 데이터를 통합하여 기능적인 miRNA-목표 유전자 쌍을 발견하고자 하는 다양한 전산학적 모델들이 제안되었다[8,9].

본 논문에서는 다수 인자들 간의 상호 연관 관계 분석이 가능한 진화연산 기반의 하이퍼네트워크 모델을 이용하여 협력적으로 생물학적 프로세스에 참여하는 miRNA-mRNA 조절 모듈을 발견하고자 한다. 제안된 하이퍼네트워크는 2개 이상의 인자 간 연관 관계만을 표현 할 수 있는 기존 그래프 이론 한계를 극복하기 위해 제안된 하이퍼그래프의 한 종류로 복잡한 생물학 문제를 비롯해 실 세계 문제를 모델링 하는데 적합한 모델이며 다양한 도메인의 문제해결에 적용되어 왔다[11-12]. 더욱이 하이퍼네트워크 모델은 세포적 분자 네트워크 작용 현상을 모방한 구조로 인자들간의 고차원 연관관계를 학습함으로써 다수의 miRNA와 mRNA 요소간 상호작용 분석을 가능하게 하여 생물학적으로 유의한 miRNA-mRNA 조절 모듈을 효율적으로 탐색 할 수 있다.

본 연구에서는 제안된 하이퍼네트워크 모델을 miRNA와 mRNA 발현데이터[6,10]에 적용하여 정상과 달리 암에서 기능적으로 상관관계가 존재하는 miRNA-mRNA 조절 모듈을 탐색하였다. 이에 발견된 miRNA-mRNA 조절 모듈은 밀접하게 연관된 miRNA와 mRNA로 구성되어 생물학적으로 유의성을 보여주는 것을 확인할

수 있었다. 더 나아가, miRNA-mRNA 모듈 분석은 miRNA와 목표 유전자의 생물학적 검증뿐만 아니라 유전자 조절 네트워크의 재구성에 있어서도 매우 유용하다. 특히 miRNA-mRNA 모듈에 의해 나타난 새로운 조절 상호작용은 기존 유전자 조절 메커니즘에서 예측되지 못했던 부분을 추론 할 수 있는 근거가 될 수 있어 더 정확한 유전자 조절 네트워크 구축이 가능하게 할 것이다. 따라서, miRNA-mRNA 조절 모듈 발견 및 그것들의 기능적 상호작용 관계 분석을 통해 질병 메커니즘을 비롯하여 새로운 유전자 조절 기전을 이해하는데 있어 다른 시각을 제시 할 수 있을 것이라 기대된다.

본 논문의 나머지 부분은 다음과 같이 구성되어 있다. 2절에서는 본 연구에서 사용된 기계 학습 모델인 하이퍼네트워크에 대하여 설명하였으며 3절에서는 실험결과를 제시하고 이를 분석하였다. 그리고 마지막으로 4절에서는 본 논문 전체의 결론을 도출하고 향후 연구방향에 대하여 제시하고 있다.

2. 진화적 하이퍼네트워크 모델

2-1. 하이퍼네트워크 모델

Zhang[11]에 의해 제안된 하이퍼네트워크 모델은 확률적 그래프 모델의 한 종류로서 기존의 그래프와는 달리 2 개 이상의 정점(vertex)을 동시에 연결 가능한 하이퍼에지(hyperedge)로 구성된 그래프 모델이다. 하이퍼네트워크에서 정점은 데이터를 구성하는 인자(attribute)를 의미하며 하이퍼에지는 인자들간의 임의의 조합을 의미한다. 하이퍼에지가 k 개의 정점들의 조합을 나타낼 때 이를 k -차수(cardinality) 혹은 k -오더(order) 하이퍼에지라고 정의하며 k -오더 하이퍼에지들로만 이루어진 하이퍼네트워크를 k -uniform 하이퍼네트워크로 정의한다. 하이퍼에지의 오더가 높아지면 특화된 정보를 저장하는 특성이 있고 오더가 낮은 경우에는 표현되는 정보의 일반성이 높아진다. 그러므로 다양한 오더의 하이퍼에지 구성을 통해 복잡한 문제공간에 대한 표현 및 학습능력이 향상될 수 있다. 그 외의 하이퍼네트워크에 대한 용어 및 수학적 정의는 Zhang 의 연구[11]에 자세하게 설명되어있다.

2-2. 진화적 하이퍼네트워크 생성 및 학습

하이퍼네트워크는 데이터를 구성하는 인자들의 조합의 공간을 확률적으로 표현하는 모델이므로 그 표현공간이 인자의 수가 증가할수록 기하급수적으로 증가한다. 그리고 하이퍼네트워크에서의 학습은 매우 넓은 문제공간을 검색하는 과정이며 이를 현실적으로 가능하게 하기 위해 랜덤 샘플링 기반의 진화적 학습방법을 적용한다. 하이퍼네트워크를 생성하는

방법을 간략히 설명하면 아래와 같다.

- 1) 데이터를 훈련데이터와 테스트 데이터로 구분한다.
- 2) 훈련데이터가 주어지면 생성할 하이퍼에지의 오더만큼 랜덤하게 인자를 선택한다.
- 3) 2)에서 선택된 인자들의 조합으로 하이퍼에지를 구성하고 가중치를 초기화한다.
- 4) 3)에서 생성된 하이퍼에지를 하이퍼네트워크에 추가한다.
- 5) 2~4 까지의 과정을 모든 훈련데이터에 대하여 반복 수행한다.

하이퍼네트워크의 모델의 생성 방법은 Ha *et al.*의 연구[12]에 자세히 설명되어 있다. 기존의 대부분의 연구에서는 하이퍼네트워크는 이산화된 값으로 표현되는 인자들만으로 구성된 데이터만을 모델링하고 학습가능 했으나 Ha *et al.*[13]의 연구에서는 이를 극복하기 위해 인자 값들의 거리를 기반으로 하여 하이퍼에지와 데이터를 비교하는 방법을 제공함으로써 별도의 이산화 과정을 수행하지 않고 데이터의 패턴을 학습하는 방법을 제시하고 있다. 하이퍼네트워크의 학습방법을 간략히 요약하면 다음 같다.

- 1) 주어진 데이터에 대하여 하이퍼에지를 구성하는 인자값을 주어진 데이터 샘플의 인자값과 비교한다.
- 2) 하이퍼에지를 구성하는 모든 인자값이 데이터 샘플의 인자 값과 같은 경우에 대하여
 - ㄱ) 하이퍼에지의 클래스 레이블이 데이터 샘플의 클래스 값과 같으면 가중치를 증가
 - ㄴ) 그렇지 않은 경우 가중치를 감소
- 3) 모든 훈련데이터에 대하여 1~2 과정을 반복한다.
- 4) 가중치를 기준으로 하여 가중치 값이 낮은 일부 하이퍼에지들을 제거한다.
- 5) 4 에 의해 학습된 하이퍼네트워크를 훈련 데이터에 대하여 성능을 측정한다.
- 6) 4 에서 제거된 하이퍼에지의 수만큼 다시 랜덤하게 생성한다.
- 7) 1~6 과정을 정해진 횟수만큼 반복한다.

하이퍼네트워크의 학습 및 모델링과 관련해서는 Zhang의 연구[11]에 자세히 설명되어 있다.

2-3. 하이퍼네트워크를 이용한 인자들간의 연관관계 분석

위 절에서 언급했다시피 하이퍼에지는 인자들간의 조합을 나타내기 때문에 인자들간의 연관관계를

표현하게 된다. 그러므로 학습된 하이퍼네트워크를 구성하는 하이퍼에지의 구성을 분석함으로써 유의미한 인자들간의 연관관계를 찾아내는 것이 가능하다. 즉 하이퍼에지에서의 각 개별 인자 및 인자조합의 출현빈도를 산출하고 이를 기반으로 하여 인자의 중요도 및 인자 조합의 중요도를 측정하는 것이 가능하다. 중요도를 수학적으로 표현하면 y 를 클래스레이블, m 을 데이터를 구성하는 인자의 수, i 번째 인자 및 i 번째와 j 번째 인자의 조합을 a_i 및 a_{ij} 라 할 때, 클래스 y 가 특정값 c 인 경우에 대하여 각각의 중요도 $s_{i,y=c}$ 및 $s_{ij,y=c}$ 는 다음과 같이 정의된다.

$$s_{i,y=c} = \frac{F(freq(a_{i,y=c}))}{\sum_{y \in Y} freq(a_{i,y})} \quad (1)$$

$$s_{ij,y=c} = \frac{F(freq(a_{ij,y=c}))}{\sum_{y \in Y} \sum_{j=1}^m freq(a_{ij,y})} \quad (2)$$

위의 식에서 $freq(a)$ 는 i 번째 인자가 하이퍼네트워크를 구성하는 모든 하이퍼에지에서 출현하는 빈도수를 의미하여 F 는 임의의 함수이다. 위의 식이 의미하는 바는 특정한 클래스 레이블에 대하여 해당 인자 및 두 인자의 조합이 얼마나 중요성을 갖는지를 표현하며 수식의 분모 부분은 클래스에 관계없이 고르게 분포하는 경우에 페널티를 부여하는 역할을 한다. 3개 이상의 인자에 대한 연관관계는 위의 식을 확장함으로써 표현하는 것이 가능하다.

3. 실험결과

3-1. 실험 데이터 및 실험 조건

본 연구에서는 인간 암 관련 miRNA와 mRNA의 발현 프로파일 데이터를 사용하여 암 관련 miRNA-mRNA 조절 모듈을 분석하였다[6,10]. 적용한 miRNA와 mRNA 발현 데이터의 구성은 아래 표1과 같다.

표1. 실험 데이터의 구성

구분	miRNA	mRNA	형태	샘플 수
값	151	10,262	실수	정상21 / 암68

데이터의 인자가 실수형태이기 때문에 본 연구에서는 실수형 데이터를 학습 및 모델링 가능한 하이퍼네트워크모델[13]을 활용하였으며 실험에 사용된 파라미터는 각각 아래의 표2와 같다.

표 2. 하이퍼네트워크 파라미터 설정

구분	miRNA 오더	mRNA 오더	Sampling Rate	학습반복 횟수
값	3	10	100	10회

또한 miRNA-mRNA 조합의 중요 연관관계 모듈을 찾기 위해 2개의 인자 중요도를 이용하여 중요 조합을 선택하였다.

3-2. 분류 성능

우리는 하이퍼네트워크의 분류 정확도를 다른 기계학습 방법들과 비교하여 보았다. 표 3은 하이퍼네트워크, 결정 트리(J48), Naïve Bayes, k-Nearest Neighbor (kNN), Support Vector Machine (SVM)와 miRNA-mRNA 발현 데이터에 대한 분류 정확도를 비교한 결과이다. 10-fold cross validation로 수행한 결과, 하이퍼네트워크는 95.51 %의 정확도로 결정트리, Naïve Bayes, kNN보다 높은 성능을 보였고 SVM에도 비할만한 성능을 보여주었다. 그러나, SVM에 비해 하이퍼네트워크 모델은 분류뿐 만 아니라 직접적으로 해석 가능한 결과를 제공 할 수 있으므로 유전자를 비롯한 다수 인자간 상호작용 관계 분석이 필수적인 생물학 문제를 해결하는데 유용한 모델이라 할 수 있다.

표 3. 다른 기계학습 방법들과 성능 비교 결과

구분	결정트리	Naïve Bayes	KNN	Hyper network	SVM
정확도(%)	79.77	87.64	93.25	95.51	96.62

또, 그림 1 은 ROC커브를 이용한 하이퍼네트워크의 분류 성능을 표현한 것이다. ROC커브의 AUC (Area under Curve)값은 0.957로써 하이퍼네트워크 모델이 높은 성능을 보여주는 것을 알 수 있다.




그림 1. 하이퍼네트워크 분류성능의 ROC커브. TPR (True Positive Rate), FPR (False Positive Rate)은 암환자를 기준으로 한 값이다.

표 4. 하이퍼네트워크 모델에 의해 탐색된 miRNA-mRNA 조절 모듈

No.	miRNA	miRNA-mRNA 조절 모듈 mRNA
I	hsa-miR-182	IFI16, ARG1, ARSA, GSTK1, L13, NR2C2, SLC9A3
II	hsa-miR-321	GCNT1, DCTD, RIMS1, HSBP1, LOC388114, R3HDM2
III	hsa-miR-126	MRPL28, C15orf31, GSR
IV	has-miR-21	ATXN7L3, INPP4A, MPP3, MTMR9, IDH1

3-3. miRNA-mRNA 조절 모듈의 생물학적 유의성

표 4는 하이퍼네트워크 모델을 이용하여 탐색한 miRNA-mRNA 조절 모듈이다. 각 모듈을 구성하고 있는 miRNA는 기존 생물학적 연구를 통해 다양한 암 기전에 있어 중요한 조절 인자 역할을 한다고 보고되었다. 특히, hsa-miR-182, hsa-miR-126, hsa-miR-21은 여러 논문을 통해 암 메커니즘에서 주요 유전자 발현을 조절하는 기능을 하는 것이 입증됨에 따라 병리학적으로 암 진단, 치료에 있어 주요 조절 물질로 보고되었다. 또한, mRNA 역시 암 발생에 영향을 주는 유전자들이 다수 포함되어 있으며, 각 miRNA의 목표 유전자는 아니지만 각 목표 유전자와의 상호작용에 대한 새로운 추론이 가능하며, 이에 더 나아가 각 miRNA와 잠재적으로 관계를 내포하고 있는 유전자로 생물학적 유의성에 대해 분석 해 볼 수 있다.

4. 결론

본 논문에서는 다수 인자들 간의 상호 연관 관계 분석이 가능한 진화연산 기반의 하이퍼네트워크 모델을 이용하여 협력적으로 생물학적 프로세스에 참여하는 miRNA-mRNA 조절 모듈을 탐색하였다. 이에 우리는 높은 분류 성능과 더불어 암에 관련된 miRNA-mRNA 모듈을 분석 할 수 있었다. 제안한 방법에 의해 탐색된 miRNA-mRNA 조절 모듈은 실제 실험적으로 밝혀지지 않았지만 구성된 miRNA와 mRNA 간 상호작용에 대한 새로운 추론이 가능하며, 더 나아가 다양한 생물학적 메커니즘에서 아직 밝혀지지 않은 유전자 조절 기전을 이해하는데 새로운 시각을 제시 할 수 있을 것이라 기대된다.

감사의 글

이 논문은 산업자원부 차세대 신기술 개발 사업의 분자 진화 컴퓨팅(MEC) 과제, 지식경제부 및 한국산업기술평가관리원의 IT산업원천기술개발사업(2009-F-051-01,

차세대 맞춤형 서비스를 위한 기계학습 기반 멀티모달 복합 정보 추출 및 추천기술 개발), 교육인적자원부 학술진흥재단(KRF-2008-314-D00377) 및 컴퓨터연구소(ICT)에 의해 지원되었음.

참고문헌

- [1] Denli, A.M. *et al.* (2004), Processing of primary microRNA by the Microprocessor complex, *Nature*, 432, 231-235.
- [2] Han, J. *et al.* (2006) Molecular basis for the recognition of primary microRNA by the Drosha-DGCR8 complex, *Cell*, 125, 887-901.
- [3] Lewis, B.P. *et al.* (2005) Conserved seed pairing, often flanked by adenosine, indicated that thousands of human genes are microRNA targets, *Cell*, 120, 15-20.
- [4] Nam, J.-W. *et al.* (2006) ProMiR II: A web server for the probabilistic prediction of clustered, nonclustered, conserved and nonconserved microRNA. *Nucl. Acid Res.*, 34, W455-W458.
- [5] Thomson, J.M. *et al.* (2004) A custom microarray platform for analysis of microRNA gene expression, *Nat. Method*, 1, 47-53.
- [6] Lu, J. *et al.* (2005) MicroRNA expression profiles classify human cancers, *Nature*, 435, 834-838.
- [7] Yoon, S. and De Micheli, G. (2005) Prediction of regulatory modules comprising microRNAs and target genes, *Bioinformatics*, 21, ii93-ii100.
- [8] Huang, J.C. *et al.* (2006) Detecting microRNA targets by linking sequence, microRNA and gene expression data, *In Proceedings of RECOMB*, 114-129.
- [9] Zilberstein, C.B.-Z. *et al.* (2006) A high-throughput approach for associating microRNAs with their activity conditions, *J. Comput. Biol.*, 13, 245-266.
- [10] Ramaswamy, S. *et al.* (2001) Multiclass cancer diagnosis using tumor gene expression signatures, *PNAS*, 98(26), 15149-15154.
- [11] Zhang, B.-T. (2008) Hypernetworks: A molecular evolutionary architecture for cognitive learning and memory, *IEEE Computational Intelligence Magazine*, 3(3), 49-63.
- [12] Ha, J.-W. *et al.* (2009) Gender Classification with Cortical Thickness Measurement from Magnetic Resonance Imaging by Using a Feature Selection Method Based on Evolutionary Hypernetworks, *IEEE International Conference on Fuzzy Systems*, 41-46.
- [13] 하정우 외. (2008) 이산화 과정을 배제한 실수 값 인자 데이터의 고차 패턴 분석을 위한 진화연산 기반 하이퍼네트워크 모델, *한국컴퓨터종합학술대회 논문집*, 35, 1(A), 122-123.