

인공 신경망을 이용한 유머 문서의 협력적 여과

지도교수 : 장병탁

이 논문을 공학학사 학위 논문으로 제출함.

2000년 12월18일

서울대학교 공과대학
컴퓨터공학부
조영민

2001년 2월

인공 신경망을 이용한 유머 문서의 협력적 여과

서울대학교 공과대학
컴퓨터 공학부
97419- 079
조영민
stbinary@yahoo.com

요 약

정보의 바다로 일컬어지는 인터넷과 같은 무제한적인 정보 환경으로부터 필요한 내용만을 분별하고 선택하는 작업은, 최근의 인공지능 연구에서 주를 이루고 있는 분야인 에이전트 시스템에서 중요하게 다루어질 뿐만 아니라 기존 인공지능 분야인 정보 검색 분야에서도 연구의 관련성을 찾을 수 있다. 특히 에이전트 시스템에서는 개인의 정보를 이용하여서 신상품이나 문서로 대표되는 새로운 관련 정보를 선별적으로 받아들이는 정보 여과 기술이 크게 중요한 이슈 가운데 하나인 것으로 알려져 있다.

이러한 정보 여과를 하는 방법은 크게 내용기반 여과(content-based filtering)와 협력적 여과(collaborative filtering)로 나눌 수 있는데, 각각의 접근 방법은 고유의 장단점을 가지고 있기 때문에 서로 보완적인 관계에 있다고 할 수 있다. 특별히 이 논문에서는 협력적 여과에 초점을 맞추어서 여러 가지 실험을 진행하며, 기계 학습(machine learning)의 측면에서 인공 신경망(artificial neural networks)을 문제 해결에 적용시켜 보기로 한다.

즉, 간단히 협력적 여과의 개념과 문제가 정의되는 실험 환경을 설명한 후 논문에서 주제로 삼고 있는 인공 신경망을 어떠한 방식으로 사용자의 선호도 측정에 사용할 수 있는지를 살펴본다. 특히 동일한 실험 대상 환경에서 다양한 방식으로 인공 신경망을 변경하여 이때 어떤 성능상의 차이를 보이는가에 중점을 맞추어서 연구를 진행하며, 알고리즘의 성능을 향상시키는 기법으로 적용한 SVD(Singular Value Decomposition)의 효과도 제시하기로 한다.

1. 서론

1.1 연구 목적

우리는 최근 몇 년간 정보화 시대와 인터넷으로 대표되는, 수많은 정보의 폭발적인 성장세를 지켜보고 있다. 이러한 정보의 영역은 이전 시대부터 다루어졌던 단순한 형태의 뉴스나 메일로부터 시작하여 복잡한 멀티미디어에 이르기까지 매우 다양하기 때문에, 이미 한 개인이 정보의 홍수로부터 자신에게 도움이 되는 것만을 효율적으로 정확히 분별하고 선택하는 것은 거의 불가능해져 버렸다.

따라서, 컴퓨터 과학의 측면에서 볼 때, 이러한 정보의 홍수로부터 개인이 효율적인 방법으로 유용한 정보를 얻을 수 있도록 도와주는 정보 여과(information filtering) 기술이 매우 필요하게 되었다. 또한, 이와 더불어서 최근 관심이 집중되고 있는 인공지능 분야의 하나인 정보 에이전트 기술은 이러한 움직임을 더욱 가속화하고 있다. 에이전트는 처한 환경을 감지하고 그 변화에 적응하며 위임자를 대신하여 주어진 임무를 자율적으로 수행하는 지능형 소프트웨어로 정의할 수 있다[10].

예를 들어, 전자메일 사용자의 변화하는 관심사를 파악하여 메일박스에 있는 메시지에 대해 관심도의 우선 순위에 따라 재분류 해주고 경우에 따라서는 사용자가 부재 시에 도착한 전자메일에 대해 간단한 메시지로 응답해 주는 전자메일 에이전트를 생각할 수 있다. 또 다른 예로, 사용자의 웹 브라우징 행동을 분석하여 기호를 파악한 후, 사용자의 부재 시에 관심에 부합되는 웹 문서를 자동으로 검색하여 제시해 주는 정보 검색 에이전트나, 전자 상거래 환경에서 사용자의 구매 기록으로부터 구매 양식을 학습하여 후에 새로운 상품이 출시되었을 때 관심을 가질 사용자에게만 선별적으로 광고를 하는 상품 추천 상거래 에이전트를 생각할 수 있다[12].

결국, 이러한 에이전트의 활용 방안에서 볼 수 있듯이, 인터넷이나 월드와이드웹(World Wide Web)으로 대표되는 동적 정보 환경에서 개인의 취향을 효과적으로 분석하고 필요한 정보만을 선별하기 위해서는, 에이전트가 정보 여과 기술을 필수적으로 구비해야 하는 것이다. 그리고, 이 논문에서는 이렇게 그 중요성이 점점 더 강조되고 있으며, 동시에 많은 연구도 이루어지고 있는 분야인 정보 여과 기술 중 하나인 협력적 정보 여과 기술에 대해서 중점적으로 살펴보기로 한다.

1.2 연구 내용

정보 여과란 특정 사용자의 장기적인 정보 요구에 대하여, 동적인 성격을 가지는 어떤 정보 집합으로부터 지속적으로 적합한 정보만을 여과하여 제공하는 것을 말한다. 특정 사용자에게 필요한 정보를 제공하는 것을 목표로 하기 때문에, 사용자의 관심사항을 표현하기 위한 사용자 프로파일(user profile)을 기반으로 해서 사용자가 관심을 가지고 있을 만한 정보를 제공한다.

사용자 각각에게 가장 필요한 정보만을 제공하기 위해 해결해야 할 문제는 사용자의 정보 요구를 정확히 표현하고 학습하며 선호도의 변화를 학습하는 문제, 여과의 대상이 되는 문서나 상품과 같은 항목을 효율적이고 정확하게 표현하는 문제, 사용자의 정보요구와 아이템간 또는 사용자들간의 유사도를 측정하는 문제, 여과 과정을 거쳐서 사용자에게 추천한 정보가 얼마나 정

확한 정보이며 또한 사용자는 제공받은 정보에 대하여 얼마나 만족하는가를 측정하기 위한 문제 등이 있다.

정보 여과 시스템은 사용자의 정보 요구를 어떻게 표현하고 표현된 정보요구를 기반으로 어떤 방법으로 필요한 정보를 찾아내느냐에 따라 크게 내용기반 여과(content-based filtering)와 협력적 여과(collaborative filtering)로 나눌 수 있다. 이들 정보 여과 기술에 대한 추가적인 설명은 2장의 관련 연구 부분에서 자세하게 제시되지만, 간략하게 용어를 정의하면 다음과 같다.

내용기반 정보 여과는 사용자가 단어의 집합 등으로 표현한 프로파일이나 사용자가 지금까지 선호해 온 아이템을 분석하여 만든 프로파일을 기반으로 하여서, 이와 유사한 다른 아이템을 추천하는 방법이다. 즉, 내용기반 여과는 용어 그대로 정보의 내용을 분석해서 얻은 메타-정보(meta-information)를 가지고 여과를 하는 기술이라고 할 수 있다.

반면 협력적 정보여과는 다른 사용자들과의 선호도 비교를 통해 정보를 추천하는 방법이다. 특히, 협력적 여과가 주목을 받는 부분은 이러한 정보 여과 작업을 분류(classification) 문제로 가정할 경우에, 기계 학습(machine learning)의 측면에서 접근할 수 있는 여지가 많다는 점이다[2]. 즉, 정보 여과라는 문제를 특정한 아이템을 특정한 사용자가 선호할 것인지 아닌지의 여부로써, 아이템의 소속 그룹을 구분하는 작업으로 간주한다면, 기계 학습 분야에서 얻을 수 있는 다양하고 유용한 시도와 이를 기반으로 한 알고리즘들을 사용해서, 기존의 단순한 예측(prediction) 알고리즘보다 더욱 향상된 성능을 이끌어낼 수 있다는 것이다.

그리고 결국, 이번 논문에서는 이러한 관점을 가지고 지금까지 언급한 협력적 여과를 이용해서 실제로 웹 문서를 여과하는 실험을 진행하기로 한다. 특히 기계 학습의 측면에서는 인공 신경망(artificial neural networks)을 분류 문제 해결에 적용시키기로 하고, 성능의 향상을 위하여 singular value decomposition(SVD)이라는 수학적 기법도 도입하기로 한다. 참고적으로 이들에 대한 보다 자세한 설명은 3장에 나와있다.

1.3 연구 범위

앞에서도 언급했듯이 협력적 여과와 인공 신경망이 이번 논문의 핵심 주제이며, 조금 더 구체적으로 설명하자면 서울대학교 컴퓨터 공학부 대학원 인공지능 연구실의 연구 과제 중 하나인 *MrHumor* ([1]: a personalized internet agent that recommends humors and jokes)로부터 얻은 사용자 데이터베이스를 이용하여 구체적인 실험을 진행시킨다.

즉, *MrHumor* system을 이용하는 사용자들간의 취향을 비교하여, 이들로부터 특정 아이템(유머 문서)에 대한 특정 사용자의 등급 매김 값(rating value)이 어느 정도로 예측 가능한지의 여부로써 협력적 여과를 실험해본다. 그리고 이때 인공 신경망을 사용함으로써 얻을 수 있는 성능상의 이득을 관찰해보기로 한다. 특히 사용자 프로파일의 집합은 사용자와 유머 문서로 이루어진 행렬로 표현되고 행렬의 원소는 유머에 대한 등급 매김 값이 되는데, 이때 전체적인 효율 향상을 위하여 이러한 사용자 프로파일 데이터베이스를 압축하는 singular value decomposition(SVD)이라는 수학적 기법을 이용한다.

1.4 논문 구성

이번 논문은 에이전트 시스템 (*MrHumor*)의 협력적 여과 기술과 이를 위해 도입한 인공 신경망에 중점을 두어서 완성되었으며, 구체적인 논문의 구성은 다음과 같다.

우선, 2장에서는 관련 연구로서 기존의 다양한 정보 여과 알고리즘에 대해서 간략하게나마 살펴보고 실험의 대상이 되는 에이전트 시스템인 *MrHumor* 시스템을 설명한다. 다음으로 3장에서는 이번 논문에서 선택한 협력적 여과 모델에 대해서 살펴보고 어떠한 방식으로 인공 신경망과 singular value decomposition을 적용할 것인지에 대해서 언급한다. 그리고, 이러한 알고리즘을 사용하여 실제로 *MrHumor*의 데이터베이스를 가지고 다양한 실험을 수행한 후, 그 결과와 이를 토대로 분석한 내용이 4장에 제시되어 있으며, 최종적으로 5장에서는 논문의 결론과 향후 과제를 제시하는 것으로서 내용을 마무리한다.

2. Related Work

2.1 내용기반 여과 알고리즘

내용기반 여과는 사용자가 아이템들에 대해 매긴 정보, 즉 프로파일에 기반하여 아이템을 추천하는 여과 방식이다. 즉, 내용기반 여과는 콘텐츠(contents) 즉 정보와, 사용자의 취향을 비교하여 여과를 시도하는 것이며, 그 대표적인 예로서는 키워드 기반 여과가 꼽힌다. 구체적으로 내용기반 여과 기술이 사용된 정보 여과 에이전트로서는, 뉴스를 여과하는 NewsWeeder[13], 웹 문서를 여과하는 Amalthaea[14], InforFinder[15] 등이 있다.

내용기반 여과는 속도가 빠르고 협력적 여과만을 사용했을 때 발생하는 2.2절의 문제가 줄어든다는 장점이 있음에도 불구하고, 몇 가지 단점을 가지고 있는데, 구체적으로는 다음과 같은 것들이 있다[4].

- 평가되는 아이템은 텍스트와 같은 형태로 쉽게 다룰 수 있는 것이어야 한다. 소리, 영상과 같은 매체의 경우에는 현재 이에 대한 메타-정보를 추출하는 기술 개발이 이루어지고 있기는 하지만, 특히 아이템이나 사용자의 수가 급격히 증가하고 있는 시점에서 볼 때 아직까지는 내용기반 여과만으로는 사람과 같은 높은 수준의 여과 능력을 기대하기가 힘들다.
- 내용기반 여과에서는 근본적으로 우연하게 유용한 발견을 할 확률(serendipity)이 적다. 즉, 시스템은 기본적으로 사용자가 이미 이전에 호감을 보인 항목들에 대해서만 추천을 하기 때문에, 사용자가 아직 경험하지는 못했지만 유용하게 사용될 가능성이 높은 정보는 새롭게 제공하기 어렵다.
- 또한, 내용기반 여과는 품질(quality)이나 형식(style), 또는 관점 등에 의해서 정보를 분류하지 못한다. 예를 들면, 유용한 문서를 찾는 과정 중 대상으로 발견한

두 글에서, 동일한 단어를 사용하였지만 전혀 다른 관점을 가지고 서술되었거나, 내용의 질적인 측면에서 차이가 많이 난다고 할지라도 내용기반 여과는 이 둘을 구별하기 힘들다.

2.2 협력적 여과 알고리즘

협력적 여과는 사람들이 가지는 고유한 성향을 분석하여 정보 여과에 적용하는 방법으로서, 사용자가 많아지고 등급 매김(rating)과 같은 각 사용자들의 데이터가 많아지면, 사람들의 성향을 잘 표현할 수 있고 더욱 정확한 예측을 할 수 있다. 협력적 여과 기술이 실제로 상용화되어서 널리 사용된 예로는 유즈넷 뉴스를 여과하는 GroupLens[16]나 유머 문서를 제공하는 Jester[3], 음악을 추천하는 Ringo[4] 등이 있다[5]. 그러나 협력적 여과도 다음과 같은 문제점으로 인해 성능이 하락하기도 한다.

- 초기 측정자(early rater) 문제: 특정한 아이템이 새로 추가되었을 때, 그 아이템에 대해 사용자들의 기존 등급 매김 데이터가 없기 때문에 순수한 협력적 여과만으로는 그 아이템을 사용자에게 추천할 수 없다. 마찬가지로 새로운 사용자가 등록되었을 경우에도 이 사용자의 취향을 분석할 수 없으므로 다른 사용자들과의 유사성을 알아내기 위해서는 별도의 조치가 필요하다. 나아가서, 처음 등록되었을 뿐 아니라 아이템이나 사용자에 대한 등급 매김 데이터가 많지 않을 경우에, 그런 적은 수의 데이터를 가지고 사용자의 취향을 판단하는 것은 정확하지 못한 결과를 낼 가능성이 크다.
- 희소성(sparsity) 문제: 정보 여과가 다루는 대부분의 문제의 경우, 아이템의 개수가 매우 많기 때문에 모든 아이템에 대한 등급 정보를 표현하는 행렬은 매우 희소한 행렬이 된다. 따라서 이러한 문제로 인하여 순수한 협력적 여과 기술만으로는 정확한 예측을 하는데 문제가 생긴다. 참고적으로 이번 논문에서 적용한 SVD(singular value decomposition)는 희소성 문제를 해결하기 위해 아이템-사용자로 표현되는 데이터 행렬의 차원을 줄이는 방법이다.
- 특수한 사용자(gray sheep) 문제: 어떤 그룹에서든지 협력적 여과의 성향을 따르지 않는 사람들이 존재한다. 즉, 일반적인 사람들의 성향을 따르지 않는 개성이 강한 개인이 있기 때문이다. 이러한 경우에는 협력적 여과만으로 예측하는 것이 힘들어진다.

2.3 통계적 결과에 기반을 둔 협력적 여과 알고리즘

협력적 여과 기법은 매우 다양하지만, 그 중 대표적으로 통계적 결과에 기반을 둔 형태를 들 수 있으며, 이번 절에서는 특히 그 중에서도 2.2 절에 제시된 Ringo[4]에 적용된 여러 알고리즘을 다소나마 자세하게 살펴보기로 한다.

· Mean Squared Differences 알고리즘

두 사용자 프로파일간의 유사성 혹은 비유사성의 정도를 측정하는 것으로서, 아래의 식과 같이 mean squared error를 사용하여 표시할 수 있다. 이러한 알고리즘을 사용할 경우의 예측은 측정값이 일정 수준의 임계값 t 보다 작은 경우의 사용자들을 선별한 후, 이들의 등급 매김에 가중치를 주어서 평균을 내는 방식으로 행해진다. 즉, 가중치는 식 (1)을 이용하여 측정한 비유사도에 반비례하도록 설정한다.

$$\overline{(U_x - U_y)^2} \quad (1)$$

· 피어슨(Pearson) 상관 계수를 사용한 방법

널리 알려진 피어슨 상관 계수를 사용한 방법으로서, 역시 사용자 프로파일간의 유사성을 측정하며 이는 식 (2)를 이용하여 가능해진다.

$$r = \frac{S_{XX}}{\sqrt{S_{XX} S_{YY}}} = \frac{\sum XY - \frac{\sum X \sum Y}{N}}{\sqrt{(\sum X^2 - \frac{(\sum X)^2}{N})(\sum Y^2 - \frac{(\sum Y)^2}{N})}} \quad (2)$$

참고적으로, 식 (2)는 Z 스코어로 변환한다면, 식 (3)과 같이 간단하게 표현할 수 있다.

$$r = \frac{\sum Z_X Z_Y}{N} \quad (3)$$

이러한 상관계수는 통계적 이론에 의하여 [-1, 1]의 값을 가지게 되는데, -1은 두 사용자의 성향이 정반대의 결과를 보이는 부정적 상관관계, 1은 긍정적 상관관계를 의미하고, 상관계수가 0인 경우는 두 사용자 프로파일간에 뚜렷한 관계가 없음을 나타낸다. 그리고 이제 이러한 상관계수들을 가중치로 사용해서 다른 사용자의 등급 매김에 대한 가중 평균을 얻으면 앞으로의 예측이 가능하게 된다.

· 제한된(constrained) 피어슨 상관 계수를 사용한 방법

피어슨 계수를 사용한 방법의 결과에서 동기를 얻은 알고리즘으로서 등급 매김의 단계를 4라는 기준에 의하여 긍정적과 부정적 영역으로 구분하는 방식이다. 즉, Ringo 시스템에서는 등급 매김을 1부터 7까지의 정수로 매기도록 되어있기 때문에, 식 (4)에서 볼 수 있듯이 4점이라는 중간 기준 값에 의해 긍정적, 부정적 영역을 구별한 뒤에, 두 사용자가 동일한 아이টে에 대하여 동시에 긍정적 (≥ 4)으로 등급을 매기거나, 부정적으로 등급을 매기는 경우에 상관 계수를 증가시키도록 하는 방법이다. 이때 4대신에 사용자 등급 매김의 평균값을 사용할 수도 있다.

$$\beta_{xy} = \frac{\sum (U_x - 4)(U_y - 4)}{\sqrt{\sum (U_x - 4)^2 \times \sum (U_y - 4)^2}} \quad (4)$$

그리고, 이러한 제한된 피어슨 상관계수를 사용해서 예측을 하는 방법은 역시 임계값 이상의 상관계수를 가지는 유사한 사용자들의 프로파일에 대하여 상관계수에 비례하도록 가중치를 주어서 평균값을 얻는 것이다.

· 아이템-아이템(artist-artist) 알고리즘

앞에서 언급한 알고리즘들과 다르게 아이템-아이템 알고리즘은 각 아이템 즉, 정보간의 상관관계를 이용하는 방법이다. (Ringo가 음악 CD를 취급하는 시스템이기 때문에, artist라는 용어가 알고리즘의 이름에 사용되었다.) 즉, 어떠한 아이템에 대한 예측은 다른 아이템과의 상관관계 정도로 나타낼 수 있기 때문에, 이들에 대한 가중치를 역시 이전에 제시한 방법으로 부여해서 평균값을 구하는 방법이며, 이는 결국 이전 알고리즘의 도치(inversion) 형태가 된다.

지금까지 제시한 이러한 알고리즘들은 여러 실험의 결과에서 보여주듯이 간단한 구현과 빠른 속도라는 장점이 있지만, 이와는 반대로 몇 가지 문제점을 가지고 있기도 하다[2].

우선, 상관관계의 정도를 측정하기 위해서는 두 사용자 프로파일이 동일한 정보에 대하여 등급 매김을 한 경우만을 측정하도록 되어 있다. 그런데, 만약 예를 들어 영화 추천 시스템에서 등급 매김을 할 수 있는 영화가 너무 많은 것처럼, 협력적 여과의 대상이 되는 영역이 너무 넓다면 비교하고자 하는 사용자 프로파일간에 공통적으로 등급을 매긴 정보를 찾기가 어려워진다. 그리고 이렇게 겹치는 등급 매김 정보의 크기가 작다는 것은 그만큼 이를 기반으로 한 예측의 정확도나 신뢰도가 감소하는 것을 의미한다.

나아가서, 두 사용자의 취향이 어느 정도로 유사한가를 비교하려는 경우에, 공통으로 등급을 매긴 정보가 없다면 앞의 알고리즘에서는 두 프로파일이 서로 관련이 없다고 판단하게 된다. 하지만, 실제로 두 사용자가 공통된 정보에 등급을 매기지 않았다는 결과만을 사용해서, 두 사용자 취향이 서로 관련이 없다는 결론을 내리기 힘든 경우가 있다.

예를 들어, 사용자 A와 사용자 C가 동일한 정보에 대해 등급을 매기지 않은 경우에도, 사용자 A와 또 다른 사용자 B가 공통으로 등급을 매긴 정보로부터 추론한 결과 A와 B가 매우 유사한 성향을 보이고, 사용자 B와 사용자 C도 마찬가지로의 경우라면 이행성(transitivity)에 의해 A와 C도 결국 유사한 성향을 나타낸다고 직관적으로 판단할 수 있다. 그러나, 앞에서 제시한 상관관계 기반의 알고리즘에서는 이러한 정보를 이끌어 낼 수 없다. 즉, 잠재적으로 유용한 정보가 손실되는 것이다.

또한, 상관관계 모델은 긍정적 상관관계나 부정적 상관관계를 이용하는데 있어서 둘 중 하나의 경우만을 가정하고 있다는 문제점을 가지고 있다. 그러나 만약, 두 사용자 프로파일의 유사도(similarity)를 계산해 본 결과 비록 긍정적 또는 부정적인 방향으로 관련되어 있지 않다고 하더라도, 두 프로파일을 비교해서 유용한 정보를 이끌어 낼 수 있는 경우도 있다.

즉, 사용자 A가 높은 선호도를 보인 정보가 사용자 B에게 매우 낮은 선호도를 보이기는 하지만, 반대로 사용자 A가 낮은 선호도를 보인 정보가 사용자 B의 높은 선호도 예측을 보장하는 것은 아니라고 할 때, 두 사용자 프로파일간의 상관관계는 거의 0에 가깝게 된다. 결국, 두 프로파일이 일정 부분은 부정적 연관 관계임에도 불구하고 상관관계 기반 접근의 한계로 인하여


서로 관계가 없다고 판단함으로써, 유용한 정보를 잃어버리게 되는 것이다.

그리고, 이러한 상관관계 기반 알고리즘은 정보 영역에 새로운 아이템이 도입될 경우, 이전에 계산된 상관관계수 값에 의하여 부적절한 영향을 받기도 한다. 또한, 상관관계수의 판단 기준치를 적절하게 조정하지 못한다면, 적은 수의 데이터 사례만을 가지고 관련성을 추정하게 되므로 오류를 범할 가능성이 확률적으로 높아지게 되는 문제점이 있다. 특히 공통으로 등급을 매긴 정보를 벡터를 통하여 수학적으로 표현해보면, 벡터의 원소를 나타내는 사용자가 많기 때문에 아이템은 큰 차수를 가진 다차원 공간상의 점으로 나타나게 되는데, 이는 결국 데이터 집합의 작은 잡음(noise)에도 벡터간의 거리가 크게 변하여 알고리즘의 성능을 하락시키는 요인으로 작용하기도 한다.

2.4 MrHumor

MrHumor (URL: <http://mrhumor.snu.ac.kr/>)는 협력적 여과 기법을 사용한 유머 문서 추천 시스템이다. 서울대학교 컴퓨터 공학부 인공지능 연구실의 연구 과제 중 하나로써 구현되었으며, 현재 이 논문에서는 새로운 유머 문서를 추천하는 부분보다는 사용자 프로파일로부터 얻은 데이터를 어떠한 방식으로 협력적 여과 할 것인가에 초점을 맞추기로 한다.


즉, 상호 영향을 미치는(interactive) 방식으로 사용자에게 각각의 취향에 맞추어서 새로운 유머 문서를 추천하고 그에 대한 만족도를 살펴보는 것이 아니라, 일단 일정 수준 이상의 양에 해당하는 유머 문서를 모든 사용자에게 동일하게 제공한다. 그리고 이러한 유머 문서들에 대해 각 사용자가 등급을 매긴 자료를 모은 후, 이들 자료 중 일부 결과만을 가지고 나머지 부분을 어느 정도로 예측할 수 있는지를 살펴보기로 한다. 결국, 이러한 점에서 현재 *MrHumor*에서 주목해서 보아야 할 부분은 어떠한 방식으로 사용자의 유머 문서 평가가 이루어지는가 하는 것인데, 이는 Fig.1에 잘 나타나 있다.



< Fig.1 MrHumor WWW Interface >

즉, 맨 위의 헤더 부분은 사용자와 유머 문서에 대한 기초적인 정보(identification)에 해당하고, 가운데에 실제의 유머 문서가 위치하게 된다. 그리고 맨 밑의 계량기(meter)를 사용함으로써, [0, 7] 사이의 정수 결과 값을 반환하고 이는 위의 유머 문서를 평가하는 척도의 역할을 한다.

MrHumor 에이전트 시스템의 전체적인 구조는 Fig.2에서 개략적으로 보여지고 있다.



< Fig.2 MrHumor Architecture >

- 각각의 사용자는 자신만의 정보 여과 에이전트를 가지게 된다. 그리고 사용자는 이러한 에이전트와 WWW(월드와이드웹) 인터페이스를 통하여 정보를 주고받게 된다.
- 사용자는 WWW 인터페이스를 통해 제공받은 유머문서를 앞에서 제시한 [0, 7]의 정수값으로 평가하게 된다.
- 이렇게 각 유머에 대해서 평가한 사용자의 점수는 사용자 프로파일 형태로 데이터 베이스에 기록된다.
- 정보 여과 에이전트는 특정한 유머 문서를 사용자에게 추천할지의 여부를 결정하는데 있어서, 다른 사용자의 프로파일을 협력적 여과 기법으로 분석한 결과를 이용한다.
- 협력적 여과 기법에는 상관 계수를 이용하거나, 클러스터링, 신경망, 베이지안 학습(bayesian networks) 등을 사용하는 방안이 있다. 특히, 이번 논문에서는 인공 신경망을 사용하는 것에 초점을 맞춘다.
- 사용자에게 추천하기로 결정된 유머는 최종적으로 WWW 인터페이스를 통하여 제공되는데, 물론 이 논문에서는 이러한 추천 방법에 초점을 맞추고 있지는 않다.

3. 협력적 여과 과정

3.1 데이터 집합의 사전처리 (Data Set Preprocessing)

실험에서 사용하게 될 원본 데이터 집합은 Fig.3과 같은 희소 행렬(sparse matrix) 형태로 표시할 수 있다. 즉, 각각의 사용자가 모든 유머 문서에 대해 등급 매김을 한 것이 아니기 때문에, 상당수의 행렬 원소 값(matrix entry)은 비어있는 상태가 된다. 그리고 Fig.2에서 살펴보았듯이 각 사용자는 자신만의 정보 여과 에이전트를 가지기 때문에 이 에이전트가 자신의 사용자 열(row)중에서 비어있는 원소 값의 값을 예측하는 모델을 제공하는 것이다.

	Humor 1	Humor 2	Humor k	Humor n
User 1	4	3	5	4
User 2	2	1	0	0
User 3	4	1	4	2
User 4		3		
User 5	4	4	1	5
User 6	4		2	2
User 7	4	3	5	1
User 8	0	1	4	?

< Fig.3 Data set example >

예를 들어 Fig.3의 “?”를 예측하기 위해서는 유머 문서 1, 유머 문서 2, …, 유머 문서 k가 트레이닝 데이터 사례가 되고, 각 사례에 대해 사용자 1~7은 입력, 사용자 8은 출력이 된다. 하지만, 이때 주목해야 할 점은 원소 중에 비어있는 항목, 즉 분실값(missing value)이 많기 때문에 이를 적절히 사전에 처리해야 한다는 것이다. 이번 논문에서 사용한 방법은 불린(boolean) 변수를 사용하여 항목의 값이 4 이상이면 선호를 참(=1), 3 이하인 값은 혐오를 참으로 분리하여 표현하는 것이었으며, 따라서 분실값은 선호, 혐오 항목이 모두 0의 값을 가진다.

	Humor 1	Humor 2	Humor k	Humor n
U1 like	1	0	1	1
U1 dislike	0	1	0	0
U2 like	0	0	0	0
U2 dislike	1	1	1	1
U3 like	1	0	1	0
U3 dislike	0	1	0	1
U4 like	0	0	0	0
U4 dislike	0	1	0	0
U5 like	1	1	0	1
U5 dislike	0	0	1	0
U6 like	1	0	0	0
U6 dislike	0	0	1	1
U7 like	1	0	1	0
U7 dislike	0	1	0	1
U8 like	0	0	1	?
U8 dislike	1	1	0	?

< Fig.4 Modified data set example >

물론, 이러한 방법을 사용하여 Fig.4와 같이 수정된 데이터 집합을 사용하게 되면, 등급 매김의 정확한 수치 값을 잃어버리게 되는 단점이 있다. 그러나, 반대로 이산 방식(discrete)으로 선호와 혐오의 두 등급으로 값을 나누지 않고, 각 수치 단계마다 불린 값을 부여하는 경우에는 정밀도 측면의 성능은 증가하지만 데이터 집합 자체의 크기가 너무 커져서 실제로는 적합하지 않을 수도 있다. 게다가 Fig.4와 같이 간소화된 데이터 집합은 여러모로 다루기도 쉽고, 예측의 측면에서도 향상된 성능을 쉽게 얻을 수 있다.


결국, 정리하면 기존의 예측문제는 인공지능 분야의 기계 학습에서 흔히 말하는 감독 학습(supervised learning), 즉 $D = (X, y)$ 인 데이터 집합으로부터 $f_W(X) = y = f(X)$ 의 성질을 지니는 함수 f_W 를 추정하는 형태로 변경된 것이다. 그리고 이때 y 의 값이 분리되어 있기 때문에(discrete), 이는 결국 논문의 앞에서 언급한 것과 같이 분류 문제에 해당한다.

3.2 인공 신경망 (Artificial Neural Networks)

이제 이러한 분류(classification) 문제를 해결하기 위하여 다양한 기계 학습 기법을 적용할 수 있는데, 이번 논문에서는 이미 언급한 바와 같이 그 효과가 널리 입증된 인공 신경망을 사용하기로 한다. 인공 신경망이란 인간이나 동물의 뇌의 구조를 모방한 계산 모델이다[11]. 이는 뇌의 신경 세포가 서로 복잡하게 연결된 상태에서 상호 작용함으로써, 병렬분산 방식으로 정보처리를 한다는 점에 착안한 것이다. 즉, 임계값을 가지는 신경 소자(threshold logic unit)들을 사용하여 신경망을 형성한 뒤, 주어진 신경망을 데이터와 같은 환경에 적응시키는 학습 알고리즘을 적용하는 것이다.

이러한 신경망을 형성하는 구조에 따라서 여러 가지 신경망 모델이 존재하게 되는데, 실제로 가장 많이 응용되는 모델은 다층 퍼셉트론 (Multi-layer perceptron 또는 MLP) 구조이다. 이 구조에서는 신경 소자가 층(layer)을 형성하며, 이러한 층에는 입력, 출력 이외에도 중간층에 해당하는 은닉 노드(hidden unit) 층이 있다. 각 층 내에서는 소자간에 연결선이 존재하지 않고, 인접한 층간에는 각 뉴런이 모든 다른 뉴런과 한 방향으로만 연결되어 있다. 이때의 방향은 입력 소자에서 출력 소자 방향이며, 이를 순차 방식(feed-forward)이라고 한다. 또한, 소자간의 연결선에는 가중치가 부여되어서 이전 층의 결과를 다음 층으로 합산하게 되는데, 신경망이 학습하는 대상이 바로 이 가중치이며, 대표적인 가중치 학습 방법으로는 오류 역전파 (error backpropagation) 방식이 있다.

실제로, 이번 논문에서도 인공 신경망 중 가장 일반적인 형태인 다층 퍼셉트론 구조를 사용하며, 기본적인 트레이닝 데이터 집합의 입력-출력 쌍은 Fig.4의 행(column) 벡터이고, 최종적으로는 테스트 데이터 집합에 대한 출력 값을 예측하는 것을 목표로 하는 모델을 제시한다. 즉, Fig.5에서 볼 수 있듯이 각 유머 문서에 대한 사용자의 등급 매김 벡터로 표현되는 여러 트레이닝 사례를 통해 인공 신경망을 학습시킨다. 이때 사용하는 인공 신경망은 가장 간단한 형태로서 단층 은닉 노드(1-hidden layer), 순차 방식, 오류 역전파 학습 방법을 사용하는 구조에 해당하며, 참고적으로 소프트웨어로서는 미국의 Nevada대학에서 무상으로 제공하고 있는 NevProp4 (Nevada Propagation[9])를 이용하였다.



< Fig.5 Artificial Neural Networks >

3.3 Singular Value Decomposition (SVD)

사실상, Fig.5에서 제시하고 있는 3.2 절의 학습 방법은 이론적으로 문제가 없는 방법이지만, 실제적으로 이를 적용하는 데는 적지 않은 어려움이 따르게 된다. 즉, Fig.4의 데이터 집합을 그대로 사용하기 힘들다는 뜻인데, 그 이유는 이미 2.2 절에서 언급한 협력적 여과 방식의 문제점에 해당하며, 이를 다시 한번 정리하면 다음과 같다[2].

- 대상으로 하고 있는 데이터 집합이 그 크기가 매우 큰 데이터베이스라면, 이를 행렬로 표현했을 때 다루기가 쉽지 않다. 즉, 데이터의 차원이 증가하면 할수록 이를 처리하는데 많은 어려움이 존재하고, 그 성능도 보장하기 힘들다. 물론, 이번의 *MrHumor* 데이터 집합은 상대적으로 적은 54명의 사용자와 100개의 유머 문서, 그리고 3,285개의 평가가 행해진 상태이므로 실행 불가능(infeasible)하다고는 할 수 없지만, 이러한 상황에서도 아래와 같은 문제점은 발생한다.
- 데이터 집합 안에서 상당수의 정보는 성능을 예측하는데 필요하지 않은 것이 많고, 또한 기존의 데이터만으로는 동일한 유머 문서를 평가하지 않은 사람끼리 연관성을 예측하는 것도 힘들다. 결국, 데이터 집합 속에 숨어있는 사용자들간의 연관성을 이끌어내는데 어려움을 겪게 된다.

따라서, 정보 검색(information retrieval) 분야에서는 이러한 문제를 해결하기 위해 다양한 특


징 추출(feature extraction) 기법을 연구하여 왔는데, 그 중 대표적인 방법이 singular value decomposition (SVD)을 통하여 데이터의 차원을 감소시키는 것이다. 이는 데이터 집합을 일단 행렬 형태로 표현한 뒤, 행렬이 수학적으로 가지는 성질을 이용하여 핵심적인 정보만을 유지하도록 데이터 집합을 변경하는 것을 뜻한다.

간략하게 SVD에 대하여 살펴보면, 일단 $m \times n$ 행렬 A 가 주어진 경우에 (w.l.o.g $m \geq n$, $\text{rank}(A) = r$), singular value decomposition ($\text{SVD}(A)$)은 식 (5)와 같이 정의된다[8].

$$A = U \Sigma V^T \quad (5)$$

이때, $U^T U = V^T V = I_n$ 이며, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n)$, $\sigma_i > 0$ ($1 \leq i \leq r$), $\sigma_j = 0$ ($j \geq r+1$)으로 표현된다. 또한, 각각 U 와 V 의 행(column) 벡터는 A 의 left, right singular vector에 해당하며, A 의 singular value는 Σ 의 대각선 원소들로 정의된다.

즉, 식 (5)가 의미하는 바는 U, V, Σ 의 singular factor가 서로 쌍(triplet)을 이루어서 관련되어 있기 때문에, 이러한 쌍들 가운데에서 가장 큰 k 개만을 선별한 후 이를 가지고 원본 행렬인 A 를 약간의 오차를 감수한 상태에서 재구성할 수 있다는 것이다. 즉, [8]로부터 참고한 Fig.6의 수학적 표현에서 볼 수 있듯이, 어두운 부분만 가지고서 A 의 근사 값인 A_k 를 얻게 된다.



< Fig.6 Matrix A_k representation >

이때 살펴볼 점은, A_k 는 완벽하게 A 의 모든 정보를 가지고 있는 것은 아니지만, 행렬 내부에 숨어있는 가장 중요한 구조부터 선별적으로 저장하고 있기 때문에, 데이터 집합 내부의 원하지 않는 잡음(noise)을 어느 정도 제거하는 작업이 가능하다는 것이다. 또한, 공통의 유머 문서에 대해 등급을 매기지 않은 사용자들 간에도 k 차원의 수학적 공간으로 데이터 집합을 변환하면, 서로간의 거리가 가까워져서 쉽게 상호 연관성을 파악할 수 있을뿐더러, 변환 후의 데이터 집합도 그 크기가 줄어들기 때문에 처리하기가 쉬워진다.

그리고, 이렇게 SVD를 구하고 난 뒤에는 새로운 테스트 데이터 집합의 사례들에 대하여, 이를

k 차원으로 사상시킬 수 있는데, 이는 식 (6)과 같이 수학적으로 간단하게 표현할 수 있다[8].


$$q' = q^T \cdot U_k \cdot \Sigma_k^{-1} \quad (6)$$

즉, q 는 등급 매김으로 구성된 불린 벡터, U_k 는 각 벡터에 k 개의 원소를 가지고 있는 singular vector 행렬, Σ_k 는 k 개의 가장 큰 singular value를 가지고 있는 대각선(diagonal) 행렬에 해당한다. 따라서, $q^T U_k$ 는 k 차원으로 변환시킨 사용자들 벡터의 합에 해당하고, 그 후 이 값은 Σ_k^{-1} 에 의해서 각각의 차원에 대해 차별적으로 가중치를 부여받게 되는 것이다. 결국, 신경망에 들어갈 입력-출력 쌍, 즉 임의의 유머 문서에 대하여 각 사용자가 등급을 매긴 값의 벡터는 q' 와 같이 낮은 차원으로 변환된다고 할 수 있다.

3.4 학습 알고리즘

최종적으로, 앞 절의 내용을 종합하면 Fig.7에서 볼 수 있듯이 이번 논문에서는 다음과 같은 과정을 거쳐서 *MrHumor* 정보 에이전트의 기계 학습이 수행된다.

- 1) 3.1절에서와 같이 각각의 유머문서에 대해 사용자로부터 받은 등급 매김값을 모아서 행렬형태로 전체 데이터 집합을 구성한다. 이때 사용자와 유머 문서가 각각 행렬의 한 축을 이루게 되며, 행렬의 원소 값은 열에 해당하는 사용자가 행에 해당하는 유머 문서를 평가한 수치이고 *MrHumor*에서는 이 값의 분포가 [0, 7] 범위의 정수 값이다.
- 2) 사용자가 등급을 매기지 않은 유머 문서는 행렬상의 공백에 해당하는 분실값(missing value)으로 표현하고, 이를 처리하기 위하여 일단 등급 매김 값을 4를 기준으로 하여 선호(like)와 혐오(dislike)의 두 분류로 나눈다. 그 후 원본 행렬의 등급 매김 값이 선호 범위에 속하는지의 여부를 하나의 불린(boolean) 값으로 표현하고, 동시에 혐오 범위에 속하는지도 또 다른 불린 값으로 나타낸다. 결국, 이전의 등급 매김 수치(numeric) 값은 두 개의 불린 값으로 변환되고, 분실값은 이 두 불린 값들이 모두 거짓, 즉 0인 형태가 된다.
- 3) Singular Value Decomposition을 사용하여 데이터 집합을 낮은 차원으로 압축한다. 3.3절에서 제시한 바와 같이 데이터의 압축은 하나의 유머 문서에 대한 여러 사용자의 등급 매김, 즉 행(column) 벡터의 원소 수를 줄이는 세로 방향으로 일어난다.
- 4) 압축된 데이터 집합을 이용하여, 각 사용자마다 3.2절의 인공 신경망으로써 유머 문서에 대한 성향을 학습하며, 다층 퍼셉트론 구조의 신경망을 사용한다. 이때, 하나의 유머 문서에 대해 자신을 제외한 다른 사용자의 등급 매김 값들이 입력, 자신의 등급 매김 값이 출력으로써 하나의 학습 대상 사례를 구성한다.
- 5) 테스트 데이터 집합을 3.1절의 전처리 과정을 거친 후, 이를 3.3절의 식 (6)을 사용하여 신경망에 들어갈 데이터 형태로 변환시킨다. 이후 이렇게 변환된 테스트 데이터에 대하여 신경망이 추정한 출력값이 실제와 일치하는 가를 평가하여 성능을 측정한다.



< Fig.7 Algorithm Visualization >

4. 실험

4.1 실험 내용

이미 앞에서 언급한 바와 같이 실험에서 사용한 *MrHumor* 데이터 집합은 현시점에서 54명의 사용자, 100개의 유머 문서, 그리고 이에 대해서 3,285개의 평가가 행해진 상태이다. 그런데, 실제의 에이전트 구조를 생각해본다면, 기존의 데이터 집합에서 얻은 사용자 선호도의 상관 관계를 이용하여 새로운 유머 문서를 추천해주어야 한다. 하지만 이번 논문에서는 제반 여건 상 기존의 *MrHumor* 데이터 집합을 트레이닝 집합과 테스트 집합으로 나눈 뒤, 트레이닝 집합으로 학습한 신경망이 테스트 집합을 어느 정도로 정확히 예측할 수 있는지 만을 살펴보기로 한다.

이때 사용할 수 있는 측정값에는 다양한 것들이 있지만, 가장 간단하게 0.5를 기준으로 하여 선호 (=1)인 경우 이보다 큰 값이 나오고, 혐오 (=0)인 경우에는 반대로 0.5보다 작은 값이 신경망의 출력으로 나오는 가를 살펴보기로 한다. 즉, 임계값을 기준으로 한 분류(classification) 오류를 척도로 삼아서 실험을 진행한다. 참고적으로, 이러한 학습 과정이 더욱 실질적인 의미를 가지기 위해서는 precision, recall, F-measure 등의 측정 기준이 사용될 수 있을 것이다[2].

4.2 실험 방법


기본적인 실험 조건은 우선 5명의 사용자를 무작위로 선별한 뒤, 최종적으로 성능을 평가할 사례를 전체 100개의 유머 문서 가운데서 10개를 선택한다. 그리고 각 사용자에 대하여, 유머문서 100개 가운데서 테스트 사례 10개를 제외한 나머지 90개의 트레이닝 집합 중 일정한 비율의 사례를 가지고 학습한 신경망이, 테스트 집합에 대하여 어느 정도로 예측을 할 수 있는지 평가한 뒤 5명의 사용자에 대한 평균을 얻어서 전체적인 성능을 제시해보도록 한다.

이때, SVD를 사용하는 단계에서 k , 즉 신경망의 입력으로써 변환된 사용자 등급 매김 벡터 중 몇 개의 원소를 실제 입력으로 선택할 것인지를 결정하는 일이 중요한데 실제 실험에서는 다양한 설정으로 실험을 해 본 뒤 그 중 가장 성능이 좋은 결과를 선택하기로 한다. 사실 데이터 집합이 양호하다면, k 값 사이에도 일정한 공식이 성립할 수 있지만 이번 실험의 수준에서는 직관적으로 그러한 경향을 발견하지는 못했다. 구체적으로 행해진 실험은 다음과 같다.

- 트레이닝 데이터를 늘려가면서 신경망을 학습시킨 뒤, 예측 성능을 측정한다. 이때 다양하게 신경망의 여러 매개변수를 설정한 뒤 학습시켜서, 가장 예측 성능이 좋은 경우를 5개 선정한다.
- 위의 실험에서 선정된 최선의 설정을 이용하여, 같은 조건으로 여러 번 성능을 측정한 뒤 일반적인 분류 오류를 살펴본다. 역시 전체적인 실험은 트레이닝 데이터의 크기를 늘려 가는 과정과 더불어서 진행된다.
- SVD의 성능을 파악하기 위해서 90개의 사례를 트레이닝 집합으로 사용하면서, SVD의 singular factor(k)를 변경시킬 때, 성능에 미치는 영향을 살펴본다.
- *MrHumor* 데이터가 신경망으로 어떻게 모델링되는지 보다 자세하게 파악하기 위하여, 은닉 노드(hidden unit)의 개수와 SVD의 singular factor를 변화시키면서 분류 오류 결과를 관찰한다.

4.3 실험 결과 및 분석

첫 번째 실험의 결과에서는 다양한 매개변수 설정 환경 중에서 성능이 가장 좋은 5가지의 경우를, 10개씩 트레이닝 데이터를 증가시키면서 각 크기마다 제시하고 있다. 즉, 신경망을 학습시킬 때는 많은 매개 변수를 적절히 조정하는 것이 관건인데, 구체적인 매개변수로는 신경망이 학습을 반복하는 기간(epoch), 은닉 노드(hidden unit) 개수, SVD의 singular factor(k) 등이 있다. 따라서, 가장 테스트 집합 예측에 적합한 신경망을 찾아내기 위해서 각 사례 크기마다 여러 가지 설정으로 실험을 해보았으며, 그 구체적인 결과는 Fig.8, Fig.9와 같다.



< Fig.8 Classification accuracy top 5 graph>

일단 Fig.8에서 붉은 계열의 점은 각 순간의 오류 비율(error rate)을 나타내는 것이며, 파란 계열의 선은 이들에 대한 추세선에 해당한다. 다음으로 Fig.9는 각 데이터 사례 크기에서 최고의 성능을 보이는 순간의 신경망 환경 설정이며, 다시 말하자면 Fig.8에서 맨 밑의 노란 점들에 해당하는 매개 변수들의 값이다. 참고적으로, Fig.8의 일부 사례 크기에서는 5개의 오류 비율 결과가 서로 겹치는 관계로 인하여 명확하게 모든 점이 나타나 있지는 않다.


사례수	Singular Factor (k)	은닉 노드 수	기간
10	2	1	50
20	2	2	100
30	3	2	100
40	6	3	180
50	4	2	180
60	7	3	150
70	9	4	100
80	8	4	80
90	4	2	200

< Fig.9 Best parameter settings>

Fig. 8의 대략적인 경향을 살펴볼 때, 트레이닝 데이터 크기가 증가하면서 신경망의 전체적인 예측 성능도 좋아지고, 최고 65% 가량의 예측에 성공하는 것을 볼 수 있다. 물론, 간혹 다소의 오차는 있지만 대체적으로 이러한 경향은 기계학습의 측면에서 당연한 결과라고 할 수 있을 것이다. 하지만, 실험이 단순한 분류 문제라는 것을 고려해 볼 때, 신경망의 예측이 들어맞을 확률이 최고 50%~65%의 수준이라는 사실은 다소 실망스러운 결과이다. 게다가 Fig.9의 매개변수 설정을 살펴보면, 전체 결과를 체계적으로 설명할 수 있는 기준 없이 무작위적으로 매개 변수 값들이 변동하고 있음을 알 수 있는데, 이러한 점 역시 실험의 미흡한 부분을 대변하고 있다.

이러한 결과가 나온 근본적인 원인은 무엇보다도 데이터 집합 자체의 문제점에서 찾을 수 있을 것이다. 5.1의 성능 하락 요인에서 보다 자세하게 살펴보겠지만, 간략히 이야기하자면 실험이 행해진 *MrHumor* 데이터 집합이 그 크기도 작을뿐더러 값 자체의 신뢰도도 높지 않은 편이라는 뜻이다. 이는 동일한 기법을 *EachMovie* 데이터베이스에 적용한 [2]의 예측 성능이 65%~85% 라는 것과 비교해볼 때 쉽게 파악할 수 있다. 참고적으로 *EachMovie* 데이터베이스는 Digital Equipment Corporation의 Systems Research Center에서 행해진 연구 결과로서, 1,628개의 영화에 대해 72,916명의 사용자가 2,811,983개의 등급 매김을 한 결과이다.

두 번째 실험의 결과인 Fig. 10은, 첫 번째 실험에서 찾아낸 최선의 환경 설정에 대한 신경망의 일반적인 성능을 나타낸 것이다. 즉, 첫 번째 실험이 최적의 매개 변수를 찾기 위한 것이었다면 두 번째 실험에서는 이렇게 찾은 동일 환경 상에서 여러 번 학습을 시킨 뒤 평균값을 얻음으로써, 실험의 우연적 요소를 감소시키고 신경망의 학습 성능을 일반화시키는 것에 목적이 있다. Fig. 10 가운데에서 파란 계열의 점은 각 순간의 오류 비율을 표시한 것이며, 이러한 점들간의 붉은 계열의 선은 평균과 표준 편차를 보여주고 있다. 당연히 전체적인 그래프의 경향은 Fig.8과 일치하며 역시 트레이닝 데이터 사례의 크기가 증가할수록 예측 성능은 대략적으로 향상되지만, Fig.8보다 값의 변동도 더욱 심하고 성능도 좋지 못하다는 것을 알 수 있다.



< Fig.10 Classification error rate graph>

세 번째 실험은 SVD에서 적합한 singular factor(k)를 찾기 위한 것이었는데, 이번 실험은 데이터 집합 자체의 크기도 작고 특정한 상황만을 설정해서 실험해 본 것에 지나지 않으므로 그 결과를 단정지을 수는 없었다. 하지만, 대략적으로 Fig.11에서와 같이 *MrHumor* 데이터 집합은 singular factor가 작은 경우에 보다 성능이 향상된다고 결론을 내릴 수 있다. 즉, *MrHumor* 데이터 집합은 자체적으로 상당히 심한 잡음을 가지고 있으며, 내부에 숨어있는 데이터들간의 관계, 즉 사용자들간의 상관 관계는 비록 만족할 만한 수준은 아니지만 상대적으로 매우 간단한 모델을 통해 설명된다는 것을 알 수 있다.


물론, 일반적인 상황을 가정해본다면 각 데이터 집합마다 고유한 singular factor가 있으며, 그 값은 데이터의 특성과 그 외의 매개변수에 의해 영향을 받을 것이다. 참고적으로 Fig.11은 은닉 노드의 개수를 singular factor (신경망의 입력 소자 개수)의 절반으로 하고, 트레이닝 사례가 90개인 경우에 대해 측정한 결과이다.



< Fig.11 Error rate with singular factor variation graph>

마지막 실험은 *MrHumor* 데이터가 가지는 특성을 신경망 학습과 SVD의 일반적인 관점에서 관측해본 것이다. 즉, 일단 트레이닝 데이터는 최대 크기인 90개의 유머 문서로 고정된 상태에서, 신경망의 대표적인 매개 변수인 은닉 노드 개수와 SVD의 singular factor(k)를 동시에 변화시키면서 분류 오류를 척도로 하여 특유의 경향성이 존재하는지를 측정해보았다.

하지만 결과는 Fig. 12에서 볼 수 있듯이 특별히 명확한 법칙 없이 분류 오류 결과가 흔들리는 것을 알 수 있었다. 그리고 결국 이러한 원인은 앞에서 설명하였듯이 데이터 집합 자체가 많은 사용자를 가지고 있지 않아서 하나의 유머 문서를 설명하는데는 대표성이 부족하다는 것과 등급 매김값 자체의 신뢰도가 높지 않다는 점에서 찾을 수 있을 것이다.



< Fig.12 Classification error rate with hidden unit number variation graph>

5. Conclusion and Future work

5.1 연구 결과 요약

이 논문에서는 내용기반 여과와 상관관계기반 협력적 여과기술의 단점에 대해서 일단 살펴보고, *MrHumor* 라는 유머 문서 추천 시스템의 데이터 집합을 이용하여 이러한 단점들을 해결하기 위한 협력적 여과 기법들을 실제로 실험해보았다. 즉, SVD와 같은 방법을 사용하여 데이터 집합을 변환시킴으로써 정보 여과 문제를 접근 가능한 분류 문제로 바꾼 뒤, 신경망을 사용하여 기계 학습의 측면에서 성능을 측정해보았다.

실험의 결과를 살펴보면, 전반적인 기계 학습의 원리가 그대로 적용되는 가운데, 신경망의 예측 성능이 그다지 만족할 만한 수준은 아니지만 일정 부분 이상은 효과를 기대할 수 있다는 것을 알았으며, SVD의 singular factor인 k 가 데이터 집합의 내부 구조에서 가지고 있는 의미를 직접 관찰할 수 있었다. 그러나 이러한 결과에도 불구하고 테스트 데이터 집합에 대한 예측 능력이 최대 65% 가량에 머무른다는 것과 데이터 집합의 경향을 명확히 설명하는데 어려움이 존재한다는 부분은 충분히 고려가 필요한 사항이다.

우선, 데이터 집합 자체의 문제점이다. 현재 실험의 대상이 된 *MrHumor* 데이터 집합은 포함하고 있는 데이터의 개수가 그다지 크지 않다는 단점이 있다. 즉, 2.2절에서 제시하고 있듯이 사용자수가 증가할수록, 특정 사용자와 비슷한 성향을 보이는 사용자를 발견할 가능성이 높아지는데 반하여, 이번 실험에 사용된 54명의 사용자들 가운데서 그 취향간의 관련성을 찾기는 쉽지 않았을 것이라는 추정이 가능하다. 특히 데이터를 제공한 사용자 집단이 부득이하게도 다소 비자발적으로 선발되었기 때문에, 등급 매김 값에 대해 그다지 신뢰도가 높지 않았고, 이는 결과적으로 데이터 집합 자체를 논리적으로 설명하기가 힘들어진다는 뜻이 된다.

또한, *MrHumor* 시스템 자체도 상당히 불안정하게 동작했다는 문제를 빼놓을 수 없는데, 이는 데이터 집합에서 동일한 사용자가 동일한 유머 문서에 대해서 평가한 값이 여러 개 존재하는 비정상적인 경우로 대표되고 있다. 실제로 아무런 처리를 하기 전의 원본 데이터 집합에서는 전체 3,518개의 등급 매김 값 중 233개가 데이터 행렬의 동일 항목에 대해 다른 값으로 할당되어 있었고, 이러한 모순을 해소할 수 있는 별도의 정보도 주어지지 않았기 때문에 임의로 이들을 삭제하고 3,285개의 등급 매김 값만을 사용하게 되었다.

이밖에도 *MrHumor* 뿐만이 아닌 일반적인 정보 여과에서 문제점으로 여겨지고 있는 요인들도 성능 상의 하락을 가져왔을 것이라고 추정되는데, 예를 들어 등급 매김 값이 등급 범위 상의 중간 값으로 할당된 경우에는 그 의미하는 바가 모호한 사례가 많다는 점을 들 수 있다. 즉, 사용자는 대부분 자신이 아주 좋아하거나 싫어하는 아이템에 대하여서만 반응을 보이는 경우가 많기 때문에, 중간 등급 매김 값은 정확히 반영되기 힘든 문제점이 있다[4]. 또한, 비록 *MrHumor* 에서 드러난 점은 아니지만, [2]에서 지적된 것처럼 자신이 좋아하는 아이템만을 선택해서 등급 매김 하는 사용자의 성향 등은, 사용자의 취향을 정확하게 파악하는 데에 어려움으로 작용하는 대표적인 사례이다.

5.2 연구 결과 활용 방안

논문에서 제시된 협력적 여과 기법은 몇 가지 측면에서 적절하게 활용될 수 있는 여지를 가지고 있다. 우선, 인공 신경망으로 대표되는 다양한 기계 학습 기법을 적용시킬 수 있도록 서비스 추천 문제가 분류에 관한 것으로 바뀌었다는 점과 SVD를 사용하여서 데이터 집합을 효율적으로 이용하게 되었다는 부분이다. 그리고 결국, 이러한 장점들을 바탕으로 하여서, 다양한 정보의 폭발적인 증가로 대표되는 정보의 홍수 속에서 효율적인 정보 여과 에이전트를 구현할 수 있다는 관점에서 이번 실험의 결과는 다소나마 의의를 가지게 될 것이다.

5.3 향후 과제

이번 실험에서는 일단 신경망의 협력적 여과 도구로서의 활용 가능성과 SVD를 사용함으로써 데이터 집합으로부터 특징 추출(feature extraction)을 효율적으로 수행할 수 있다는 것을 확인하였다. 하지만, 아쉽게도 각 신경망의 매개변수 설정과 트레이닝 사례 크기간의 관계는 명확하게 밝히지 못했는데, 이 부분에 대해서는 추가적인 연구가 더욱 필요할 것이다.

또한, 이번 *MrHumor* 데이터 집합과는 상관이 없지만, 일반적인 협력적 여과에서 데이터 집합 자체의 크기가 너무 커서 처리에 너무 오랜 시간이 걸리는 경우에는, SVD이외에도 선별적으로 사례를 학습하는 능동적 학습 기법(active learning)을 도입하는 방안도 고려해 볼 수 있을 것이다. 그리고, 신경망 이외에 특징들 간의 의존성을 파악하는데 좋은 성능을 보이는 베이지안 학습방법(bayesian networks)과 같은 기계 학습 기법을 적용하는 연구도 주목할 만하다. 또한, 이밖에도 [2]에서 제시된 바와 같이 협력적 여과의 단점을 보완하기 위하여 상보적인 관계에 있는 내용기반 여과를 동시에 구현하는 방법도 흥미로운 향후 연구 주제 중의 하나인데, 이는 내용에 관한 메타-정보를 특징(feature)의 형태로 변환한 뒤, 학습의 대상이 되는 기존의 벡터에 원소로서 삽입하는 방식으로써 가능해진다.

Acknowledgements

SNU SCAI laboratory 이종우 for *MrHumor* database available and paper guidance
Compaq (Digital Equipment Corporation) for *EachMovie* database available

References

- [1] *MrHumor* (URL: <http://scai.snu.ac.kr/Research/mrhumor.html>)
- [2] D. Billsus and M. J. Pazzani, Learning collaborative information filters, *Proceedings of the Fifteenth International Conference on Machine Learning*, pp. 46-54, 1998.

- [3] D. Gupta, M. DiGiovanni, H. Narita, and K. Goldberg, Jester2.0: Evaluation of a new linear time collaborative filtering algorithm applied to jokes, *Poster Session and Demonstration, 22nd Int. ACM SIGIR Conf. on Research and Development in Information Retrieval*, pp. 191-192, 1999.
- [4] U. Shardanand and P. Maes. Social Information Filtering: Algorithms for Automating "Word of Mouth", *Proceedings of the Conference on Human Factors in Computing Systems (CHI95)*, pp. 210-217, 1995.
- [5] D. Turnbull, Augmenting Information Seeking on the World Wide Web using Collaborative Filtering Techniques, <http://donturn.fis.utoronto.ca/research/augmentis.html>, 1995.
- [6] D. H. Ballard, *An Introduction to Natural Computation*, The MIT Press, pp. 71-88, 1997.
- [7] V. Cherkassky and F. Mulier, *Learning From Data Concepts, Theory and Methods*, John Wiley & Sons, INC., pp. 431-436, 1998.
- [8] M. W. Berry, S. T. Dumais, and G. W. O'Brien, Using linear algebra for intelligent information retrieval, *SIAM Review* 37:4, pp. 573-595, 1995.
- [9] PH. Goodman, NevProp software, version 4. Reno, NV: *University of Nevada*, 1998. (URL: <http://www.scs.unr.edu/nevprop/>)
- [10] 장병탁, 기계학습 연구 방법론, <http://scai.snu.ac.kr/~btzhang/>, 1998.
- [11] 장병탁, 신경망, *Natural Sciences*, Vol. 8, 2000.
- [12] B. T. Zhang, J. W. Lee, and Y. W. Seo, Learning Agents, *Journal of KISS*, Vol. 18, No. 5, pp.26-35, 2000.
- [13] K. Lang, NewsWeeder: Learning to filter netnews, *Proceedings of International Conference on Machine Learning (ICML-95)*, pp. 331-339, 1995.
- [14] A. Moukas, Amalthaea: Information discovery and filtering using a multiagent evolving ecosystem, *Proc. Practical Application of Intelligent Agents and Multi-Agent Technology*, pp. 421-436, 1996.
- [15] B. Krulwich and C. Burkey, The InfoFinder agent: Learning user interests through heuristic phrase extraction, *IEEE Experts*, 12(5): pp. 22-27, 1997.
- [16] P. Resnick, N. Iacovou, M. Suchak, P. Bergstrom, and J. Riedl, GroupLens: An open architecture for collaborative filtering, *Proc. ACM 1994 Conf. on Computer Supported Cooperative Work*, pp. 175-180, 1994.