

공학석사학위논문

순차 커널분포추정을 이용한 독립성분분석

Independent Component Analysis using Sliding Kernel
Density Estimation

2003년 2월

서울대학교 대학원

전기 · 컴퓨터공학부

정 승 우

순차 커널분포추정을 이용한 독립성분분석

Independent Component Analysis using Sliding Kernel
Density Estimation

지도 교수 장 병 탁

이 논문을 공학석사 학위논문으로 제출함

2002년 10월

서울대학교 대학원

전기 · 컴퓨터공학부

정 승 우

정승우의 공학석사 학위논문을 인준함

2002년 12월

위원장 유 석 인 印

부위원장 장 병 탁 印

위 원 문 병 로 印

초록

독립성분분석(ICA)이란 선형적으로 혼합된(mixing) 신호들로부터 통계적으로 상호 독립적인 신호들을 분리해 내는 기술이다. 이 기술은 신호 영역뿐만 아니라 이미지나 텍스트 분야에서도 활발하게 적용되고 있다. 이러한 다양한 분야에서 사용되는 동시에 독립성분분석의 알고리즘 자체에 대한 연구도 집중적으로 연구되어 왔으며 최근 들어 정밀성과 효율성 면에서도 많은 발전이 있어왔다.

독립성분분석을 하기위해 필요한 과정 중의 하나로서 확률밀도함수의 추정치가 있다. 분포추정 방법의 특성에 따라 독립성분분석의 성격과 특징이 달라지게 된다. 본 논문에서는 독립성분분석의 성능을 높이기 위해 다른 방법들보다 정확도가 높다고 알려진 커널(kernel) 방법을 사용하여 분포추정을 하였다. 커널 방법으로 분포추정을 할 경우 다른 방법들에 비해 실제 분포를 더 정확하게 근사할 수 있으나 계산 비용이 많이 드는 단점이 있다.

본 논문에서는 계산 비용을 줄이기 위해 새로운 방법인 *순차 커널추정방법 (Sliding Kernel Density Estimation)*을 제시한다. 이 방법은 분포와 그 미분값들을 순차적인 방법으로 추정하기 위해 지수(exponential) 함수를 커널로 사용한다. 또한 이 방법을 사용한 추정 과정이 효율적으로 수행될 수 있음을 이론적으로 보인다. 그리고 이를 적용한 독립성분분석 역시 좋은 성능을 보인다는 것을 실험적으로 증명한다.

주요어: 독립성분분석, 커널, 순차 커널, 분포추정

학번: 2001-21565

목차

1. 서론	1
1.1 연구 배경	1
1.2 논문의 구성	4
2. 독립성분분석	5
2.1 개념	5
2.2 관련 연구	9
3. 순차 커널분포추정	15
3.1 커널분포추정의 개념	15
3.2 순차 커널분포추정	19
3.3 순차 커널분포추정의 예	27
4. 순차 커널분포추정을 이용한 독립성분분석	32
4.1 알고리즘	32
5. 실험 및 분석	34
5.1 첫 번째 실험	34
5.2 두 번째 실험	38
6. 결론 및 향후 과제	43

참고 문헌	44
감사의 글	50

1장

서론

1.1 연구 배경

다차원(multi-dimension)으로 이루어진 데이터의 경우 그대로 사용할 수도 있지만 데이터를 어떤 축으로 투영(projection)시켜 데이터의 속성을 바꿀 수 있다. 이 때 투영시키는 축의 수를 원래의 데이터 차원수와 일치시켜 투영 이후에 만들어지는 데이터의 차원이 투영 전의 데이터와 같게 할 수 있고 더 적게 하여 압축의 효과를 볼 수도 있다. 다차원 데이터가 투영될 때 투영된 결과 수치들이 의미있는 속성을 지니도록 축을 결정하는 방법으로서 Projection Pursuit이 있다 [Huber, 1985; Hyvärinen, 1998]. Projection Pursuit에서 의미있는 속성이란 투영된 수치들이 가우시안(Gaussian) 분포로부터 가능한 멀리 떨어진 분포를 이루는 것을 말한다. 즉 non-gaussianity가 높게 나타나는 방향으로 축을 정하는 것이다. 주성분분석(Principal Component Analysis)은 단위 크기이고 서로 직교(orthogonal) 관계에 있는 아이겐 벡터(eigen vector)들을 아이겐 값(eigen value)의 크기 순으로 일부를 선택하여 데이터를 본래보다 더 적은 차원으로 압축할 수 있다. 또한 차원들간의 상관관계(correlation)를 없앴으로써 데이터의 상관행렬(correlation matrix)을 $I\sigma^2$ 꼴로 바꿀 수 있다[Jolliffe, 1986; Oja *et al.*, 1995].

데이터의 상관관계뿐만 아니라 더 높은 차수의 상관관계까지도 없앨 수 있으

며 결국 차원들간의 관계를 독립(independent)으로 변환시키는 방법을 독립성 분분석(Independent Component Analysis, ICA)이라고 한다 [Hyvärinen and Oja, 2000; Hyvärinen, 1999; Amari *et al.*, 1996]. 본래 독립성분분석은 cocktail-party problem라는 문제와 연관되어 있다. 파티장에서 여러 사람, 음악, 물체 등의 소리를 동시에 듣게 되지만 대화를 하기 위해서는 대화 상대의 목소리를 제대로 인식해야 하는 것이다. 여기서 각각의 독립적인 소리가 독립성분분석에서의 소스(source)에 해당된다. 이때 원래의 소스와 소스들이 섞이게(mixing) 되는 과정에 대한 정보를 모른 채 단지 섞인 신호(mixture)만을 가지고 원래의 소스를 밝혀내게 되는데 이를 Blind Source Separation(BSS) [Jutten and Herault, 1991; Bell and Sejnowski, 1995; Cichocki and Moszczynski, 1992]라고 부른다. Sparse Coding은 요소간의 행동패턴에서 중복이나 의존성(dependence)을 줄이는 것으로서 뇌의 sensory processing에서 뉴런(neuron)이 작용하는 방식을 설명하기도 한다. Sparse Coding이 선행적으로 이루어질 때 독립성분분석의 한 방법이 될 수 있으며 압축(compression), 노이즈제거(denosing)에 사용될 수도 있다[Olshausen and Field, 1996; Hyvärinen, 1999].

독립성분분석이 사용되는 분야 중의 하나로서 뇌 표면의 신호를 전극을 이용하여 측정한 전위인 EEG(electroencephalogram) 신호에서의 적용을 들 수 있다[Bartlett *et al.*, 1995]. EEG 신호는 뇌활동에 의해 발생하는 신호와 그 외의 다른 노이즈(noise)들이 섞인 상태로 측정이 되므로 독립성분분석을 적용하면 원하는 뇌파를 얻을 수 있다. 또 하나의 분야는 속성 추출(feature extraction)이며 이미지나 음향 데이터에 쓰일 수 있다[Hoyer and Hyvärinen, 2000]. 여기서 속성의 차원과 개수는 데이터의 차원과 같으며 각 데이터들은 모두 이 속성들의 superposition으로 이루어지고 이 superposition의 계수(coefficient)는 독립성분분석에 의해 찾아지는 소스이다.

가령 natural image에 독립성분분석을 적용하면 서로 독립적인 계수들의 선형적인 조합에 의해 각 이미지들을 이룰 수 있는 edge 모양의 속성들이 추출될 수 있다. 이러한 성질을 이용하여 노이즈 섞인 이미지 데이터로부터 노이즈를 제거(image denoising)하는데도 독립성분분석이 쓰일 수 있다[Hyvärinen *et al.*, 2001a].

본 논문에서는 독립성분분석을 위해 정보이론(information theory)적인 기준(measure)을 사용한다. 독립성분분석을 하기 위해서는 신호에 대한 확률분포 함수(probability distribution function, pdf)를 추정하는 과정이 필요한데 이를 위해 커널분포추정(kernel density estimation) 방법을 이용한다. [Vlassis, 2001]에서는 가우시안 커널을 사용하여 독립성분분석을 실행하였다. 본 논문에서는 커널분포추정을 할 때 계산비용을 줄이기 위해서 지수(exponential) 함수를 이용한 순차 커널을 제시하였다. 순차 커널을 사용함으로써 일반적인 커널 방법의 정확도를 유지하면서도 확률분포함수와 그 미분값을 효율적으로 계산할 수 있었다. 따라서 독립성분분석 역시 좋은 성능을 보여주었다.

1.2 논문의 구성

본 논문의 구성은 다음과 같다. 2장에서는 독립성분분석의 기본적인 개념과 관련 연구들을 다룬다. 3장에서는 커널 방법을 이용한 분포추정에 관해 설명한다. 또한 일반적인 커널방법의 계산비용을 줄일 수 있는 순차 커널분포추정을 제안하고 분포추정 결과를 실험을 통해 제시한다. 4장에서는 순차 커널분포추정을 이용한 독립성분분석의 알고리즘을 보인다. 5장은 순차 커널분포추정을 이용한 독립성분분석에 대한 실험을 보여준다. 6장은 결론으로서 논문의 내용을 정리하고 앞으로의 연구 과제를 제시한다.

2장

독립성분분석

(Independent Component Analysis)

2.1 개념

d 개의 독립적인 신호들을 $s_1, s_2, \dots, s_d$ 라 하고 이들이 a_{ij} 에 의해 선형적인 조합으로 만들어진 d 개의 신호들을 $x_1, x_2, \dots, x_d$ 이라 할 때 이들의 관계는 다음과 같이 표현할 수 있다.

$$x_i = \sum_{j=1}^d a_{ij} s_j \quad (2.1)$$

여기서 x_i 와 s_j 들을 각각 벡터로 $\mathbf{x} = (x_1, x_2, \dots, x_d)^T$, $\mathbf{s} = (s_1, s_2, \dots, s_d)^T$ 와 같이 나타내고 a_{ij} 를 i 행, j 열 원소로 갖는 정방행 행렬을 $\mathbf{A}$ 라 하면 식 2.1은 다음과 같이 벡터, 행렬식으로 쓸 수 있다.

$$\mathbf{x} = \mathbf{A} \mathbf{s} \quad (2.2)$$

여기서 $\mathbf{s}$ 가 주어지지 않고 mixing 행렬인 $\mathbf{A}$ 에 대해서는 어떠한 정보도 없는 상태에서 $\mathbf{x}$ 만을 가지고 소스 $\mathbf{s}$ 와 mixing 행렬인 $\mathbf{A}$ 를 추정(estimation)하게 된다. 이것을 BSS(Blind Source Separation)라고 부른다. 식 2.2은 다음과 같

이 바꿀 수 있다.

$$\mathbf{s} = \mathbf{A}^{-1}\mathbf{x} = \mathbf{W}\mathbf{x} \quad (2.3)$$

여기서 $\mathbf{W}$ 는 $\mathbf{A}$ 의 역행렬(inverse matrix)로서 주어진 $\mathbf{x}$ 에 $\mathbf{W}$ 를 곱해 $\mathbf{s}$ 를 추정할 수 있다. 이 때 소스에 관해 필요한 몇 가지 일반적인 가정은 다음과 같다.

- 소스들은 통계적으로 서로 독립 관계에 있다.
- 소스의 분포는 non-gaussian이다
- 단, 하나의 가우시안(gaussian) 소스는 허용된다
- $\mathbf{s}$ 와 $\mathbf{x}$ 의 차원은 같다.
- $\mathbf{A}$ (혹은 $\mathbf{W}$)는 non-singular 행렬이다.
- 소스의 크기(scale)는 유일하게 정의되지 않는다.

첫 번째로 소스들이 서로 독립이라는 것은 독립성분분석의 기본적인 전제이며 이 때 소스들간의 관계를 다음과 같이 나타낼 수 있다.

$$p(s_1, s_2, \dots, s_d) = p_1(s_1)p_2(s_2)\dots p_d(s_d) \quad (2.4)$$


여기서 $p(s_1, s_2, \dots, s_d)$ 는 $s_1, s_2, \dots, s_d$ 의 결합 확률밀도함수(joint pdf)이고 $p_i(s_i)$ 는 s_i 의 한계(marginal) 확률밀도함수이다. 다음으로 소스의 분포가 non-gaussian이라는 것은 소스의 식별(identification)을 위해 필요하다. 두 개 이상의 독립관계의 소스들이 가우시안 분포를 이룰 경우 그 소스들에 orthogonal한 행렬을 곱한 결과 역시 서로 독립적인 가우시안 분포가 되기 때문이다. 따라서 이 경우 독립관계를 만족하지만 원래의 소스와는 다른 추정치가 존재하는 것이다. $\mathbf{s}$ 와 $\mathbf{x}$ 의 차원은 같다는 것은 $\mathbf{A}$ 가 정방형 매트릭스임을 의미하며, $\mathbf{x}$ 의 차원이 $\mathbf{s}$ 의 차원보다 적거나 $\mathbf{A}$ 가 singular이면 $\mathbf{s}$ 에 관한 정보부

족으로 소스를 추정을 할 수 없다. 이것은 식 2.3에서 s_i 와 x_j 의 관계를 풀어 쓴 다음 식에서 알 수 있다.

$$s_i = \sum_{j=1}^d w_{ij} x_j \quad (2.5)$$

여기서 w_{ij} 는 W 의 i 행, j 열 원소이다. 이렇듯 s_i 를 추정하기 위해서는 d 개의 x_j 가 모두 필요하므로 이중 하나라도 빠지면 추정하기 힘든 것이다. 마지막 가정은 소스의 원래 크기는 추정할 수 없음을 의미한다. 가령 식 2.2에서 s_i 에 상수 c 를 곱하고 A 의 i 번째 열에 해당하는 원소들을 모두 c 로 나누면 x 가 그대로 나옴을 알 수 있다. 즉 소스의 크기 변화는 이와 같이 상쇄되어 원래의 소스 크기를 추정할 수 없다. 그림 2.1은 s 와 x 간의 선형관계를 나타내고 x 만을 관찰할 수(observable) 있음을 나타낸다.

그림 2.1: ICA 모델



위에서 설명한 가정 중 소스가 non-gaussian이어야 한다는 가정을 바꿔서 독립성분분석을 적용한 경우도 있다. [Tong *et al.*, 1991; Belouchrani *et al.*, 1997]에서는 소스의 자기상관관계(autocorrelation)가 0이 아니고(nonzero)

뚜렷(distinct)하다는 것을 이용하였다. 또한 [Hyvärinen, 2001; Matsuoka *et al.*, 1995]에서는 소스의 분산(variance)의 nonstationarity를 이용해 소스를 추정하였다. 이제까지 설명한 내용은 일반적인 선형(linear) 독립성분분석에 관한 것이지만, s 와 x 의 관계가 비선형(nonlinear)인 경우에도 독립성분분석을 적용할 수 있다[Karhunen, 2001].

2.2 관련 연구

소스를 추정할 때 각각의 소스를 하나씩 따로 추정하는 방식과 모든 소스를 한번에 추정하는 방식이 있다. 먼저 전자의 방식을 살펴보기로 한다. 식 2.5를 내적(inner product) 꼴로 바꿔 쓰면 다음과 같다.

$$s_i = \mathbf{w}_i \cdot \mathbf{x} \quad (2.6)$$

즉 벡터 $\mathbf{x}$ 를 어떤 축에 투영시켜 하나의 소스를 얻게 된다. 이때 원하는 소스를 얻기 위해서 투영된 값이 소스와 얼마나 가까운지를 나타내는 기준이 필요하다. 이것은 신호의 nongaussianity를 측정하면 가능해진다. 어떤 신호의 nongaussianity가 높을수록, 즉 가우시안 분포로부터 멀어질수록 그 신호는 소스에 가까워지는 것이다. 이것은 중심극한정리(Central Limit Theorem) [papoulis, 1984]와 관련이 있다. 이 정리에 의하면 iid(independent and identically distributed)인 확률변수(random variable)들이 무한히 더해진 합은 가우시안 분포를 이룬다. 다시 말해 독립관계에 있는 두 변수를 더하게 되면 그 합은 원래의 변수보다 더 가우시안에 가깝게 되는 것이다. nongaussianity를 측정하는 대표적인 measure로서 kurtosis가 있다. kurtosis는 fourth-order cumulant로서 x 에 관해 다음과 같이 쓸 수 있다.

$$\text{kurt}(x) = E\{x^4\} - 3(E\{x^2\})^2 \quad (2.7)$$

x 의 평균이 0이고 표준편차가 1이라고 할 때 x 의 분포가 가우시안이면 kurtosis는 0값을 갖는다. 반면에 super-gaussian 분포일수록 양수값으로서 증가하고 sub-gaussian이 되면 음수값으로서 감소한다. super-gaussian은 가우시안보다 폭이 좁고 중심값이 더 높은 분포이고 sub-gaussian은 반대로 가우시안보다 폭이 넓고 꼬리(tail)가 긴 분포를 뜻한다. 즉 kurtosis를 최대 또는 최소로 만드는 신호가 nongaussianity가 가장 높으며 곧 소스가 됨을 알

수 있다. [Hyvärinen and Oja, 1997]에서는 $w \cdot x$ 에 관한 kurtosis를 w 에 관해 미분하고 이를 0으로 놓은 방정식 이용해 다음과 같은 알고리즘을 제안했다.

$$w(k) = E\{x(w(k-1)^T x)^3\} - 3w(k-1) \quad (2.8)$$

여기서 $w(k)$ 와 $w(k-1)$ 은 식 2.6의 w_i 에 해당하며 각각 시간이 $k, k-1$ 일 때에 주어진 x 를 투영시키는 벡터이다.

nongaussianity를 측정하는 또 다른 measure로서 엔트로피(Entropy)를 들 수 있으며 다음과 같다.

$$H(x) = - \int p(x) \log p(x) dx = E\{-\log p(x)\} \quad (2.9)$$

여기서 $p(x)$ 는 x 의 확률밀도함수이다. 표준편차가 일정할 때 엔트로피를 최대로 만드는 확률변수는 가우시안 분포이다 [Cover and Thomas, 1991]. 반대로 엔트로피값이 적어질수록 nongaussianity가 높아져 소스에 가까워지는 것이다. [Hyvärinen, 1998]에서는 최대 엔트로피 법칙(maximum entropy principle) [Cover and Thomas, 1991]을 이용해 확률밀도함수를 근사(approximation)하고 다시 이를 사용하여 엔트로피를 다음과 같이 근사하였다.

$$H(x) \approx \frac{1}{2} (1 + \log(2\pi)) - \frac{1}{2} \sum_{i=1}^m E\{G_i(x)\} \quad (2.10)$$

여기서 G_i 는 모든 $i, j = 1, \dots, m$ 에 대해 다음의 조건을 만족하는 함수이다.

$$\begin{aligned} \int \varphi(x) G_i(x) G_j(x) dx &= \begin{cases} 1, & \text{if } i = j \\ 0, & \text{if } i \neq j \end{cases} \\ \int \varphi(x) G_i(x) x^k dx &= 0, k = 0, 1, 2. \end{aligned} \quad (2.11)$$

여기서 φ 는 표준 가우시안 분포이다. 위와같이 구한 엔트로피의 최소화

(minimization)를 통해 독립성분분석을 적용할 수 있다.

지금까지 살펴본 방식들은 소스를 한번에 하나씩 추정하는 방식으로 모든 소스를 찾기 위해서는 같은 방식의 알고리즘을 소스의 개수만큼 실행해야 한다. 그러나 아무런 제약없이 알고리즘을 반복할 경우 이미 찾은 소스를 다시 찾게 될 수 있다. 이 문제점을 해결하기 위해 독립성분분석을 적용하기 전에 centering과 whitening(sphering)이라는 두 가지 기법을 사용한다. 원래의 mixture 신호벡터를 $\mathbf{x}'$ 이라 할 때 centering은 다음과 같다.

$$\mathbf{x} = \mathbf{x}' - E\{\mathbf{x}'\} \quad (2.12)$$

즉 변환된 $\mathbf{x}$ 의 평균은 0벡터가 된다. centering한 후 다음

$$E\{\mathbf{v}\mathbf{v}^T\} = \mathbf{I} \quad (2.13)$$

을 만족하도록 $\mathbf{x}$ 를 다음과 같이 $\mathbf{v}$ 로 변환시킨다.

$$\mathbf{v} = \mathbf{M}\mathbf{x} \quad (2.14)$$

이처럼 것이 whitening이다. whitening은 PCA를 이용하여 실행할 수 있다. 이제 이 $\mathbf{v}$ 를 가지고 소스 s 와 mixing 행렬을 추정하는 것이다. 이 때 식 2.2를 2.14에 대입하면 다음과 같다.

$$\mathbf{v} = \mathbf{M}\mathbf{x} = \mathbf{M}\mathbf{A}\mathbf{s} = \mathbf{B}\mathbf{s} \quad (2.15)$$

즉 이제 찾아야할 mixing 행렬은 $\mathbf{B}$ 가 되는 것이다. 식 2.13과 식 2.15를 이용해 다음과 같은 식을 얻을 수 있다.

$$E\{\mathbf{v}\mathbf{v}^T\} = \mathbf{B}\mathbf{s}\mathbf{s}^T\mathbf{B}^T = \mathbf{B}\mathbf{B}^T = \mathbf{I} \quad (2.16)$$

즉 $\mathbf{B}$ 는 orthogonal 행렬이고 이 성질을 이용해 모든 소스를 겹치지 않고 찾을 수 있다. [Hyvärinen *et al.*, 2001b]에서 다음과 같은 방법들을 제시하고 있다. 우선 Gram-Schmidt orthogonalization[Luenberger, 1969]을 이용하여 각 소스 s_i 에 해당하는 투영 축 w_i 를 한 번 학습해서 변경(update)할 때마다 다음과 같은 식을 적용할 수 있다.

$$\mathbf{w}_i \leftarrow \mathbf{w}_i - \sum_{j=1}^{i-1} \frac{\mathbf{w}_j^T \mathbf{w}_i}{\mathbf{w}_j^T \mathbf{w}_j} \mathbf{w}_j \quad (2.17)$$

이것은 모든 $\mathbf{w}_i$ 들이 서로 직교하기 위한 것이다. 또는 축들을 다음과 같이 한꺼번에 변경할 수도 있다.

$$\mathbf{W} \leftarrow (\mathbf{W}\mathbf{W}^T)^{-1/2} \mathbf{W} \quad (2.18)$$

여기서 $\mathbf{W}$ 는 $\mathbf{w}_i$ 를 i 번째 행벡터로 갖는 행렬이며 $\mathbf{w}_i$ 들을 모두 한 번씩 변경할 때마다 후 위의 식을 적용해 $\mathbf{W}$ 를 직교화할 수 있다.

모든 소스들을 한꺼번에 학습할 수 있는 알고리즘을 살펴보자.

소스 s 와 mixture x 의 관계가 $s = \mathbf{W}x$ 일 때 확률밀도함수로서 표현하면 다음과 같다.

$$p(x) = |\det \mathbf{W}| p(s) = |\det \mathbf{W}| \prod_i p_i(s_i) \quad (2.19)$$

여기서 $p(x)$ 와 $p(s)$ 는 각각 x 와 s 의 확률밀도함수이고 $p_i(s_i)$ 는 i 번째 소스의 확률밀도함수이다. 이 식을 log 우도(likelihood)에 적용하면 다음과 같다.

$$\frac{1}{T} \log L(\mathbf{B}) = E \left\{ \sum_{i=1}^d \log p_i(\mathbf{w}_i^T \mathbf{x}) \right\} + \log |\det \mathbf{W}| \quad (2.20)$$

여기서 T 는 x 의 개수이고 $\mathbf{W} = (\mathbf{w}_1, \dots, \mathbf{w}_d)^T$ 다. 이를 이용해 우도가 최대로 되게 하는 $\mathbf{W}$ 를 찾으면 된다.

정보이론적인(information-theoretic) 대표적 기준, 척도(criteria)로서 Mutual Information(이하 MI)이 있다. MI는 확률변수간의 독립성(independence)을 측정할 수 있으며 확률변수 $y_1, y_2, \dots, y_d$ 들간의 MI는 다음과 같이 쓸 수 있다.

$$\begin{aligned}
& I(y_1, y_2, \dots, y_d) \\
&= \int p(y_1, y_2, \dots, y_d) \log \frac{p(y_1, y_2, \dots, y_d)}{p(y_1)p(y_2)\dots p(y_d)} dy_1 dy_2 \dots dy_d \quad (2.21) \\
&= \sum_{i=1}^d H(y_i) - H(y)
\end{aligned}$$

여기서 y 는 $(y_1, y_2, \dots, y_d)^T$ 벡터이다. MI는 0이상의 값을 가지며 확률변수들이 통계적으로 서로 독립일 때 0이 된다. 즉 변수들간에 확률적으로 의존성(dependence)이 높을수록 큰 값을 가지게 된다. 이를 이용하면 소스의 추정인 $\hat{s} = y = Wx$ 의 독립성을 다음과 같은 식으로 측정할 수 있다.

$$I(y_1, y_2, \dots, y_d) = \sum_{i=1}^d H(y_i) - H(x) - \log|\det W| \quad (2.22)$$

MI를 최소화할 통해 독립 관계에 있는 y 를 구할 수 있다. 식 2.22는 우도에 관한 식 2.20과 형태가 비슷함을 알 수 있다. 식 2.22에서 $H(x)$ 는 고정값이니 생략할 수 있고 식 2.20의 오른쪽편의 첫 번째 항은 엔트로피이므로 결국 같은 꼴이 된다.

[Bell and Sejnowski, 1995]에서는 1-layer 뉴럴 네트워크(Neural Network)에서 출력벡터 v 와 출력노드의 sigmoid 함수로 들어가는 벡터 $y = Wx$ 간의 정보전달을 최대화(maximum information transmission)하게 되면 출력들(y) 간의 중복성(redundancy)이 줄어들어 결국은 독립성분분석의 효과를 내게 된다. 이 때 v 와 y 간의 정보전달은 다음과 같이 MI로 측정할 수 있다.

$$I(v, y) = H(v) - H(v|y) \quad (2.23)$$

이 식을 W 에 대해 미분하면 다음과 같다.

$$\frac{\partial}{\partial W} I(v, y) = \frac{\partial}{\partial W} H(v) \quad (2.24)$$

$\frac{\partial}{\partial \mathbf{W}} H(\mathbf{v}|\mathbf{y}) = 0$ 이기 때문이다. sigmoid 함수가 $g(u) = (1 + e^{-u})^{-1}$ 일 때 $\mathbf{v} = g(\mathbf{W}\mathbf{x} + \mathbf{w}_0)$ 이므로 가중치(weight)의 학습 알고리즘은 다음과 같다.

$$\Delta \mathbf{W} \propto [\mathbf{W}^T]^{-1} + (1 - 2\mathbf{v})\mathbf{x}^T, \quad \Delta \mathbf{w}_0 \propto 1 - 2\mathbf{v} \quad (2.25)$$

여기서 $\mathbf{1}$ 은 원소가 모두 1인 벡터이다. sigmoid 함수 g 는 super-gaussian 확률밀도함수의 누적밀도함수(cumulative distribution function)이다. 따라서 이 경우 super-gaussian의 소스들을 찾게 된다.

3장

순차 커널분포추정

(Sequential Kernel Density Estimation)

3.1 커널분포추정의 개념

분포, 즉 확률밀도함수를 추정하는 방법은 모델이 파라미터에 의해 정형화되어 있는지 아닌지에 따라 parametric과 nonparametric으로 나눌 수 있다. nonparametric한 대표적인 한 방법으로 히스토그램(histogram)을 들 수 있다. 그러나 히스토그램은 범위의 초기점(origin)과 구간 간격(bin width)을 어떻게 정하냐에 따라 추정된 분포의 모양이 달라진다. 또한 확률밀도함수의 미분을 구할 수 없다. 이런 점을 보완하기 위해 nonparametric한 방법으로 커널분포추정(kernel density estimation)이 있다[Silverman, 1986]. 본 논문에서는 1차원 확률 변수에 대한 커널분포추정에 대해 살펴보겠다. 우선 확률변수 X 의 확률밀도함수의 정의는 다음과 같다.

$$p(x) = \lim_{h \rightarrow 0} \frac{P(x < X \leq x + h)}{h} \quad (3.1)$$

여기서 P 는 확률을 의미한다. 이 확률분포로부터 나온 임의의(random) n 개의 샘플(sample) 데이터들을 $x_1, x_2, \dots, x_n$ 이라 할 때 어떤 작은 값 h 에 의한 확

률분포의 추정치를 위 정의에 근거하여 다음과 같이 표현할 수 있다.

$$\hat{p}(x) = \frac{\text{no. of } x_i \text{ satisfying } (x-h < x_i \leq x+h)}{2hn} \quad (3.2)$$

즉 x 로부터 h 거리이하에 있는 샘플 x_i 의 개수를 간격 $2h$ 와 샘플 수 n 으로 나눈 것이다. 여기서 $w(x)$ 를 정의하여 식을 다시 쓰면 다음과 같다.

$$\hat{p}(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h} w\left(\frac{x-x_i}{h}\right), \quad w(x) = \begin{cases} \frac{1}{2} & \text{if } |x| < 1 \\ 0 & \text{otherwise} \end{cases} \quad (3.3)$$

즉 여기서 $\frac{1}{h} w\left(\frac{x-x_i}{h}\right)$ 는 샘플 포인트 x_i 를 중심으로 너비가 $2h$ 이고 높이가 $\frac{1}{2h}$ 이며 넓이가 1인 사각형 모양의 함수이다. 이제 미분이 가능하기 위해 w 대신에 다음 조건들을 만족하는 K 함수를 도입한다.

- 대칭(symmetric)이다.
- 중심으로부터 멀어질수록 단조감소한다.
- 미분가능한 smoothing 함수이다.
- 확률밀도함수의 성질을 만족한다.

$$\left(\int_{-\infty}^{\infty} K(x) dx = 1, K(x) \geq 0 \right)$$

$$\hat{p}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right) \quad (3.4)$$

여기서 각 샘플 포인트 x_i 가 중심인 K 가 n 개 모여 확률분포를 추정하게 되는 것이다. 이 때 h 는 K 의 너비로서 window width 혹은 smoothing parameter로 불린다. h 가 너무 크면 추정의 세밀함이 떨어져 굴곡이 심한 분포에 대해

정확성이 떨어지며 h 가 너무 적으면 오히려 추정된 분포의 굴곡이 원래의 분포보다 심해진다. 따라서 h 값에 따라 추정의 정확도가 달라진다. K 로 자주 쓰이는 함수로는 가우시안 분포가 있지만 K 의 모양은 앞에 나온 조건들을 만족하기만 하면 성능에 큰 영향이 없다[Turlach, 1993].

다음 조건들

- $\sup_x K(x) < \infty$
- $\lim_{|x| \rightarrow \infty} K(x)x = 0$
- $\lim_{n \rightarrow \infty} h = 0$
- $\lim_{n \rightarrow \infty} nh = \infty$

을 만족시키면 샘플의 개수 n 이 무한대로 감에 따라 커널분포추정에 의해 추정된 분포는 Convergence in mean square로 실제 분포에 근접하게 됨을 다음에서 알 수 있다[Duda *et al.*, 2001].

$$\lim_{n \rightarrow \infty} E[\hat{p}(x)] = \int \delta(x-v)p(v)dv = p(x) \quad (3.5)$$

$$\begin{aligned} \lim_{n \rightarrow \infty} E[(\hat{p}(x) - E[\hat{p}(x)])^2] &= 0 \\ (\because E[(\hat{p}(x) - E[\hat{p}(x)])^2] &\leq \frac{\sup(K(\cdot))E[\hat{p}(x)]}{nh}) \end{aligned} \quad (3.6)$$

여기서 E 는 각각의 샘플 포인트 x_i 에 대한 기대값(Expectation)이다.

커널분포추정에서 h 에 의해 정해지는 추정분포 $\hat{p}$ 와 실제분포 p 사이의 거리

를 측정하기 위한 척도, 기준으로서 MISE(Mean Integrated Squared Error)이 있다.

$$\text{MISE}(h) = E\left[\int \{\hat{p}_h(x) - p(x)\}^2 dx\right] \quad (3.7)$$

또한 MISE를 점근적(asymptotic)으로 근사한 Asymptotic Mean Integrated Squared Error(AMISE)는 다음과 같다.

$$\text{AMISE}(h) = (nh)^{-1}R(K) + h^4(\mu_2(K)/2)^2R(p^{(2)}) \quad (3.8)$$

여기서 $R(K) = \int K(x)^2 dx$, $\mu_2(K) = \int x^2 K(x) dx$ 이고 $p^{(2)}$ 는 p 의 2계도 미분 함수이다. AMISE를 최소화하기 위해 식 3.8을 미분하여 0이 되게 하는 h 를 구하면 다음과 같다.

$$h = \left(\frac{R(K)}{\mu_2^2(K)R(p^{(2)})}\right)^{\frac{1}{5}} n^{-\frac{1}{5}} \quad (3.9)$$

여기서 h 는 $n \rightarrow \infty$ 일 때 $h \rightarrow 0$, $hn \rightarrow \infty$ 을 만족한다. 또한 K 와 p 를 모두 가우시안으로 놓으면 h 는 다음과 같다[Silverman, 1986].

$$h = 1.06 \hat{\sigma} n^{-\frac{1}{5}} \quad (3.10)$$

여기서 $\hat{\sigma}$ 는 샘플의 표준편차이며 window width인 h 는 가우시안 커널의 분산에 해당한다.

3.2 순차 커널분포추정

커널분포추정에서 n 개의 샘플 포인트에 대해 확률밀도함수 값 또는 그 미분값을 추정하는데 걸리는 비용은 FFT(Fast Fourier Transform)를 이용해 $O(n \log n)$ 이다. 본 논문에서는 이를 $O(n)$ 으로 줄일 수 있는 순차 커널분포 추정을 제시한다. 순차 커널 K_e 는 다음

$$K_e(x) = \begin{cases} ae^{-b|x|} + c & \text{if } x < |d| \\ 0 & \text{otherwise} \end{cases} \quad (3.11)$$

과 같이 지수 함수를 이용한 대칭 함수 형태이며 일반적인 커널을 근사하여 모양이 정해진다. 여기서 $d(< 0)$ 는 $K_e(x)$ 가 0이 되는 x 의 값이다. 식 3.4에

서 $\frac{1}{h} \sum_{i=1}^n K(\frac{x-x_i}{h})$ 부분을 대체하여 다음과 같이 쓸 수 있다.

$$\hat{p}(x) = \frac{1}{n} \sum_{i=1}^n K_e(x - x_i) \quad (3.12)$$


본 논문에서는 순차 커널이 근사하려는 커널을 일반적으로 잘 쓰여지는 가우시안으로 정한다. $e(x) = ae^{bx} + c(x < 0)$ 라 할 때 가우시안 커널 g 를 근사하기 위해 다음 네 가지 조건들을 만족해야 한다.

$$\begin{aligned} l(d) &= 0, d < 0 \\ l(0) &= g(0) \\ l'(0) &= [0.2, 2] \\ \int_d^0 l(x)dx &= 0.5 \end{aligned} \quad (3.13)$$

첫 번째 조건은 d 에서 커널값이 0을 갖기 위한 것이다. 두 번째는 0에서의 순

차 커널값과 가우시안 커널 g 값이 같게 하기 위해서다. 따라서 가우시안 커널의 너비값이 정해져야 두 번째 조건식을 세울 수 있다. 세 번째 조건은 0에서의 미분값을 정하는 것인데 이는 가우시안 커널의 너비 즉 분산값에 따라 달라진다. 너비가 좁을수록 미분값은 커지게 된다. 마지막 조건은 정적분값이 1이 되어 확률밀도함수의 조건을 만족시키기 위한 것이다. 그림 3.1은 위 조건들을 만족시켜 가우시안 커널의 왼쪽 부분을 근사한 $l(x)$ 와 가우시안 커널을

그림 3.3: 가우시안과 이를 근사한 $l(x) = ae^{bx} + c$



보여준다. 조건들을 만족시키는 네 개의 미지수 a, b, c, d 를 구하기 위해서는 위의 네 개의 방정식(조건)을 풀어야 한다. 방정식을 서로 대입하여 a 에 관한 식으로 나타내면 다음과 같다.


$$ae^{\frac{0.5l'(0)-g(0)a}{a(a-g(0))}} + g(0) - a = 0 \quad (3.14)$$

이 식의 왼쪽 편을 다음

$$f(a) = ae^{\frac{0.5l'(0)-g(0)a}{a(a-g(0))}} + g(0) - a \quad (3.15)$$

처럼 정의할 때 $f(a)$ 를 a 에 관한 그래프로 나타내면 그림 3.2와 같다. 그림 3.2에서 알 수 있듯이 식 3.14를 만족시키는 a 값은 원점으로부터 약간 왼쪽에 떨어져 있다. 또한 g 의 너비값 h 가 좁아질수록 a 는 원점에 가까워지게 된다. 따라서 a 의 초기값을 0으로 하고 Newton Method를 써서 식 3.14를 만족하

그림 3.2: a 값에 따른 $f(a)$ 의 그래프



는 a 를 구할 수 있고 이를 다른 방정식에 대입해 나머지 b, c, d 도 구할 수 있다.

$$a \leftarrow -\frac{f(a)}{f'(a)} + a \quad (3.16)$$

여기서 $f(a)$ 는 다음과 같다.

$$e^{\frac{0.5l'(0)-g(0)a}{a(a-g(0))}} \left(1 + \frac{g(0)a^2 - l'(0)a + 0.5g(0)l'(0)}{a(a-g(0))^2}\right) - 1 \quad (3.17)$$

이렇게 해서 a, b, c, d 값을 구해 순차 커널 K_e 의 형태가 정해지면 순차 커널분포추정을 하게 된다. 순차 커널분포추정 알고리즘은 그림 3.3과 같다.



그림 3.3: 순차 커널분포추정 알고리즘

1. $K_e = ae^{bx} + c$ ($K_e(d) = 0$) 에서 a, b, c, d 값을 구한다.
 - 근사하려는 가우시안 커널 g 의 너비(분산)값 h 를 $h = 1.06n^{-\frac{1}{5}}$ 에 의해 구한다(n 은 샘플 개수).
 - $a \leftarrow -\frac{f(a)}{f'(a)} + a$ 를 반복적으로 수행해 수렴값 a 를 구한다.
($f(a)$ 는 식 3.15)
 - a 를 식 3.13에 대입해 b, c, d 를 구한다.
2. 샘플의 히스토그램을 구한다.
 - 샘플을 표준편차가 1이 되도록 변환한다.
 - 샘플의 최소, 최대값을 찾아낸다.
 - 최소, 최대값 사이의 구간을 샘플의 개수 n 으로 나누어 샘플의 히스토그램을 구한다.
3. n 개 구간 각각의 대표값(구간의 중간값)에 대해 확률밀도함수값을 추정한다.
 - 그림 3.4를 이용해 n 개의 확률밀도함수값을 순차적으로 구한다.
 - 그림 3.5를 이용해 n 개의 확률밀도함수의 미분값을 순차적으로 구한다.

그림 3.4: 순차 커널분포추정

r_i 는 i 번째 구간의 대표값, n_i 는 i 번째 구간의 히스토그램값, 구간의 크기는 S , $W = \left\lfloor \frac{|d|}{S} \right\rfloor$ 라 할 때 r_i 에서의 분포추정값 $\hat{p}(r_i)$ 은 다음과 같다.

$$\begin{aligned}
 \hat{p}(r_i) &= \frac{1}{n} \sum_{j: |i-j| \leq W} K_e(r_i - r_j) n_j \\
 &= \frac{1}{n} \sum_{j: |i-j| \leq W} (ae^{-b|r_i - r_j|} + c) n_j \\
 &= \frac{1}{n} \left\{ \sum_{j: 0 < i-j \leq W} (ae^{-b(r_i - r_j)} + c) n_j + \sum_{j: -W \leq i-j \leq 0} (ae^{b(r_i - r_j)} + c) n_j \right\} \\
 &= \frac{1}{n} \left\{ \sum_{j: 0 < i-j \leq W} ae^{-b(r_i - r_j)} n_j + \sum_{j: 0 < i-j \leq W} cn_j \right. \\
 &\quad \left. + \sum_{j: -W \leq i-j \leq 0} ae^{b(r_i - r_j)} n_j + \sum_{j: -W \leq i-j \leq 0} cn_j \right\}
 \end{aligned}$$

여기서 각 항을 $\hat{p}_{L1}(r_i), \hat{p}_{L2}(r_i), \hat{p}_{R1}(r_i), \hat{p}_{R2}(r_i)$ 라 할 때

$$\begin{aligned}
 \hat{p}_{L1}(r_i) &= \sum_{j: 0 < i-j \leq W} ae^{-b(r_i - r_j)} n_j \\
 &= \sum_{j: 1 < i-j \leq W} ae^{-b(r_i - r_j)} n_j + ae^{-b(r_i - r_{i-1})} n_{i-1} \\
 &= \sum_{j: 1 < i-j \leq W} ae^{-b(r_{i-1} - r_j)} e^{-b(r_i - r_{i-1})} n_j + ae^{-b(r_i - r_{i-1})} n_{i-1} \\
 &= \sum_{j: 0 < i-1-j \leq W-1} ae^{-b(r_{i-1} - r_j)} e^{-bS} n_j + ae^{-b(r_i - r_{i-1})} n_{i-1} \\
 &= \left(\sum_{j: 0 < i-1-j \leq W} ae^{-b(r_{i-1} - r_j)} n_j - ae^{-b(r_{i-1} - r_{i-1-W})} n_{i-1-W} \right) e^{-bS} \\
 &\quad + ae^{-b(r_i - r_{i-1})} n_{i-1} \\
 &= (\hat{p}_{L1}(r_{i-1}) - ae^{-b(r_{i-1} - r_{i-1-W})} n_{i-1-W}) e^{-bS} \\
 &\quad + ae^{-b(r_i - r_{i-1})} n_{i-1}
 \end{aligned}$$

그림 3.4:

()

즉 $\hat{p}_{L1}(r_i)$ 은 $\hat{p}_{L1}(r_{i-1})$ 을 이용하여 구할 수 있으므로 i 가 1부터 n 까지 분포값을 순차적으로 계산할 수 있다. $\hat{p}_{R1}(r_i)$ 역시 같은 방식으로 $\hat{p}_{R1}(r_{i-1})$ 에 관한 식으로 풀 수 있다.

$$\begin{aligned}
 \hat{p}_{R1}(r_i) &= \sum_{j: -W \leq i-j \leq 0} ae^{b(r_i-r_j)} n_j \\
 &= \sum_{j: -W+1 \leq i-j \leq 0} ae^{b(r_i-r_j)} n_j + ae^{b(r_i-r_{i+W})} n_{i+W} \\
 &= \sum_{j: -W+1 \leq i-j \leq 0} ae^{b(r_{i-1}-r_j)} e^{b(r_i-r_{i-1})} n_j + ae^{b(r_i-r_{i+W})} n_{i+W} \\
 &= \sum_{j: -W \leq i-1-j \leq -1} ae^{b(r_{i-1}-r_j)} e^{bS} n_j + ae^{b(r_i-r_{i+W})} n_{i+W} \\
 &= \left(\sum_{j: -W \leq i-1-j \leq 0} ae^{b(r_{i-1}-r_j)} n_j - ae^{b(r_{i-1}-r_{i-1})} n_{i-1} \right) e^{bS} \\
 &\quad + ae^{b(r_i-r_{i+W})} n_{i+W} \\
 &= (\hat{p}_{R1}(r_{i-1}) - an_{i-1}) e^{bS} + ae^{b(r_i-r_{i+W})} n_{i+W} \\
 \hat{p}_{L2}(r_i) \text{와 } \hat{p}_{R2}(r_i) \text{도 각각 } \hat{p}_{L2}(r_{i-1}) \text{와 } \hat{p}_{R2}(r_{i-1}) \text{를 이용하여 구할 수 있다.}
 \end{aligned}$$

$$\hat{p}_{L2}(r_i) = \sum_{j: 0 < i-j \leq W} cn_j = \hat{p}_{L2}(r_{i-1}) - cn_{i-1-W} + cn_{i-1}$$

$$\hat{p}_{R2}(r_i) = \sum_{j: -W \leq i-j \leq 0} cn_j = \hat{p}_{R2}(r_{i-1}) - cn_{i-1} + cn_{i+W}$$

이런 식으로 n 개의 샘플 포인트들에 대한 확률밀도함수값을 $o(n)$ 에 계산할 수 있다.

그림 3.5: 순차 커널분포미분추정

r_i 는 i 번째 구간의 대표값, n_i 는 i 번째 구간의 히스토그램값, 구간의 크기는 S , $W = \left\lfloor \frac{|d|}{S} \right\rfloor$ 라 할 때 r_i 에서의 분포의 미분 추정값 $\hat{p}'(r_i)$ 은 다음과 같다.

$$\begin{aligned}\hat{p}'(r_i) &= \frac{1}{n} \sum_{j: |i-j| \leq W} K'_e(r_i - r_j) n_j \\ &= \frac{1}{n} \sum_{j: |i-j| \leq W} (ae^{-b|r_i - r_j|} + c)' n_j \\ &= \frac{1}{n} \left\{ \sum_{j: 0 < i-j \leq W} -abe^{-b(r_i - r_j)} n_j + \sum_{j: -W \leq i-j \leq 0} abe^{b(r_i - r_j)} n_j \right\}\end{aligned}$$

여기서 각 항을 $\hat{p}'_L(r_i), \hat{p}'_R(r_i)$ 라 할 때 그림 3.4와 같은 방식으로 식을 다음과 같이 전개할 수 있다.

$$\begin{aligned}\hat{p}'_L(r_i) &= \sum_{j: 0 < i-j \leq W} -abe^{-b(r_i - r_j)} n_j \\ &= (\hat{p}'_L(r_{i-1}) + abe^{-b(r_{i-1} - r_{i-1-W})} n_{i-1-W}) e^{-bS} - abe^{-b(r_i - r_{i-1})} n_{i-1} \\ \hat{p}'_R(r_i) &= \sum_{j: -W \leq i-j \leq 0} abe^{b(r_i - r_j)} n_j \\ &= (\hat{p}'_R(r_{i-1}) - abn_{i-1}) e^{bS} + abe^{b(r_i - r_{i+W})} n_{i+W}\end{aligned}$$

즉 $\hat{p}'_L(r_i)$ 과 $\hat{p}'_R(r_i)$ 은 각각 $\hat{p}'_L(r_{i-1})$ 과 $\hat{p}'_R(r_{i-1})$ 을 이용하여 구할 수 있으므로 i 가 1부터 n 까지 분포의 미분값을 순차적으로 계산할 수 있다.

3.3 순차 커널분포추정의 예

3.2장에서 제시된 방법대로 주어진 확률밀도함수에 대해 순차 커널분포추정을 적용해 보았다. 다음과 같은 10개의 확률밀도함수에서 각각 3000개의 샘플을 뽑아낸 후 순차 커널분포추정을 실행한 결과 그림 3.6과 같았다(실선은 주어진 확률밀도함수, 점선은 추정된 함수).

(a) 가우시안 분포

$$\frac{1}{\sigma\sqrt{2\pi}}e^{-(x-\mu)^2/(2\sigma^2)}, (\mu = 0, \sigma = 0.45)$$

(b) 가우시안 분포

위 식과 동일, $(\mu = 0, \sigma = 0.7)$

(c) 가우시안 분포

위 식과 동일, $(\mu = 0, \sigma = 0.2)$

(d) 두 개의 가우시안을 조합한 분포

$$\frac{1}{2} \frac{1}{\sigma_1\sqrt{2\pi}}e^{-(x-\mu_1)^2/(2\sigma_1^2)} + \frac{1}{2} \frac{1}{\sigma_2\sqrt{2\pi}}e^{-(x-\mu_2)^2/(2\sigma_2^2)},$$

$$(\mu_1 = -0.5, \sigma_1 = 0.3, \mu_2 = 0.5, \sigma_2 = 0.3)$$

(e) 두 개의 가우시안을 조합한 분포

위 식과 동일, $(\mu_1 = -0.4, \sigma_1 = 0.3, \mu_2 = 0.4, \sigma_2 = 0.3)$

(f) 두 개의 가우시안을 조합한 분포

위 식과 동일, $(\mu_1 = -0.5, \sigma_1 = 0.4, \mu_2 = 0.5, \sigma_2 = 0.25)$

(g) 세 개의 가우시안을 조합한 분포

$$\sum_{i=1}^3 \frac{1}{3} \frac{1}{\sigma_i \sqrt{2\pi}} e^{-(x-\mu_i)^2/(2\sigma_i^2)},$$

$$(\mu_1 = -0.8, \sigma_1 = 0.25, \mu_2 = -0.2, \sigma_2 = 0.2, \mu_3 = 0.4, \sigma_3 = 0.4)$$

(h) 세 개의 가우시안을 조합한 분포

위 식과 동일,

$$(\mu_1 = -0.4, \sigma_1 = 0.2, \mu_2 = 0, \sigma_2 = 0.2, \mu_3 = 0.4, \sigma_3 = 0.2)$$


(i) 맥스웰(Maxwell) 분포

$$\sqrt{\frac{2}{\pi}} a^{3/2} x^2 e^{-ax^2/2}, (a = 0.8)$$

(j) 라플라스(Laplace) 분포


$$\frac{1}{\sqrt{2}\sigma} e^{-|x-\mu|/\sqrt{2}\sigma}, (\mu = 0, \sigma = 0.6)$$

그림 3.6: 순차 커널분포추정




(a)


그림 3.6: ()



(b)




(c)




(d)


그림 3.6: ()



(e)




(f)




(g)


그림 3.6: ()



(h)



(i)



(j)

4장

순차 커널 분포추정을 이용한 독립 성분분석

4.1 알고리즘

MI에 관한 식 2.22를 다시 쓰면 다음과 같다.

$$I(y_1, y_2, \dots, y_d) = \sum_{i=1}^d H(y_i) - H(\mathbf{x}) - \log|\det \mathbf{W}|$$

위 식을 $\mathbf{W}$ 에 대해 미분하면 다음과 같다.

$$\begin{aligned} \frac{\partial I}{\partial \mathbf{W}} &= E[\phi(\mathbf{y}) \mathbf{x}^T] - (\mathbf{W}^T)^{-1}, \\ \phi(\mathbf{y}) &= \left[-\frac{p'(y_1)}{p(y_1)}, \dots, -\frac{p'(y_d)}{p(y_d)} \right]^T \end{aligned} \quad (4.1)$$

Natural gradient[Amari *et al.*, 1996]를 적용하기 위해 $\frac{\partial I}{\partial \mathbf{W}}$ 의 오른쪽에

$\mathbf{W}^T \mathbf{W}$ 를 곱해주면 다음과 같다.

$$\frac{\partial I}{\partial \mathbf{W}} \mathbf{W}^T \mathbf{W} = (E[\phi(\mathbf{y}) \mathbf{y}^T] - \mathbf{I}) \mathbf{W} \quad (4.2)$$

따라서 MI를 최소화하기 위해 $\mathbf{W}$ 를 학습시키는 식은 다음과 같다.

$$\Delta W = c(I - E[\phi(y)y^T])W \quad (4.3)$$

여기서 c 는 학습률(learning rate)이다. ϕ 에서의 p 와 p' 을 구하기 위해 3장에서 설명한 순차 커널분포추정을 사용하는 독립성분분석의 알고리즘은 그림 4.1과 같다.

그림 4.1: 순차 커널분포추정을 이용한 독립성분분석

1. $y = Wx$ 를 계산한다.
2. 그림 3.3의 알고리즘을 이용해 n 개의 구간에 대해 y_i 의 확률밀도함수와 그 미분값을 추정한다.
3. W 를 학습시킨다.

$$W \leftarrow W + c(I - E[\phi(y)y^T])W$$
 (이 때 ϕ 에서 샘플 포인트에서의 p 와 p' 값은 그 샘플 포인트가 속한 구간 대표값에서의 값(2번에서 구한 값)을 취한다.)
4. W 의 행벡터 w_i 들을 normalize한다.

$$w_i \leftarrow \frac{w_i}{\|w_i\|}$$
5. 수렴하지 않으면 1번으로 되돌아간다.

5.1

실험

5.1 첫 번째 실험

소스의 개수는 3, , 가우시안 두 개를 조합한 분포로부터 iid 3000 (sampling) .

$$p_1(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/(2\sigma^2)} \quad (5.1)$$

$$p_2(x) = \frac{1}{\sqrt{2}\sigma} e^{-|x-\mu|/\sqrt{2}/\sigma} \quad (5.2)$$

$$p_3(x) = \frac{1}{2} \frac{1}{\sigma_1\sqrt{2\pi}} e^{-(x-\mu_1)^2/(2\sigma_1^2)} + \frac{1}{2} \frac{1}{\sigma_2\sqrt{2\pi}} e^{-(x-\mu_2)^2/(2\sigma_2^2)} \quad (5.3)$$

여기서 각 분포의 파라미터 설정은 다음과 같다.

- $p_1 : \mu = 0, \sigma = 1$
- $p_2 : \mu = 0, \sigma = 1$
- $p_3 : \mu_1 = -1, \sigma_1 = 0.3, \mu_2 = 1, \sigma_2 = 0.3$

mixing .

$$A = \begin{bmatrix} 0.244 & 0.972 & 0.925 \\ 0.527 & 0.263 & 0.715 \\ 0.473 & 0.345 & 0.37 \end{bmatrix} \quad (5.4)$$

식 3.13 |서 $l'(0)$ 의 값을 0.8, $\alpha = 0.1$, iteration = 300 |로 설정하고 그림 4.1 | 알고리즘대로 순차 커널분포추정을 이용한 독립성분분석을 적용하였다.

- $a = -0.100355$
- $b = -7.97166$
- $c = 1.96686$
- $d = -0.373256$

실험 결과 $Wx = \hat{s}$ 에 해당하는 W 를 다음과 같이 구하였다.

$$W = \begin{bmatrix} 0.287579 & -0.70812 & 0.644875 \\ 0.0938783 & 0.650836 & -0.753392 \\ -0.305796 & -0.106692 & 0.9461 \end{bmatrix} \quad (5.5)$$

이 때 W 는 A^{-1} 과 비교할 때 행벡터의 위치가 바뀔 수 있으며 행벡터의 크기 (scale)는 1로 고정되어 있다. 따라서 WA 는 0이 아닌 값 (0이 아닌 값이 많지 않은)인 1 (permutation)이다. 실험에
서의 결과도 다음과 같이 순열 행렬로 나왔다.

$$WA = \begin{bmatrix} 0.00201607 & 0.315774 & -0.00169023 \\ 0.00966974 & 0.00251618 & 0.273525 \\ 0.31658 & 0.00109187 & -0.00918429 \end{bmatrix} \quad (5.6)$$

식 2.22 MI

$$I(y_1, y_2, \dots, y_d) = \sum_{i=1}^d H(y_i) - H(x) - \log|\det W|$$

여기서 $H(x)$ 는 구할 수 없으나 고정된 값이므로 $I(y_1, y_2, \dots, y_d) = I(y)$ 에서

$-H(x)$ 를 제외시킨 $I(y) + H(x)$ 을 iteration $|$ 따라 구해보았으며 결과는 그림 5.1 .

그림 5.1: iteration $|$ 따른 $I(y) + H(x)$ 의 변화






그림 5.2 : 5.1 iteration 100 300 |지의 부분



위 그래프에서 $MI + H(x)$ 가 2 | 가까운 수로 수렴하는 것은 $H(x)$ 가 2 | 가까운 수이기 때문이다. 따라서 MI는 0 . 이 실험에서 사용된 순차 커널의 $l(x) = ae^{bx} + c$ 와 순차 커널이 근사하려는 가우시

안 커널과 독립성분분석에 의해서 추정된 세 개의 소스 분포를 그림 5.3 |서 보여주고 있다.

그림 5.3: 가우시안 커널과 이를 근사한 순차 커널의 $l(x)$ 와 세 개의 소스 분포



5.2 두 번째 실험

원래의 소스와 추정된 소스를 시각적으로 비교하기 쉽게 하기 위해 다음과 같이 두 번째 실험을 하였다. 5 10000 |씩 샘플링하였다. 5.4 : 다음 순서대로 나열된 소스들의 처음 100

- 시대, (random) 값
을 갖는 random-walk process
- M2M” “Why”()
- 필자의 “ ” 하고 외치는 목소리
- 쇼팽(Chopin) (Nocturne Op.9-2)
- in 파

이 5 mixing 행렬에 의해 섞은 결과 처음 100 5.5 . 3.13 |서 $l'(0)$ 의 값을 1.6, 학습률을 0.1, iteration 300 mixture | 순차 커널분포추정을 이용한 독립성분분석을 적용하였다. 이 때 순차 커널의 파라미터값은 다음과 같았다.

- $a = -0.100355$
- $b = -7.97166$
- $c = 1.96686$
- $d = -0.373256$

그림 5.4: 5 }의 소스 신호




그림 19.5: 5 mixture 신호




그림 5.6: 5 }의 추정된 신호




그림 5.6 100 | 부분에 대한 그래프를 보여준다. 5.4 | 비교해 보면 추정된 소스가 원래의 소스와 순서와 진폭이 바뀐 채로 제대로 추정되었음을 확인할 수 있다.

6장

결론 및 향후 과제

커널분포추정의 경우 추정의 정확도가 다른 분포추정 방법에 비해 높은 편이지만 계산 비용이 크다. 본 논문에서는 기존의 커널분포추정의 계산 비용을 줄이기 위해 순차 커널 제시하여 독립성분분석에 이를 사용하였다. 또한 커널분포추정의 높은 정확성으로 인해 독립성분분석 역시 소스를 명확하게 찾아냄을 확인하였다. 커널분포추정의 경우 샘플 개수가 많아질 때 추정의 효율성을 높이기 위한 처리가 필요하다. 계산비용도 남은 과제로는 순차 커널의 모양을 정할 때 식 3.13에서 $l'(0)$ 값을 경험적으로(empirically) 사용했는데 이를 보다 정확하고 효율적으로 구할 필요가 있다.

참고 문헌

S. Amari, A. Cichocki, and H.H. Yang, A New Learning Algorithm for Blind Signal Separation, In *Advances in Neural Information Processing Systems 8 (NIPS '95)*, pp. 757-763, 1996.

M. Bartlett, S. Makeig, A.J. Bell, T.P. Jung, and T.J. Sejnowski, Independent Component Analysis of EEG Data, *Society for Neuroscience Abstracts*, vol. 21, pp. 437, 1995.

A.J. Bell and T.J. Sejnowski, An Information-Maximization Approach to Blind Separation and Deconvolution, *Neural Computation*, vol. 7, pp. 1129-1159, 1995.

A. Belouchrani, K. Abed Meraim, J.-F. Cardoso, and E. Moulines, A Blind Source Separation Technique Based on Second Order Statistics, *IEEE Transactions on Signal Processing*, vol. 45, no. 2, pp. 434-444, 1997.

A. Cichocki and L. Moszczynski, A New Learning Algorithm for Blind Separation of Sources, *Electronics Letters*, vol. 28, no. 21, pp. 1986-1987, 1992.

P. Comon, Independent Component Analysis - a New Concept? *Signal*

Processing, vol. 36, pp. 287–314, 1994.

T.M. Cover and J.A. Thomas, *Elements of Information Theory*, John Wiley & Sons, 1991.

R.O. Duda, P.E. Hart, and D.G. Stork, *Pattern Classification, 2nd ed.*, Chapter 4, pp. 161–174, John Wiley & Sons, 2001.

T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, Springer-Verlag, 2001.

P.O. Hoyer and A. Hyvärinen, Independent Component Analysis Applied to Feature Extraction from Colour and Stereo Images, *Network: Computation in Neural Systems*, vol. 11, no. 3, pp. 191–210, 2000.

P.J. Huber, Projection Pursuit, *The Annals of Statistics*, vol. 13, no. 2, pp. 435–475, 1985.

A. Hyvärinen and E. Oja, A Fast Fixed-Point Algorithm for Independent Component Analysis, *Neural Computation*, vol. 9, no. 7, pp. 1483–1492, 1997.

A. Hyvärinen, New Approximations of Differential Entropy for Independent Component Analysis and Projection Pursuit, In *Advances in Neural Information Processing Systems 10 (NIPS '97)*, pp. 273–279,

1998.

A. Hyvärinen, Beyond Independent Components, In *Proceedings of International Conference on Artificial Neural Networks*, pp. 809–814, 1999.

A. Hyvärinen, P. Hoyer and E. Oja, Image Denoising by Sparse Code Shrinkage, In S. Haykin and B. Kosko (eds.), *Intelligent Signal Processing*, IEEE Press, 2001.

A. Hyvärinen, J. Karhunen, and E. Oja, *Independent Component Analysis*, John Wiley & Sons, 2001.

A. Hyvärinen, Blind Source Separation by Nonstationarity of Variance: A Cumulant-based Approach, *IEEE Transactions on Neural Networks*, vol. 12, no. 6, pp. 1471–1474, 2001.

I.T. Jolliffe, *Principal Component Analysis*, Springer-Verlag, 1986.

C. Jutten and J. Herault, Blind Separation of Sources, Part I: An Adaptive Algorithm based on Neuromimetic Architecture, *Signal Processing*, vol. 24, pp. 1–10, 1991.

J. Karhunen, Nonlinear Independent Component Analysis, In R. Everson and S. Roberts (eds.), *ICA: Principles and Practice*, Review Chapter, pp.

113-134, Cambridge University Press, 2001.

D. Luenberger, *Optimization by Vector Space Methods*, John Wiley & Sons, 1969.

K. Matsuoka, M. Ohya, and M. Kawamoto, A Neural Net for Blind Separation of Nonstationary Signals, *Neural Networks*, vol. 8, no. 3, pp. 411-419, 1995.

E. Oja, J. Karhunen, L. Wang, and R. Vigario, Principal and Independent Components in Neural Networks - Recent Developments, In *Proceedings of the VIIth Italian Workshop on Neural Nets*, 1995.

B.A. Olshausen and D.J. Field, Emergence of Simple-Cell Receptive Field Properties by Learning a Sparse Code for Natural Images, *Nature*, vol. 381, pp. 607-609, 1996.

A. Papoulis, *Probability, Random Variables, and Stochastic Processes*, 2nd ed., McGraw-Hill, 1984.

B.W. Silverman. *Density Estimation for Statistics and Data Analysis*, CRC Press, 1986.

L. Tong, R.-W. Liu, V.C. Soon, and Y.-F. Huang, Indeterminacy and Identifiability of Blind Identification, *IEEE Transactions on Circuits and*

Systems, vol. 38, pp. 499–509, 1991.

B.A. Turlach, Bandwidth Selection in Kernel Density Estimation: a Review, *Discussion Paper 9307*, Institut für Statistik und Ökonometrie, Humboldt-Universität zu Berlin, 1993.

N. Vlassis, Efficient Source Adaptivity in Independent Component Analysis, *IEEE Transactions on Neural Networks*, vol. 12, no. 3, pp. 559–566, 2001.

Abstract

Independent component analysis (ICA) is a method separating the mixture of signals into statistically and mutually independent ones. It has been applied to not only the signal processing area but also image or text analysis field actively. Being used in so diverse fields, the algorithm of ICA itself has been studied intensively and developed its accuracy and usefulness.

Density estimation is one step of the whole ICA process. The characteristics of ICA depends on the quality of method for density estimation. In this thesis, density estimation is carried out using kernel method known to be more accurate than other methods, in order to improve the performance of ICA. While kernel density estimation approximates the real density more precisely compared with others, it has the defect of intensive computational cost.

In this thesis, a novel method, *Sliding Kernel Density Estimation* is presented to reduce the computational cost. It uses exponential functions as kernel to estimate density and its derivative in a sequential way. It is theoretically shown that the estimation using this method is accomplished more efficiently. And I experimentally prove the improvement on the performance of ICA with this method.

Keywords: independent component analysis (ICA), kernel, sliding kernel, density estimation

Student Number: 2001-21565

감사의 글

대학원 2년차의 한 해가 제 인생에서 가장 힘든 한 해가 아니었나 생각됩니다. 저를 그냥 보시는 분들은 그냥 놀면서 지냈으리라 추측하시겠지만 그동안 개인적인 일들로 상당히 괴로워하면서 보냈습니다. 그런 순간들로부터 이렇게 무사히 논문까지 쓸 수 있었던 것은 랩분들이 지맘대로인 저를 이해해 주시고 그나마 사람 만들겠다고 도와주신 덕분이라고 생각합니다. 정말 감사드립니다! 정말 많은 생각들이 떠오르면서 코끝을 짝금 찡하게 합니다. 특히나 작년 (2001) 여름, 451에 있을 때 에어컨 공사한다면서 온몸을 전율케하는 소음과 수명단축에 일조하려고 폐 속으로 들어오는 미세, 굵새의 먼지, 극악의 더위들이 가슴을 찡하게 합니다. 하지만 그때의 상황은 별로 힘들게 느껴지지 않습니다. ‘즐겁다’는 단어가 오히려 어울릴 것 같습니다. 그게다 bi분들 덕분이겠죠? 흠흠...준비...땅!, 일에 대한 열정과 workaholic의 진면모를 가르쳐주시고 자상하며 이해심 많은 장교수님, 화려한 그래픽 디자인의 진수를 보여준(성윤이 잘 잘 지내죠?) 제균이형, 그 어려운 통계학을 업으로 하시는 양박사님, 웬지 장풍을 날릴 수 있을 것 같은 성배형(특남 축하해요!), 임요한에 버금가는 셔틀 플레이를 구사하는 스타 게이머 종우형, 하늘을 봐야 별을 판다고 어머님께 하소연하던 정호형, bi 이바구의 황태자이자 설악산 MT 정상에서의 화장실 사건의 주역인 규백이형, 요새 애인 사귀느라 맨날 입에서 웃음이 새는 장민이형, 결혼(축하해요!)식할 때 올백으로 본래의 모습을 선보인 수용이형, 언제나 열심히 하는 동연이형, 고딩 동문 선배이자 부드러운 성격의 소유자 선이형, 내가 ICA에 관심을 갖게 해주고 등록금 까먹고 톡빠져서 공익으로 간 유환이형, 겉으론 통명스러우면서도 사실은 마음이 여린(정말?) 재홍이형, 눈빛에서 유유자적의 무공을 내뿜는 오토바이 수집광 (박)상준이형, 인라인을 자기학대의 도구로 삼는(조심해서 타요!) 승준이형, 내게 무술에서 전래한 안마시술법을 전

수하려한 무술인 종윤이형, 내가 우리랩에 들어온 동기를 부여해 준 태진이형, 말할 때 연성을 높이고 이상한 소리만 해대는 현구형, 나와 서로 까댐의 대화를 즐기는 스포츠맨 동민이형, 웃으면서 가볍게 유창한 영어를 구사하는 희주 누나, 공부하면서 학교에서 일하느라 고생했던 착한 은주씨, 학부와 대학원 동기인 인희, MT 때 내게 스키를 가르쳐준 스키 사부님 호진이, 신앙심에 불타서 내 성경을 슬쩍했다(이해해요!) 걸린 정문이형, 학문에 대한 열정을 보여준 준식씨, 작업(?)하느라 집에도 안가고 학교서 자는 (어)상준이형, 나랑 팔 기브스 생활을 공유하며 서로 연민해준 하영이형, 똑심이 떠오르는 수동이형, 언제나 밝고 명랑한 지선씨, 본지 얼마 안되는 승훈이형, 대학 동기이자 TeamZ 친구들인 유성, 수웅, 정민, 정욱, 중형, 형민, 성서, 진혁, 대현, 성욱, 영민, 그리고 지금 중환자실에서 병으로 힘들어하는 종률이(빨리 나아라!), 고등학교 1학년 때 기둥이 되어준 대웅이, 내 의형제인 정호와 경준이, 초딩 때 삼총사인 덕기와 지휘, 초·중·고딩어 친구들, 어린 나를 어여뻐 여겨주신 초딩 선생님인 손정대, 김향미 선생님, 초딩 때 미술의 즐거움을 깨닫게 해주신 규인이 어머니, 그 분의 아드님인 규인이, 초딩 때 울던 나를 달래주신 김영희 선생님, 유치원 때 입원했다 돌아온 나를 친구들과 함께 따뜻하게 안아주신 최창숙 선생님, 어렸을 때 동네의 동생들인 정환이, 지윤이, 성훈이, 정빈이, 어렸을 때 에스컬레이터 침타다가 넘어진 나를 들어올려 구해준 어떤 형, 내 동생, 내가 있게해 주신 부모님께 진실한 마음으로 감사드립니다.