

공학석사 학위논문

데이터마이닝을 위한 베이지안망
구조 학습

Structural Learning of Bayesian Networks
For Data Mining

2001 년 2 월

서울대학교 대학원
협동과정 인지과학전공
하 선 영

데이터마이닝을 위한 베이지안망
구조 학습

Structural Learning of Bayesian Networks
For Data Mining

지도교수 장 병 탁

이 논문을 공학석사 학위논문으로 제출함

2000 년 10 월

서울대학교 대학원

협동과정 인지과학전공

하선영

하선영의 공학석사 학위논문을 인준함

2000 년 12 월

위원장 _____ 印

부위원장 _____ 印

위 원 _____ 印

요 약

베이지안망은 많은 변수들간의 확률관계를 비교적 축약된 형태로 표현하는데 유용한 모델로 확률적 추론, 예측, 의사 결정 등에 잘 적용될 수 있다. 본 논문에서는 이러한 베이지안망을 이용하여 데이터마이닝의 과제를 해결하는 방법을 연구한다.

베이지안망을 데이터 마이닝에 적용하고자 할 때 가장 큰 문제중의 하나는 데이터의 변수의 수가 많아짐에 따라 베이지안망의 구조를 학습하기가 어려워진다는 것이다. 이에 본 논문에서는 표본추출기반의 최적화 방법인 Simulated Annealing을 사용하여 베이지안망 구조를 학습하는 방법을 제안한다. 이 방법은 탐색공간을 효율적으로 줄이기 위해 전체 가능한 구조 공간에서 최상의 베이지안망 구조를 찾아내는 것이 아니라 각 노드에서 지역적으로 그 노드의 부모노드를 찾아내는 것을 목표로 한다. 이것이 가능한 이유는 결측치가 없는 데이터에서 각 노드들이 분리성(decomposability)을 가지기 때문이다. 즉 각 노드에서 목표함수를 최대(최소)화하는 것은 전체망을 최대(최소)화하는 것과 같다. 이런 분리성은 노드의 크기에 관계없이 각 노드에서의 계산량만이 전체 계산에 영향을 미치도록 한다.

표본추출기반의 최적화방법은 특히 어닐링 온도 파라미터의 초기값과 감소 비율 등에 영향을 받는다. 이에 본 논문에서는 베이지망 구조 학습 성능평가를 위한 벤치마크 문제들에 대해 제안한 알고리즘을 구현하여 적용하였으며 온도 파라미터의 설정값과 데이터의 노드 수에 따른 성능의 변화를 측정 하였다. 그 결과 변수의 수가 늘어나도 각 노드당 계산량은 일정 하였으며 온도 파라미터의 설정값은 학습 결과에 크게 영향을 미치지 않는다는 것을 발견하였다. 또한 데이터의 수가 많아짐에 따라 베이지안망 구조 학습의 결과가 좋아진다는 것을 발견하였다.

본 논문에서는 또한 실제 환경에 베이지안망을 적용하여 보았다. 첫번째

적용과제는 고객 예측 및 성향분석으로 보험회사의 고객정보를 이용하여 caravan insurance policy에 가입할 고객을 예측하고 이 고객들의 성향을 묘사하였다. 두 번째는 문서분류의 과제에 적용하였다. 이것은 대용량의 문서를 네 가지 주제로 분류하는 과제이다. 베이지안망을 사용하면 문서분류의 효과 이외에도 각 주제별 주요 단어들 사이의 상관관계를 파악할 수 있다. 이는 언어학이나 인지과학등에 적용될 경우 단어의 애매성 해결등과 같은 과제에 효율적으로 쓰일 수 있을 것으로 생각된다.

주요어: 베이지안망 구조 학습, 데이터마이닝, Simulated Annealing

학 번: 99132-507

차 례

1. 서론-----	1
1.1 연구의 배경 및 필요성-----	1
1.2 논문의 구성-----	4
2. 관련연구-----	5
2.1 베이지안망-----	5
2.2 베이지안망 학습-----	6
2.2.1 파라미터 학습-----	6
2.2.2 구조 학습-----	8
2.3 인지과정 모델로서의 베이지안망의 가능성과 적용-----	13
3. 표본추출기반의 최적화 방법을 이용한 구조 학습-----	15
3.1 마르코프 사슬 몬테칼로 방법-----	17
3.2 Simulated Annealing을 이용한 구조 학습-----	19
3.3 전체 알고리즘-----	17
4. 실험 및 결과-----	21
4.1 벤치마크 과제에 대한 성능평가-----	21
4.1.1 화재망 데이터에 대한 성능비교-----	27
4.1.2 아시아망 데이터에 대한 성능 비교-----	32
4.1.3 경고망 데이터에 대한 성능비교-----	37
4.1.4 해일 예측망 데이터에 대한 성능비교-----	40
4.1.5 결과 분석-----	44
4.2 실제 문제의 적용 -----	45

4.2.1 CoIL Challenge 2000 데이터	45
4.2.2 베이지안망을 이용한 문서분류	48
5. 결론	50
참고 문헌	53
Abstract	56

1.서론

1.1 연구의 배경 및 필요성

데이터 마이닝(data mining)이란 대규모의 데이터베이스로부터 해석 가능한 유용한 정보를 추출해내는 과정이다[1]. 마이닝이란 단어가 의미하듯 데이터 마이닝은 산 속에서 금을 캐내듯 데이터의 무의미한 더미 속에서 데이터에 대한 분석을 통해 그 데이터가 산출된 도메인에 대한 지식을 얻어내는 것이다. 예를 들어 인터넷 쇼핑몰의 고객들의 소비기록과 방문기록 그리고 그들의 신상기록 등을 이용하여 데이터 마이닝을 할 때, 우리가 얻고자 하는 것은 어떤 유형의 사람들이 물건을 많이 사는가? 라든지 홈페이지의 어느 광고를 본 사람이 물건을 더 많이 사는가? 등과 같이 해석 가능한 유용한 정보들이다.

현재 데이터마이닝 과제에 주로 쓰이고 있는 것은 판별분석과 같은 통계적 방법들과 의사결정 나무, 신경망등의 인공지능 기법들이다[2]. 의사결정 나무는 변수들간의 규칙을 만들어 낼 수 있다는 점에서 매우 유용하게 쓰인다. 그러나 도메인이 복잡하거나 숨은 속성이 있는 경우에는 성능이 떨어지는 단점이 있다. 이에 비해 신경망은 복잡한 비선형 도메인이나 숨은 속성이 있는 도메인에서 뛰어난 예측능력을 보인다. 그러나 결과를 통해 변수들간의 상관관계의 해석이나 규칙 등을 만들어 낼 수 없다는 단점을 가진다.

이에 새롭게 주목 받고 있는 것이 베이지안망이다[3,4]. 베이지안망은 변수간의 확률관계를 비교적 축약된 형태로 나타내는 그래프 모델이다. 베이지안망은 기본적으로 변수들의 결합확률분포를 나타내기 때문에 모델의 예측과 설명이 가능하다. 또한 숨은 속성에 대한 추론 또한 가능하다. [5,6]은 베이지안망을 사용하여 사용자 속성을 성공적으로 모델링 하였다.

그림 1은 [6]에서 학습해낸 베이지안망으로 자선 단체의 이메일 홍보를 보고 기부금을 낸 사람들의 속성을 모델링 한 것이다. 이들은 자신들이 개발한 Bayesware Discoverer를 이용하였다. 이 모델은 낮은 소득을 가지고 도시 외곽에 거주하는 기부자는 일반적으로 10달러 이하의 기부금을 내는데 반해 비록 낮은 소득을 가졌지만 부유한 지역에 거주하는 기부자들은 10달러 이상을 기부한다는 것과 같은 현상들을 찾아내었다. 또한 이 모델은 이메일 응답자 모델과 결합하여 자선단체의 수익을 예측하는 데에도 효과적으로 사용되었다.




그림 1. 기부자들의 속성을 모델링한 베이지안망[6]

그러나 베이지안망이 실제 데이터마이닝의 도구로서 자리잡기에는 아직 많은 문제점을 가지고 있다. 그 중 대표적인 것이 대용량 데이터에서의 베이지안망 구조 학습의 문제이다. 베이지안 구조 학습이란 변수간의 상관관계를 나타내는 연결선(edge)을 데이터로부터 직접 학습하는 것이다. 초기의 베이지안망 사용자들은 대부분 사전지식을 이용해서 베이지안망의 구조를 고정해놓고 이를 기반으로 파라미터를 데이터로부터 학습한 후 예측이나 추론등의 과제에 베이지안망을 사용해왔다. 그러나 대부분의 데이터 마이닝 과제에서 분석자는 데이터에 대한 충분한 사전지식을 가지고 있지 못하다. 이런 이유로 베이지안망 구조를 데이터로부터 학습하는 것은 베이지안망을 이용하여 데이터 마이닝을 하고자 할 때 필수적인 과정이라 하겠다.

베이지안망 구조 학습 방법으로 널리 쓰이는 것이 K2 알고리즘[7]이다. 이 방법은 결측치가 없는 데이터에서 베이지안망을 쉽고 간단하게 학습해낸다. 이 방법은 기본적으로 노드의 순서에 의존한다. 노드의 순서란 인과적 순서라고도 하는데 인과적으로 선행하는 사건의 노드가 후행하는 사건의 노드 앞에 놓이는 것을 의미한다. 예를 들어 흡연 여부는 폐암의 원인이 될 가능성이 있지만 폐암은 흡연의 원인이 될 수는 없다. 이 경우 흡연을 나타내는 노드는 폐암을 나타내는 노드보다 순서상으로 앞서게 된다. 이런식으로 베이지안망의 각 노드(변수를 나타냄)들의 인과적 순서가 주어지면 구조 학습은 훨씬 간단해지게 된다. 그러나 아쉽게도 이런 노드의 인과적 순서가 알려진 경우 또한 데이터마이닝의 과제에서는 거의 없다.

이에 본 논문에서는 이런 인과적 순서에 대한 정보없이도 효율적으로 대규모의 데이터로부터 베이지안망 구조를 학습하는 방법을 제안하는 것을 목표로 한다. 본 논문에서 제안하는 방법은 Simulated Annealing을 이용하여 각 노드의 부모노드 집합을 탐색하는 것이다. 표본추출기반의 최적화 알고리즘인 Simulated Annealing을 사용하여 부모노드의 집합을 탐색할 경우 문제가 되는 것은 노드의 수가 작은 과제에 있어서는 오히려 지나치게 계산의

양이 많아진다는 것이다. 그러나 노드의 수가 증가함에 따라 선형적으로 계산의 양이 늘어나기 때문에 데이터 마이닝과 같은 대용량의 데이터를 다룰 때는 매우 유용하다.

본 논문에서는 Simulated Annealing을 이용하여 효과적으로 베이지안망 구조를 학습할 수 있는 방안을 제시하고 이를 구현하여 그 성능을 평가하고자 한다. 베이지안망 구조 학습 알고리즘의 성능평가는 일반적으로 베이지안망 구조가 잘 알려진 여러 벤치마크 데이터를 사용하여 수행된다. 본 논문에서도 여러 다양한 벤치마크 문제에 위의 알고리즘을 적용하여 그 결과를 본래 데이터가 생성된 베이지안망의 구조와 비교함으로써 그 성능을 평가한다.

또한 실제 데이터 마이닝 과제에 이를 효과적으로 적용할 수 있음을 보이기 위하여 고객 예측 및 성향분석의 과제와 문서분류의 과제에 적용하여 본다.

1.2 논문의 구성

본 논문은 다음과 같이 구성되었다. 2장에서는 베이지안망과 베이지안망 학습방법에 대해 설명하고 관련연구에 대해 살펴본다. 3장에서는 표본추출 기반의 최적화 방법에 대해 설명하고 이를 이용하여 베이지안망 구조를 학습하는 방법을 제안한다. 4장에서는 3장에서 제안된 방법을 구현하여 여러 베이지안망 벤치마크 데이터에 적용하여 성능을 평가하고 또한 실제 데이터 마이닝 과제에 적용한다. 5장에서는 본 연구의 내용을 요약하고 결과를 기술한다.

2. 관련연구

2.1 베이زي안망(Bayesian networks)

베이زي안망은 불확실한 상황에서 지식을 표현하고 결론을 추론하고자 할 때 유용하게 쓰일 수 있는 도구이다. 베이زي안망은 그림 2와 같이 변수를 나타내는 노드와 변수들간의 상관관계 또는 인과관계를 나타내는 연결선(edge)으로 이루어져 있는 Directed Acyclic Graph(DAG)이다. 여기서 각 노드는 조건부 확률을 나타내는 확률 테이블을 가지고 이것이 각 연결선의 강도를 모델화한다. 두 노드 사이에 연결선이 없다는 것은 서로 독립적이라는 의미로 해석된다. 베이زي안망에서 표현되는 모든 독립적인 집합은 d-separation criterion[12]을 사용하여 결정될 수 있다.




그림 2. 베이زي안망

각 노드의 조건부 확률과 노드간의 연결선들로 이루어진 베이زي안망 구조가 주어지면 변수들에 대한 결합확률분포(Joint Probability Distribution)를 다음 식(1)에 의해 나타낼 수 있다. 여기서 $\text{Pa}(x_i)$ 는 x_i 의 부모노드를

의미한다. $A \rightarrow B$ 의 그래프 구조를 가질 때 노드 A 는 노드 B 의 부모노드가 된다.

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i | \mathbf{Pa}(x_i)) \quad (1)$$

베이지안망이 주어지면 우리는 이것을 이용하여 다양한 확률 예측 및 추론을 할 수 있다. 예를 들어 그림 2에서 x_1 과 x_2 노드의 값이 관찰되었다면 이 새로운 관찰값에 근거하여 나머지 노드들이 일어날 확률들을 예측할 수 있게 된다.

또한 주어진 베이지안망을 이용하면 노드들의 인과적 또는 의존적 순서를 구할 수 있다. 그러나 이것은 유일하지는 않다. 예를 들어 그림 2의 경우 베이지안 노드 순서는 $\{x_1, x_2, x_3, x_4, x_5, x_6\}$ 와 $\{x_1, x_4, x_2, x_3, x_5, x_6\}$ 모두 가능하다.

2.2 베이지안망 학습

데이터로부터 베이지안망을 학습하는 과정은 파라미터 학습과 구조 학습으로 나누어 생각할 수 있다.

2.2.1 파라미터 학습

각 노드의 확률을 데이터로부터 학습하는 것을 파라미터 학습이라 한다. θ_i 는 각 요소들의 분포의 파라미터를 의미하고 G^h 는 주어진 베이지안망의 구조를 $\mathbf{pa}_i$ 는 부모 노드를 가리킨다고 할 때, 이를 이용하여 베이지안망을 수식으로 표현하면 다음과 같다.

$$P(x|\hat{\mathbf{e}}_G, G^h) = \prod_{i=1}^n p(x_i | \mathbf{pa}_i, \hat{\mathbf{e}}_i, G^h) \quad (2)$$

이 때 베이زي안망의 파라미터 $\hat{\mathbf{e}}_G$ 를 학습한다는 것은 $p(\hat{\mathbf{e}}_G | D, G^h)$ 의 값을 최대로 하는 파라미터 $\hat{\mathbf{e}}_G$ 를 찾아내는 것이며 이런 파라미터의 값을 MAP (Maximum a Posterior)이라고 한다.

$p(\hat{\mathbf{e}}_G | D, G^h)$ 를 계산하는 방법은 문제의 상황 및 제약조건에 따라 다를 수 있지만 여기서는 베이زي안망의 학습 방법 중 가장 기본적인 방법인 다항분포(unrestricted multinomial distribution)를 이용하여 확률을 학습하는 방법에 대해서 설명하고자 한다. 여기서 다항의 의미는 변수가 복수개의 이산적인 값을 취할 수 있음을 의미하고 있다. 이 방법의 주요 가정은 다음과 같다.

- 모든 확률 변수가 r개의 이산 값 중 하나의 값을 취한다.
- 모든 국소 분포(local distribution)는 부모 노드의 분포의 결합으로서 표현된다
- 데이터에 결측치(missing value)가 존재하지 않는다.

파라미터 $\hat{\mathbf{e}}_{ij}$ 가 상호 독립이라고 가정하면 식은

$$p(\hat{\mathbf{e}}_s | G^h) = \prod_{i=1}^n \prod_{j=1}^{q_i} p(\hat{\mathbf{e}}_{ij} | G^h)$$

로 분리 될 수 있다. 여기서 $\hat{\mathbf{e}}_{ij}$ 의 사전 확률 분포는 Dirichlet distribution $Dir(\hat{\mathbf{e}}_{ij} | a_{ij1}, \dots, a_{ijr_i})$ 를 따른다고 가정한다. Dirichlet distribution은 다항분포를 나타내는 데 사용되는 확률분포 함수 중의 하나이고, 이항분포를 나타내는 베타분포의 확장으로 이해될 수 있다. Dirichlet distribution에서 각 파라미터는 변수가 취할 수 있는 값의 빈도를 반영하고 있다. 사전 확률분포가 이와 같이 주어 진 경우, 사후 확률 분포, 즉 베이زي안망의 파라미터는

$$p(q_{ij} | D, G^h) = \text{Dir}(q_{ij} | a_{ij1} + N_{ij1}, \dots, a_{ijr_i} + N_{ijr_i})$$

로 계산 될 수 있다. 여기서 N_{ijk} 는 데이터 집합 D 에서 $X_i = x_i^k$ 이고 $\text{Pa}_i = \text{pa}_i^j$ 인 경우의 개수를 나타내고 있다.

이를 이용하여 $p(X_{N+1} | D, G^h)$ 의 계산은 다음과 같이 나타낼 수 있고,

$$p(X_{N+1} | D, G^h) = E_{p(\mathbf{e}_G | D, G^h)} \left(\prod_{i=1}^n q_{ijk} \right) = \int \prod_{i=1}^n q_{ijk} p(\mathbf{e}_G | D, G^h) d\mathbf{e}_G$$

이를 계산하면

$$p(X_{N+1} | D, G^h) = \prod_{i=1}^n \frac{a_{ijk} + N_{ijk}}{a_{ij} + N_{ij}}$$

와 같은 식을 얻을 수 있다.

2.2.2 구조학습

구조 학습을 위해 그 동안 제시되었던 방법들은 크게 두 가지의 범주로 나뉜다. 하나는 각 변수들 사이의 조건부독립성을 추정하는 의존성 분석(Dependency Analysis)을 통한 학습 방법이고 다른 하나는 탐색과 평가함수(Score Function)를 이용한 방법이다. 이는 통계적으로 유도된 평가함수(Score Function)를 구한 후 이 함수의 값을 최대로 하는 구조를 선택하는 방법이다. 이런 통계적 평가함수로 가장 많이 쓰이는 것은 베이저안 평가(Bayesian scores)함수와 MDL 평가함수이다.

의존성 분석을 통한 구조 학습 시 의존성의 측정으로 흔히 쓰이는 것이 CI검사(Conditional Independence test)이다. CI검사는 두 변수간의 독립성의 여부를 측정하기 위해 정보함수(Information function)를 사용한다. 정보함수 중 가장 많이 쓰이는 Mutual Information은 아래와 같다.

$$I(X_i, X_j) = \sum_{x_i, x_j} P(x_i, x_j) \frac{P(x_i, x_j)}{P(x_i)P(x_j)}$$

이 방법을 처음 제시한 Wermuth 와 Lauritzen[13]은 노드의 정해진 순서에 따라 CI검사를 순차적으로 행하였다. 그러나 이것은 변수의 수가 많아질수록 높은 차원의 CI검사가 요구되어지고 또한 데이터의 양이 작은 경우에는 성능이 떨어지는 단점을 가진다. 또한 노드 순서를 사전에 알수 있는 경우는 거의 없다, 이에 최근에 쓰이고 있는 PC 알고리즘[14]은 노드 순서에 대한 정보 없이 구조를 학습하고자 노력한다. 베이지안망 구조 학습을 평가하기 위해 흔히 쓰이는 경고망(ALARM network) 데이터에 대해 이 방법은 3개의 잘못된 연결선과 2개의 추가 연결선을 가지는 베이지안망을 학습해내었다.

최적화의 문제로 베이지안망 구조 학습을 보는 관점에서는 학습 데이터 $D = \{\mathbf{x}^1, \dots, \mathbf{x}^N\}$ 가 주어졌을 때 이 데이터에 가장 잘 적합하는 베이지안망을 찾는 것이 학습이 된다. 초기의 Chow-Liu Tree Construction 알고리즘[15]은 트리구조를 학습하는 방법으로 현재까지도 베이지안망 구조 학습에 많은 영향을 끼치고 있는 방법이다. 입력값으로 확률 분포를 받아 트리구조를 출력으로 내놓는 이 알고리즘은 단지 $O(N^2)$ 의 계산복잡도를 가진다(여기서 N 은 노드의 수를 의미). 이 방법에서 사용하고 있는 평가함수는 Kullback-Leibler Cross-entropy이다. 그러나 이 방법은 의존성 분석 방법과 같이 두 노드간의 의존성 추정을 목적으로 한다는 점에서는 의존성 분석의 방법으로 분류되어 질 수 있다. 이 방법은 매우 간단하고 원래 구조가 트리 형태일 경우에는 정확한 해를 찾아낸다는 장점을 가지고 있으나 multiply connected graphs는 찾아낼 수가 없는 단점을 가지고 있다.

이에 비해 Cooper와 Herskovits에 의해 제안된 K2 알고리즘[7]은 가장 일반적으로 쓰이는 방법으로 노드순서와 데이터를 입력으로 받아서 베이지안망

구조를 출력으로 내어놓는다. K2 알고리즘은 베이지안 평가함수를 사용한다. 베이지안 평가함수의 가장 큰 특징은 missing value가 없는 데이터에서 분리성(decomposability)을 가진다는 점이다. 여기서 분리성이란 한 노드의 부모노드를 결정하는 것이 다른 노드의 부모노드를 결정하는 것에 아무런 영향을 끼치지 않는다는 것을 말한다. 이런 분리성은 지역적 탐색(local search)을 가능케 한다. 이런 이유로 모든 데이터가 관찰되었을 때 평가함수는 아래와 같이 표현될 수 있으며

$$\text{Score}(G : D) = \sum_i \text{Score}(x_i | \mathbf{Pa}(x_i) : N_{x_i, \mathbf{Pa}(x_i)})$$

$$g(x_i, \mathbf{Pa}(x_i)) = \log P(D | G, q_G) - \frac{\log N}{2} \sum_{i=1}^n (r_i - 1) q_i \quad (3)$$

$N_{x_i, \mathbf{Pa}(x_i)}$ 는 x_i 와 $\mathbf{Pa}(x_i)$ 의 통계량(statistics)으로 데이터에서 각각의 횟수를 나타내며, Score는 평가함수를 의미한다. 여기서 대표적인 평가함수인 베이지안 평가함수(BIC)는 식(3)과 같으며 이것은 데이터에 대한 log likelihood의 값에 penalty가 더해진 형식으로 [20]에 유도식이 나와있다. K2 알고리즘이 많이 쓰이는 이유는 이 방법이 경고망(ALARM network) 데이터에 대해 아주 좋은 성과를 보였기 때문이다. 이 알고리즘은 하나의 잘못된 연결선과 추가적인 하나의 연결선을 가진 베이지안망을 학습해내었다. 그러나 이 방법은 노드의 순서를 미리 알아야 한다는 단점을 가지고 있다. K2 알고리즘은 그림 3과 같다.

이 밖에 엔트로피를 베이지안 평가함수를 대신하여 사용하는 Kutato 알고리즘[7]과 parameter modularity와 event equivalence라는 두 가정을 이용하여 전문가의 사전지식과 데이터의 통계적 정보를 결합하여 학습하는 방법을 제시한 HGC(Heckerman, Geiger and Chickering) 알고리즘[16]이 있다.

그러나 위에서 제시된 여러 방법들(의존성 분석 기반과 평가함수 기반 방법들 모두)은 아직 아래의 문제점들을 가지고 있다.

- 노드의 순서가 요구된다.

기존의 많은 연구들이 노드의 순서를 가정하고 실험을 하였지만 실제 상황에서 이것이 알려진 경우는 거의 없다.

- 효율성이 낮다.

비록 최근 들어 노드의 순서를 가정하지 않고도 학습할 수 있는 방법이 제시되기는 하였으나 노드의 수가 많아지는 대용량 데이터에는 그 계산의 복잡도로 인해 효율적으로 적용될 수가 없다.

For each node i , $1 \leq i \leq n$, find $ParentList(i)$ as follows:

$ParentList(i) \leftarrow \phi$

$P_{old} \leftarrow g(i, ParentList(i));$

NotDone $\leftarrow$ do

$\forall l \ \pi \ i \ (l \notin ParentList(i)), g_l \leftarrow g(i, ParentList(i) \cup \{l\})$

$P_{new} \leftarrow \max_l g_l(i, ParentList(i) \cup \{l\})$

Let z be the node which maximizes g_l above

If $P_{new} > P_{old}$ then

$P_{old} \leftarrow P_{new};$

$ParentList(i) \leftarrow ParentList(i) \cup \{z\}$

Else NotDone $\leftarrow$ false

EndFor

그림 3. K2 알고리즘[7]

위의 구조 학습의 문제점을 극복하기 위한 대표적인 방법이 노드 순서를 추정하여 구조를 학습하는 방법이다. 이것은 여러 베이지안 구조 학습 방법이 노드 순서를 알면 쉽게 구해질 수 있으나 실제로 노드의 순서를 알 수 없는 경우가 많다는 데서 비롯된다. 이에 노드의 순서를 미리 추정한 후

이 노드의 순서를 바탕으로 성능이 좋은 K2 알고리즘 등을 이용하여 베이지안망 구조를 학습하게 된다.

이런 대표적인 방법이 CB 알고리즘[8]이다. CB 알고리즘은 의존성 분석 방법인 PC 알고리즘을 이용하여 노드 순서를 근사한 후 이 노드 순서를 가지고 K2 알고리즘을 사용하여 베이지안망을 학습한다. 그러나 이 방법 역시 노드의 수가 많아지면 PC 알고리즘의 계산이 어려워지는 단점이 있다. 이것은 가능한 노드 순서의 수가 $n!$ 로 모든 경우를 다 탐색하여 최선의 노드순서를 찾는다는 것은 쉬운 일이 아니기 때문이다. 이에 여러 효율적인 탐색 방법들이 제시되었는데 이중 Genetic Algorithm을 이용하여 찾고자 하는 방법도 제시되었다[9]. 이 경우 population은 각 가능한 노드 순서가 되고 fitness function은 K2 알고리즘에서 사용된 베이지안 평가함수가 된다.

그러나 노드 순서화를 이용하여 베이지안망 구조를 학습하고자 할 때 명심해야 할 것은 베이지안망 구조가 주어졌을 때 노드의 순서가 유일하지 않다는 것이다. 또한 노드의 순서화를 추정시 여전히 구조 학습의 부모 노드 탐색의 효율성에 대한 문제는 남아있게 된다.

노드의 순서를 추정하지 않고 직접 베이지안망을 학습하고자 하는 방법들도 최근에 제시되었다[4,18]. 그러나 [4]에서 제시한 것과 같이 노드의 순서를 추정하지 않고 베이지안망을 구할 때는 베이지안망 구조 학습 후 연결선의 방향(orienting edges)을 결정하는 과정을 거쳐야 한다. 이것은 베이지안 평가함수나 CI검사 모두 연결선의 방향까지는 학습하지 못하기 때문이다. 연결선의 방향 검사에 가장 많이 쓰이는 것은 V-구조를 이용한 것이다. V-구조란 X, Y, Z 의 세 노드가 있을 때, X 와 Y , Y 와 Z 이 연결되어 있고 Y 와 Z 은 연결되어 있지 않는 구조를 말한다. 이런 V-구조는 오직 세종류의 베이지안망 구조를 갖게 되는데 그것은 (1) $X \rightarrow Y \rightarrow Z$, (2) $X \leftarrow Y \rightarrow Z$ 그리고 (3) $X \rightarrow Y \leftarrow Z$ 이다. 이중 세번째 경우는 베이지안망에서 Y 의 값이 관찰되었을때 정보가 X 에서 Z 로 흐르는, 즉

X 와 Z 이 Y 에 의존적으로 된다. 이런 원리를 이용하여 베이지안망에서 V -구조를 찾아낸 후, 이 중 세번째에 해당하는 경우를 찾아내면 연결선의 방향을 구할 수 있게 된다. 물론 이 방법은 극단적으로 학습된 베이지안 망에 V -구조가 하나도 없다면 어떤 연결선의 방향도 찾아낼 수 없다. 그러나 그 효율성때문에 현재까지 가장 널리 쓰이고 있는 방법이다. 이에 [21]등에서 단순히 평가함수만을 사용하여 연결선의 방향을 구하는 방법에 대해 기술하고 있으나 이것은 매우 느린 단점이 있다. 베이지안망에서 V -구조를 찾아내는 방법은 [4]에 자세히 나와있다.

2.3 인지과정 모델로서의 베이지안망의 가능성과 적용

2.1장과 2.2 장에서 학습된 베이지안망은 다양한 확률 추론 과 예측, 설명 등의 과제에 사용될 수 있다. 처음 인공지능과 인지과학에서 베이지안망에 관심을 가지게 된 동기는 읽기 과제등에서 사람의 정보처리과정이 하향식(Top-down)과정과 상향식(Bottom-up)과정의 결합된 형태라는 증거들이 제시되면서이다. 상징주의와 연결주의로 대표되던 기존의 방법들은 모두 이 두 과정 중 한가지에 방법에만 의존하여 정보를 처리한다. 예를 들어 전문가 시스템은 대표적 상징주의의 방법으로 기존의 지식으로부터 새로운 사실을 추론해 내는 하향식 추론을 한다. 이에 비해 신경망은 데이터로부터 새로운 지식을 추론하는 상향식 과정이다. 하향식 추론은 고차원의 지식이나 추론에는 효율적이지만 융통성이 부족하고 규칙에 어긋나는 불확실한 상황등에서의 추론이 불가능하다. 이에 비해 상향식 추론은 융통성이 뛰어나고 패턴인식 등의 과제에 뛰어난 성과를 나타내지만 고차원의 지식추론과 맥락효과 등을 설명 할 수 없는 단점을 가진다.

이에 기존의 지식과 데이터로부터 얻은 지식을 결합하여 새로운 지식을 추론해낼 수 있는 베이지안망이 주목 받게 되었다. 이런 양방향으로의

추론이 가능한 것은 베이지안망에서 화살표의 방향이 전문가 시스템이나 신경망에서와 같이 추론이 일어나는 과정을 의미하지 않고 인과적 연결성을 의미하기 때문이다. 예를 들어 그림 2에서 만약 스프링쿨러가 켜져 있다면 바닥이 젖어있을 것이라고 예측할 수 있다. 그러나 우리가 만약 바닥이 젖어 있는 것을 발견한다면 우리는 역으로 스프링쿨러가 켜져 있거나 비가 왔을 것이라고 추론할 수 있게 된다. 여기서 만약 스프링쿨러가 켜져 있는 것을 알게 된다면 자연스럽게 비가 왔을 확률은 작아지게 된다¹. 이런 불확실한 상황에서 효율적으로 추론할 수 있는 능력은 베이지안망의 가장 큰 장점이라 할 수 있다. 물론 실제 인간의 인지과정이 베이지안망과 같다는 증거는 아직 없다. 단지 인간의 인지과정이 베이지안망과 같이 두개의 정보처리가 동시에 일어나며 기존의 지식과 새로운 데이터로부터 얻은 정보를 통한 기존지식의 수정과정이라는 것이 인간의 인지과정과 유사하다는 증거만이 있을 뿐이다.

베이지안망의 적용분야는 무궁하다. 인지과정을 모델링하는 분야에서는 대상인식(object recognition), 읽기 과제(reading comprehension)등과 같이 선택적 주의 집중과정(selective attention)이 요구되는 과제에 특히 유용하다[23]. 선택적 주의 집중이란 사전 지식 등이 자극의 처리에 관여하여 다음 관찰이 있기 전에 미리 정보량이 많은 자극을 선택하게 하는 것이다. 이 밖에 베이지안망은 인과구조를 파악하는 데에도 유용하게 쓰일 수 있으며 의사결정 모델로도 사용될 수 있다.

¹ 이것을 ‘explaining away’ 효과라고 한다.

3. 표본추출기반의 최적화를 이용한 베이지안 망 구조 학습

3.1 마르코프 사슬 몬테칼로 (Markov Chain Monte Carlo, MCMC)와 Simulated Annealing

마르코프 사슬 몬테칼로(Markov Chain Monte Carlo, MCMC)는 모형이 복잡하고 고려되는 변수가 많은 다차원 적분을 손쉽게도 효율적으로 계산하기 위해 개발된 방법으로 마코프 사슬(Markov Chains)을 이용한 몬테칼로 적분이다. 몬테칼로 적분은 우리가 적분을 구하고자 하는 피적분함수를 $g(x)$ 라고 할 때 이 함수를 가장 잘 근사하는 어떤 함수 $h(x)$ 를 찾아서 이 $h(x)$ 로부터 표본을 얻은 후 이 표본들의 평균값을 이용하여 위 피적분함수의 기대값을 근사하는 방법(식(4))이다.

$$E[g(X)] \approx \frac{1}{T} \sum_{t=1}^T g(X_t) \quad (4)$$

이 때 이 표본들은 정교하게 생성된 마코프 사슬을 따라 얻어지게 된다. 여기서 이용하는 마코프 사슬은 안정분포(stationary distribution)가 $g(x)$ 가 됨이 증명되어야 한다. 마코프 사슬을 생성하는 방법에 따라 다양한 MCMC 표본기법이 존재하게 되는데 우선 가장 기본이 되는 Metropolis 알고리즘에 대해 알아보자.

Metropolis 알고리즘은 현재 상태에서 다음 상태의 후보를 제안할 때 현재상태에만 의존하는 정교하게 고안된 제안분포를 따른다. 이후 다음 상태로의 이동은 아래의 확률을 가지고 일어난다.

$$a(X, Y) = \min\left(1, \frac{g(Y)}{g(X)}\right)$$

이런 MCMC를 최적화의 문제에 적용할 수도 있다. 위의 Metropolis 알고리즘의 경우는 아래와 같이 최적화의 관점에서 기술되어 질 수 있기 때문이다. 이는 stepwise mode-finding algorithm의 stochastic 버전으로 볼 수 있다.

- 만약 현 상태에서 다른 상태로의 이동이 목표 분포의 값을 증가시킨다면 이동한다.
- 만약 현 상태에서 다른 상태로의 이동이 목표 분포 값을 감소시킨다면 $a(X,Y)$ 의 확률로 이동한다.

Metropolis 알고리즘이 최적화 문제에 사용될 때는 흔히 Simulated Annealing의 방법과 함께 쓰인다. Simulated Annealing[17]은 탐색시 지역국소에 걸리는 것을 방지하고 탐색의 성능을 향상시키는 역할을 한다. 이것은 온도를 나타내는 파라미터 T 를 두는데 이 값이 1보다 크게 되면 탐색공간을 큰 움직임으로 움직이게 되고 T 의 값이 0에 가까울 정도로 작아지게 되면 우리가 원하는 안정된 상태에 도달한 것으로 본다. 이 방법은 에너지 함수를 최소화 시키는 것이 우리가 원하는 안정된 상태라고 보기 때문이다. Metropolis 알고리즘과 함께 사용될 때는 $-\log p$ 를 에너지 함수 E 로 두게 되는데 여기서 p 는 목표 함수 $g(x)$ 의 값을 나타낸다. 즉 $g(x)$ 를 최대화 시키는 파라미터를 찾는 것이 목표라면 이것은 E 를 최소화 시키는 것과 같게 된다. 이 알고리즘은 아래와 같다.

- 만약 $E_{new} < E_{old}$ 이면 새로운 상태를 수락한다.
- 만약 $E_{new} > E_{old}$ 이면 새로운 상태를 $\left\{ -\frac{E_{new} - E_{old}}{T} \right\}$ 의 확률로 수락한다.

Simulated Annealing의 성능에 영향을 미치는 것은 온도 파라미터의 초기값, 감소비율 그리고 정지조건인 세가지이다. 이 세가지 파라미터를 잘 조절하는 것을 annealing schedule이라 한다. 일반적으로 이상적으로 여겨지는 annealing schedule은 아래 그림 4와 같이 초기에는 제안된 다음 상태의 수락비율이 1에 가까웠다가 차츰 작아져서 0.2~0.3에서 더 이상 변화하지 않도록 온도 파라미터의 값과 감소비율을 결정하는 것이다. 또한 각 온도에서 평균적으로 10번 이상의 수락이 이루어지도록 하면서 온도를 감소시켜야 한다.




그림 4. 이상적인 annealing schedule

3.2 Simulated Annealing을 이용한 베이지안망 구조 학습

베이지안망 구조 학습에서 각 노드의 부모노드 탐색에 Simulated Annealing을 사용하고자 하는 생각은 처음은 아니다. Singh와 Valtorta는 그들의 논문[8]에서 이런 생각을 처음 밝혔다. [8]에 의하면 Simulated Annealing을 사용하여 각 노드의 부모노드를 탐색할 경우 에너지 함수는 K2 알고리즘의 평가함수 $g(x_i, \mathbf{Pa}(x_i))$ 를 음수화한 값이 된다. 본 논문에서는 [8]의 방법을 따라 에너지 함수의 값을 정하였다. 그러나 [8]과 달리 CI 검사를 이용하여

노드의 순서를 추정된 후 베이지안망을 학습하는 방법은 취하지 않았다. 노드의 순서를 추정하지 않는 이유는 [8]과 같이 Mutual Information을 이용하여 노드의 순서를 추정할 경우 전체 베이지안망 학습의 성능이 노드 순서 추정의 성능에 크게 의존하기 때문이다. 즉 처음 노드의 순서를 잘못 추정하면 올바른 베이지안망을 학습할 수 없다는 단점을 가지게 된다. 또한 Mutual Information은 서로 짝을 이룬 두 변수의 의존성은 잘 찾지만 여러 변수들간의 복잡한 인과관계는 찾지 못하는 단점을 가지고 있다[18].

Simulated Annealing을 사용시 Metropolis 알고리즘을 이용한 표본추출은 그림 5와 같이 수행한다. 여기서 현재 부모노드의 리스트인 *ParentList*의 새로운 상태 *ParentList_{new}*로의 이동은 아래의 두 가지 방법을 사용하였다.

- ‘Exchange’ 이동

$$(a_1, a_j)(a_k \dots a_n) \propto (a_1, a_k)(a_j \dots a_n)$$

- ‘Cutting or Birth’ 이동

$$(a_1, a_j)(a_{j+1} \dots a_n) \propto (a_j)(a_{j+1} \dots a_n)$$

‘Exchange’ 이동은 현재 부모노드의 리스트에 있는 변수중 하나를 임의로 선택하여 역시 임의로 선택된 부모노드의 리스트에 없는 다른 변수와 교환하여 주는 것이다. ‘Cutting or Birth’ 이동은 부모노드 리스트가 공집합일 경우 임의로 선택된 변수를 부모노드의 리스트에 넣어주거나 부모노드 리스트가 공집합이 아닐 경우는 현재 부모노드의 리스트에 있는 변수중 임의로 하나를 선택하여 제거해준다. 이 두 가지 이동은 아래의 확률을 가지고 수락하게 된다.

$$\min \left[1, \frac{P(ParenList_{new} | D)}{P(ParentList | D)} \right]$$


```

While not (stopping condition) do
    Sample  $u \sim U[0,1]$ 
    If ( $u \leq 0.5$ ) then Exchange( )
    Else Cutting or Birth( )
Endwhile

Exchange( )
If  $ParentList(i)$  is not  $f$ 
    Choose one variable  $Tmp$  from  $ParentList(i)$ 
    Choose one variable  $Tmp2$  from  $VariableList$ 
     $ParentList_{new} \leftarrow$  exchange  $Tmp$  and  $Tmp2$ 
    Compute  $g_l \leftarrow g(i, ParentList_{new})$ 
     $E_{new} = -g_l$ 
    If  $E_{old} > E_{new}$ 
        Then  $ParentList(i) = ParentList_{new}$ 
    Else
        Sample  $d \sim U[0,1]$ .
         $Acceptance\ Ratio \leftarrow \exp(E_{old} - E_{new} / T)$ 
        If  $d > Acceptance\ Ratio$ 
            Then  $ParentList(i) = ParentList_{new}$ 

Cutting or Birth( )
If the number of  $ParentList = 0$ 
    Then choose one variable  $Tmp$  from  $VaeiableList$ 
     $ParentList_{new} \leftarrow Tmp$ 
Else
     $ParentList_{new} \leftarrow$  cut one variable from  $ParentList(i)$ 

Compute  $g_l \leftarrow g(i, ParentList_{new})$ 
 $E_{new} = -g_l$ 
If  $E_{old} > E_{new}$ 
    Then  $ParentList(i) = ParentList_{new}$ 
Else
    Sample  $d \sim U[0,1]$ .
    Compute  $Acceptance\ Ratio = \exp(E_{old} - E_{new} / T)$ 
    If  $d > Acceptance\ Ratio$ 
        Then  $ParentList(i) = ParentList_{new}$ 

```

그림 5. Metropolis 알고리즘

3.3 전체 알고리즘

위 3.2에서 제시된 알고리즘을 정리하여 보면 그림 6과 같다.

```
For each node  $i$ ,  $1 \leq i \leq n$ , find  $ParentList(i)$  as follows:  
   $ParentList(i) \leftarrow \phi$   
   $Pold \leftarrow g(i, ParentList(i));$   
   $Eold = -Pold$   
  Initialize the temperature  $T(0)$ ,  $k = 0$   
  While not(stopping condition) do  
     $l = 1$   
    While ( $l < L_k$ ) do :  $L_k$  is maximum iteration number  
      Sample  $u \sim U[0,1]$   
      If ( $u \leq 0.5$ ) then Exchange( )  
      Else Cutting or Birth( )  
       $l = l + 1$   
    EndWhile  
     $k = k + 1$   
     $T = c * T(0)$  :  $c$  is a decrease parameter  
  EndWhile
```

그림 6. Simulated Annealing을 이용한 전체 알고리즘

4. 실험 및 결과

4.1 벤치마크 과제에 대한 성능평가

먼저 Simulated Annealing을 이용한 베이지안망 구조 학습의 효용성을 알아보기 위해 여러 베이지안망 구조 학습의 벤치마크 과제에 대해 성능을 측정하였다. 베이지안망 구조 학습의 성능 측정은 일반적으로 도메인에 대해 참인 베이지안망 구조를 알 수 있는 경우가 없기 때문에 전문가에 의해 개발된 널리 알려진 베이지안망 구조를 가지고 데이터를 생성한 후, 이 데이터를 가지고 학습한 결과를 데이터가 생성된 베이지안망 구조와 비교하는 방법을 사용한다. 여기서 사용된 각 베이지안망은 Norsys system²에서 제공하는 버전을 사용하였고 데이터의 생성 또한 Norsys system의 Netica를 사용하여 생성하였다. Netica는 데이터 생성시 몬테칼로 방법을 이용한 Probabilistic Logic Sampling을 이용하고 있으며 이 방법은 [4]에 자세히 나와있다.

실험은 먼저 Simulated Annealing의 과정에 영향을 미치는 온도 파라미터의 값을 감소시키는 감소비율값 c 를 0.5, 0.7, 0.9로 초기값 T 를 1, 3, 5로 조절하면서 실험하였다. 이와 함께 데이터의 크기를 200, 500, 1000, 2000, 5000, 10000의 경우로 조절하면서 이에 따른 성능의 변화를 살펴보았다.

본 논문에서 제시된 Simulated Annealing을 이용한 베이지안망 구조 학습 방법은 MATLAB을 이용하여 구현하였으며 모든 실험은 128M, Pentium III PC에서 이루어졌다.

4.1.1 화재망(Fire network) 데이터에 대한 성능비교

먼저 간단한 화재망을 이용하여 실험을 하였다. 이 화재망은 빌딩안에 화재 경고음이 울려서 사람들이 대피를 하고 있을 때 이 화재 경고음이 진짜 화재로 인해 울렸는지 아니면 다른 이유에서인지에 대한 의사결정망으로 그림 7과 같다.




그림7. 화재망 (Fire network)

화재망은 노드의 수가 6개인 작은 베이지안망으로 full search를 통한 학습이 가능하다. 이런 이유로 Simulated Annealing으로 구해낸 값이 full search의 값에 얼마나 근사하는지 평가해 볼 수 있다. full search를 통해 학습을 해낸 결과는 그림 8과 같으며 Tampering→Fire로 향한 연결선을 하나 더 찾아내는 실수만을 범하였으며 베이지안 평가 함수의 최대값은 -305 이다.

² www.norsys.com




그림 8. full search에 의해 찾아낸 베이지안망
1:Tampering, 2:Smoke, 3:Leaving, 4:Report, 5:Alarm 6:Fire

이에 비해 Simulated Annealing으로 학습한 베이지안망의 결과는 그림 10과 표 1에 나와있다. 그림 10은 온도 파라미터의 초기값이 1이고 감소비율이 0.7일 때 데이터 수에 따른 베이지안망의 학습 결과이다. 대체로 성능이 좋았으며 데이터의 수가 많을 수록 성능은 더 좋아졌다. 데이터의 수에 따른 평균 에러수를 그래프로 그려보면 그림 9와 같다.







그림 9. 데이터의 크기에 따른 평균 에러 수




(e) $N=5000$, $c=0.7$, $T=15$




(f) $N=10000$, $c=0.7$, $T=15$




(c) $N=1000$, $c=0.7$, $T=1$



(d) $N=2000$, $c=0.7$, $T=1$



(e) $N=5000$, $c=0.7$, $T=1$



(f) $N=10000$, $c=0.7$, $T=1$

그림 10. 베이지안망 구조 학습의 결과
1:Tampering, 2:Smoke, 3:Leaving, 4:Report, 5:Alarm 6:Fire

표 1은 온도 파라미터의 각 조건에 대한 결과를 표로 정리한 것이다. 표의 윗부분은 온도 파라미터를 1로 고정한 후 감소비율을 0.5, 0.7, 0.9로 바꾸어 가며 시험한 결과이고 아래는 감소비율을 0.7로 고정한 후 초기값을 1, 3, 5로 바꾸어 가며 시험한 결과이다.

표 1. 온도 파라미터의 초기값(T), 감소비율(c), 데이터 수에 따른 학습 결과
(max score는 모든 노드에서의 평가함수값)

데이터 수	$T = 1$		$T = 3$		$T = 5$	
	max. score	잘못 학습된 연결선의 수	max. score	잘못 학습된 연결선의 수	max. score	잘못 학습된 연결선의 수
200	-79.8	missing(1),extra(2)	-80.6	missing(2),extra(1)	-83	missing(2),extra(2)
500	-219	missing(1),extra(2)	-280	missing(2),extra(2)	-250	missing(1),extra(2)
1000	-325	missing(1),extra(2)	-326	missing(1),extra(2)	-335	missing(2),extra(1)
2000	-651	missing(0),extra(2)	-650	missing(1),extra(2)	-649	missing(1),extra(1)
5000	-1706	missing(0),extra(1)	-1705	missing(1),extra(0)	-1710	missing(1),extra(1)
10000	-3615	missing(0),extra(1)	-3620	missing(1),extra(1)	-3619	missing(1),extra(1)
데이터 수	$c = 0.5$		$c = 0.7$		$c = 0.9$	
	max. score	잘못 학습된 연결선의 수	max. score	잘못 학습된 연결선의 수	max. score	잘못 학습된 연결선의 수
200	-86	missing(3),extra(1)	-80	missing(2),extra(2)	-79	missing(2),extra(2)
500	-220	missing(2),extra(2)	-215	missing(1),extra(2)	-230	missing(2),extra(2)
1000	-327	missing(2),extra(1)	-330	missing(1),extra(2)	-327	missing(2),extra(1)
2000	-652	missing(2),extra(1)	-653	missing(1),extra(2)	-653	missing(2),extra(1)
5000	-1708	missing(1),extra(2)	-1700	missing(0),extra(1)	-1704	missing(1),extra(2)
10000	-3621	missing(1),extra(1)	-3620	missing(0),extra(1)	-3619	missing(1),extra(1)

표 1의 결과 중 데이터의 수가 1000인 경우와 2000인 경우를 그래프로 표시한 것이 그림 11, 12 이다. 두 그래프를 보면 데이터의 수가 1000인 경우보다 2000인 경우에 온도 파라미터 각각의 설정값에 관계없이 수렴한 값이 비슷함을 알 수 있다. 즉 데이터의 수가 많아질 수록 온도 파라미터의 설정값에 영향을 적게 받음을 알 수 있다. 그림 11과 12에서 x축이 뜻하는 것은 반복 횟수인데 이것은 온도를 감소 시키는 횟수를 의미한다. 한 온도에서 평균적으로 12번 정도의 표본추출과 다음 상태로의 전이가

일어나므로 총 반복횟수는 x 축의 수에 12를 곱한 형식이 되며 이 반복횟수에 대한 표는 그림 13과 그림 14에 나와있다.




그림 12. 표본이 1000일 때, 각 조건별 사후확률과 수락율의 변화모습




그림 13. $N = 2000$ 일 때, 각 조건별 사후확률과 수락율의 변화모습




그림 14. N= 1000일 때, 각 노드별 반복횟수
(총 계산량은 노드별 반복횟수 * 노드수가 됨)




그림 15. N= 2000일 때, 각 노드별 반복횟수
(총 계산량은 노드별 반복횟수 * 노드수가 됨)

4.1.2 아시아망(Asia network) 데이터에 대한 성능 비교

아시아망은 간단한 가상의 의학 진단망으로 환자의 X-ray 검사결과, 아시아 방문여부, 흡연습관, 폐암 또는 호흡곤란 등의 상태를 보고 폐암인지 결핵인지 기관지염인지의 여부를 가리고자 하는 베이즈안망이다(그림 16). 아시아망 역시 노드의 수가 8개로 full search가 가능하다. full search로

학습해낸 결과는 그림 16으로 Smoking → Tuberculosis로 향하는 연결선을 추가로 더 찾는 실수만을 범하였고 최대 베이지안 평가점수는 -2100이다.




그림 16. 아시아망(Asia networks)






그림 17. full search에 의한 베이지안망

1:VisitAsia, 2:Smoking, 3:Tuberculosis, 4:Cancer,5:Bronchitis,
6:TbOrCa, 7:XRay, 8:Dyspnea


아시아망의 학습결과 역시 앞의 화재망과 크게 다르지 않았다. 다만 전반적으로 에러의 수가 화재망의 경우보다 아주 조금 많아졌다. 그러나 여전히 상당히 좋은 성능을 보였다. 베이지안망 학습의 결과는 그림 18과 표 2에 나와있다.




(a) $N=1000$, $c=0.9$, $T=1$



(b) $N=1000$, $c=0.7$, $T=1$



(c) $N=2000$, $c=0.5$, $T=3$



(d) $N=2000$, $c=0.9$, $T=3$

그림 18. 베이지안망 구조 학습의 일부 결과
 1:VisitAsia, 2:Smoking, 3:Tuberculosis, 4:Cancer,5:Bronchitis,
 6:TbOrCa, 7:XRy, 8:Dyspnea

표 2. 온도 파라미터의 초기값(T), 감소비율(c), 데이터 수에 따른 학습 결과

데이터 수	$T = 1$		$T = 3$		$T = 5$	
	max. score	잘못 학습된 연결선의 수	max. score	잘못 학습된 연결선의 수	max. score	잘못 학습된 연결선의 수
200	-450	missing(4),extra(2)	-444	missing(4),extra(1)	-430	missing(3),extra(3)
500	-906	missing(3),extra(2)	-916	missing(3),extra(2)	-970	missing(3),extra(3)
1000	-2295	missing(3),extra(1)	-2295	missing(2),extra(2)	-2298	missing(2),extra(2)
2000	-4049	missing(2),extra(1)	-4055	missing(2),extra(2)	-4058	missing(2),extra(2)
5000	-9056	missing(2),extra(0)	-9066	missing(2),extra(1)	-9054	missing(2),extra(1)
10000	-17890	missing(2),extra(0)	-17908	missing(1),extra(1)	-17977	missing(2),extra(1)

데이터 수	$c = 0.5$		$c = 0.7$		$c = 0.9$	
	max. score	잘못 학습된 연결선의 수	max. score	잘못 학습된 연결선의 수	max. score	잘못 학습된 연결선의 수
200	-427	missing(4),extra(1)	-430	missing(3),extra(2)	-427	missing(4),extra(0)
500	-900	missing(4),extra(3)	-912	missing(3),extra(2)	-904	missing(2),extra(2)
1000	-2290	missing(2),extra(2)	-2293	missing(3),extra(2)	-2287	missing(2),extra(2)
2000	-4062	missing(2),extra(2)	-4055	missing(2),extra(2)	-4052	missing(2),extra(2)
5000	-9065	missing(1),extra(2)	-9054	missing(2),extra(1)	-9065	missing(1),extra(1)
10000	-17908	missing(2),extra(1)	-17890	missing(2),extra(1)	-17900	missing(1),extra(0)




그림 19. 표본이 1000일 때, 각 조건별 사후확률과 수락율의 변화모습




그림 20. 표본이 2000 일 때, 각 조건별 사후확률과 수락율의 변화모습

그림 19 와 20 는 표 2 중 일부를 그래프로 나타낸 것으로 앞의 4.1.1 절과 같이 데이터의 수가 많아질수록 온도 파라미터의 설정값에 대해 더 적게 영향을 받음을 알 수 있다. 그림 21 과 22 역시 앞의 절과 마찬가지로 각 노드별 반복횟수를 나타내며 노드의 수가 증가해도 각 노드당 반복횟수에는 변함이 없다는 것을 알 수 있다.




그림 21. $N=1000$ 일 때, 6개의 온도 파라미터 조건하에서 각 노드의 평균 반복횟수




그림 22. N= 2000일 때, 6개의 온도 파라미터 조건하에서 각 노드의 평균 반복횟수

4.1.3 경고망(Alarm network) 데이터에 대한 성능비교

경고망은 베이지안망 구조학습의 벤치마크 과제로 흔히 쓰이는 망으로 환자에 대한 의학진단 망으로 환자의 상태에 대한 모니터링에 대한 베이지안망으로 그림 23과 같다.

경고망 데이터는 노드의 수가 37개나 되는 비교적 큰 베이지안망에 속한다. 이런 이유로 full search를 통한 학습은 불가능하다 하겠다. full search를 통해 부모노드를 탐색할 경우, 각 노드별 계산량은 최대 $n!$ 이된다. 즉 이 경고망의 경우 최대 $37!$ 의 계산이 요구된다. 그런데 일반적으로 부모노드의 수를 k 개로 한정하기 때문에 이런 한정이 주어질 경우는 ${}_{37}C_2$ 번의 탐색으로 학습이 가능하다. 그러나 Simulated Annealing을 사용하면 그림 28과 그림 29에서 보여지는 것처럼 각 노드당 계산량이 최대 300을 넘지 않는다. 이런 이유로 노드의 수가 크게 증가해도 총 계산량은 크게 증가하지 않음을 알 수 있다.

표 3은 베이지안망을 학습한 결과를 정리한 표이다. 이 결과 중 일부는 그림 24에 나와있다. 그림 24의 베이지안망 그림은 경고망의 크기가 큰

관계로 시각적 편의를 위하여 Netica의 그래프 기능을 이용하여 학습된 베이저안망을 다시 그려 얻어진 것이다. 굵은 선은 있어야 할 연결선이 없는 경우를 나타내며 동그라미는 추가로 학습된 연결선을 의미한다.





그림 23. 경고망(Alarm network)


표 3. 온도 파라미터의 초기값(T), 감소비율(c), 데이터 수에 따른 학습 결과

데이터 수	$T = 1$		$T = 3$		$T = 5$	
	max. score	잘못 학습된 연결선의 수	max. score	잘못 학습된 연결선의 수	max. score	잘못 학습된 연결선의 수
200	-2296	missing(6),extra(3)	-2290	missing(5),extra(3)	-2285	missing(5),extra(3)
500	-4050	missing(5),extra(2)	-4059	missing(5),extra(2)	-4060	missing(5),extra(2)
1000	-9547	missing(4),extra(3)	-9632	missing(3),extra(3)	-9371	missing(3),extra(3)
2000	-15678	missing(4),extra(2)	-14889	missing(3),extra(3)	-13456	missing(4),extra(2)
5000	-19870	missing(3),extra(1)	-19980	missing(3),extra(2)	-19890	missing(3),extra(2)
10000	-26789	missing(2),extra(3)	-26790	missing(3),extra(1)	-26800	missing(3),extra(2)


데이터 수	$c = 0.5$		$c = 0.7$		$c = 0.9$	
	max. score	잘못 학습된 연결선의 수	max. score	잘못 학습된 연결선의 수	max. score	잘못 학습된 연결선의 수
200	-2287	missing(5),extra(3)	-2287	missing(4),extra(3)	-2286	missing(5),extra(4)
500	-4064	missing(4),extra(4)	-4050	missing(4),extra(2)	-4050	missing(5),extra(2)
1000	-9456	missing(4),extra(4)	-9901	missing(4),extra(2)	-9801	missing(4),extra(2)
2000	-14323	missing(3),extra(4)	-13452	missing(3),extra(2)	-14563	missing(3),extra(2)
5000	-19890	missing(2),extra(2)	-19900	missing(3),extra(1)	-19890	missing(2),extra(2)
10000	-26809	missing(2),extra(3)	-26803	missing(3),extra(1)	-26799	missing(1),extra(3)



(a) $N = 1000$, $c = 0.9$, $T = 3$



(b) $N = 1000$, $c = 0.9$, $T = 1$



(c) $N = 2000$, $c = 0.9$, $T = 1$

그림 24. 베이지안망의 학습 결과




그림 25. 표본이 500 일 때, 각 조건별 사후확률과 수락율의 변화모습




그림 26. $N=1000$ 일 때, 6개의 온도 파라미터 조건하에서 각 노드의 평균 반복횟수




그림 27. N= 2000일 때, 6개의 온도 파라미터 조건하에서 각 노드의 평균 반복횟수

4.1.4 Hailfinder 망 데이터에 대한 성능비교

Hailfinder 망은 56개의 노드를 가지는 비교적 크고 실제 데이터 마이닝 과제와 비슷한 베이지안망이다. 그러므로 이 데이터에 대한 학습 결과가 이 알고리즘의 데이터 마이닝 과제의 적용여부를 확인할 수 있는 방법이 되리라고 생각한다. 각 노드별 계산량은 앞선 실험에서 크게 변화하지 않았다. 그러나 학습의 성능은 다소 떨어지는 것을 볼 수 있었다.

표 4. 베이지안망 구조 학습 결과

데이터 수	잘못 학습된 연결선의 수(각 조건에서의 평균수치)		
	연결선이 없는 경우	연결선이 추가로 있는 경우	연결선의 방향이 틀린 경우
1000	6(5)	7(6)	4(5)
2000	5(4)	5(4)	6(5)

표 5. 각 실험 조건별 베이지안 평가함수 값의 변화

데이터 수	T = 1		T = 3		T = 5	
	c = 0.5	c = 0.9	c = 0.5	c = 0.9	c = 0.5	c = 0.9
1000	-22302	22289	-22304	22301	-22293	22283
2000	-24053	24107	24055	24057	24052	24051




그림 28. 학습된 베이지안망($N = 1000$, $c = 0.9$, $T = 25$ 일 때)

1:TempDis, 2:SynForcng, 3:RHRatio, 4:MvmtFeatures, 5:MidLLapse,
6:MeanRH, 7:LowLLapse, 8:Date, 9:IRCloudCover, 10:QGVertMotion,
11:RaoCont, 12:SatContMo, 13:SubjVertMo, 14:VISCloudCov, 15:N0_7muVerMo,
16:WndHod, 17:CombMoi, 18:CombClouds, 19:AMInstabMt, 20:CombVerMo,
21:AreaMo, 22:ScenRelA, 23:AreaMeso, 24:MorningCIN, 25:InsChange,
26:Boundarie, 27:CompPIFcst, 28:CldShade, 29:PlainsFcst, 30:MountainFcst,
31:CapInSce, 32:CurProp, 33:LatestCIN, 34:LLIW, 35:ScnRelPIFcst,
36:R5Fcst, 37:N34Star, 38:ScenRel3_4, 39:CapChange, 40:Llfr12ZDENSd,
41:InsSclIn, 42:AMInsWliS, 43:AMDewpt, 44:LoLevMois, 45:Morning,
46:CldShad, 47:Outflowt, 48:InsInMt, 49:ScenRelA, 50:AMCINInScen,
51:WindF, 52:WindA, 53:Dewpoints, 54:SfcWndShfDis, 55:WindFieldMt,
56:Scenario




그림 30. N= 1000일 때, 6개의 온도 파라미터 조건하에서 각 노드의 평균 반복횟수




그림 31. N= 2000일 때, 6개의 온도 파라미터 조건하에서 각 노드의 평균 반복횟수

4.1.5 결과 분석

실험에 사용된 데이터의 노드의 수가 증가할 수록 요구되는 계산량은 아래 그림 32에서 보는 것과 같이 선형관계를 나타내고 있다. 이것은

노드의 수가 증가하더라도 계산의 양이 크게 늘어나지 않는다는 것을 의미하며 데이터 마이닝을 위해서는 매우 바람직하다고 하겠다.








그림 32. 노드의 수의 증가에 따른 계산량의 증가율

Metropolis 이동의 비율 p 의 값의 변화에 따른 “Exchange” 이동과 “Cutting or Birth” 이동의 수락과 거절비율은 아래와 같다. 또 c 의 변화에 따른 두 이동의 수락 비율은 그림 33과 같다. 일반적으로 c 의 값이 1에 가까울 수록 수락비율이 크고 작아질 수록 수락비율이 작아져야 하는데 c 의 값이 작을 수록 급속히 0에 가까와 지므로 수락비율이 c 가 큰 값에 비해 훨씬 작음을 알 수 있다. 이는 Simulated Annealing이 효과적으로 일어나고 있음을 보여준다고 하겠다.








그림 33. Metropolis 이동의 비율 P 의 값에 따른 수락율의 변화
(aFlip : “Exchange” 이동의 수락, rFlip: “Exchange” 이동의 거절, aCutting: “Cutting Birth” 이동의 수락, rCutting: “Cutting or Birth”이동의 거절)

실험결과 반복횟수가 많다고 반드시 성능이 좋은 것은 아님이 밝혀졌다. 또한 T, c 등 온도 파라미터의 조절값은 어떤 특정 패턴을 나타내지는 않았다. 그러나 대체로 데이터의 수가 많아질수록 온도 파라미터의 영향을 받지 않는 것으로 나타났다. 또한 평가함수의 점수가 클수록 연결선 학습에서 에러를 더 적게 범하는 경향을 볼 수 있었다. 이것은 이 논문에서 사용한 베이지안 평가함수가 베이지안망 구조 학습의 평가함수로 적절함을 보인다고 하겠다. 물론 이것은 같은 조건에서 학습한 경우를 의미한다.

데이터의 수가 다르거나 노드의 수가 다른 실험환경에서 학습된 베이지망의 평가함수의 값을 서로 비교하는 것은 아무 의미가 없다. 그것은 베이지안 평가함수가 상대적 점수를 의미하기 때문이다.

벤치마크 문제들을 이용하여 실험을 한 경우의 장점은 다른 알고리즘과의 성능비교가 용이하다는 것이다. 이 논문에서 사용된 데이터 중에서 특히 아시아망과 경고망은 베이지안망 구조학습의 성능 평가시 자주 쓰이는 데이터인 까닭에 이런 비교는 더욱 용이하다. 그림 34는 여러 다른 알고리즘들 중에서 현재 상용 툴로 널리 쓰이고 있는 Bayesian Knowledge Discoverer와 Belief Net Power Constructor[4]의 성능을 이 논문의 알고리즘과 비교한 것이다. 여기서 에러수는 데이터의 수가 5000과 10000일 때의 평균 에러를 말하며 연결선의 방향을 포함하여 연결선을 찾지 못한 모든 횟수를 에러로 보았다. 그림에서 보는 것과 같이 세 알고리즘의 성능이 거의 비슷하나 아시아망에서 본 논문에서 제안한 Simulated Annealing 방법이 다소 성능이 좋았고 경고망에서는 나머지 두 방법의 성능이 좋았다.




그림 34. 다른 알고리즘과의 비교

4.2 실제문제의 적용

4.2.1 CoIL Challenge 2000 데이터

CoIL Challenge 2000 데이터는 실제 데이터에 여러가지 데이터 마이닝 기법을 적용하여 성능을 평가할 수 있도록 매년 열리는 CoIL Competition의 2000년도 과제이다. 2000년도의 과제는 두 가지로 나누어져 있는데 첫째는 실제 보험회사의 자료를 바탕으로 caravan insurance policy에 관심을 가질 고객을 예측하는 것이고 두 번째는 이 고객들의 성향을 묘사하는 것이다. 베이지안망은 앞에서 기술한대로 해석이 용이하기 때문에 어느 알고리즘보다 두 번째 과제인 고객의 성향을 묘사하는데 적합하다고 하겠다. 여기서는 베이지안망을 사용하여 위의 두 과제를 다 해결해 보았다. 먼저 데이터중 가장 의미있다고 생각하는 속성 19개를 [23]에 언급되어 있는 대로 선택하였다. 이 속성은 그림 35와 같다.

이 19개의 속성과 함께 실제 소비자의 구매여부를 나타내는 항목까지 합쳐서 20개의 항목을 가지고 베이지안망을 학습하였다. 이 결과는 그림 36와 같다. 학습된 베이지안망을 이용하여 소비자를 예측하여 보면 대략 75%의 정확률을 보였다. 데이터의 분류는 베이지안망에서 구매여부를 나타내는 항목이 1이 나올 조건부 확률을 구하여 이것이 0.5보다 크면 보험상품을 구입했다는 것으로 분류하는 방법에 의하여 구하였다. 표 5에 나타나는 것과 같이 신경망이나 다른 방법에 비해 다소 분류성능은 떨어졌다.

그러나 학습된 베이지안망을 살펴보면 매우 흥미있는 고객들의 속성들을 찾아낼 수가 있었다. boat policies 의 수가 0인 사람들 중에서 Contribution car policies가 0 또는 5와 6인 사람들은 caravan policies를 사지 않을 확률이 각각 0.945, 0.864, 0.860으로 매우 높았다. 또한 Contribution car policies가 0인

사람은 Contribution social security insurance policies 또한 0일 확률이 0.945로 매우 높았다. 이것은 쉽게 예측이 가능한데 boat policies에 대한 소비가 없는 사람들 중 car policies에 대한 소비가 없는 사람이라면 당연히 caravan policies를 살 것 같지는 않다. 소비자의 수입 내역도 역시 중요한 요소로 나타났다. income의 수준이 높고 교육수준이 높으며 power-related 소비가 많은 사람은 caravan insurance policies를 살 확률이 0.56으로 높게 나타났다.

이와 함께 교육수준도 중요한 요소로 나타났다

1. Customer subtype
2. Other relation
3. High level education
4. Medium level education
5. Social class A
6. 2 cars
7. No car
8. Average income
9. Purchasing power class
10. Contribution private third party insurance
11. Contribution car policies
12. Contribution agricultural insurance polices
13. Contribution private accident insurance policies
14. Contribution social security insurance policies
15. Number of third party insurance(firms)
16. Number of delivery van polices
17. Number of motorcycle/scooter policies
18. Number of boat policies
19. Number of bicycle policies

그림 35.추출된 속성들

그러나 학습된 베이지안망(그림 36)을 살펴보면 매우 흥미 있는 고객들의 속성들을 찾아낼 수가 있었다. 이 결과들을 열거해보면 아래와 같다.

1. boat policies = 0인 사람들 중에서 Contribution car policies가 0 또는 5와 6인 사람들은 caravan policies를 사지 않을 확률이 각각 0.945, 0.864,

0.860으로 매우 높다

2. Contribution car policies = 0인 사람은 Contribution social security insurance policies 또한 0일 확률이 0.945로 매우 높다.

3. boat policies = 2인 사람들 중에서 Contribution car policies가 5 또는 6인 사람들은 caravan policies를 살 확률이 각각 0.645, 0.564로 높다.

4. High level education이 높을수록 caravan insurance policies를 살 확률이 높다.

5. power-related 소비가 많은 사람일 수록 caravan insurance policies 를 살 확률이 높다.

위에서 찾아낸 결과들을 정리해보면 caravan insurance policies에 관심을 가지는 소비자는 일반적으로 높은 교육수준을 가지고 car policies에 대한 지출이 많은 사람들이다. car policies에 대한 소비가 많은 사람중에서도 boat policies와 같이 다른 보험 상품에 가입해 있는 사람이 더욱더 caravan insurance policies를 구입할 확률이 높다가 결론 내릴 수 있다. 이 데이터에 대한 우승자가 찾아낸 소비자에 대한 규칙[22]은 그림 37과 같으며 위에서 베이지안망이 찾아낸 규칙과 비슷함을 알 수 있다. 다른 점은 베이지안망에서는 소비자의 boat policies에 대한 소비를 중요하게 본 반면 [22]에서는 fire policies에 대한 지출 내용을 더 중요한 요소로 찾아낸 것이다. 그러나 fire policies에 대한 항목은 [22]가 위의 19개의 속성들 외에 Chi-square Test를 이용하여 찾아낸 속성이므로 이 논문의 실험 시에는 아예 빠져있었기에 이것을 이용하여 성능을 평가하는 것은 불가능하다.




그림 36. CoIL 2000 데이터를 이용하여 학습한 베이지안망

- 1.if(high level education = 37-49%) then yes(0.006,0.113)
- 2.if(purchasing power class = 7) then yes(0.012,0.141)
- 3.if(contribution car policies = 6) then yes(0.045,0.113)
- 4.if(contribution fire policies = 6) then yes(0.026, 0.123)
- 5.if(number of car policies = 2) then yes(0.007, 0.154)

그림 37.CoIL Challenge 2000 데이터에 대한 연관 규칙들[22]

4.2.1 베이지안망을 이용한 문서분류

문서분류의 과제에 베이지안망을 사용하였다. 여기서 문서분류란 문서를 문서의 내용에 따라 주제별로 분류하는 것이다. 이 실험에서 사용한 데이터는 아래 그림 39와 같이 네 가지 주제로 구성되어 있다. 실제 실험에서 사용한 데이터는 각 주제별로 사용된 빈도수에 따라 선택된 주제어들 10개를 바탕으로 재구성한 데이터를 사용하였다. 여기서 각 주제당 선택된 주제어의 내용은 그림 38 과 같다.

주제 1: german, germani, mr, parti, year, foreign , peopl, countri, govern, asylum
주제 2: percent , estonia, bank, state, privat, russian, year, enterprise, trade, million
주제 3: research, technologi, deelop, mar, materi, system, nuclear, environment, electr, process
주제 4: jordan, peac, israel, palestinian,king isra, arab, meet, talk , husayn

그림 38. 각 주제별로 선택된 주제어들

학습된 베이지안망을 이용하여 행한 문서분류에 대한 성능은 85%로 나타났다. 그러나 미리 주제어를 추출해 내었으므로 다른 알고리즘과의 무조건적 비교는 불가능하다. 그보다는 학습된 베이지안망을 이용하여 단어간 연관관계를 살펴보는 것이 베이지안망의 인지과학적 의미를 살펴보는 데 있어 중요하리라 생각한다. 베이지안망의 학습결과를 살펴보면 주제별 분류에 가장 많은 영향을 준 단어들은 peac, system, enterpris, isra, privat이다. 여기서 peac이란 단어가 존재하는 문서가 주제 4로 분류될 확률이 0.629이고 privat인 단어가 관찰된 문서가 주제 2로 분류될 확률은 0.671인 것으로 나타났다. 이와 함께 system, environment, nuclear와 주제 4의 주제어중의 하나인 talk는 동시에 나타나지 않을 확률이 0.96으로 높게 나타났다. 이와 유사하게 서로 다른 주제어들간에는 함께 나타나지 않을 확률이 대체로 높게 나타났음을 알 수 있었다. 주제어 중 year는 두 가지 주제에 동시에 속해 있는 주제어였다. 학습 시 year는 year와 year1과 같이 두 변수로 다루었다. 그 결과 year는 주제 1에 year1은 주제 2에 영향을 미치는 것으로 나타났다. 즉 같은 단어이지만 같이 쓰인 단어들에 따라 문서를 전혀 다른 내용으로 분류하고 있음을 볼 수 있다. 학습된 베이지안망은 그림 40에 나와있다.

Topics	Descriptions
Topic 401	Foreign minorities, Germany What language and cultural differences impede the integration of foreign minorities in Germany? A relevant document will focus on the causes of the lack of integration in a significant way; that is, the mere mention of immigration difficulties is not relevant. Documents that discuss immigration problems unrelated to Germany are also not relevant.
Topic 434	Estonia, economy What is the state of the economy of Estonia? Documents that give concrete economic information such as economic statistics, entering economic unions and treaties, or monetary performance are relevant, as are discussions of economic issues such as transportation or pollution.
Topic 439	inventions, scientific discoveries What new inventions or scientific discoveries have been made? The word "new" in the description is defined as occurring in the 1990s. Documents that indicate a "recent" invention or scientific discovery are considered relevant. Discoveries made in astronomy or any scientific discoveries that are not patentable are not relevant.
Topic 450	King Hussein, peace How significant a figure over the years was the late Jordanian King Hussein in furthering peace in the Middle East? A relevant document must include mention of Israel. King Hussein himself as opposed to other Jordanian officials; discussion of the King's on-going, previous or upcoming efforts; and efforts pertinent to the peace process, not merely Jordan's relationship with other middle-east countries or the U.S.

그림 39. 네 가지 주제에 대한 설명




그림 40. 문서 데이터로부터 학습한 베이지안망

5. 결론

본 논문에서는 Simulated Annealing을 사용하여 베이지안망 구조를 학습하는 방법을 제안하였다. Simulated Annealing 방법을 사용할 때 가장 큰 장점은 노드의 수가 증가할수록 계산의 양이 선형적으로 늘어난다는 것이다. 이것은 데이터 마이닝과 같은 대규모의 데이터 분석에 적용시 큰 장점이 될 수 있다. 또한 Simulated Annealing은 다른 탐색 알고리즘에 비해서 수렴이 빠르고 지역국소에 빠지지 않는 장점을 가지고 있다. 이 논문에서 구현된 Simulated Annealing 방법이 기존의 방법과 다른 점은 기존의 방법들은 Mutual Information과 같은 CI검사들을 이용하여 노드의 순서를 가정한 후 부모노드의 탐색에 Simulated Annealing을 사용한 반면 이 논문에서는 이런 노드의 순서를 사전에 추정하는 과정을 생략하였다는 것이다.

실제 실험에서 연결선의 방향 검사 없이 베이지안망 구조를 학습하였을 시에는 대규모 데이터에서 많은 에러가 발생함을 보았다. 그러나 연결선의 방향검사를 행한 후 에러가 훨씬 줄어드는 것을 볼 수 있었다. 또한 다양한 실험조건에서 대부분 안정적으로 수렴됨을 알 수 있었다. 특히 데이터의 크기가 커질수록 더욱 안정적인 결과를 얻을 수 있었다. 얻어진 결과는 기존의 알고리즘들의 성능과 비교되었고 기존의 방법들에 비해 성능이 조금씩 향상된 것을 볼 수 있었다.

베이지안망을 실제 데이터의 분석에 적용하였을 때 가장 큰 장점은 예측과 변수간 인과관계에 대한 설명을 동시에 행할 수 있다는 것이다. 실제 실험 결과 예측의 성능이 떨어지지 않았으며 그럴듯한 변수들간의 인과관계를 파악할 수 있었다. 특히 문서분류의 경우 단어들간의 연관관계를 찾아낼 수 있었는데 이것은 중의어 구분등과 같은 언어의 모호성 분석에 유용하게 쓰일 수 있으리라 생각한다.

본 논문에서 제시한 알고리즘의 중요한 한계점은 결측치를 가지는

데이터를 다룰 수 없다는 것이다. 사실 결측치는 데이터 마이닝에서는 흔히 발생하는 상황이다. 그럼에도 이 알고리즘이 결측치를 다루도록 확장되지 못한 이유는 각 노드에서의 지역 탐색을 가능케하는 분리성이 결측치가 있는 데이터에서는 성립하지 못하기 때문이다. 사실 결측치를 가진 데이터로부터 베이지안망 구조를 학습하는 문제는 아직도 연구실적이 많지 않은 어려운 과제이다. 이에 대해서는 [19]에 잘 나와있다.

위와 같은 문제점에도 불구하고 이 논문이 의미를 가지는 것은 노드의 수에 exponential하게 증가하지 않는 학습 알고리즘을 제시함으로써 실제 데이터 마이닝에 베이지안망을 적용할 수 있는 가능성을 제시했다는 것이다.

참고 문헌

- [1] Berry, M. and Linoff, G., *Data Mining Techniques*, Wiley, New York, 1997.
- [2] Breiman, L., Friedman, J.H., Olshen, R.A., and Stone, C.J., *Classification and Regression Trees*, Chapman & Hall, New York, 1984.
- [3] Heckerman, D., “Bayesian networks for knowledge discovery,” In *Advances in Knowledge Discovery and Data Mining*, AAAI/MIT Press, 1996.
- [4] Cheng, J., Bell, D.A., and Liu, W., “Learning belief networks from data: an information theory based approach,” *Proceedings of the Sixth ACM International Conference on Information and Knowledge Management*, 1997.
- [5] Heckerman, D., Meek, C., and Cooper, G., “A Bayesian approach to causal discovery,” *Technical Report MSR-TR-97-05*, Microsoft Research, February, 1997.
- [6] Sebastina, P., Ramoni, M., and Crea, A., “Profiling your customers using bayesian networks,” *KDD'99 Knowledge Discovery Contest*, Available at <http://www-cse.ucsd.edu/users/elkan/kdresults.html>, 1999.
- [7] Cooper, G.F. and Herskovits, E., “A Bayesian Method for the induction of probabilistic networks from data,” *Machine Learning*, 9, pages 309-347, 1992.
- [8] Singh, M. and Valtorta, M., “Construction of Bayesian networks structures from data: A survey and an efficient algorithm,” *International Journal of Approximate Reasoning*, 12: pages 111-131, 1995.
- [9] Larranaga, P., Kuijpers, C., Murga, R., and Yurranmendi, Y., “Learning Bayesian network structure by searching for the best ordering with genetic algorithms,”

- IEEE Transactions on Systems, Man and Cybernetics- Part A: Systems and Humans*, 26(4): pages 487-493, 1996.
- [10] Campos, L. and Huete, J., "Approximating causal orderings for Bayesian networks using genetic algorithms and simulated annealing," *Tech. Rep. DECSAI-990212*, Dpto. de Ciencias de la Computaci'on e I.A. Universidad de Granada, 1999.
- [11] Friedman, N. and Koller, D., "Being Bayesian about network structure," *Proceedings of the 16th Annual Conference on Uncertainty in AI (UAI)*, Stanford, California, pages 201-210, 2000.
- [12] Pearl, J., *Probabilistic Reasoning In Intelligent Systems: Networks of Plausible Inference*, Morgan and Kaufmann, San Mateo, 1988.
- [13] Wermuth, N. and Lauritzen, S., "Graphical and recursive models for contingency tables," *Biometrika*, 72, pages 537-552, 1983.
- [14] Spirtes, P., Glymour, C., and Schenies, R., "An algorithm for fast recovery of sparse causal graphs," *Social Science Computer Review*, 9, pages 62-72, 1991.
- [15] Chow, C.K. and Liu, C.N., "Approximating discrete probability distributions with dependence trees," *IEEE Transactions on Information Theory*, 14, pages 462-467, 1968.
- [16] Heckerman, D., Geiger, D., and Chickering, D.M., "Learning Bayesian networks: the combination of knowledge and statistical data," *Technical Report MSR-TR-94-09*, Microsoft Research, 1994.
- [17] Kirkpatrick, S., Gelatt, C., and Vecchi, M., "Optimization by simulated annealing," *Science*, 220(4598), pages 671-680, 1983.

- [18] Friedman, N., Nachman, I., and Pe'er, D., "Learning bayesian network structure from massive datasets: The "Sparse Candidate" algorithm," *Proceedings of the 15th Annual Conference. on Uncertainty in Artificial Intelligence (UAI)*, pages 145-148, 1999.
- [19] Friedman, N., " The Bayesian structural EM algorithm," *Proceedings of the 14th Annual Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 442-446, 1998.
- [20] Schwarz, G., "Estimating dimension of a model," *Annual Statistics*, 6: pages 461-464, 1978.
- [21] Fried, N. and Goldszmidt, M., "Building classifiers using bayesian networks," *In Thirteenth National Conference on Artificial intelligence(AAAI)*, 1996.
- [22] Kim, Y. and Street, W., "CoIL Challenge 2000: Choosing and explaining likely caravan insurance customers," *CoIL Challenge 2000*, Available at <http://www.wi.leidenuniv.nl/~putten/library/cc2000/report2.html>, 2000.
- [23] Pearl, J., "Bayesian networks," *Technical Report (R-277)*, UCLA Cognitive Systems Laboratory , November 2000.

ABSTRACT

Bayesian networks are useful models to represent, in relatively simple forms, the probability relations among variables and can be successfully applied to various tasks such as probability reasoning, prediction, decision-making. In this thesis, I made an inquiry into the method of performing data-mining tasks, using Bayesian networks.

When one applies Bayesian networks to data mining, one of the most difficult problems is that the more variables of data, the more difficult to learn the structures of Bayesian networks. In this thesis, for structural learning of Bayesian networks I propose a new method which utilize “Simulated Annealing”, a sampling-based optimization method. In this method to downsize the search space efficiently, the aim is to find out, locally at each node, the parent node of it, not to search the best Bayesian network structure in the whole possible structure space. The reason why this is possible is that in data without missing values, each node has the decomposability. That is, to maximize(minimize) object function at each node is the same as to maximize (minimize) the whole network. Such decomposability makes it possible that without regard to the size of node, only computation amount at each node has an effect on the whole computation.

Sampling-based optimization method is affected by initial value and reduction ratio of annealing temperature parameter especially. Hence in this thesis algorithm, which was proposed for the benchmark problems for performance estimation of structural learning of Bayesian network, is implemented and applied. Also change of performance according to the estimate value of temperature parameter and number of data node is measured. As the result, it is found that even if the number of variables increases, computation amount at each node keeps constant and that estimate value of temperature parameter has little effects on the result of learning. Moreover I found that as the number of data increases, the result of structural learning of Bayesian network comes out better.

In this thesis, I also applied Bayesian networks to real environment. The first task

was customer prediction and propensity analysis. Utilizing customer information of insurance company, I predicted which customer will take out the caravan insurance policy and described the propensity of those customers. The second applied task was document classification. This is to classify enormous amount of documents into four kinds of topics. The application of Bayesian network does not merely enable us to classify documents but it also reveals the correlations of key words in each topic respectively. When applied in the area of linguistics or cognitive science, Bayesian networks could produce effective results in such tasks as word's ambiguity problem.

Keywords: Structural learning of Bayesian networks, Data mining, Simulated annealing

Student number : 99132-507

감사의 글

먼저 부모님께 감사 드립니다. 공부를 다시 시작한다고 했을 때 제게 가장 큰 힘이 되어주셨습니다. 늘 만족보다는 실망을 안겨드린 것 같아 죄송스럽습니다.

이 논문이 나오기까지 가장 애써 주신분은 지도 교수님이신 장 병탁 선생님입니다. 모자란 저에게 인내심과 끊임없는 관심으로 지켜봐주시는 선생님께 정말 감사 드립니다.

논문심사를 해주신 홍 재성 선생님과 김 청택 선생님께도 진심으로 감사 드립니다. 홍 재성 선생님과 나누었던 대화는 이 논문의 2.3 절을 쓰는데 밑바탕이 되었고 김 청택 선생님의 날카로운 지적들은 이 논문의 수정 시 많은 도움이 되었습니다.

인지과학 협동과정의 동기들인 수경이, 미경이, 성호오빠, 호진오빠와 여러모로 도움을 주신 윤현 오빠, 소영 언니들, 광주오빠 그리고 제가 잘 보살펴주지 못한 2000 학번 후배들에게도 감사의 마음을 전합니다. 인공지능 랩에서 같이 생활하면서 가장 힘이 되어준 형주, 수용씨, 상욱이, 재홍씨, 선, 동연씨, 그리고 양박사님에게도 감사드립니다.

10여년이 넘는 세월 동안 날 지켜봐온 혜정이 그리고 마음의 벗 정화, 도도희 친구들인 정민, 수진, 주은, 소영, 지연, 보연이 그리고 이 논문이 나올 무렵 가장 큰 힘이 되어준 IBM 동기 혜승이에게도 고마움을 전합니다.

마지막으로 대학원 생활 내내 도움이 되어준 큰오빠, 작은오빠, 경이언니, 사랑스런 조카 현민이와, 무엇보다 소중한 정우 오빠에게 이 논문을 드립니다.