

이학석사학위논문

분자컴퓨팅을 이용한 기억기반 학습
Memory-Based Learning
Using Molecular Computing

2003년 2월

서울대학교 대학원

협동과정 인지과학전공

정 희 재

분자컴퓨팅을 이용한 기억기반 학습

Memory-Based Learning

Using Molecular Computing

지도교수 장 병 탁

이 논문을 이학석사 학위논문으로 제출함

2002년 11월

서울대학교 대학원

협동과정 인지과학전공

정 희 재

정희재의 이학석사 학위논문을 인준함

2002년 12월

심사위원장 인

부위원장 인

심사위원 인

초 록

화학적 시냅스에서 발생하는 내성은 신경전달물질을 매개체로 하고 피드백 기제를 통해 자극을 처리하고 그 결과 시냅스 가소성을 야기한다. 시냅스 가소성이 일어나는 과정에서 자극에 대한 감각정보가 처리되고 저장되므로 이와 같은 현상을 학습과정이라고 볼 수 있다.

본 논문에서는 화학적 시냅스에서 일어나는 학습 과정에 기반한 기억기반 학습의 방식을 구현하는 방법을 제시한다. 초별렬성과 기억 집적성을 최대 장점으로 내세울 수 있는 분자컴퓨팅의 일종인 DNA 컴퓨팅을 이용했다. 실리콘을 메모리로 사용하는 기존의 컴퓨터로는 많은 양의 정보를 동시다발적으로 처리하는 화학적 시냅스의 학습과정을 구현하기 어렵기 때문이다. 하지만 현재 분자컴퓨팅의 기술로 시냅스의 학습과정을 그대로 구현할 수 있는 알고리즘이 부재하여 기존의 기계학습 알고리즘 중 시냅스 가소성이 일어나는 과정과 가장 근접한 기억기반 학습의 방식을 이용했다.

기억기반 학습의 방식을 구현하고 직접 DNA 컴퓨팅으로 실험하기 앞서 본 논문의 구현 알고리즘의 실효성을 테스트하기 위해서 시뮬레이션을 실시했다. CoIL Challenge 2000 데이터를 이용한 시뮬레이션의 결과, 800명의 후보 중 123명이 적중했다. 대회 우승자가 121명을, 이전의 다른 기계학습 알고리즘을 이용한 연구자가 118명을 맞춘 결과에 비해 본 논문의 구현 결과가 우수했음을 알 수 있다. 본 논문의 시뮬레이션에서는 85개 중 17개의 요인을 이용했지만 DNA 컴퓨팅을 생물학적인 방법으로 실험한다면 모든 요인을 써서 더 우수한 결과를 얻을 수 있을 것이다. 그리고 지금의 실리콘 메모리 기반의 컴퓨터처럼 사용자 인터페이스가 편리한 DNA 컴퓨팅 도구가 개발된다면 실제적인 시간의 절약도 가능할 것이다.

주요어: 기억기반 학습, DNA 컴퓨팅, 시냅스 가소성, 기억기반 의사결정지원시스템, 내성

학번: 2001-20153

목 차

1. 서론	1
2. 시냅스 가소성	5
2.1 내성의 단계	5
2.2 시냅스 가소성	7
2.3 화학적 시냅스의 학습 과정	8
3. DNA 컴퓨팅에 의한 기억기반 학습	10
3.1 DNA 컴퓨팅	10
3.1.1 DNA 컴퓨팅의 연산	12
3.1.2 DNA 컴퓨팅의 속성	17
3.1.3 Version space learning with DNA molecules	18
3.2 기억기반학습	21
3.3 DNA 분자를 이용한 기억기반학습	23
3.3.1 모형의 구조	23
3.3.2 DNA 가닥의 부호화	25
4. 응용: 기억기반 의사결정지원시스템	28
4.1 의사결정	28
4.2 의사결정지원시스템	30
4.2.1 계층 분석 과정	31
4.3 기억기반 의사결정지원시스템	35
5. 실험 및 결과	37
5.1 CoIL Challenge 2000 데이터	37
5.1.1 CoIL Challenge 2000에서 과제	37
5.1.2 기억기반 의사결정지원시스템에서 과제	39
5.2 시뮬레이션	41
5.2.1 변수 정의하기	42
5.2.2 시뮬레이션	43
5.3 시뮬레이션의 결과	46
5.3.1 기억기반 의사결정지원시스템의 알고리즘의 정당성 ...	46

5.3.2 기억기반 의사결정지원시스템의 알고리즘의 복잡도 ...	49
5.3.2 기억기반 의사결정지원시스템의 수행의 정확성	50
6. 결론	52
참고문헌	55
Abstracts	60
감사의 글	61

그림목차

그림 1: 뉴런에서 내성의 가설적인 단계	6
그림 2: 화학적 시냅스와 화학적 시냅스에서 발생하는 학습 과정 모델의 모식도.....	9
그림 3: DNA computing의 개념도.....	10
그림 4: DNA 구조.....	11
그림 5: Ligation	14
그림 6: Polymerase extension	15
그림 7: 유전자 증폭 기술 (PCR)	17
그림 8: 버전 스페이스를 유지하는 절차	19
그림 9: 범주화 과정	20
그림 10: CoIL Challenge 2000 데이터를 이용한 기억기반 학습의 기본 개념도.....	22
그림 11: 화학적 시냅스에서 일어나는 학습 과정 모델의 모식도.....	24
그림 12: DNA 분자를 이용하여 시냅스 가소성이 일어나는 과정을 구현	26
그림 13: 출력반응장치에서 관찰되는 이중 DNA 가닥.....	27
그림 14: 이상적인 의사결정과정.....	29
그림 15: AHP의 장점	34
그림 16: 시뮬레이션을 위한 순서도	42
그림 17: hybridization의 가능성 상수, k_t	43
그림 18: 실험 방법을 고려한 시뮬레이션 상에서 분자농도의 조절과 표준화	44
그림 19: 시뮬레이션에서 단위시간당 진행되는 반응	45
그림 20: 알고리즘의 안정성	47

표목차

표 1: 두 개 요인간의 쌍대 비교	33
표 2: CoIL Challenge 2000의 결과	38
표 3: 시뮬레이션을 위한 CoIL Challenge 2000 데이터	40
표 4: 도메인	41
표 5: 수행의 정확성	51

1. 서론

인간의 지적 과정 중 하나인 기억과 학습은 밀접한 관계에 있다. 기억이 존재함으로써 학습이 성립되고 학습을 통해 기억이 완성되기 때문이다. 그러나 기존의 심리학에서는 학습과 기억을 다른 범주로 나누어 다루었다. 학습은 행동심리학의 주된 관심 대상이었고 기억은 인지심리학의 주된 연구 대상이었다.

분자생물학이 발달하면서 기억과 학습을 세포단위나 분자단위로 설명하기 시작했다. 대표적인 설명이 “시냅스 가소성(synaptic plasticity)”이다. 시냅스 가소성은 신경회로망의 변화로서 경험적이거나 환경적인 요인에 의한 학습과 기억의 신경생리학적인 표상(representation)이다.

뇌는 인간이 환경에 적응하기 위해서 정보처리를 하는 기관이다. 그러므로 시냅스 가소성과 같은 뇌의 속성을 연구하면 인간처럼 학습하고 추론할 수 있는 컴퓨터를 만들 수 있을 것이다. 그러나 이와 같은 기대를 충족시키기 위해 실리콘 메모리로 정보를 처리하는 기존의 컴퓨터는 많은 한계를 안고 있다. 한 예로 뇌의 가장 대표적인 정보처리 속성인 병렬성을 현재의 컴퓨터는 처리하지 못하고 있다. 그래서 제안된 대안적인 계산 매체가 분자컴퓨팅이다. 1994년에 Adleman은 Science에 발표된 그의 논문에서 DNA를 사용하여 컴퓨터 과학에서의 난제(NP-hard problem)¹ 중의 하나

¹ Non Polynomial-hard problem으로서 한정적인 접근방법(deterministic

인 해밀톤 경로문제를 분자생물학의 도구를 사용하여 초병렬적(massive parallel)으로 해결할 수 있음을 실험적으로 보임으로써 생물체의 DNA(deoxyribonucleic acid)의 상보성(complementarity)을 이용한 분자 컴퓨팅의 일종인 DNA 컴퓨팅이 알려지게 되었다[Zhang, 2002].

기존의 방법론을 통한 인지적인 문제와 계산적인 문제의 연구의 한계가 드러나면서 분자컴퓨팅에 거는 기대가 커지고 있다. 계산적인 문제에 있어서 앞에서 기술한 바와 같이 난제의 해결에 초병렬적인 분자컴퓨팅을 적극적으로 응용하고 있다. 그리고 인지적인 문제에 있어서는 논리적으로 설명하기 어려운 사고나 감정의 문제를 환원적인(reductive) 사고²로 해결할 수 있다고 기대하고 있다. 환원적인 사고는 생체 내의 분자가 정신작용을 조정하는 것처럼 인공적으로 분자를 조작하면 근접하게 인지과정을 구현할 수 있을 것이라는 생각이다. 다시 말해서, 대안적인 계산방식인 분자의 상호작용에 의해 정신작용이 해석될 수 있다는 생각이다.

고통이라는 감각자극을 수용하고 전달하는 엔케팔린 경로(enkephalin pathway)가 존재하는 화학적 시냅스에서 발생하는 내성(tolerance)이 본 연구의 시작점이다[Vander, Sherman, and Luciano, 1994]. 내재적인 아편체가 관여하는 화학적 시냅스에서 발생하는 내성은 시냅스의 화학적인 성

approaches)으로 해결할 수 없는 문제를 일컫는다. 대표적인 문제로 TSP (Travelling Salesperson Problem: 가장 짧은 여행거리로 N개의 도시를 한번씩만 방문하고 출발점으로 돌아오기 위한 경로를 찾는 문제)가 있다.
² 환원주의(reductionism)와 차별적인 개념이다. 학제적인 연구에서 거론되고 있는 개념인 ‘이론간 환원성(theoretical reduction)’에서 비롯되었다.

질을 상당 기간동안 변화시킨다[Kandel et al., 2000]. 이 과정에 존재하는 피드백 현상은 시냅스후 신경말단과 시냅스전 신경말단 사이의 정보전달 역할을 한다. 이와 같이 화학적 시냅스에서 발생하는 내성의 과정은 자극을 처리하고 저장하므로 학습 현상이다. 요약하자면 화학적 시냅스에서 일어나는 내성의 과정은 학습 현상이고 내성의 결과 시냅스 가소성이 일어난다.

화학적 시냅스에서 일어나는 학습 과정의 주요한 매개체인 신경전달물질이 시냅스 가소성을 일으키므로 인공적으로 조작할 수 있는 분자인 DNA를 이용하면 시냅스 가소성의 과정을 구현할 수 있을 것이라는 환원적인 사고의 분자컴퓨팅에서 본 논문이 비롯되었다.

DNA 컴퓨팅은 현재 연구 초기이므로 앞의 기대와 같은 고차원의 문제를 당장 해결할 수는 없다. 본 논문에서는 우선 DNA 컴퓨팅의 가능성을 알아보기 위한 간단한 인지적인 문제를 다룰 것이다. 그래서 기존의 기계 학습 중 시냅스 가소성의 과정과 가장 근접한 기억기반 학습의 개념을 도입하여 간단한 의사결정 모델을 통해 화학적 시냅스에서 일어나는 학습 과정을 DNA 컴퓨팅으로 구현하고자 한다.

이 논문의 구성은 다음과 같다. 2장에서는 본 연구의 배경이 되는 내성과 시냅스 가소성에 대해 살펴 본다. 3장에서는 방법론의 핵심이 되는 DNA 컴퓨팅과 기억기반 학습을 살펴보고 기억기반 학습의 분자적인 구현과 시뮬레이션을 위한 모형의 구조와 DNA 가닥의 부호화(encoding)에 관

한 아이디어를 소개한다. 4장에서는 본 연구에 사용한 실제 데이터를 소개하고 구현 알고리즘을 제시한다. 5장에서는 4장의 알고리즘을 시뮬레이션한 후 결과를 통해 알고리즘의 정당성(correctness)과 복잡도(time complexity)를 검증하고 수행의 정확성을 평가한다. 6장에서는 본 연구의 내용을 요약하고 의의 및 문제점을 설명하며 결론짓는다.

2. 시냅스 가소성 (Synaptic Plasticity)

2.1 내성의 단계 (Steps of tolerance)

내성은 행복감을 유발하는 약용량에 급진적으로 적응하는 생체의 현상이다. 투여한 약물 때문에 행복감이 높아지면 높아진 행복감을 동일하게 느끼기 위해서 더 많은 약용량이 필요하다. 이와 같이 약물 때문에 유도된 양의 강화(positive reinforcement) 현상은 다행증(euphoria)의 유발을 뒷받침한다[Kandel et al., 2000].

내성이 이와 같이 약용량에 의존하는 이유는 약물 투여 시 체내에서 그 약물과 경쟁적으로 작용하는 신경전달물질을 퇴화 시키는 효소의 합성을 자극하기 때문이다. 약물의 농도가 높아질수록 신경전달물질을 퇴화 시키는 효소의 농도도 증가한다. 따라서 처음 투여할 때와 동일한 효과를 위해서는 나중에 요구되는 약물의 혈장 농도가 점점 커진다. 이와 같은 피드백 과정을 통해 양의 강화 현상이 발생하게 된다. 그러므로 내성의 단계에서 발생하는 피드백은 양의 피드백³이다. 다시 말해서, 내성의 단계에서는 정상적인 신경전달물질에 의한 효과에 약물의 효과가 더해짐으로써 반응이 증가하게 되고 양의 피드백 기전에 의해 내재적인 신경전달물질의 방출이

³ 피드백에는 두 가지 종류가 있다. 양의 피드백(positive feedback)과 음의 피드백(negative feedback)이 그것이다. 양의 피드백은 현상의 진행방향으로 성질이 증가하는 현상이다. 증가는 증가를 일으키고 감소는 감소를 일으킨다. 음의 피드백은 항상성의 메커니즘으로 증가는 감소를 일으키고 감소는 증가를 일으켜 일정한 수준을 유지시킨다

감소하게 된다.

내제적인 아편제(endogenous opiates)인 엔케팔린(enkephalin)과 모르핀(morphine)을 이용해 내성의 절차를 설명하면 다음과 같다. 엔케팔린은 지속적으로 최소농도만큼 방출되고 신경단위(neuron)의 신경전달물질로서 쓰인다. 따라서 그 수용체는 항상 자극의 일정한 양만큼 노출되어 있다. 그




그림 1. 뉴런에서 내성의 가설적인 단계 . A. 모르핀 투여전: 수용체의 50%가 활성화 됨. B. 모르핀 투여; 모든 수용체의 활성화; 진정-홍분 효과의 수준이 높아짐; 엔케팔린을 생산하는 뉴런에 억제 피드백을 일으킴. C. 따라서, 이전보다 적은 엔케팔린이 방출됨; 수용체의 50%가 활성화됨; 진정-홍분 효과 감소. D. 모르핀 과량 투여; 모든 수용체의 활성화; 진정-홍분 효과의 수준이 높아짐; 엔케팔린을 생산하는 뉴런이 억제됨 [Vander, Sherman, and Luciano, 1994].

러나 모르핀이 투여되면 엔케팔린에 의해 아직 결합이 일어나지 않은 수용체에 모르핀이 결합하여 엔케팔린 경로의 진정-흥분 효과 (analgesic - euphorogenic effects)는 증가한다. 그리고 엔케팔린 수용체의 일정한 노출량을 넘었으므로 시냅스전 신경단위에 피드백 시스템이 작용하여 엔케팔린을 퇴화시키는 효소의 농도를 증가한다. 그 결과 엔케팔린의 합성과 방출이 감소하게 된다. 더 이상 필요량의 엔케팔린을 받지 못하는 시냅스후 신경 수용체는 더 많은 모르핀을 받아들이게 된다[Vander, Sherman, and Luciano, 1994]. 다시 말해서, 고통을 경감시키기 위한 반복적인 모르핀의 투여는 약물의 효과에 대한 저항력(resistance)을 증가시키고 그 결과 동일한 진정 효과를 얻기 위해서 급진적으로 고용량의 약물, 즉 모르핀이 필요하게 된다[Kandel et al., 2000].

2.2 시냅스 가소성

내성의 단계에서 고통이라는 감각자극에 대해 형성되어 있던 시냅스의 화학적인 속성이 모르핀의 투여로 변한다. 진정-흥분 효과에 필요한 역치가 증가하게 되고 내재적인 엔케팔린의 합성과 방출은 감소한다. 이 과정을 심리학적인 관점으로 해석하면 기존의 감각자극에 대해 형성되어 있던 기억이 새로운 환경 요인으로 인해서 학습되어 변한 것이다.

이와 같이 외부 자극에 반응해서 시냅스의 물리적이거나 화학적인 속성이 변화하는 과정이 시냅스 가소성이다. 다시 말해서, 시냅스 가소성은 학

습이나 기억과 같은 경험적이거나 환경적인 요인에 의해서 시냅스가 기능적으로나 구조적으로 재구성되는 현상이다.

분자생물학적으로 시냅스 가소성이 장기기억 형성에 관여함이 밝혀졌다. 상당한 시간동안 지속되는 정보전달 처리과정인 Long-term potentiation (LTP)이 시냅스 가소성의 한 모형으로서 연구되어 왔다[Kandel et al., 2000].

2.3 화학적 시냅스의 학습 과정

시냅스 가소성이라는 개념만으로도 분자 단위의 기억과 학습을 설명할 수 있다. 그러나 분자컴퓨팅으로 구현하기 용이하게 하기 위해서 시냅스의 가소성이라는 현상이 진행되는 과정에 초점을 맞췄다. 시냅스 가소성의 결과는 엄격하게 말해서 기억에 해당한다. 그에 반해서 시냅스 가소성이 진행되는 과정을 학습이라고 구분할 수 있다. 왜냐하면 가소성이 진행되는 과정에서 정보가 처리되고 갱신되기 때문이다.

정보를 처리하고 갱신하는 핵심적인 기제는 피드백이다. 학습을 정보처리 과정으로 보았을 때 시냅스 가소성이 진행 중인 화학적 시냅스는 학습을 수행한다고 간주할 수 있다. 그래서 본 논문에서는 시냅스 가소성을 진행시키는 핵심 매개체인 신경전달물질과 핵심 기제인 피드백을 화학적 시냅스의 학습 과정의 핵심 개념으로 가정했다.




그림 2. 화학적 시냅스와 화학적 시냅스에서 발생하는 학습 과정 모델의 모식도

그림 2는 화학적 시냅스와 시냅스 가소성이 일어나는 과정을 모식적으로 구현한 그림이다. 왼쪽 그림은 생체내에 존재하는 화학적 시냅스에서 발생하는 학습 과정에 관여하는 신경전달물질과 피드백 기제를 보여주고 있다. 오른쪽 그림은 왼쪽 그림을 분자컴퓨팅으로 모델링하기 위해서 모식적으로 옮겨놓은 개념도이다.

3. DNA 컴퓨팅에 의한 기억기반 학습 (Memory-Based Learning Using DNA Computing)

3.1 DNA 컴퓨팅

분자 혹은 양자 컴퓨터가 최근 튜링머신(Turing machine) [Beaver, 1995; Rothmund, 1996], 논리회로 (Boolean circuits)[Boneh, Dunworth, and Shall, 1995] 등과 같은 전형적인 모델의 대안으로 고려되고 있다. Shor는 양자컴퓨터가 거대한 수를 인수분해할 수 있고 이산 대수(discrete logarithms)를 다항식을 계산하는 시간(polynomial time)에 풀 수 있음을 보였다. Adleman은 NP-완전 해밀톤 경로문제를 풀 수 있는 분자 “컴퓨터”를 제안했다. 대략적으로 구조화한 DNA 조각의 재조합을 통해 문제의




그림 3. DNA computing의 개념도 [2]

해법을 제시한 경우도 있다[Beaver, 1995]. 이와 같은 새로운 대안인 DNA 컴퓨팅이라는 방법론은 본 논문에서 간단한 의사결정모형을 효율적으로 구현할 수 있게 하는 비중 있는 도구이다.

전통적인 컴퓨터 프로그램은 문제를 바이트(bits)로 표현하고 그 문제를 실리콘으로 만들어진 전자 컴퓨터를 이용하여 해결한다. 반면에 DNA 컴퓨팅은 문제를 DNA 분자들로 표상하고 생물학적인 실험실 기술로 문제를 풀어낸다[Shin, Zhang, and Jun, 1999]. DNA는 염기(base)와 당(sugar)과 인(phosphate molecule)으로 이루어져 있다. 이중 당과 인은 DNA의 뼈대(backbone)를 형성하고 당과 염기를 합쳐 뉴클레오타이드(nucleotide)라고 명명한다. 핵산의 구성 성분인 뉴클레오타이드는 아데닌(A: Adenine), 티




그림 4. DNA 구조. DNA의 네개의 질소함유 염기들은 당-인산 뼈대를 따라 특별한 순서(DNA sequence)로 정렬되어 있다. 그리고 하나의 유기체에 대해 모든 유전적인 지시를 부호화 하고 있다. 아데닌(A)과 티아민(T), 사이토신(C)과 구아닌(G)이 쌍을 이룬다. DNA 가닥들은 염기사이의 약한 결합으로 연결되어 있다. 하나의 유전자는 DNA 분자의 조각이다. 유전자는 고유한 염색체의 특정한 자리에 위치하고 단백질 합성을 위한 필수 정보를 포함하고 있다.

민(T: Thymine), 사이토신(C: Cytosine), 구아닌(G: Guanine)의 4 가지 유형으로 나눌 수 있다. DNA 컴퓨팅에 이용하는 생물학적인 기술로는 hybridization, ligation, polymerase chain reaction(PCR), 겔 전기영동(gel electrophoresis) 등 여러 가지가 있다.

계산에 DNA 분자를 최초로 사용한 사람은 Adleman이다. 그는 DNA 가닥을 annealing하여 해밀턴경로 문제(Hamiltonian path problem, HPP)의 해를 계산했다[Adleman, 1994]. Adleman은 분자들의 상호작용을 계산현상으로 가정하였다. 그리고 DNA의 서열 친화적인(sequence-specific) 결합(binding)은 시험관 안에서 초병렬적인 계산을 수행할 수 있게 할 것이라고 가정했다. 이와 같은 가정 하에 구상된 모형은 그럴싸했지만 구현은 서툴렀다. 아마도 새로운 분야의 첫 디딤이기 때문일 것이다[Maley, 1998].

3.1.1 DNA 컴퓨팅의 연산

DNA는 계산을 위해 다양한 방식으로 이용되었다(예: 튜링머신 (Turing machine: D. Beaver, 1995; P. W. K. Rothmund, 1996), 셀룰라 오토마타 (blocked cellular automata: E. Winfree, 1996), 불리언 회로 (Boolean circuit: D. Boneh, C. Dunworth, and J. Shall, 1995), 유형-0 촘스키 문법 (type-0 Chomsky grammars: Csuhaj-Varjú et al., 1996)). 이와 같은 많은 시도들은 DNA를 이용해서 유용한 계산을 수행하기 위한 좀 더 나은

기술들을 정착시키는 것이 어렵고 여전히 방법들을 찾고 있다는 증거이다. 위의 각각의 모형에서 DNA를 다루기 위해서 사용된 비교적 실현 가능하고 유용한 연산자들을 찾아 볼 수 있다. 여러 가지의 기본적인 조작들은 고차원적인 조작인 유전자증폭기술(PCR)과 결합되어 DNA 컴퓨팅을 완성한다. 우선 기본적인 연산들부터 살펴보자[Maley, 1998].

annealing DNA 컴퓨팅에서 가장 기본적인 연산이다. 단일 가닥(이하 ssDNA)의 상보적인 DNA는 용액에 퍼져있을 때 자연적으로 두 가닥의 DNA(이하 dsDNA)를 형성할 것이다. 이와 같은 반응은 상보적인 염기쌍이 가까워졌을 때 수소결합(hydrogen bond)을 형성함으로써 발생한다. 이 과정은 “hybridization”이라고도 불려진다.

melting annealing의 역(逆) 연산자이다. dsDNA를 ssDNA로 분리하는 과정이다. 용액에 함축되어 있듯이 용해는 DNA의 상당히 긴 dsDNA가 안정한 온도 이하까지 가온함으로써 진행된다. 가닥 사이의 수소결합은 연결되어 있는 뉴클레오타이드의 공유 결합보다 약하기 때문에 열을 가함으로써 뉴클레오타이드의 서열을 깨지 않고도 dsDNA를 ssDNA로 분리할 수 있다. 낮은 농도의 염분용액도 DNA 사이의 수소결합을 불안정하게 하여 두 개의 ssDNA로 분리한다. 가열방법은 긴 dsDNA의 서열은 그대로 나두고 짧은 것들만을 분리할 때 선택적으로 이용될 수 있다.

ligation annealing 연산 이후 수행되는 경우가 대부분이지만 ligation 은 DNA 가닥들을 서로 연결시키는 연산이다. 효소(ligase enzyme)로 부유(浮游)하는 두 가닥의 DNA를 연쇄적으로 연결시킬 수 있을지라도 단일 가닥들을 함께 가열하여 ligation하는 연산에 훨씬 효과적이다. 이처럼 ssDNA의 조각들(fragments)을 일렬로 연결할 뿐만 아니라 인접한 조각들의 공유 결합을 봉하는 데에도 효소가 이용된다.




그림 5. Ligation. 가닥 x에 가닥 y을 연결하기 위해서 “접착 가닥(glue strand)”가 필요하다. 접착 가닥과 x, y 각각이 annealing하여 두 가닥을 접근시키기 위해서이다. 이후에 ligase 효소가 두 가닥을 융화시켜서 하나로 잇는다 [Maley, 1998].

polymerase extension DNA와 RNA의 형성에 촉매 작용을 하는 효소인 중합효소는 긴 ssDNA에 annealing하기 위해 결합한 짧은 ssDNA (primer)의 3'에 붙는다. 그 다음에 긴 가닥에 상보적인 서열을 만들어 낼 만큼 짧은 가닥의 3'쪽을 확장 시킨다.

cutting 제한효소는 특정한 서열이 있는 부분에서 DNA 가닥을 절단한다. 1993년까지 200개 이상의 다른 서열에 친화적인 2,300여 개의 제한효소가 발견되었다. 이와 같은 서열들은 대개 4개에서 8개의 뉴클레오타이드를 포함한다. 어떤 제한효소들은 오직 ssDNA만을 절단하는 반면에 다른 제한효소들은 dsDNA만을 절단할 것이다. 비슷하게 DNA 가닥의 사이토신 뉴클레오타이드의 메틸화는 일부 제한효소들의 활성화




그림 6. Polymerase extension. 짧은 primer의 3'에 중합효소가 부착한 후 긴 서열(x)에 상보적인 서열을 만든다 [Maley, 1998].

을 저해한다. 게다가 어떤 제한효소들은 DNA의 상당히 넓은 부위의 서열을 인식하고 절단한다. 즉 효소 활성의 친화성은 제한효소의 종류에 따라 매우 다양하다.

destroying 가닥들의 일부분은 체계적으로 소멸될 수 있다. 다시 말해서 ssDNA 혹은 dsDNA의 뉴클레오타이드를 우선적으로 파괴해버리는 효소에 의해 “소화”될 수 있다.

merging 두 개의 시험관은 하나의 시험관의 용액을 다른 시험관에 흘러 넣어 합해질 수 있다.

separating by length DNA가 담겨져 있는 시험관이 주어졌을 때 그 내용물을 두 개의 시험관에 쪼개 넣는다. 이 때 하나는 특정 길이의 가닥들로만 채우고 나머지는 그 이외의 가닥들로 채운다. 이와 같은 가닥들의 분리는 겔 전기영동으로 할 수 있다. 겔 전기영동에서 염색이나 방사선원소에 의한 꼬리표(radioactive tagging)로 식별된 각기 다른 길이의 가닥들은 겔에서 추출될 수 있어야 한다.

이와 같은 기본적인 연산 조작에 고차원적 연산인 PCR을 더하여 Adleman은 최초의 DNA 컴퓨팅을 완성했다. 유전자증폭기술은 결합한 두 가닥의 DNA의 복제본을 다량으로 만들어내는 기술이다. 원하는 DNA 서열의 시작과 끝을 표시하는 primer를 기준으로 중합효소를 이용하여 복제한다. 최초의 DNA 컴퓨팅은 PCR을 이용하여 원하는 결과를 관독했지만




그림 7. 유전자 증폭 기술 (PCR)는 3단계의 주기로 진행된다 [Maley, 1998].

최근의 연구들은 PCR의 단계 없이도 결과를 판독하고 있다[Winfrey, 1996; Csuhaaj-Varjú et al., 1996].

3.1.2 DNA 컴퓨팅의 속성

현재로서 생물학적 조작 기술이 알고리즘에 비해 많이 뒤떨어져있다. 그러나 DNA 컴퓨팅의 최대 장점이 초병렬성은 기존의 실리콘 컴퓨터를 앞지를 수 있는 가능성을 보여준다. 초병렬성이 실용화된다면 초병렬적 계산

의 시간은 실시간($O(1)$)이 되므로 매우 빠르게 결과를 얻을 수 있다. 그리고 DNA는 매우 큰 정보 저장 능력이 있다. 즉, 정보 밀도가 1리터의 용액에 10^{20} 개의 가닥을 수용할 수 있을 만큼 거대하다. 이 와 같은 정보량은 현 하드디스크 기술의 5배에 해당하는 능력으로 매우 큰 문제 공간을 실시간에 탐색할 수 있게 한다. 또 DNA는 생체 구성물로서 annealing의 반응시 실제로 에너지를 방출하기 때문에 DNA 컴퓨팅을 할 경우 기존 컴퓨터보다 적은 에너지가 필요할 것이라는 기대가 있다[Maley, 1998].

그러나 이와 같은 장래성에도 불구하고 현재의 DNA 컴퓨팅은 기술 상 많은 어려움이 있다. 그 중 하나가 정확성(accuracy)의 문제이다. 양성 반응에 오류가 나타날 수 있다. 현행 생물학적 실험실 기술은 hybridization의 부적당한 짝이나 추출의 오류와 같은 실수의 가능성이 다분하다. 또 다른 문제는 실험 비용이 상당하다는 점이다. 현재 이 두 가지의 문제점들은 DNA 코드와 실험 조건을 최적화하기 위해 DNA 컴퓨팅을 시뮬레이션 하는 소프트웨어 툴(tool)을 통해 해소하고 있다[Shin, Zhang, and Jun, 1999].

3.1.3 Version space learning with DNA molecules

기계학습의 가장 기초적인 개념학습 방법 가운데 버전 스페이스 학습(version space learning)이 있는데 이는 학습 데이터와 모순되지 않는 모든 가설들을 탐색해 나가면서 목표 개념에 해당하는 가설을 찾아내는 학습

방법이다. 가설의 형태가 각 요인값들에 대한 제한 조건들의 결합 (conjunction)으로 표현될 수 있다는 가정을 하여 탐색공간의 크기에 제한을 두지만 여전히 그 크기가 요인의 크기에 따라 지수적으로 증가하는 한계를 가지고 있다. 이러한 한계를 초병렬성과 무수히 많은 DNA 분자를 이용하여 극복하는 방법을 제안하였다. DNA 분자들을 이용하여 각각의 요인들과 가설들을 표현하였으며 초기 가설공간의 생성방법과 학습 과정에 따라 이 가설공간을 유지, 갱신하는 방법을 구현하였다. 이러한 과정은 학습 과정이 집합연산으로 이루어질 수 있음에 바탕을 두어 기본적인 집합 연산인 교집합(intersection)과 차집합(difference)을 이용하여 구현되었다. 다시 말해서 학습 데이터가 주어질 때마다 현재의 학습 데이터와 모순되지




그림 8. 버전 스페이스를 유지하는 절차. 버전 스페이스 학습은 일관성 없는 가설을 제거함으로써 버전 스페이스를 재정의하고 학습의 예를 탐색하는 과정이다 [Lim, Yun, Jang, Chai, Yoo, and Zhang, 2002]

않는 가설들만을 골라내는 과정을 반복해 나가는 것이다. 또한 현재의 버전 스페이스를 사용하여 답을 모르는 예가 과연 해당 개념에 속하는지 여부를 예측할 수 있는 방법을 제안하였다. [Lim, Yun, Jang, Chai, Yoo, and Zhang, 2002].

예를 들어, “An office that has belonging to an faculty”라는 개념을 department, status, floor라는 3개의 요인으로 가설 공간을 가정하고 각각의 요인에 대해 cs or ee, faculty or staff, four or five와 고려 제외한 경우에 해당하는 9개의 값을 가지는 학습 대상을 9개의 DNA 가닥으로 기호화하고 각 가닥마다 검출을 위해서 자성 구슬(magnetic beads)과 연결하였다. 주어진 예제들을 긍정적인 경우와 부정적인 경우로 나누어 상보적인




그림 9. 범주화 과정. 교집합과 차집합은 독립적으로 수행된다. 남아 있는 분자들은 DNA 분자의 형광 강도에 의해 비교된다. 따라서 대다수를 차지하는 이 분리된다 [Lim, Yun, Jang, Chai, Yoo, and Zhang, 2002].

순서쌍이 결합한 DNA 가닥들만을 검출하였다. 이 두 과정은 각각 진행되며 최종 결과들을 비교하여 주어진 예제가 부정적인지 긍정적인지를 분류해내었다 (그림 9).

요인이 지수적으로 증가하는 경우의 수를 비교적 간단한 알고리즘으로 선형적인 경우의 수로 변형시킬 수 있음을 시사하는 연구 결과이다. 이와 같은 결과는 DNA의 초병렬성 때문에 가능하다고 할 수 있다.

3.2 기억기반 학습 (Memory-based learning)

사례기반학습(case-based learning)이라고도 한다. 기존의 사례에 근거해서 새로운 사례를 판단하여 범주화하거나 분류하는 학습방법이다. 다시 말해서 유사한 사례로 새로운 문제의 사례를 범주화하는 알고리즘이다. 처음 훈련자료로 학습시킬 때 시간이 오래 걸리지만 일단 사례학습이 끝나면 그 다음부터 주어지는 새로운 사례에 대해서는 매우 우수한 학습효율을 보여준다. 이런 학습 현상을 lazy learning이라고 한다. 이 알고리즘에서 사례들은 논리적이고 상징적인 기술로 표상된다[Mitchell, 1997].

기존 사례를 학습한 기반으로 새로운 문제 사례를 범주화하는 학습방식은 외부 자극에 대해 단기 혹은 장기 기억을 형성하여 그 기억을 바탕으로 새로운 외부 자극을 받아들이고 반응하는 인간의 환경에 대한 상호작용 절차와 흡사하다. 그리고 문제의 대상을 분자단위로 낮춰 잡아 볼 때도 화학적 시냅스에서 일어나는 학습 과정이 기억기반 학습 알고리즘과 유사함을

알 수 있다. 시냅스후 신경말단에 포진되어 있는 수많은 수용체들은 시냅스전 신경말단에서 유리된 신경전달물질들과 결합할 때 정보를 얻어 전달할 수 있다. 이 과정에서 신경전달물질들은 최소한의 정보만 가지고 있는 질문자에 해당하고 수용체는 질문자와 결합해서 최종의 해를 생산하는 저장된 기존 사례와 동등한 위치임을 유추할 수 있다. 이와 같이 분자망에서 발생하는 일련의 학습 과정을 개념적으로 단순화할 수 있다. 여기서 한 단계 더 나아가 DNA 컴퓨팅과 연결해 보자. 질문자에 해당하는 신경전달물질 분자 하나가 가지는 정보들은 DNA 가닥 하나에 부호화될 수 있다. 뿐만 아니라 수용체들이 가지고 있는 정보들도 마찬가지이다. 신경전달물질들과 수용체의 결합은 질문자와 저장된 각각의 DNA 가닥들의 수소결합과

A. Concept: Attributes

Education level	# of cars	Income	Avg income	Purchasing power class	Contribution car policies	Contribution fire policies	# of car policies	# of fire policies
-----------------	-----------	--------	------------	------------------------	---------------------------	----------------------------	-------------------	--------------------

B. Instance: Values

244	702	25300	3	4	6	0	1	3
-----	-----	-------	---	---	---	---	---	---

C. Encoding ssDNA sequence: Attribute – value pair

Education level	# of cars	Income	Avg income	Purchasing power class	Contribution car policies	Contribution fire policies	# of car policies	# of fire policies
244	702	25300	3	4	6	0	1	3

그림 10. CoIL Challenge 2000 데이터를 이용한 기억기반 학습의 기본 개념도

유사하다. 이와 같은 유사성은 통해 분자망의 시냅스 학습을 DNA 컴퓨팅을 통해 구현할 수 있는 동기를 부여했다. **Figure 10.**에서 보여지는 개념도는 기억기반 학습을 DNA 컴퓨팅으로 시뮬레이션 할 수 있음을 보여준다. 기억기반 학습의 개념과 개별 사례는 DNA 컴퓨팅에서 요인과 값에 해당한다. 기억기반 학습에서 가장 포괄적인 개념을 기본으로 개별 사례를 기존 사례와 비교하여 범주화 하듯이 DNA 컴퓨팅에서 상위개념인 요인을 기본으로 요인값을 기존 요인의 값들과 비교하여 판단한다. 이와 같은 계층적인 요인-값의 짝짓기는 DNA 컴퓨팅에서 문제의 질문자로 주어지는 DNA 가닥의 부호화의 동기가 될 수 있다.

3.3 DNA 분자를 이용한 기억기반 학습

이 절에서는 본 연구를 통해 구현할 모형을 개략적으로 살펴 볼 것이다. 우선 모형의 구조를 살펴보고 데이터를 저장하는 ssDNA를 어떻게 부호화할 것인가를 기술할 것이다.

3.3.1 모형의 구조

입력과 출력, 연산의 반응장치를 기본 뼈대로 출력값의 정확도 따라 연산 반응장치의 기존 경우의 ssDNA들을 수정할 수 있는 피드백 경로가 있다. 이와 같은 모형을 도식화하면 **그림 11**과 같다. 그림의 값들은 본 논문의 시뮬레이션에서 사용한 실험 수치들이다.

연산 반응장치에는 모든 종류의 기존 데이터들의 요인값들을 복수개로 부호화하여 저장한다. 이처럼 기존 요인값들을 연산 반응장치에 저장하는 학습법이 기억기반 학습이다. 요인값의 실제 값을 저장하는 것이 아니고 ssDNA에 부호화하여 저장하므로 사례기반 학습이라고도 할 수 있다.

입력 반응장치에 한종류이지만 여러 개의 질문자를 ssDNA으로 부여하면 연산 반응장치의 기존 경우들과 반응하여 출력 반응장치에 해가 출력된다. 출력된 해들이 긍정적인 경우가 더 많으면 입력했던 질문자를 긍정 경우로 분류하고 해들이 부정일 경우는 부정으로 분류한다. 그리고 긍정과 부정 중 사용자가 원하는 경우에 해당하는 기존경우를 증폭시켜 연산 반응




그림 11. 화학적 시냅스에서 일어나는 학습 과정 모델의 모식도

장치에 저장한다. 이 과정이 양의 피드백이다. 이상은 개략적인 모형의 구조이고 구체적인 모형은 다음 절에서 설명할 것이다.

이 모형을 화학적 시냅스에 관련시켜 설명하면 다음과 같다. 입력하는 질문자들은 신경전달물질에 해당하고 저장되어 있는 기존 경우들은 시냅스 후 신경의 수용체와 같다. 그리고 출력된 해들은 활동전위를 발생시키기 위한 2차 전달자를 흥분 시키는 리간드-수용체 결합체(ligand-receptor complex)에 해당한다. 즉, 본 연구의 모형은 화학적 시냅스에 존재하는 외부 자극 혹은 선행 전기자극과 이웃 뉴런으로 자극 신호를 전달하는 활동전위 등이 생략되어 있다.

3.3.2 DNA 가닥의 부호화

그림 11은 시냅스 가소성이 일어나는 과정을 DNA 컴퓨팅으로 구현할 수 있도록 개념화 한 도식화이다. 반면에 **그림 12**는 실제 실험과 시뮬레이션을 위한 모형의 구조이다. **그림 11**에서는 요인값들을 DNA 가닥에 4종류의 염기(bases; A, T, C, G)를 이용하여 부호화하여 이용했기 때문에 기호적(symbolic)인 개념의 사례기반학습에 비유될 수 있었다. 그러나 실제 시뮬레이션과 구현을 위한 모형을 나타내는 **그림 12**는 요인값들이 DNA 가닥에 벡터 값으로 부호화되어 이용된다. 질문자는 기존 경우의 요인값과 상보적인 서열로 부호화($\bar{X}_q$)되고 연산 반응장치의 DNA 가닥들은 요인값(X_n)과 판정값(Y_n)을 가지는 2차원의 벡터로 부호화된다.




그림 12. DNA 분자를 이용하여 시냅스 가소성이 일어나는 과정을 구현

부호화한 DNA 가닥을 확대한 그림이 그림 13이다. 모든 DNA 가닥들의 요인값의 부호화 순서는 동일하다. 왼쪽부터 시작하여 부호화하므로 요인을 따로 입력하지 않고 요인값들만 순서대로 서열화 한다. 요인값의 부호화가 끝나는 지점에 비활성 서열을 대입하고 계속해서 해의 값을 부호화한다. 그림 13는 출력 반응장치에서 볼 수 있는 hybridization 상태의 해이다.

DNA의 두 개의 염기쌍 중 C-G 쌍이 결합력이 더 강하다. 왜냐하면 A-T 쌍은 2중 수소결합을 하는 반면에 C-G 쌍은 3중 수소결합을 하기 때문이다. 따라서 DNA 서열에 C나 G가 많이 포함되어 있을수록 결합(hybridization)할 가능성이 높아진다. 그리고 DNA 가닥의 양끝(5'과 3')이




그림 13. 출력반응장치에서 관찰되는 이중 DNA 가닥

확실하게 hybridization되어야 dsDNA가 될 수 있다. 이와 같은 성질을 이용하여 요인들 중 해에 결정적인 요인을 제공하는 것들에는 C나 G의 염기가 많이 포함되고 ssDNA의 양끝에 위치하도록 부호화한다.

4. 응용: 기억기반 의사결정지원시스템

(Application: Memory-based Decision Support System)

4.1 의사결정

우리는 매일 당면하는 문제들에 관해서 의사를 결정해야 한다. 그래서 의사결정이 다소 복잡한 연구주제라는 생각이 처음에는 이상하게 느껴질 수 있다. 그러나 지금까지 연구 결과들을 통해 대부분의 사람들이 생각하는 것보다 의사결정을 잘 하지 못하고 있음을 알 수 있다[Harris, 1998]. 의사결정을 할 때 수반되는 요소들과 효과적인 기술들을 이해한다면 더 훌륭한 의사결정을 할 수 있을 것이다. 그래서 사람들은 수많은 의사결정지원시스템(Decision Support System, 이하 DSS)을 연구하고 개발해왔다.

의사결정의 속성으로 회귀성(recursive process)을 들 수 있다. 이는 비선형적인 속성에서 비롯된다. 대부분의 의사결정은 의사결정자가 진짜 원하는 목표에 도달할 수 있는 기준의 선택과 대안들의 확실성 사이에서 좌우되기 때문이다. 이용가치가 있는 대안들은 의사결정자가 도달하고자 하는 기준에 영향을 미친다. 마찬가지로 의사결정자가 세운 기준 또한 고려하고자 하는 대안들에 영향을 미친다. 그 외 의사결정은 불확실성(entropy)이 크고 환경과 다른 의사들의 맥락에서 결정해야 하는 제한성이 존재한다. 결국, 의사결정은 기준을 선택하고 대안을 확실히 한 후 최종선택을 할지 여부를 정하는 과정이다[Harris, 1998].

당면한 문제에 관한 해법은 여러 가지이므로 의사결정자는 여러 대안들 중에 하나를 선택해야 한다. 대안들의 질과 양은 중요도, 시간, 자질 등에 따라 조정되므로 의사결정의 가장 중요한 전략은 최적화(optimizing)와 만족이다. 더불어 만족감은 최대한으로 하고 불만족감은 최소로 할 수 있는 대안을 선택해야 바람직하고 이상적인 의사결정이 될 것이다.

앞서 기술한 의사결정의 회귀적 속성 때문에 의사결정의 절차들이 차례




Figure 14. 이상적인 의사결정과정. 의사결정자는 (1) 문제의 완벽한 정의, (2)모든 기준의 확인, (3) 선호도에 따른 기준의 가중치 선정, (4) 모든 가능한 대안 인식, (5) 각 기준에 근거한 각 대안의 점점, 마지막으로 (6) 계산 후 가장 높은 값의 대안 선택함을 가정한다. 참고로 실선은 선형적인 의사결정의 방향을, 점선은 의사결정과정 중의 피드백을, 굵은 점선은 각 의사결정 단계에서 직접적인 의사결정을 나타낸다 [Bazerman, 1998].

로 진행되는 동시에 각 단계들이 필요에 따라 다시 실행되어야 할 때도 있다[Harris, 1998].

Figure 14.과 같은 의사결정과정은 이미 기존 컴퓨터로 시스템화 되어 상품으로 나온 경우(4.2절 참고)도 많다. 하지만 많은 비용과 유동하는 환경에 유연성 있게 대처하지 못하는 단점때문에 단편적으로만 실용화되고 있는 실정이다. 이와 같이 의사결정지원시스템의 설계를 어렵게 하는 의사결정의 속성 중의 하나인 비선형성과 회귀성은 분자컴퓨팅의 초병렬성을 통해 해결될 수 있을 것이다.

4.2 의사결정지원시스템

DSS는 컴퓨터를 사용하여 정형화되지 않은 문제(semi-structured or unstructured problem)에 관해 의사결정자가 효과적인 의사결정을 할 수 있도록 지원하는 시스템이다. 의사결정지원 기법으로는 사례기반, 지식기반, 귀납적 학습, 신경회로망, 데이터마이닝, 유전 알고리즘, 에이전트 등과 같은 기계학습 알고리즘이 있다. DSS는 “정보를 제공하는 응용프로그램”으로 일상적인 업무 운영을 통해 데이터를 수집하는 등의 “운영 시스템”과는 구별되는 개체이다.

DSS에 빈번하게 활용되는 의사결정분석기법에는 의사결정나무(decision tree, 이하 DT)와 계층분석과정(analytic hierarchy process, 이하 AHP)이

있다. DT는 DecisionPro⁴ 라는 소프트웨어로 구현되어 있고 AHP는 Expert Choice⁵라는 소프트웨어로 출시되어 있다. DT는 동 시간대에 고려해야 할 요소가 한 가지인 반면에 AHP는 2개 이상의 요소들을 고려해서 의사결정을 내리는 기법이다. 그래서 AHP와 같은 의사결정분석기법을 다 요소 의사결정(multi attributes decision making, 이하 MADM)이라고 명명한다.

본 논문의 의사결정 문제는 동시에 여러 가지의 요소들을 고려해야 하기 때문에 AHP와 유사하다고 할 수 있다. 그래서 AHP에 대해 좀 더 알아보겠다.

4.2.1 계층 분석 과정 (Analytic hierarchy process, AHP)

AHP는 MADM 기법들 중 가장 널리 응용되고 있는 기법이다. 지금까지 유연 생산시스템을 비롯한 대규모 자동 생산시스템의 도입 타당성 분석, 각종 에너지 정책 수립, 수송 정책 수립 등 광범위한 분야에 응용되어 왔다. 그 이유로는 첫째, 분석 과정이 간단하다는 점을 들 수 있다. 요소나 대안의 중요도 평가 과정에서 쌍대 비교(pairwise comparison)를 함으로써 의사결정자의 선호정보를 얻기가 용이하기 때문이다. 둘째, 분석 과정의 특성상 정량적 요소와 정성적 요소를 동시에 고려하기가 용이하다는 점을

⁴ <http://www.vanguardsw.com>

⁵ <http://www.expertchoice.com>

들 수 있다. 특히, 정성적 요소에 대한 평가 결과를 정량화하거나 평가 결과를 표준화하는 과정을 거치지 않기 때문이다[김성희 외, 1999].

Saaty에 의해 AHP 기법의 4단계가 제안되었다[Saaty, 1980].

제 1단계: 의사결정문제의 의사결정 요소들간의 관계를 분석하여 계층 구조를 형성한다.

제 2단계: 각 계층내의 의사결정 요소들의 쌍대 비교를 통하여 계층별로 쌍대 비교 행렬을 구한다.

제 3단계: 쌍대 비교 행렬로부터 각 계층내의 의사결정 요소의 상대적 중요도를 계산한다.

제 4단계: 각 계층별로 얻어진 요소들의 중요도를 결합하여 대안들 사이의 중요도를 계산한다.

의사결정의 가장 일반적인 목표를 최상위 계층으로 두고 두 개 이상의 하위 계층을 통해 의사결정의 요소들을 살핀 다음에 최하위 계층에서 여러 가지 대안을 고려하는 구조이다. 이와 같은 구조가 완성되면 특정 계층 내에 있는 요소들의 중요도에 대한 의사결정자의 선호도를 평가한다. 쌍대 비교는 선호도 평가를 쉽게 하기위해 이용되는 평가 수단이다. 이와 같이 쌍대 비교를 하는 이유는 어느 한 요소 또는 대안에 대한 중요도를 절대적인 평가보다 두 개의 서로 다른 요소 또는 대안들의 중요도를 상대적으로 비교 평가하는 것이 용이하기 때문이다. 표 1은 두 요소의 쌍대 비교의 척도를 보여주고 있다.

표 1. 두 개의 요인 사이의 쌍대 비교

<i>Semantic scale</i>			<i>Numerical values</i>
	Equally important		1
	Weakly more important		3
A	Strongly more important	than(as) B	5
	Very strongly more important		7
	Absolutely more important		9

쌍대 비교를 통해 선호도를 평가하고 쌍대 비교 행렬을 얻은 후에는 각 행렬별로 요소들의 상대적인 중요도를 구한다. 이 때 산술 평균법, 기하 평균법, 최소 자승법, 고유 벡터법 등의 방법을 통해 중요도를 계산할 수 있다. 이와 같이 얻어진 요소들 사이의 중요도와 각 요소에 대한 대안들 사이의 중요도를 이용하여 대안들의 총중요도, 즉 만족도를 계산한다. 이와 같은 AHP의 장점들을 그림 15에서 보여준다.

이상과 같은 방법으로 진행되는 AHP는 Expert Choice(이하 EC)라는 의사결정지원시스템을 통해 구현되었다. EC는 사용방법이 간단하여 공공기관, 기업체 등 전세계적으로 널리 사용되고 있다. 구현 절차를 간단히 설명하면 다음과 같다[김성희 외, 1999]. 의사결정자는 의사결정문제를 정의하고 관련된 요소들을 입력해야 한다. 다음은 계층 구조내의 요소들에 대한 중요도 평가를 위해서 계층별로 쌍대 비교를 하도록 한다. EC에서는 의미 척도, 그래프 척도, 수치 척도 중 의사결정자가 선택한 척도에 따라 쌍대




그림 15. AHP의 장점 [1]

비교를 하도록 하고 있다. 쌍대 비교 행렬의 일치성 비율을 보여줌으로써 의사결정자로 하여금 자신의 판단에 대한 검토 과정을 거치도록 한다. 마지막으로 얻어진 쌍대 비교 행렬을 종합하여 대안의 최종적인 우선 순위와 중요도를 제시한다. EC는 사용하기에 편리한 사용자 인터페이스를 제공함으로써 전문가의 도움이 없이도 MADM 문제 해결 과정에서 쉽게 이용할 수 있도록 하고 있다.

4.3 기억기반 의사결정지원시스템 (Memory-based DSS)

DNA의 정보저장의 밀집성과 정보처리의 초병렬성을 이용하여 경험을 바탕으로 새로운 질문에 대해 의사결정자가 효율적인 의사결정을 내릴 수 있도록 도와주는 시스템이 기억기반 의사결정지원시스템이다.

기존의 DSS에 비해 알고리즘이 간단하여 이해하기 쉽고 처리과정 및 결과가 상당히 효율적이라는 점이 가장 큰 장점이다. 그리고 컴퓨터로 구현하면 비효율적이라서 구현이 거의 되지 않은 기억기반 학습 알고리즘이 DNA 컴퓨팅을 통해 매우 효율적인 시스템으로 모델링 되었다는 점에 의의가 있다. 3장의 3절에서 소개된 화학적 시냅스에서 일어나는 학습 과정을 구현한 알고리즘을 기반으로 의사결정 문제를 처리하는 모형이 기억기반 의사결정지원시스템이다.

기억기반 의사결정지원시스템의 구현 알고리즘을 다시 한번 소개하면 다음과 같다. 연산 반응장치에 저장되어 있는 ssDNA들에 기존의 정보들이 기억되어 있다. 입력 반응장치에 주어지는 DNA들은 질문자로서 연산 반응장치에 저장되어 있는 DNA들과 동일한 요인을 기억하고 있지만 목표값을 포함하고 있지 않다. 입력 반응장치와 연산 반응장치의 서로 다른 ssDNA들이 hybridization하여 생성된 dsDNA를 증폭시켜 검출한다. 검출한 dsDNA는 기존 정보를 닮고 있는 DNA로 더 많은 비율을 포함하고 있는 목표값으로 의사결정을 한다. 목표값의 비율과 실제 목표값과 의사결정지원시스템을 통한 목표값의 오류에 따라 피드백하여 연산 반응장치의 DNA

들을 업데이트한다. 이와 같은 피드백 과정을 거치는 것은 향후 높은 정확도의 목표값을 얻기 위해서이다.

5. 실험 및 결과

5.1 CoIL Challenge 2000 데이터

5.1.1 CoIL Challenge 2000에서 과제

CoIL Challenge 2000 데이터 집합은 The Insurance Company(TIC) Benchmark의 데이터로서 이동식 주택을 위한 보험(caravan policy)의 잠재 고객에 관한 정보로 이루어져 있다. 한 명의 고객에 대해서 전체 86개의 요인이 있고 그 중 43개가 고객의 우편 번호를 통해 알아낼 수 있는 사회 인구 통계 정보 (socio-demographic data, #1~43)이고 나머지는 이 보험 상품 구매와 관련된 보험 상품의 구매 정보(product ownership data, #44~86)이다. 이 중 목표요인은 마지막 86번의 이동식 주택을 위한 보험의 수(number of mobile home policies)로서 0과 1의 값을 가진다. 훈련 데이터는 5822명, 테스트 데이터는 4000명으로 이루어져 있다. 실제 대회에서는 참가자들은 5822명에 관한 데이터를 이용하여 목표 값이 빠진 4000명의 잠재 고객들이 이동 주택 보험에 가입을 할 것인지를 예측해야 했다.

한편 이 데이터는 전체 데이터의 약 6% 정도만 실제 고객으로 그 분포가 매우 불균형적으로 되어 있다. 학습 데이터 중 348명만 실제 고객이고 비슷하게 테스트 데이터에서도 238명만이 실제 고객이므로 고객인지 아닌지를 정확히 판별하는 것은 매우 어려운 문제이다. 이에 실제 대회에서는

4000명의 잠재 고객 중 고객이 될 확률이 높은 800명을 선택해서 이들 중 몇 명이 실제 고객인지를 측정함으로써 우승자를 결정했다. 이는 어떤 회사가 상품 광고 메일을 보내는 경우에 구매할 확률이 높은 고객에게만 메일을 보내어 비용을 줄이고 효용을 높이는데 도움이 될 수 있다[박상욱, 2001].

4000명의 잠재 고객 중에서 가장 구매 확률이 높은 800명을 선택하는 경우에 가장 좋은 선택 방법을 적용하면 전체 800명 중 238명 전부를 예측할 것이다. 그러나 실제 대회에서는 121명의 실제 고객을 예측한 참가자가 1등을 했다. 임의로 선택한 경우에는 800명의 약 6%인 42명만 찾아낼 수 있다. 표 2에 대회 결과가 나와 있다[박상욱, 2001].

표 2. CoIL Challenge 2000의 결과[박상욱, 2001]

방법	결과(전체 800명 중 실제 고객 수)
최적의 방법	238
임의선택의 방법	42
1등	121
2등	115
3등	112

5.1.2 기억기반 의사결정지원시스템에서 과제

이동식 주택을 위한 보험에 가입할 잠재 고객을 예측한다는 점에서 CoIL Challenge 2000와 본 연구의 과제는 동일하다. 다만 주어진 훈련 데이터를 통해 이동식 주택을 위한 보험을 구매한 고객과 구매하지 않은 고객 모두를 고려한다. 연산 반응장치에 해당하는 시험관에 주어진 훈련 데이터의 요인들을 모두 부호화하여 DNA 가닥들로 저장한다. 질문자에 해당하는 테스트데이터도 마찬가지로 모든 요인들을 DNA 가닥에 부호화한다. 이와 같이 모든 요인들을 다 이용할 수 있는 이유는 앞에서도 언급했지만 DNA 컴퓨팅의 초병렬성에서 기인한다. 질문자와 저장된 사례로 부호화된 DNA 가닥들을 반응시킨 후 PCR을 통해 결과를 판독한다. 이후에 실제 고객과 일치하는 경우 PCR을 통해 증폭된 DNA 가닥을 연산 반응장치-시뮬레이션 모형에서는 반응 시험관에 해당-에 더 넣어주거나 실제 고객과 불일치 비율이 높은 DNA 가닥들은 분해효소로 퇴화 시키는 등의 피드백 과정을 거친다.

컴퓨터로 본 모형을 시뮬레이션 하기 위해 편의상 86개 중 17개의 요인만을 선정했다. CoIL Challenge 2000의 우승자 및 참가자들이 비교적 중요하다고 강조한 요인들만을 선정했다. 표 3은 시뮬레이션을 위한 데이터를 간단히 분석한 결과이다. 43번 이전의 데이터는 사회인구 통계학적 정보들로 우편 번호와 지번 등을 통해 보험사에서 추측한 데이터이므로 동일한 범주에 대해서범위를 나눠서 값을 상정했음을 알 수 있다. 표 3의

‘Domain’의 의미는 표 4을 참고하면 된다. 사회인구 통계학적 정보들은 우편번호를 통해 얻어진 것이므로 이동식 주택을 위한 보험의 구매 여부를 예측하는데 결정적인 요인을 제공하지 않지만 보험상품의 구매 정보는 상관관계가 유의미함을 여러 참가자들이 증명했다.

표 3. 시뮬레이션을 위한 CoIL Challenge 2000 데이터

#	Description	Domain	Average	
			YES	NO
16	High level education	L3	0.21	0.15
17	Medium level education	L3	0.39	0.36
18	Lower level education	L3	0.40	0.49
32	1 car	L3	0.70	0.64
33	2 cars	L3	0.14	0.14
34	No car	L3	0.16	0.21
37	Income<30.000	L3	0.19	0.27
38	Income 30-45.000	L3	0.36	0.36
39	Income 45-75.000	L3	0.32	0.27
40	Income 75-122.000	L3	0.11	0.08
41	Income>123.000	L3	0.02	0.02
42	Average income	L3	4.26	3.75
43	Purchasing power class	L3	5.00	4.19
47	Contribution car policies	L4	4.72	2.86
59	Contribution fire policies	L4	2.53	1.78
68	Number of car policies	1-12	0.91	0.54
80	Number of fire policies	1-12	0.71	0.56
86	Number of mobile home policies	0-1	348	0

우승자 및 참가자들이 유의미하다고 주장한 요인들은 교육수준, 자동차 보유대수, 수입, 구매력, 자동차 및 화재 보험의 가입여부와 보험료 등이다. 그래서 86개의 요인 중에 이에 해당하는 17개의 요인을 선택함으로써 시뮬레이션의 효율성을 높였다. 물론 이와 같은 선정은 대회 참가자들과 동일한 초기 조건이 아니므로 결과 고찰시 고려할 것이다.

표 4. 도메인(Domain)

L3:	L4:
0 0%	0 0
1 1 - 10%	1 1 - 49
2 11 - 23%	2 50 - 99
3 24 - 36%	3 100 - 199
4 37 - 49%	4 200 - 499
5 50 - 62%	5 500 - 999
6 63 - 75%	6 1000 - 4999
7 76 - 88%	7 5000 - 9999
8 89 - 99%	8 10.000 - 19.999
9 100%	9 20.000 - ?

5.2 시뮬레이션

DNA 컴퓨팅이 가장 최적의 결과를 낼 수 있는 환경을 가정하고 시뮬레이션에 들어갔다. 그러므로 본 시뮬레이션에서 고려한 조건들은 DNA 가닥들이 얼마나 잘 결합할 수 있는지를 보여주는 hybridization 가능성(probability of hybridization, k_p)과 각 질문자들이 주어진 과제를 얼마나 잘 수행할 수 있는지를 예측하는 유사성 역치(similarity threshold, θ)이다.




그림 16. 시뮬레이션을 위한 순서도

5.2.1 변수 정의하기

첫째, hybridization 가능성은 각 요인들의 가중치(weight of attributes, W_n)와 일치여부를 통해 결정했다. 사회 인구 통계 정보와 같이 유의미하지 않은 요인보다 보험 상품의 구매 정보와 같은 유의미한 요인에 더 큰 가중치를 임의적으로 부여했다. 그리고 일치여부는 우선은 시뮬레이션의 편의를 위해 이진값의 함수를 취했다. 중요한 요인일수록 hybridization에 큰 영향을 미치고 일치를 많이 할수록 hybridization이 잘 일어나므로 요인들의 가중치와 일치여부는 hybridization 가능성과 비례함을 알 수 있다.

$$k_i \propto W_1 f(a_1) + W_2 f(a_2) + \dots + W_{17} f(a_{17})$$

k : constant for hybridization

W : weight of attributes

a : attributes

i : number of previous cases

$f(a) = 0$ (when the attribute value is unmatched)

1 (when the attribute value is matched)

그림 17. hybridization의 가능성 상수, k_i

둘째, 유사성 역치인 θ 의 값은 휴리스틱한 방법(heuristic method)으로 결정했다. 기존 사례의 초기값의 구성과 hybridization의 가능성 등이 유사성 역치값에 영향을 줄 수 있다고 예상할 수 있지만 수학적으로 그 관계를 계산하는 것이 어려움이 있어서 휴리스틱한 방법을 선택했다. 동일한 알고리즘에 대해 질문자 대신 판정값을 생략한 기존 사례를 입력하여 유사성 역치의 값을 결정했다.

기억기반 DSS에서는 기존 사례가 피드백을 통해 매 질문자에 대해 업데이트 되므로 유사성 역치가 매우 유동적이다. 이 과정에서 기존 사례의 밀도가 조정되고 기존 사례가 표준화된다. 즉, 기존 사례의 조성은 변화지만 총 농도가 일정하게 유지됨으로써 자료의 분포가 조정되는 것이다.

5.2.2 시뮬레이션

일정한 시간마다 병렬적인 hybridization 반응이 반복되는 구조를 기본으로 각각의 변수들을 초기화했다. 기존 사례는 각각의 사례의 농도를 동일하게 하여 초기화했다. 시뮬레이션 상에서의 반응은 그림 19에서 볼 수 있




그림 18. 실험 방법을 고려한 시뮬레이션 상에서 분자농도의 조절과 표준화

듯이 17개의 정수들의 완벽한 결합에 의한 판정값에 대한 판별이다. 즉, 일정한 단위시간(Δt)마다 완벽한 병렬 반응이 일어나고 주어진 질문자가 기준 사례와 완전히 결합($[q]_n=0$)해야 반응이 종료된다.

실험실 실험을 감안한 시뮬레이션은 그림 18와 같다. 각 질문자마다 새로운 시험관을 쓰면서 표준화하는 방법과 하나의 시험관만으로 표준화하는 방법을 시행할 수 있다. 비용면에서는 후자의 실험이 저렴하지만 hybridization하여 빠져나간 농도만큼 새로운 사례를 채우는 작업이 현 기술 상 어려움이 많아서 비용이 많이 들지만 전자의 방법을 선택했다. 각각의 질문자에 대해 hybridization반응 후 판정값에 따라 새로운 종류의 기

존사례가 만들어진다. 그 다음에 새로운 사례까지 포함된 전체 기존사례의




그림 19. 시뮬레이션에서 단위시간당 진행되는 반응

농도는 일정해야 하므로 각각의 기존사례 농도는 새로 포함된 기존사례의 수를 합한 값으로 전체 농도를 나눈 값이다. 매 질문자에 대해 행하는 실험에서 각각의 시험관의 기존사례의 농도를 일정하게 유지하는 것은 본 알고리즘의 분포를 표준화해주기 위함이다.

시뮬레이션은 학습양식(learning mode)과 시험양식(test mode)으로 나뉘어 행해진다. 학습양식에서는 초기화된 상태에서 휴리스틱한 방법으로 유사성 역치가 결정되고 새로운 기존 사례들이 피드백을 통해 형성된다. 이때 약 30%에 해당하는 기존 사례만을 이용하고 나머지는 유사성 역치가 얼마나 유의미한가를 판정하는데 이용한다. 시험양식에서는 학습양식에서

결정된 유사성 역치의 값과 새로 생성된 기존 사례들을 이용하여 질문자의 판정값을 결정한다.

5.3 시뮬레이션의 결과

시뮬레이션은 구현한 알고리즘이 문제를 해결하기 위한 절차로서 적당한 가 여부를 평가하고 판단하기 위한 도구이다. 그러므로 시뮬레이션을 결과를 고찰하기 위해서는 알고리즘을 평가해야 할 것이다.

알고리즘의 평가는 보편적으로 두 가지로 나뉘어 이루어진다[박정호, 1992]. 첫째는 알고리즘이 정당성을 갖추었는지 여부이다. 둘째는 알고리즘이 얼마나 복잡한지 여부이다. 본 논문에서도 이와 같은 두 가지 관점으로 알고리즘을 평가함으로써 시뮬레이션의 결과를 고찰할 것이다. 그리고 수행의 정확성을 기존 결과들과 비교 평가할 것이다.

5.3.1 기억기반 의사결정지원시스템의 알고리즘의 정당성

알고리즘의 정당성은 어떤 문제 P 를 해결하기 위해 고안된 알고리즘이 문제 P 의 입력에 대한 정답을 제대로 계산해 내야 한다는 평가 기준이다. 그리고 계산은 언젠가는 반드시 종료한다는 보증이 필요하다. 이와 같은 알고리즘의 정당성의 조건을 정리하면 다음과 같다[박정호, 1992].

조건 1 어떠한 입력 데이터에 대해서도 틀린 답을 계산해 내지 않아야 한다. 다시 말해서 답을 출력할 때는 반드시 그 답이 정확해야 한다.

(안정성 조건)

조건 2 어떠한 입력 데이터에 대해서도 유한 시간내에 답을 내야 한다.

즉, 반드시 계산은 끝내야 한다. (종료 조건)




Figure 20. 알고리즘의 안정성

조건 1은 안정성(stability) 조건으로 어떠한 질문자 데이터에 대해서도 일정한 패턴을 보일 때 알고리즘의 정당성이 보장된다. 역으로 무슨 데이터를 적용하더라도 일정한 패턴의 학습양식을 보여줘야 그 알고리즘이 안정하다고 할 수 있다.

기억기반 의사결정지원시스템의 알고리즘이 안정한가를 판단하기 위해 질문자를 임의적으로 입력했다. 각 경우에 대한 유사성 역치와 판별값의 반응 패턴은 항상 유사했다. 어떠한 경우라도 시작점과 종료점이 비슷하며 질문자의 수가 증가할수록 판별값과 유사성 역치의 증가 양상이 유사함을 알 수 있다. 가입자만을 몰아서 먼저 입력하거나 나중에 입력할 때와 같은 극단적인 입력순서일 때 유사성 역치의 값이 처음과 마지막에 편향된 값을 보였으나 일정한 범위 안에서 크게 벗어나지 않았다. 그리고 이와 같은 학습의 결과로 산출되는 유사성 역치의 값은 매 시도마다 다른 값이었지만 일정한 범위(0.25 ± 0.02) 안에 존재했다. **그림 20**의 첫번째 도표에서와 같이 학습양식에서 입력해주는 예의 순서를 임의적으로 정해줬을 때 유사성 역치나 새로 생성된 기존사례의 비율 등이 크게 차이가 나지 않음을 알 수 있다. 그리고 이들 각각의 학습양식 후 테스트 결과 0부터 입력한 결과(122/800)외에는 모두 동일한 수행 성과(123/800)를 이뤘다.

그림 20의 두번째 도표에서는 알고리즘의 안정성을 결정하는 매개변수 중에 하나인 학습비율(learning rate)⁶에 따른 각종 변수값을 보여준다. 새

⁶ 유사성 역치를 업데이트시, 기존 유사성 역치와 새로 생성된 기존사례의

로 생성된 기존사례의 비율만으로 유사성 역치를 업데이트시키는 학습비율값(0.0)부터 새로 생성된 기존 사례를 유사성 역치 업데이트에 전혀 이용하지 않는 학습비율값(1.0)까지를 고려했다. 양극단의 학습비율값이 아닌 나머지의 학습비율값(0.2, 0.4, 0.6, 0.8)에서는 유사성 역치와 정답률, 수행의 정확도 등에서 거의 동일한 결과를 보였다. 새로 생성된 기존사례만으로 유사성 역치를 업데이트하는 경우에도 정답률만 제외하고 나머지 측정치에서는 극단적이지 않은 학습비율값과 유사한 결과였다. 이상에서 극단적이지 않은 학습비율값은 상당히 안정한 알고리즘을 구현하게 함을 알 수 있다.

조건 2는 종료 조건으로 알고리즘을 통해 수행이 유한 시간 내에 종료되어야 한다. 기억기반 DSS의 시뮬레이션은 시험양식과 학습양식 모두 3분 이내에 종료되었다.

이상에서 기억기반 DSS를 구현한 알고리즘은 조건 1과 조건 2를 모두 만족하므로 정당성을 갖추었음을 알 수 있다.

5.3.2 기억기반 의사결정지원시스템의 알고리즘의 복잡도

알고리즘의 복잡도는 주어진 문제를 구상한 알고리즘을 이용하여 빨리 해결할수록, 적은 메모리 영역을 이용하여 해결할수록 훌륭한 알고리즘임을 보여준다.

비율간의 가중치를 결정하는 값.

기억기반 DSS의 알고리즘은 주어진 요인의 종류에 상관없이 일정한 시간에 하나의 질문자에 대한 결과값을 얻을 수 있다. 고려해야 할 요인이 1종류이건 수십종류이건 문제를 해결하는 시간은 동일하다. 다만 전체 집합의 크기(시뮬레이션에서는 농도)에 따라서 반복 횟수가 증가하므로 전체 문제 해결 시간이 길어질 뿐이다. 그림 19로 설명하면 Δt 는 요인의 종류와 무관하게 일정하고 T 만 전체 데이터 집합의 크기에 따라 증가한다는 뜻이다.

분자컴퓨팅이 아닌 실리콘 메모리를 가지고 있는 컴퓨터로 기억기반 DSS를 구현하면 요인의 종류마다 메모리를 할당하여 문제를 처리해야 하므로 요인의 종류가 증가할수록 시간 복잡도는 선형적으로 증가하게 된다.

이상에서 기억기반 DSS의 구현 알고리즘은 빠른 시간 내에 적은 메모리로 주어진 문제를 해결할 수 있으므로 우수한 알고리즘임을 알 수 있다.

5.3.2 기억기반 의사결정지원시스템의 수행의 정확성

결과부터 언급하자면 기존의 어느 알고리즘보다 높은 정확성을 보였다. CoIL Challenge 2000에서 우승자가 후보자 800명 중에 121명을 맞추고 능동적인 RBF(Radial Basis Function) 신경망 학습으로 데이터를 처리한 경우에는 118명을 맞췄다[박상욱, 2001]. 그러나 기억기반 의사결정기반 시스템에 이용한 알고리즘에 의할 경우 123명을 맞췄다. 물론 숫자상으로는 아주 우수한 정확성을 나타내는 것은 아니다. 그리고 주어진 초기 조건

의 차별성을 고려하면 역시 우수한 정확성은 아니다. 하지만 시뮬레이션이

표 5. 수행의 정확성

Methods	Results (the # of real customers among 800)
Methods for optimization	238
Methods for randomness	42
Memory-based DSS	123
CoIL Challenge 2000	121
Active RBF neural network	118

지니는 한계점을 감안한다면 실제 DNA 컴퓨팅으로 구현할 경우 훨씬 높은 정확률을 나타낼 수 있음을 예상할 수 있다.

실제로 이동식 주택 보험을 가입했음에도 학습의 결과 가입하지 않은 것으로 판명된 사람들의 판별값을 조사해보니 유사성 역치보다 매우 작은 값을 가지는 경우였다. 이와 같이 편향(biased)된 자료가 아닌 요인의 속성과 값이 일관성을 보이는 자료라면 훨씬 더 우수한 정확성을 보였을 것이다.

6. 결론

인간의 인지과정을 밝혀내고 흉내내려는 노력은 작금(昨今)의 일이 아니다. 튜링머신이라는 보편적인 계산도구가 발명되면서 모방의 길이 열렸다. 인지과정은 상당히 복잡하므로 사람들은 처음부터 인간의 모든 인지과정을 모방할 수 없었다. 그래서 인지과정의 한 요소만을 집중적으로 탐구하고 구현해왔다. 그러나 선이 있는 계산도구는 선형적인 논리구조를 가지기 때문에 비선형적이고 동시다발적인 인간의 정신구조를 흉내내는데 한계에 부딪혔다. 하지만 정신작용이 일어나는 매체(material)로 인지과정을 밝혀보려는 환원적인 사고는 인지과정 탐구의 새 장을 열고 있다. 그 대표적인 도구가 선이 없는 계산도구인 DNA 컴퓨팅이다.

인간의 인지과정을 탐구하는 또 하나의 새로운 시각은 생물학적 관점이다. 얼마 전까지만 해도 인지라는 것을 지나치게 사변적(思辨的)인 존재로 취급하여 자극과 반응 사이의 블랙박스로 여겼었다. 그러나 생물학의 발달로 정신작용을 세포 혹은 분자 단위로 설명할 수 있게 되었다. 화학적 시냅스의 연구도 이와 같은 흐름에서 기인했다.

화학적 시냅스에서 발생하는 분자 차원의 현상을 학습 과정으로 보고 한 단계 더 추상화 시켜서 입력과 반응과 출력이 존재하는 기억기반 학습에 기반한 모델로 구현한 작업이 분자컴퓨팅을 이용한 기억기반 학습이다. 시

냅스 가소성이 일어나는 과정을 가장 잘 표현할 수 있는 기존의 기계학습이 기억기반 학습이기 때문에 구현에 이용하게 되었다. 그리고 의사결정과정은 결정 혹은 목표치라는 방향성을 유지하면서 새로운 요인을 반영하고 오류를 수정하는 피드백 과정을 포함하므로 화학적 시냅스에서 일어나는 학습 현상과 유사하고 기억기반 학습 알고리즘과도 유사하므로 응용의 대상으로 의사결정과정을 선정했다. 또 화학적 시냅스에서 발새하는 학습 과정의 모델을 의사결정과정이라는 과제로 응용하는 것은 기존의 의사결정지원시스템(DSS)와 유사한 기능을 하는 것이므로 기억기반 DSS이라는 개념을 만들 수 있었다. 이와 같은 추상화가 가능했던 것은 기억기반 DSS가 확률적 모형이라는 수학적 근거도 있지만 동일 기능에 대해 다양한 입장에서 해석하고 개념화 할 수 있는 학제적인 연구 분위기도 무시할 수 없다.

이와 같은 추상화를 통해 분자망 학습을 시뮬레이션한 결과는 DNA 컴퓨팅, 더 나아가 분자컴퓨팅의 가능성을 시사한다. DNA 컴퓨팅의 속성을 고려한 알고리즘이 정당하고 효율적인 학습방법 이었고 초병렬성이라는 특성이 일부만 반영된 시뮬레이션임에도 불구하고 기존의 여러 결과와 비교할 때 가장 우수한 수행의 결과를 얻었기 때문이다. 그리고 기존의 MADM 기법에 근거한 DSS에 비해 기억기반 DSS가 많은 요인들을 처리해야 하는 의사결정 문제를 간단한 알고리즘으로 손쉽게 해결할 수 있음을 시사한다.

DNA 컴퓨팅은 연구 초기이므로 본 논문에도 많은 한계점이 존재한다. 우선, 시뮬레이션의 문제를 들 수 있다. DNA 컴퓨팅은 초병렬성을 장점으로

내세우는 도구인데 선형적인 논리의 컴퓨터로 정교하게 시뮬레이션 하기란 매우 어렵다. 이와 같은 한계점이 시뮬레이션의 결과에도 반영이 되어있다. DNA를 이용하면 정성적인가 또는 정량적인가를 나타내는 요인의 속성과 요인의 값을 동시에 염기 서열의 배열로 부호화할 수 있지만 기존 컴퓨터로는 요인의 속성과 값을 동시에 표현하기가 어려웠다. 그리고 17개의 요인과 각각의 요인이 10개의 값을 가지는 170 여 가지의 속성을 표현하는 DNA의 서열을 디자인한 예가 지금까지 없어서 실제적인 DNA 가닥의 부호화를 본 논문에서는 다룰 수 없었다.

앞으로 화학적 시냅스의 학습 현상을 기반으로 한 기억기반 DSS를 위한 알고리즘을 현재의 DNA 컴퓨팅 기술로 효율적으로 실험할 수 있게 수정하고 보완할 것이다. 알고리즘 중 피드백을 통한 학습 과정이 그 주 대상이 될 것이다. 그리고 다수의 속성을 표현하는 DNA 가닥의 부호화 방법을 구상할 것이다. 이와 같은 수정, 보완 작업을 통해 본 논문에서 제안한 방법을 실험실에서 구현하고자 한다.

반세기 전의 보편적인 계산도구가 오늘날의 컴퓨터가 되었듯이 DNA 컴퓨팅도 사용자 인터페이스가 편리한 도구로 발전된다면 화학적 시냅스의 학습 현상을 모델링 한 기억기반 DSS는 안정적이고 효율적인 도구가 될 것이다.

참고문헌

- [김성희 외, 1999] 김성희, 정병호, 김재경, 제13장 계층 분석 과정, *의사 결정분석 및 응용*, 영지문화사, pp. 379-404, 1999.
- [박상욱, 2001] 박상욱, 능동 데이터 선택에 의한 RBF 신경망의 건설적 학습, 서울대학교 공과대학 대학원 석사학위 논문, pp. 27-30, 2001.
- [박정호, 1992] 박정호, 제1장 알고리즘의 개요, *알고리즘*, 상조사, pp. 13-44, 1992.
- [Adleman, 1994] Adleman, L. M., Molecular computation of solutions to combinatorial problems, *Science*, 266: 1021-1024, 1994.
- [Adleman, 1998] Adleman, L. M., Computing with DNA: the manipulation of DNA to solve mathematical problems is redefining what is meant by “computation”, *Scientific American*, August , pp. 34-41, 1998.
- [Anderson, 1995] Anderson, J. R., Memory of human: coding and storage, *Cognitive Psychology and Its Implications*, 4, pp.178-205, 1995.
- [Bazerman, 1998] Bazerman, M., Ch. 1 Introduction to managerial

- decision making, *Judgment in Managerial Decision Making*, 4th, pp. 1–10, 1998.
- [Beaver, 1995] Beaver, D., Molecular computing. *Technical Report TR95-001*, Penn State University, January, 1995.
- [Black, 1994] Black, I. B., A general introduction to a specific synapse: definition and explanations. *Information in the Brain: A Molecular Perspective*, pp. 23–42, 1994. [Boneh, Dunworth, and Sgall, 1995] Boneh, D., Dunworth, C., and Sgall, J., On the computational power of DNA, *Technical Report TR-499-95*, Princeton University, 1995.
- [Csuhaĵ-Varjú et al., 1996] Csuhaĵ-Varjú, E., Freund, R., Kari, L., and Paun, G., ssDNA computing based on splicing: universality results, In Hunter and Klein, Editors, *Proceedings of the 1996 Pacific Symposium on Biocomputing*, pp. 179–190, 1996.
- [Desheng, 1993] Desheng, W., Rock mass blastability classification by region, *Selected Papers of the 4th Conference on Engineering Blasting*, pp. 159–165, 1993.
- [Han, Weiya and Shouyi, 2000] Han, J., Weiya, X., and Shouyi, X., Automatic generation of 3D digital model for rock mass quality assessment, *Chinese Journal of engineering geology*, 8, pp.

123-126, 2000.

[Harris, 1998] Harris, R., Introduction to decision making,
<http://www.virtualsalt.com/crebook5.htm>, 1998.

[Kandel et al., 2000] Kandel, E. R., Schwartz J. H., and Jessell, T. M.,
Ch. 10 Overview of synaptic transmission, Ch. 24 The
perception of pain, *Principles of Neural Science*, 4th, pp. 175-
186, 472-491, 2000.

[Köhler, 1947] Köhler, W., *Gestalt psychology*, New York: Harcourt,
1947.

[Lim, Yun, Jang, Chai, Yoo and Zhang, 2002] Lim, H.-W., Yun, J.-E.,
Jang, H.-M., Chai, Y.-G., Yoo, S.-I., and Zhang, B.-T., Version
space learning with DNA molecules, *Preliminary Proceedings
of the Eighth International Meeting on DNA Based Computers*
(DNA8), pp. 261-270, 2002. [그림 8, 9]

[Linial and Linial, 1995] Linial, M., Linial, N., On the potential of
molecular computing, *Science*, 268, pp. 481-484, 1995.

[Maley, 1998] Maley, C. C., DNA computation: theory, practice, and
prospects, *Evolutionary Computation*, 6(3), pp. 201-229, 1998.

[그림 5, 6, 7]

[Mitchell, 1997] Mitchell, T. M., *Machine Learning*, The McGraw-Hill

- Companies, Inc, 1997.
- [Ouyang, Kaplan, Liu and Libchaber, 1997] Ouyang, Q., Kaplan, P. D.,
Liu, S. and Libchaber, A., DNA solution of the maximal clique
problems, *Science*, 278, pp. 446-449, 1997.
- [Robbins, 1999] Robbins, T., The pharmacology of thought and emotion,
*From Brains to Consciousness? : Essays on the New Sciences
of the Mind*, Princeton University Press, pp. 33-52, 1999.
- [Rothemund, 1996] Rothemund, P. W. K., A DNA and restriction
enzyme implementation of Turing machines, *Proceedings of
DNA Based Computers II*, pp. 1-22, 1996.
- [Saaty, 1980] Saaty, T. L., The Analytic Hierarchy Process, McGraw-
Hill, 1980.
- [Schacter and Tulving, 1994] Schacter, D. L., and Tulving, E.,
Declarative and nondeclarative memory: multiple brain system
supporting learning and memory, *Memory Systems*, pp. 203-
232, 1994.
- [Schultz, 1998] Schultz, W., Predictive reward signal of dopamine
neurons. *J. Neurophysiol.*, 80(1), pp. 1-27, 1998.
- [Shin, Zhang and Jun, 1999] Shin, S.-Y., Zhang, B.-T., and Jun, S.-S.,
Solving travelling salesman problems using molecular

- programming. *Proceedings of the 1999 Congress on Evolutionary Computation (CEC99)*, pp. 994–1000, 1999.
- [Tolman, 1948] Tolman, E. C., Cognitive maps in rats and men, *Psychological Reviews*, 55, pp. 189–208, 1948.
- [Vander, Sherman and Luciano, 1994] Vander, A. J., Sherman, J. H., and Luciano, D. S., Ch.13 Consciousness and behavior, *Human Physiology: The Mechanisms of Body Function*, pp. 369–390, 1994.
- [Winfree, 1996] Winfree, E., On the computational power of DNA annealing and ligation, *Proceedings of DNA Based Computers*, pp. 199–221, 1996.
- [Zhang, 2002] Zhang, B.-T., [Molecular information processing technologies](#) (in Korean), *IEEK Magazine*, 29(3), pp. 286–298, 2002.
- [1] <http://www.expertchoice.com/books/dml/> [그림 15]
- [2] <http://www.markpoyser.com/stockmarket.htm> [그림 3]
- [3] <http://www.ornl.gov/hgmis/publicat/primer/fig2.html> [그림 4]
- [4] <http://www.wi.leidenuniv.nl/~putten/library/cc2000/index.html>

Abstracts

At chemical synapses, the information on stimuli is processed through neurotransmitters and the feedback mechanism, so that synaptic plasticity is occurred. Thus, this “tolerance” step is ‘learning,’ because the external information is processed and saved chemically and physically during this process.

In this paper, we introduced a method for the memory-based learning stimulating the process at a chemical synapse to implement. We used DNA computing, a kind of molecular computing, which has massive parallelism and high density of information, since it is difficult to take the silicon computer for implementing the learning process at chemical synapses.

Simulations have been performed to evaluate the effectiveness of the method. The experiments on the CoIL Challenge 2000 data showed better result (123/800 candidates) than those with the machine-learning algorithms (121 or 118/800). We selected 17 attributes out of 85 to overcome the current limitation of simulating DNA computing. with the development of DNA computing tool with user-friendly interface, — like those of these days’ silicon computers — there also exists the possibility of time reduction.

Key words: memory-based learning, DNA computing, synaptic plasticity, memory-based DSS, tolerance

Student number: 2001-20153

감사의 글