

Non-negative Matrix Factorization을 이용한 텍스트 문서 및 마이크로어레이 데이터 분석

Using Non-negative Matrix Factorization for the Analysis of Text Documents and Microarray Data

김 윤 희

서울대학교 컴퓨터공학부

Abstract

It is very useful to extract automatically the meaning or relationships among variables when we are faced with a vast amount of data that is hard to handle manually. Dimensionality reduction techniques are one of the most useful methods to mine some meaningful information, such as main topics of a set of document. This thesis utilizes the non-negative matrix factorization (NMF) technique which is used to decompose the data matrix into the product of two meaningful matrices. In the experiment of topic extraction from a subset of TREC-8 document set, NMF could extract meaningful word sets related to some topics underlying the document set. In the information retrieval experiment with a subset of MEDLINE data set, the NMF-based similarity estimation method accomplished better average performance than basic VSM method up to 14%. Also, the NMF method has been applied to the clustering of microarray data, where it successfully clustered acute leukemia samples according to their specific cancer type.

1. 서론

정보화 및 과학기술의 발달에 따라 다양한 데이터가 엄청난 속도로 쏟아져 나오고 있다. 이와 같은 데이터의 홍수 속에서 원하는 데이터를 찾거나 데이터의 의미를 파악해 내는 것은 매우 어렵다. 무수히 쏟아지는 많은 데이터의 내용을 읽거나 일일이 분석하지 않고 데이터의 특성을 파악해 내거나 데이터들의 관계를 파악해 내는 것은 매우 유용할 것이다.

대량의 데이터들은 일련의 변수들에 대해 빈도수, 가중치 등을 가진다. 이와 같은 변수들과 데이터의 관계 정보에서 각 데이터와 데이터의 관계, 변수들끼리의 관계,

데이터와 변수의 관계를 도출해 낼 수 있다. 이를 분석하기 위한 하나의 방법으로서, 차원 감소 (dimensionality reduction) 기법은 관찰된 데이터와 변수의 차원 감소를 통해서 단순화 시킴으로써 새로운 정보를 도출한다. 이러한 차원 감소를 적용한 기법에는 벡터 양자화(vector quantization), 주성분분석(principal components analysis), non-negative matrix factorization (이하 NMF) 기법 등이 있다.

벡터 양자화(VQ) 기법은 감소 차원- 차원 감소를 위해 데이터와 변수들을 사상(mapping)시킨 공간의 차원- 의 갯수대로 데이터들을 이산적으로 나눈다. 즉 각 데이터는 한 개의 클러스터에 분류되며 후에 각 클러스터의 프로토 타입으로 복구된다. 주성분분석(PCA)은 감소 차원개의 벡터의 선형 합으로 나타난다. 그러나 주성분분석이 각 벡터값에 대해 음수 가중치를 가질 수 있는 반면에 NMF는 양수(non-negative) 가중치만을 사용하여 데이터와 변수들의 관계를 나타낸다. NMF의 결과값은 부분적인 값들의 합이며 사상시킨 공간의 각 축은 실제적인 의미를 갖는다. 대부분의 서로 다른 종류의 데이터 행렬은 희소행렬(sparse matrix)로 구성되고, NMF는 이런 성질을 갖는 행렬을 분해하여 희소행렬을 만든다.

본 논문에서는 위와 같은 특성을 가지는 NMF를 세 종류의 데이터에 적용하여 그 효용성과 적용가능성을 확인한다. 먼저 NMF기법을 문서 데이터에 적용하여 NMF가 차원 감소를 통해 단어와 문서집합들로부터 효과적으로 주제에 관한 정보를 도출하는지 확인하고, 추출된 주제어 정보에 기반한 문서간 유사도 측정을 통해 NMF의 문서 검색에의 적용가능성과 기존 VSM방법에 비해 성능향상이 있는지를 검토한다. 또한 최근 많은 연구가 진행되고 있는 마이크로어레이 데이터 분석의 하나로서 NMF를 데이터 클러스터링에 적용해 보고 그 유용성을 확인해 보고자 한다.

논문의 구성은 다음과 같다. 먼저 2장에서 NMF의 기반이론이 되는 차원 감소를 검토하고 차원감소를 이용하는 NMF와 유사한 두 개의 기법, 벡터양자화와 주성분분석에 대해 살펴본다. 3장에서는 NMF의 주요개념, 기법과 알고리즘을 정리한다. 4장에서는 문서 데이터와 마이크로어레이 데이터에 대한 실험 및 그 결과를 다룬다. 5장에서는 연구 결과와 향후 연구 방향에 대해 논의한다.

2. 관련연구

2.1. 차원 감소 (Dimensionality Reduction)

차원 감소(Dimensionality Reduction)는 데이터나 변수들을 원래 공간보다 더 낮은 차원의 공간으로 사상시키는 것이다. 차원 감소는 문제를 단순화시키고, 데이터의 차원 감소,

데이터의 이해 및 해석, 예측을 위한 모델링(predictive modeling), 향후 지도학습(supervised learning)을 위한 전처리 등의 목적으로 사용한다.

먼저 차원 감소는 복잡한 문제를 단순화시켜 쉽게 해결할 수 있도록 한다. 대부분의 경우 학습을 하는데 있어서 데이터의 차원이 높을수록 문제는 복잡해진다. 예를 들어 최대우도(Maximum Likelihood)를 사용하여 밀도함수(density)를 계산하는 문제에서 차원이 높을수록 모델의 학습 알고리즘은 시간 비용이 증가할 뿐 아니라, 최적해를 찾지 못하고 지역 최소값(local minima)에 빠지며, 초기 조건에 강하게 의존하는 경향이 있다. 그러나 많은 실제적인 문제를 해결할 때 d -차원 유클리드 공간상의 많은 다변량 데이터들은 실상은 원래 데이터 공간 차원보다 훨씬 낮은 차원으로 문제를 단순화시킬 수 있으며, 따라서 이러한 문제를 원래의 고차원 공간이 아니라 저차원 공간에서 바꾸면 문제를 좀더 쉽게 해결 가능하다.

뿐만 아니라 차원 감소는 데이터의 차원감소, 데이터의 이해 및 해석, 예측을 위한 모델링(predictive modeling), 향후 지도학습(supervised learning)을 위한 전처리 등의 목적으로 적용될 수 있다. 다시 말해, 차원감소 기법은 데이터를 단순한 저차원으로 표현해주고 (데이터의 차원 감소), 차원감소 과정에서 주어진 데이터에 대한 새로운 해석을 제시하는데 활용될 수 있다 (데이터의 이해 및 해석). 또한, 학습데이터(training data)와 같은 분포를 가지는 새로운 데이터들에 대해 작은 근사 에러를 가지는 모델을 생성할 수 있으며 (예측을 위한 모델링), 데이터의 차원을 줄임으로써 향후 분류나 여과 기법에서의 학습 시간이나 성능 등을 개선시키기 위한 목적으로 적용될 수도 있다 (지도학습을 위한 전처리)[2].

차원 감소 문제는 형식적으로 d -차원 입력 공간 $\mathcal{R}^d$ 에서 m -차원 출력 공간 $\mathcal{R}^m$ ($m \ll n$) 으로 사상시키는 문제로 나타낼 수 있다. 모든 입력 벡터 $\mathbf{x}$ 에 대해 낮은 차원에서의 인코딩 $G(\mathbf{x}) : \mathcal{R}^d \rightarrow \mathcal{R}^m$, $\mathbf{z}=G(\mathbf{x})$ 를 만든다. "좋은" 사상 G 는 원래 분포를 유지하는 낮은 차원에서의 인코더가 된다. "역" 사상 $F(\mathbf{z}) : \mathcal{R}^m \rightarrow \mathcal{R}^d$ 는 디코딩 과정이 되고, 따라서 전체적인 인코딩-디코딩 과정에서의 사상은 $\mathbf{x}'=F(G(\mathbf{x}))$ 가 되고, 차원 감소 문제는 $\mathbf{x}$ 의 분포와 최대한 유사한 $\mathbf{x}'$ 를 생성하는 F 와 G 를 찾는 것이 된다.

어떤 데이터에 대해 최적의 인코딩/디코딩 함수들을 구하기 위해, 데이터로부터 이러한 함수를 추정하기 위해 다음과 같은 근사 함수들의 클래스 $f(\mathbf{x}, \omega) = F(G(\mathbf{x}))$ 를 정의한다.

이 때, 최적화된 ω 를 추정하는 과정은 다음과 같은 risk 함수를 최소화 하는 과정으로 정의될 수 있다.

$$R(\omega) = \int L(\mathbf{x}, \mathbf{x}')p(\mathbf{x})d(\mathbf{x}) = \int L(\mathbf{x}, f(\mathbf{x}, \omega))p(\mathbf{x})d\mathbf{x} \quad (1)$$

2.2 다양한 차원 감소의 적용

차원 감소는 행렬 분해(matrix factorization)를 통해 적용될 수 있다. 벡터양자화와 주성분분해, NMF는 모두 행렬 분해를 사용하여 차원 감소를 적용할 수 있다. 행렬 분해는

주어진 데이터 행렬 V 를 $V_{i\mu} \approx (WH)_{i\mu} = \sum_{a=1}^r W_{ia} H_{a\mu}$ 로 분해(factorization)하여 데이터와

변수들의 관계를 설명하기 위해 새로운 공간(space)를 도입시킨다. 여기서 W 와 H 행렬의 차원은 각각 $n \times r$, $r \times m$ 이 되는데 W 행렬은 변수들과 감소 공간과의 관계를 H 행렬은 데이터와 감소 공간과의 관계를 나타내게 된다. 여기서 감소 공간의 차원, rank r 은 $(n+m)r < nm$ 인 r 이 일반적으로 선택되고 새로운 공간으로 mapping된 W 와 H 는 V data의 압축된 형태라고 볼 수 있다.

2.2.1 벡터 양자화 (Vector Quantization)

벡터 양자화는 모든 데이터를 몇 개의 프로토 타입으로 단순화시킨다. 벡터로 만들어진 입력 데이터 공간을 감소 차원 개의 구역으로 나누고, 각 구역마다 프로토타입(prototype)을 정한다. 그리고 주어진 입력 데이터가 어떤 구역에 속하는지, 즉 그 데이터의 인덱스를 기억한 후에 압축을 풀 때 그 인덱스에 따라 프로토타입으로 데이터를 복구하는 것이다. 이 때 압축된 데이터의 크기는 구역의 갯수에 따르게 되고 에러율은 구역의 갯수와 어떻게 구역을 나누는지에 따라 달라지게 된다. VQ에 행렬 분해를 적용하면 W 행렬의 각 열은 한 개의 프로토 타입이며 H 의 각 열은 각 데이터가 속한 클러스터를 나타내는 벡터가 된다. 벡터양자화기(vector quantizer) Q 는 d -차원 유클리드 공간 R^d ($d \geq 2$) 을 유한한 R^d 의 부분집합 C 로 사상시키는 함수이다. Q 는 $Q: R^d \rightarrow C$ 로 정의할 수 있으며, 여기에서 $C = \{c_1, c_2, \dots, c_m\}$ 로 정의되고 c_j 는 결과 벡터로 각 j 에 대해 R^d 의 원소이다. 즉, 벡터양자화는 감소차원만큼 입력 공간을 분할하고, 각 입력 데이터는 이산적인 분할 중에 한 구역에 속하게 되는 것이다. 그리고 벡터양자화에서 주요한 관심사는 분할을 하여 데이터를 프로토타입으로 나타낼 때의 에러를 최소화 시키는 벡터 값을 가지는 근사 함수 $f(x, \omega) = Q(x) = \sum_j c_j I(x \in R_j)$ 를 찾는 것이 된다.

2.2.2 주성분 분석(Principal Component Analysis)

주성분 분석(principal component analysis)은 데이터의 집합을 정규직교(orthonormal)벡터들의 선형 합으로 나타낸다. $d \times n$ 행렬 X 가 차원이 d 인 n 개의 데이터를 표현한다고 할 때, 데이터 $x \in X$ 는 다음과 같은 근사함수를 통해 그 차원을 축소할 수 있다.


$$f(x, U) = m + U(U^T x) \quad (2)$$

여기서 $f(\mathbf{x}, \mathbf{V})$ 는 벡터값을 가지는 함수이고, $\mathbf{m}$ 은 데이터 $\mathbf{x}$ 의 평균, 그리고, 행렬 $\mathbf{U}$ 는 열이 정규직교 ($d \times r$) 행렬이다. 사상 $\mathbf{z} = \mathbf{U}\mathbf{x}$ 는 $\mathbf{x}$ 의 감소 공간 차원으로의 정사영인 것이다. 이러한 벡터 $\mathbf{V}$ 와 정사영 벡터 $\mathbf{z}$ 는 비정칙치분해(singular value decomposition)을 통해 계산할 수 있는데, 이 때, $d \times n$ 데이터 행렬 $\mathbf{X}$ 는 $\mathbf{X} = \mathbf{U}\Sigma\mathbf{V}^T$ 로 나누어진다고 가정한다 (데이터 행렬 $\mathbf{X}$ 는 centering 되었다고 가정한다). 여기서 행렬 Σ 는 대각행렬이고 $\mathbf{X}\mathbf{X}^T$ 의 고유치의 제곱근이다. 대각행렬의 값들이 큰 것부터 순서로 되어있다고 생각하면 각 고유치들은 각 구성요소의 분산을 설명하므로 $r < d$ 인 정사영을 만들려면 처음 r 개만 빼고 나머지는 다 0값을 갖게 된다. 따라서 $\mathbf{X} = \mathbf{U}\Sigma_r\mathbf{V}^T$ 로 나타낼 수 있다. 여기서 Σ_r 는 처음 r 개만 0이 아닌 $d \times d$ 행렬이다. 주성분 분석은 원래 데이터의 낮은 차원으로의 정사영의 최대 표준편차값을 나타내는 선형 근사값을 제공하고 데이터들에서 정사영까지의 거리 제곱합을 최소화 시키는 낮은 차원의 선형 벡터들로 나타낼 수 있는 등의 장점을 제공한다. 이러한 주성분분석은 다변량 정규 분포에 대해 가장 적절하다. 그러나 여러 개의 클러스터를 가지는 다른 종류의 분포에 대해서는 적절치 않다.

3. Non-negative Matrix Factorization

3.1. NMF(Non-negative Matrix Factorization)

NMF는 음수가 아닌 변수들로 행렬 형태의 데이터를 분해한다. 분해를 통해서 데이터와 변수들의 관계를 두 개의 행렬로 나타낸다. 이 두 개의 행렬을 통해 데이터와 변수들의 관계를 단순하게 표현하여 새로운 해석을 가능하게 한다[1]. 특히, NMF는 음수가 아닌 가중치만을 가지므로 가중치의 합만으로 결과를 나타내게 된다. 이러한 특징은 감소 공간의 축이 실제적인 의미를 갖게 하고 전체적인 결과는 부분적인 특징을 합한 것이 된다. 예를 들어, 얼굴 이미지를 분석하는 데 있어서 음수가 아닌 변수들의 사용은 입, 코, 눈 등의 부분 이미지의 합으로 전체 이미지를 나타내도록 만든다. 데이터들의 감소 공간에서 각 축에 대한 관계는 [그림 1]에서와 같이 아랫층의 관찰된 데이터들 $v_1, v_2, \dots, v_n$ 이 은닉 변수가 특정 가중치를 가지고 발현된 것이라고도 해석할 수 있다.




[그림 1] 숨겨진 변수로부터 관찰 데이터로의 사상으로서의 NMF

NMF, 벡터양자화, 주성분분석 모두 V 행렬을 근사적인 행렬 W 와 H 의 곱으로 분해(factorization)하는 방법을 적용한다. 주어진 결과데이터 행렬

$$V \text{는 } V_{i\mu} \approx (WH)_{i\mu} = \sum_{a=1}^r W_{ia} H_{a\mu} \text{ 와 같이 } W \text{와 } H \text{ 행렬로 분해된다. 따라서 } V \text{ 행렬이 } m \times n$$

(m 은 변수의 수, n 은 데이터의 갯수)일 때 W 와 H 는 각각 $(m \times r)$, $(r \times n)$ (여기서 r 은 변수와 데이터가 사상되는 차원)으로 [그림 2]와 같이 분해된다. 따라서 데이터와 변수의 관계를 설명함에 있어 감소 차원 공간이 도입된다.



[그림 2] 데이터 행렬 V 의 분해(matrix factorization)

3.2 Non-negative Matrix Factorization(NMF) 알고리즘

NMF는 데이터 행렬 V 가 주어졌을 때, WH 가 V 에 가장 가까워 지도록 W 와 H 행렬을 반복적으로 업데이트한다. 여기서 업데이트의 방향은 목적함수(Objective function) F 의 지역 최대값(local maximum)이 되는 방향이다. 이 목적 함수는 최대 우도(Maximum likelihood)에 로그를 취한 값이다. 여기서 목적함수는

$$F = \sum_{i=1}^n \sum_{\mu}^m [V_{i\mu} \log (WH)_{i\mu} - (WH)_{i\mu}] \quad (3)$$

가 된다. 그리고, 이 목적 함수의 값이 지역 최대값 되도록 W 와 H 는 EM 알고리즘[6]과 비슷한 형식으로 다음과 같이 반복적으로 갱신된다.

$$W_{ia} \leftarrow W_{ia} \sum_{\mu} \frac{V_{i\mu}}{(WH)_{i\mu}} H_{a\mu} \quad (4)$$

$$W_{ia} \leftarrow \frac{W_{ia}}{\sum_j W_{ja}} \quad (5)$$

$$H_{a\mu} \leftarrow H_{a\mu} \sum_i W_{ia} \frac{V_{i\mu}}{(WH)_{i\mu}} \quad (6)$$


3.3 NMF를 이용한 데이터 분석의 예

3.3.1 이미지 데이터 분석

벡터 양자화(VQ)가 하나의 기저 이미지(basis image)에 의해 결정되고, 주성분분석은 음수를 허용하는 특성으로 직관적인 의미가 결여된 기저이미지를 사용하는데 반해서 NMF는 음수가 아닌 수만을 사용해서 얼굴의 부분이미지인 코, 입 눈등을 조합시킴으로서 하나의 결과 이미지를 만들어 낸다. 이 때, 부분적인 이미지들을 선택적으로 조합하므로 기저 이미지 W 와 이미지 인코딩 H 은 희소행렬(sparse matrix)이 된다.

3.3.2 텍스트 데이터 분석

NMF는 또한 문서데이터에서 주제를 찾아내고 다수의 문서들을 주제별로 분류하는 데도 적용이 가능하다. 이 때 하나의 문서는 벡터로 표현되는데 문서에 나타난 단어의 의미나 단어의 순서 등을 고려하지 않는다는 것을 의미한다. 여기서 결과 행렬 V 의 원소 V_{ij} 는 j 번째 문서에 i 번째 단어의 빈도수를 의미한다. 한 문서 안의 특정 단어의 빈도수는 그 단어와 문서 주제와의 상호 관계에 의해서 결정된다고 볼 수 있다. 마찬가지로 문서도 주제와 연결되어 서로 다른 두 문서가 의미적으로 유사하면 단어의 빈도수가 비슷하게 된다. 따라서 문서데이터에서의 감소된 차원들은 문서의 주제와 관련이 되고, 이 때 감소된 차원의 각 축을 하나의 은닉변수라고 해석할 때, semantic variable이라고도 한다.



[그림 3] NMF의 텍스트 문서에의 적용

3.3.3 NMF 기반 의미 커널을 이용한 문서 유사도 측정

NMF는 또한 방대한 데이터에서 검색과 분류, 군집화 등의 작업을 자동화하기 위해 사용될 수 있다. 기존 벡터공간모델(VSM)에서의 'bag-of-words' 방식과는 다르게 유의어와 다의어를 고려하여, 즉 단어들 간의 의미 관계를 고려하여 문서를 검색, 분류할 수 있다.

의미 커널

정보검색을 위한 벡터공간 모델에서 두 벡터 d_1 와 d_2 의 유사도는 일반적으로 다음과 같이 표현할 수 있다.

$$\text{sim}(d_1, d_2) = (P^T d_1)^T \cdot (P^T d_2) = d_1^T P P^T d_2 \quad (7)$$

여기서 행렬 P 는 기본 벡터 공간에서의 데이터를 특정한 다른 자질공간으로 매핑시키기 위한 변환 행렬로서 $P=I_M$ (M 은 문서 집합 내 단어 개수이고 I_M 은 $M \times M$ 항등행렬) 일 때는 원래 단어 벡터 공간에서의 두 문서간 유사도를 의미한다. 하지만, 이 경우에는 각 단어들에 의해 표현되는 축이 벡터공간상에서 직교를 이루게 되므로 단어들의 상관관계를 고려할 수 없는 문제점이 있다.

이러한 문제점을 해결하기 위해서 P 가 단어간의 상관관계에 대한 정보를 포함하도록 행렬 P 를 구한다. 행렬 P 를 구하는 방식에는 문서집합 내에 나타나는 단어들 간의 공기정보를 이용하는 GVSM, 온란인 어휘 의미망인 워드넷을 활용하여 유의어를 이용하여 P 를 구하는 기법등 여러가지가 있다. 임의의 두 문서와 자질공간으로의 사상 ϕ 에 대해 커널 함수는 $k(d_i, d_j) = \langle \phi(d_i), \phi(d_j) \rangle$ 로 정의된다. 따라서 데이터를 사상시킬 자질공간을 선택하는 것은 문서 유사도 측정에서의 변형행렬 P 를 결정하는 것과 관련이 있으며 $\phi(d)$ 는 $P^T d$ 로 주어진다. 행렬 P 를 통해 단어들간의 의미 관계를 고려하여 문서간

유사도를 측정할 수 있을 때 이를 "의미 커널(semantic kernel)"이라고 한다[7].

NMF에서의 의미 커널 구축

여기에서는 NMF를 사용하여 문서 데이터 분석 과정에서 의미 커널에서의 변환 행렬 P 를 어떻게 구할 수 있는지와 문서간 유사도 계산에 대해 서술한다.

NMF는 행렬 분해 방법 중 하나로써 전체 데이터 행렬 V 는 W 와 H 로 factorization되고 W 는 $m \times r$ (m 은 문서 집합 내 단어 개수, r 는 새로운 공간의 차원)의 행렬이다. NMF로 최적화된 W matrix에서는 상관관계가 높은 단어들이 특정 차원에 대해 유사한 값의 분포를 가지게 되므로 단어들의 상관관계를 파악할 수 있다. 따라서 차원 r 은 토픽의 개수를 나타내게 되며 W 의 각 열은 각 어휘에 대한 잠재의미 자질의 가중치이다. 따라서 W 로 만들어진 의미커널은 단어들간의 상관관계를 고려하여 유사도를 계산하게 해준다.

3.4. NMF 프로그램의 구현

프로그램은 데이터를 적절하게 읽어들이어 V 행렬을 기억한 후, 임의의 값을 갖는 W 와 H 를 생성하여 업데이트 규칙에 따라 W 와 H 행렬을 반복적으로 업데이트한다. 이를 정리한 pseudo code는 [표 1]과 같다.

[표 1] NMF 알고리즘의 pseudo-code

입력 : 행렬 형태로 된 데이터 ($N \times M$)

출력 : base 행렬 $W(N \times R)$, encoding matrix $H(R \times M)$

N : 데이터 크기 M : 변수들의 갯수, R : 줄이고자 하는 목표차원

목적 함수 :

Procedure:

1. W 와 H 행렬을 임의의 수로 초기화

$$W_{ij} \geq 0, W_{ij}=1$$

2. 다음 두 과정을 목적함수 F 의 값이 수렴할 때까지 반복적으로 수행한다.

① W, H 를 순차적으로 원하는 만큼 업데이트 한다.

$$W_{ia} \leftarrow W_{ia} \sum_{\mu} \frac{V_{i\mu}}{(WH)_{i\mu}} H_{a\mu}$$

$$W_{ia} \leftarrow \frac{W_{ia}}{\sum_j W_{ja}}$$

$$H_{a\mu} \leftarrow H_{a\mu} \sum_i W_{ia} \frac{V_{i\mu}}{(WH)_{i\mu}}$$

② Objective function F를 계산한다

$$F = \sum_{i=1}^n \sum_{\mu}^m [V_{i\mu} \log (WH)_{i\mu} - (WH)_{i\mu}]$$

언어는 C로 작성하였으며, 데이터를 희소 행렬로 저장하기 위해 값이 1이상인 데이터의 위치와 데이터 값만을 저장하는 자료 구조를 사용하였다. 1이상인 데이터에 대해서만 매개변수 수정을 고려하면 되므로 계산 비용을 줄이는데 도움이 된다

4. NMF를 이용한 데이터 분석 실험

4.1. NMF를 이용한 텍스트 문서 분석

4.1.1 텍스트 문서의 표현

텍스트 문서의 분석은 먼저 문서를 분석에 적합한 형태로 표현하는 것으로부터 출발하며, 보통 벡터(vector)로 표현하는 방법이 사용된다[5]. 즉 문서들 내의 단어들을 stemming, stop word를 제거하는 과정을 거쳐서 단어의 빈도를 확인하여 벡터형태로 나타내는 것이다. 문서를 이와 같은 벡터로 표현한다는 것은 문서에 나타난 단어의 의미(context)나 단어의 순서 등을 고려하지 않는다는 것을 뜻한다. 이러한 접근 방법은 문서를 bag-of-words로 보는 관점으로 단어의 순서나 의미등을 고려하는 여타 모델과 구별된다. bag-of-words 접근법에서의 가정은 문서에 나타나는 단어들의 빈도수는 주제에 따라 달라진다는 것이다. 이러한 행렬은 다음과 같은 형식으로 나타낼 수 있다.

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & & \cdots & a_{2n} \\ \vdots & & & \vdots \\ a_{m1} & & \cdots & a_{mn} \end{pmatrix}$$

a_{ij} : i 번째 문서에 나타난 j 번째 단어의 빈도수

n : 문서의 개수

m : 고려한 단어의 개수

[그림 4] 문서 분석에 사용되는 데이터의 형태

4.1.2 NMF를 이용한 텍스트 문서 주제어 추출

4.1.2.1 실험 내용

이 실험에서는 NMF가 문서 데이터의 차원을 줄임으로써 문서 데이터에서 주제나 내용에 관련하여 정보를 해석해낼 수 있는 지를 확인한다. 즉 NMF가 데이터의 차원을 줄임으로써 많은 수의 변수들이 새로운 소수의 차원에서 어떠한 관계로 나타나는 가를 확인하는 것이다. 문서 데이터에서 문서 데이터를 활용하여 다수의 단어들이 소수의 차원으로 정리될 때 파악할 수 있는 의미 관계를 갖게되는 것을 확인하는 것이다.

문서 데이터: 뚜렷이 나뉘져 있는 문서들로 결과값을 알고 있는 TREC-8 ad-hoc task data¹의 subset[3]을 사용하였다. [그림 4]와 같은 2차원의 문서-단어 행렬형태로 (1,069 문서 × 5,286 단어)의 크기를 가진다. 데이터는 topic 401, topic 434, topic 439, topic 450 네 개의 주제, 즉 Foreign minorities, Germany' (ID 401), 'Estonia, economy' (ID 434), 'inventions, scientific discoveries' (ID 439), 'King Husayn, peace' (ID 450)들에 관한 document 1069개로 이루어져 있다. 주어진 topic에 대한 설명이 [표 2]에 나와 있다.

Topics	Descriptions
Topics 401	Foreign minoroties, Germany What language and cultural differences impede the integration of foreign minorities in Germany? A relevant document will focus on the causes of the lack of integration in a significant way; that is, the mere mention of immigration difficulties is not relevant. Documents that discuss immigration problems unrelated to Germany are also not relevant.
Topic 434	Estonia, economy What is the state of the economy of Estonia? Documents that give concrete economic information such as economic statistics, entering economic unions and treaties, or monetary performance are relevant, as are discussions of economic issues such as transportation or pollution
Topic 439	inventions, scientific discoveries What new inventions or scientific discoveries have been made?

¹이 데이터는 topic 401~topic 450까지 50개의 주제 및 주제에 대한 설명이 문장으로 주어져 있고, 각 주제에 대한 문서의 집합이 주어져 있다. 각 문서가 어떤 topic에 해당하는지는 사람이 판단한 것이다.

	The word "new" in the description is defined as occurring in the 1990s. Documents that indicate a "recent" invention or scientific discovery are considered relevant. Discoveries made in astronomy or any scientific discoveries that are not patentable are not relevant.
Topic 450	King Hussein, peace How significant a figure over the years was the late Jordanian King Hussein in furthering peace in the Middle East? A relevant document must include mention of Israel. King Hussein himself as opposed to other Jordanian officials; discussion of the King's on-going, previous or upcoming efforts; and efforts pertinent to the peace process, not merely Jordan's relationship with other middle east countries or the U.S.

[표 2] TREC-8 adhoc task에서 주어진 토픽 중 4가지 토픽에 대한 설명

4.1.2.2 실험 방법

실험 과정: 문서-단어 행렬로 되어 있는 데이터와 원하는 차원값을 입력으로 주고 NMF알고리즘으로 W 와 H 값을 구한다.

감소 차원: 주제가 4가지 이므로 감소 공간 차원을 4로 하여 측정한다.


결과 평가: 결과 평가는 20번의 반복 실험 중 가장 좋은 목적함수값을 나타내는 실험의 W 행렬의 값에서 각 감소 공간 축(은닉 변수)에 따른 단어의 가중치가 높은 50단어를 추출, 순서대로 정렬한 결과를 비교하여 본다. 결과는 단어들을 읽어서 주제와 관련이 된 단어들이지를 파악할 수 있는 가로 판별할 수 있다.

4.1.2.3 실험 결과

group 1	group 2	group 3	group 4
jordan	percent	germani	research
peac	bank	german	develop
israel	estonia	foreign	technologi
king	state	countri	mar
palestinian	privat	mr	materi
jordanian	year	parti	system
arab	enterpris	year	nuclear
isra	russian	govern	jul
meet	million	state	environ
talk	trade	minist	environment
al	compani	peopl	industri
husayn	foreign	polit	process
state	invest	nation	electr
mr	econom	asylum	power

agreem	loan	european	basic
process	govern	europ	compani
negoti	product	union	high
majesti	estonian	law	report
presid	countri	democrat	wast
minist	fund	east	product
issu	polish	wing	energi
region	program	attack	amp
plo	price	member	method
time	poland	polici	apr
hope	russia	social	control
visit	export	west	japan
sign	import	immigr	function
relat	industri	turkish	plant
econom	feder	baltic	pollution
offici	market	group	feb
east	increas	refuge	measur
discuss	billion	time	engin
peopl	ministri	extremist	chemic
washington	share	turkei	patent
countri	financ	presid	dec
arafat	rate	report	plan
middl	kroon	problem	base
secur	capit	elect	vehicl
coordin	busi	feder	design
hussein	currenc	number	manufactur
syria	warsaw	call	test
unit	agreem	soviet	organ
side	total	intern	year
progress	servic	econom	applic
problem	develop	secur	sep
prime	english	violenc	project
territori	time	seeker	gener
amman	project	eu	batteri
futur	economi	live	institut
polit	includ	free	fuel

[표 3] 감소 공간 차원 별 가중치가 높은 단어들의 목록



[그림 5] NMF를 이용하여 업데이트할 경우의 Log Likelihood

4.1.2.4 결과 분석

[그림 5]와 같이 업데이트 규칙에 따라 반복적으로 W 와 H 행렬을 개선할 경우 완만하게 우도가 증가하는 것을 확인할 수 있다. 또한 실험 결과 [표 3]에서 확인할 수 있는 바와 같이 한 열에 대한 가중치가 높은 단어끼리 정렬한 결과 각 열에 대한 단어 목록에는 문서들의 주제와 관련도가 높은 단어들끼리 추출된 것을 확인할 수 있다. 즉 [표 3]에서 group 1에 속한 단어들은 topic 450([표 2])과 밀접한 관련이 있는 단어들이다. 각 차원은 하나의 문서 주제를 의미하며 주제와 연관성이 높은 단어가 높은 가중치를 갖는 것을 확인할 수 있다.

4.1.3 NMF를 이용한 문서 검색

4.1.3.1 실험 내용

처음 실험에서 NMF로 만들어진 W 행렬이 단어와 주제에 대한 정보를 담고 있는 것을 확인했다. W 행렬을 이용해서 이번에는 주제와 관련있는 문서를 검색하는데 이용한다. 이 실험은 NMF를 이용하여 의미 커널을 생성하여 문서 검색을 해보고 그 성능을 기존의 코사인 유사도를 이용한 VSM 결과와 비교하여 본다.

사용한 데이터: 데이터는 MEDLINE² 데이터를 사용하였다. 미국 국립 의학 도서관으로부터의 초록 1033개로 구성되어 있으며 질의어수는 30개이다. 불용어 제거와 스템밍(stemming)과정을 거친 후, 각 문서의 어휘 크기는 7,014이다.

4.1.3.2 실험 방법

실험 과정 : 먼저 입력 데이터로 MEDLINE데이터의 문서-단어 행렬을 주고, 이 데이터를 통해 W 와 H 를 구한다. 여기서 구한 W 를 의미 커널로 사용하여 문서 검색 실험을 한다. 기본 벡터공간 모델에서의 코사인 유사도 측정치에 의한 결과를 기본성능으로 하고 NMF의 W 매트릭스를 변환 행렬 P 로 사용하여 측정한다.

차원 설정 : 새로운 차원 m 를 $K=16, 24, 32, 48, 64, 96$ 으로 변화시켜 나가면서 비교해본다.


유사도 측정 방법 - 각 질의어에 대해 검색된 문서와의 유사도를 측정하기 위해 기본 벡터 공간에서의 코사인 유사도 측정치와 사상된 공간상에서의 유사도 측정치의 평균값을 취하였다. 질의문 q 와 문서 d 간의 유사도 $\text{sim}(q,d)$ 는 다음과 같이 정의된다

$$\text{sim}(q,d) = \frac{1}{2}(q^T d + q^T R R^T d) = \frac{1}{2} q^T (I + R R^T) d \quad (8)$$


검색 결과 평가 : 기준에 주어진 질의어에 대한 유사 문서 목록과 실험 결과와 비교한다.

4.1.3.3 실험 결과

² MEDLINE은 미국 국립 의학 도서관(U.S. National Library of Medicine)에서 제공하는 생의학 관련 데이터베이스로써 미국 및 70 여개국가에서 발행된 3,800 종 이상의 생의학 잡지의 저자 초록 및 서지 이용등이 수록되어 있다. MEDLINE은 전 세계적인 초록을 보유하고 있으며 그중에서 87%는 영어권이고 72%는 영어이다. 오늘날 MEDLINE은 모든 언어에 8,600,000이상의 인용문을 포함한다. 논문의 abstract와 인덱스로 구성되어 있다.



[그림 6] VSM, NMF, NMF+VSM 에 대한 차원 별 평균 정확도



[그림 7] 질의 2,3, 11, 23에 대한 VSM과 NMF+VSM의 precision recall 그래프 비교

[표 4] 각 질의에 대한 VSM과 NMF(감소 공간 차원이 48,96일때), NMF(감소 공간 차원=48)+VSM의 성능 비교

	VSM	Latent (48)	Latent (96)	Latent (48) + VSM
Query 1	82.28	88.93	88.26	94.75
Query 2	39.85	80.19	49.28	67.29
Query 3	48.32	69.01	68.69	74.08
Query 4	34.67	27.22	37.47	39.31
Query 5	79.92	83.45	73.74	85.12
Query 6	72.13	84.32	82.04	83.19
Query 7	58.31	48.44	52.18	69.36
Query 8	40.75	41.03	39.58	40.72
Query 9	51.11	23.98	56.38	33.60
Query 10	31.99	50.62	61.05	59.85
Query 11	47.83	80.36	82.24	77.41
Query 12	42.87	33.92	34.48	39.93
Query 13	87.51	93.15	98.75	94.54
Query 14	62.50	73.18	47.21	76.65
Query 15	52.71	72.57	58.54	71.84
Query 16	58.19	29.74	28.31	49.49
Query 17	21.94	16.82	18.46	44.91
Query 18	49.53	41.79	54.88	54.07
Query 19	41.46	33.02	53.80	41.04
Query 20	26.32	17.04	20.63	21.33
Query 21	23.37	45.21	40.61	40.07
Query 22	29.81	23.96	54.94	33.34
Query 23	43.27	59.11	68.77	77.26
Query 24	79.96	82.68	81.59	83.60
Query 25	73.58	70.94	70.24	78.10
Query 26	50.71	9.44	13.43	29.09
Query 27	58.05	41.03	49.22	55.26
Query 28	65.85	77.77	67.44	79.61
Query 29	78.78	77.57	69.50	80.47
Query 30	52.29	11.65	21.35	37.69
Average	52.86	52.94	54.77	60.43

4.1.3.4 결과 분석

NMF만을 이용한 결과가 기존의 VSM보다 월등히 좋은 검색 성능을 보이지는 않지만 차원이 96일 때 더 좋은 성능을 보인 것은 NMF를 이용하여 검색할 수 있는 가능성을 보여준다. NMF는 단어 집합을 낮은 차원으로 사상시켰을 때 주제와 단어들을 연결시킬 수 있기 때문에 이를 통해 의미 커널을 구축하여 이 커널을 이용하여 유사도를 검색할 수 있게 하는 것이다.

[그림 6]에서 볼 수 있듯이 NMF를 사용한 데이터는 감소 공간 차원을 높여감으로써 정확도가 상승하는 것으로 보아서 실험을 해보지는 않았지만, 데이터 집합에는 문서들의 주제가 96개보다 다양하며 어느 정도의 차원까지는 계속 그 정확도가 상승할 것이라고 보아진다. 그러나 현실적인 계산로드를 생각했을 때 비교적 낮은 96차원에서 기본 VSM방법의 성능을 넘은 것은 의미가 있다. VSM과 NMF를 동시에 사용한 방법은 모든 차원에서 VSM을 사용할 경우의 성능을 능가하는 것을 [그림 7]에서 확인할 수 있다.

4.2. NMF를 이용한 마이크로어레이 데이터 분석

4.2.1 실험 내용

이번에는 NMF를 사용하여 텍스트 문서가 아닌 DNA chip 데이터를 분석하여 본다. 여기서는 두 가지로 확실히 분류된 백혈병 데이터에 대해 NMF를 이용한 클러스터링을 시도해 본다.

실험에 사용한 데이터: 여기서는 유전자 발현 데이터 중 [4]에서 제시된 데이터를 사용하였다. DNA chip이란 2cm² 정도의 유리판에 수 천 개의 DNA를 심은 것으로, 이 유리판에 특정한 환경에서 채취된 RNA(cDNA)와 hybrid하면 유전자마다 발현 정도가 달라지게 되는데, 어떤 유전자는 발현이 촉진되기도 하고, 어떤 유전자는 발현이 억제되기도 하며, 그 촉진과 억제의 정도도 유전자 별로 다르다. 이러한 각 유전자의 발현 정도를 수치화한 것을 DNA chip data라고 한다. 여기서 사용된 데이터는 DNA chip에 7129개의 유전자를 심어서 이 chip과 72명의 백혈병 환자에서 추출한 RNA를 hybrid하여 각 유전자의 발현정도를 수치화한 것이다. 이를 통해 백혈병 환자들이 두 종류의 백혈병, 즉 AML(acute myeloid leukemia)과 ALL(acute lymphoblastic leukemia), 중 어디에 속하는지를 그들의 유전자 발현 패턴에 기초하여 분류하고자 한다. 환자가 AML이나 ALL이냐에 따라 치료 방법이 달라지기 때문에 이 분류는 현실적으로 중요하다. 즉 개개의 환자는 7129개의 속성의 벡터로 표현이 되는데 이 패턴이 어떠한가에 따라 AML과 ALL을 구분할 수 있다고 가정한다.

4.2.2 실험 방법

실험 과정: 학습 데이터와 실험 데이터에 대해 두 번의 실험을 한다. 먼저 학습 실험에서의 입력 데이터는 38명의 환자에 대해 발현 정도를 수치화한 것을 행렬로 나타낸 것으로 38×7219 행렬이다. 이 행렬을 NMF로 W 와 H 로 factorization한다. 실험 데이터는 34명의 환자로 이루어져 있는데 이 때의 실험에서는 학습 실험에서 구한 W 행렬을 고정시키고 H 행렬을 구한다.


감소 공간 차원: 두 개의 클러스터 (AML과 ALL)로 나누고자 하므로 차원은 2로 설정

결과의 평가: 각 실험 결과의 H 행렬에서 큰 가중치를 가지는 인자가 백혈병의 종류가 된다. 즉, 각 백혈병의 인덱스가 1 또는 2일 때, i 번째 환자의 백혈병 종류는

$T = \arg \max_j (H_{ij})$ ($j=1,2$)의 결과가 된다. 여기서 백혈병의 종류와 인덱스를

연결시키는 것은 학습데이터를 이용한다. 이 결과와 실제 환자의 백혈병 종류 데이터를 비교하여 판단의 정확도를 측정한다.

4.2.3 실험 결과



[그림 8] H 행렬값의 분포

학습 set에 대한 에러	0~1
test set에 대한 에러	1~2

[표 5] 두 개의 데이터 집합 분류 에러

4.2.4 결과 분석

NMF가 생물학적 데이터에 대해서도 차원을 줄였을 때 데이터에서 새로운 관계를 도출해 낼 수 있다는 것을 확인할 수 있다. [그림 8] 에서 알 수 있듯이 ALL과 AML 이냐에 따라서 H 행렬의 가중치는 다르게 분포한다. AML환자는 H 의 1번 인덱스가 2이상이고 2번 인덱스는 2이하인데 반해 ALL환자는 H 의 1번 인덱스가 2이하이고 2번 인덱스는 2이상으로 두 클러스터가 $y=x$ 또는 $y=2, x=2$ 로 나뉠 수 있는 것을 확인할 수 있다. AML과 ALL의 여부를 잘못판단한 에러는 [표 5]와 같이 적어서 NMF가 데이터를 효과적으로 클러스터링하고 있음을 확인할 수 있다.

특히, 이 실험에서는 실험 분석을 H 행렬에 대해서 함으로써, 데이터의 차원을 줄였을 때, H 행렬도 데이터에 대한 정보를 포함한다는 것을 확인할 수 있다. 문서 데이터에 대해서도 H 행렬을 통한 클러스터링이 가능할 것이라고 추측한다. 또한 W 행렬을 이용한 새로운 정보를 추출하는 것도 가능할 것이다.

5. 결론

본 논문에서는 NMF 기법의 전반적인 내용 및 관련 이론을 살펴보고, 차원감소를 통해서 새로운 정보를 도출할 수 있다는 것을 NMF를 다양한 데이터에 적용해 확인해 보았다. NMF를 적용하여 관찰된 변수와 데이터들의 차원을 감소시킴으로써 변수와 데이터들의 새로운 관계를 해석할 수 있고, 이를 이용하여 정보 검색이나 분류등의 작업에 사용할 수 있다는 것을 확인하기 위해서, 세 가지 종류의 데이터에 대해 주제에 관련된 단어 추출, 문서 검색, 클러스터링 실험을 해보았다.

NMF기법을 이용하여 텍스트 문서에 적용한 결과, 제한된 주제의 문서들로 이루어진 문서 집합에서 문서에서 주제를 추출하고, 주제와 관련된 단어 리스트를 추출할 수 있다는 것을 확인하였다. 또한, 얻은 문서와 단어, 주제에 관련한 정보를 가지고, 문서 검색을 할 수 있다는 것도 확인하였다. 문서 검색의 성능은 뚜렷하게 기본 VSM을 능가하는 것은 아니지만 이론적으로 차원 감소를 통하여 얻어낸 정보를 다른 문제를 해결하는데 이용할 수 있다는 가능성의 검증으로써는 충분하다고 보여진다. 또한, 마이크로 어레이 데이터의 클러스터링에 적용한 결과, 충분히 관계있지 않은 데이터가 포함된 DNA chip 데이터에서도

데이터를 효과적으로 분류하였다.

향후에, NMF를 이용하여 문서 분석이나 DNA chip data같은 이산적인 데이터뿐 아니라 연속적인 이미지 데이터에도 적용해보는 한편, 같은 데이터에 대하여 벡터양자화나 주성분분석기법을 적용해보아 문서 검색이나 주제 추출 등의 결과를 비교하는 것도 의미 있을 것이다. 또한 마이크로어레이 데이터 분석을 통한 암 분류 문제의 경우, 어떤 유전자가 특정 종류의 암을 분류하는데 있어 중요한지를 분석하는 것도 상당히 의미 있는 일이므로, 본 논문에서의 마이크로어레이 분석 실험에서 NMF를 통해 얻어진 은닉 변수의 각 입력 변수 (마이크로어레이 데이터에서는 유전자에 해당)에 대한 가중치 값의 의미 분석도 향후 연구 과제 중의 하나라고 할 수 있다.

참고문헌

1. Lee, D.D.& Seung, H. S. Learning the parts of objects by non-negative matrix factorization. *Nature* 401, 788-791, 1999.
2. V. Cherkassky and F. Mulier. *Learning from Data - Concepts, Theory and Methods*. John Wiley & Sons, New York, 1998.
3. Shin, H. J, A Probabilistic Clustering Model with Latent Variables, Master Thesis, School of Computer Sci. and Eng., Seoul National University, February 2001.
4. T. R. Golub, D. K. Slonim, P. Tamayo, C. Huard, M. Gaasenbeek, J.P. Mesirov, H. Coller, M. L. Loh, J. R. Downing, M. A. Caligiuri, C. D. Bloomfield, and E. S. Lander. Molecular classification of cancer: class discovery and class prediction by gene expression monitoring. *Science*, pages 531-537, 1999.
5. Salton, G. & McGill, M. J. *Introduction to Modern Information Retrieval* (McGraw-Hill, New York, 1983).
6. A. P. Dempster, N. M. Laird, and D. B. Rubin. Maximum likelihood for incomplete data via the EM algorithm (with discussion). *J. Roy. Stat. Soc. Ser. B*, 39:1--38, 1977.
7. Cristianii, N., Shawe-Taylor, J., and Ldhi, H., Latent semantic kernels, *Journal of Intelligent Information Systems*, vol. 18, no. 2/3, pp. 127-152, 2002.